山西大学学报(自然科学版)48(1):180－191,2025
Journal of Shanxi University(Nat. Sci. Ed.)

DOI:10.13451/j.sxu.ns.2024148

基于YOLOv5与背景优化的静态手势识别算法

李书娴[1],王宇翔[2],赵雪峰[2*],仲兆满[2]
(1.江苏财会职业学院 信息工程学院,江苏 连云港 222061;
2.江苏海洋大学 计算机工程学院,江苏 连云港 222005)

摘　要:手势识别是人机交互中的关键技术。传统实时手势识别模型对光照变化、复杂背景等干扰因素适应性不强,所用分类数据集仅包含特定手势,在实际应用中泛化能力不足。针对以上问题,提出背景优化的二阶段静态手势识别算法。在检测阶段,采用YOLOv5s(You Only Look Once version 5 small)作为检测网络,利用其定位能力快速检测手部位置。在识别阶段,首先,利用背景与传感器热噪声对分类数据集进行增强,设计背景优化预处理算法,提升模型对复杂背景的适应性;然后,将VGG-16(Visual Geometry Group-16)作为识别网络的原型,增加归一化层并替换激活函数以加速收敛并防止过拟合。实验中,模型可以在多种干扰下提取图像特征,准确率达到97.9%,*F*1值达到92.3%。实验结果表明,模型对复杂场景的适应能力高于经原始分类数据集训练后的传统模型,具有更高的实际应用价值。

关键词:手势识别;YOLOv5;复杂背景;实时识别
中图分类号:TP391.4　　**文献标志码:**A　　**文章编号:**0253-2395(2025)01-0180-12

Static Hand Gesture Recognition Algorithm Based on Deep Learning and Background Optimization

LI Shuxian[1], WANG Yuxiang[2], ZHAO Xuefeng[2*], ZHONG Zhaoman[2]
(1. *School of Information Engineering, Jiangsu Colledge of Finance & Accounting, Lianyungang* 222061,*China;*
2. *College of Computer Engineering, Jiangsu Ocean University, Lianyungang* 222005,*China*)

Abstract: Gesture recognition is a key technology in human-computer interaction. Traditional real-time gesture recognition models are less adaptive to disturbing factors such as illumination changes and complex backgrounds, and the classification dataset used only contains specific gestures, which is not enough for generalization in practical applications. To address these problems, a background-optimized two-stage static gesture recognition algorithm was proposed. In the detection phase, YOLOv5s ((You Only Look Once version 5 small) was used as the detection network to quickly detect the hand position using its localization capability. In the recognition phase, firstly, the background and sensor thermal noise was used to enhance the classification dataset, and the background optimization preprocessing algorithm was designed to improve the model's adaptability to complex backgrounds; then, VGG-16 (Visual Geometry Group-16) was used as the prototype of the recognition network, adding normalization layers and replacing the activation function to accelerate convergence and prevent overfitting. In the experiments, the model can extract image features under various disturbances with 97.9% accuracy and 92.3% *F*1 value. The experimental results show that the model is more adaptive to

收稿日期:2024-06-06;**接受日期:**2024-10-24
基金项目:国家自然科学基金(72174079);江苏省“青蓝工程”优秀教学团队项目(2022-29);江苏海洋大学“研究生科研与实践创新计划项目”(KYCX2023-79)
作者简介:李书娴(1983－),女,江苏连云港人,博士研究生,副教授,研究方向为数字图像处理、软件技术、数据挖掘。E-mail:261705815@qq.com
* **通信作者:**赵雪峰(ZHAO Xuefeng),E-mail:zhaoxf@jou.edu.cn
引文格式:李书娴,王宇翔,赵雪峰,等.基于YOLOv5与背景优化的静态手势识别算法[J].山西大学学报(自然科学版),2025,48(1):180-191. DOI:10.13451/j.sxu.ns.2024148.

中国知网　https://www.cnki.net

complex scenes than the traditional model trained by the original classification dataset, and has higher practical application value.
Key words: gesture recognition; YOLOv5; complex background; real-time recognition

0 引言

在全球数字化与智能化的背景下,高效的人机交互需求日益迫切。手势识别技术通过机器感知和解析手势动作,已成为智能设备、虚拟现实、智能家居及自动驾驶等领域的关键技术。随着数字图像处理技术的进步,基于计算机视觉的手势识别成为主流,因其简单易维护而优于数据手套等设备。然而,传统方法依赖图像分割、特征提取和先验知识,容易出现拟合问题并受手势与背景分割难题的影响,导致对复杂背景的适应性差,限制了其实际应用。

自深度学习理论体系构建以来,将其应用于手势识别的研究和应用能够显著提升手势识别的准确度与实时响应能力,并有效地提高对复杂背景的适应性。现阶段基于深度学习的手势识别方法按照其处理流程和模型结构,主要分为单阶段方法和两阶段方法。单阶段方法在一次网络前向传播过程中同时完成手势识别的所有任务,包括候选框生成、手势分类和位置精确定位,例如单次多框检测器(Single Shot MultiBox Detector, SSD)[1]、YOLO(You Only Look Once)系列[2]、高效网络(EfficientNet)[3]等单阶段方法。杨晨奕等[1]在SSD目标检测的基础上结合MobileNetv3网络进行优化,提出面向嵌入式平台手势识别方法达到平均准确率99.61%,且识别速度达到每秒50帧以上;Mujahid等[4]基于YOLOv3构建的轻量级模型,在简单背景数据集上达到了97.68%的准确率;Hussain等[5]提出一种使用微调的Inception-v3和Efficientnet-Bo网络的手势识别系统,在手势识别(Hand Gesture Recognition, HGR)数据集识上取得了90%的准确率和93%的准确率。基于单阶段方法的模型结构紧凑、计算效率高且推理速度快,但直接在全图尺度的特征图上预测,可能导致精细特征表达不足,从而影响定位精度和分类准确性。在复杂背景环境下,尤其当目标与背景差异较小时,易产生较多假阳性(背景被误判为目标)。

两阶段方法将目标检测分为两个独立的阶段,第一阶段生成一组可能包含目标的候选框,第二阶段对候选框进行精细的分类和边界框坐标微调,例如区域卷积神经网络(Region-based Convolutional Neural Network Features, R-CNN)系列,包括快速区域卷积神经网络(Fast R-CNN)、更快的区域卷积神经网络(Faster R-CNN),以及带掩膜的区域卷积神经网络(Mask R-CNN)等扩展模型。Soe等[6]使用Faster R-CNN构建的手势识别模型,可以在复杂背景下正常识别,但特征提取能力较弱,部分手势识别准确率较低,且无法识别小于图像尺寸1/10的目标。在此基础上,吴晓凤等[7]提出为FasterR-CNN增加扰动IoU(Intersection over Union)算法,有效改善训练模型的过拟合问题,提高了手势检测和识别的准确率,但未对复杂背景与光照条件进行优化。类似地,胡宗承等[8]通过向MobileNetV2中引入注意力机制与多层特征融合方法,增强了网络表征能力,提高了手势识别的分类精度,但模型的泛化能力仍存在不足。相较于单阶段方法,两阶段方法通过在第二阶段对第一阶段生成的候选框进行局部特征提取,有助于捕捉目标的细节和周围环境的上下文信息,因此往往能获得更高的检测精度,尤其在处理复杂背景时表现优秀。

为了进一步增强两阶段手势识别方法的稳健性和准确性,本文结合YOLOv5s、VGG-16(Visual Geometry Group-16)[9],提出一种新的两阶段手势识别方法。在第一阶段即检测阶段,充分利用YOLOv5s的速度与精度优势,构建出高效的检测网络,并通过公开数据集进行充分的训练,以确保其能够准确快速地定位出可能的手势候选框。在第二阶段,即识别阶段,针对静态背景问题,设计了专门的背景优化算法,用于处理静态背景并抑制非随机噪声,以降低环境干扰,提升算法稳健性。基于VGG-16进行改进,精简全连接层以减少计算量,替换激活函数以抑制过拟合,优化后的模型更适合手势识别任务。通过自建分类数据集

中国知网 https://www.cnki.net

进行训练,改进后的网络能精准区分不同手势,并对背景噪声具有高度免疫力。

本文的主要贡献有3个方面:

1)基于YOLOv5s构建高效的检测网络,在检测阶段能够快速准确地定位手部,提高了模型检测的速度和精度。

2)针对常见的静态背景问题,在识别阶段设计专门的背景优化算法,利用热噪声对背景进行增强,增强了模型的抗干扰能力,并针对VGG-16进行改进,在精简计算量的同时抑制过拟合现象,使其更适合于手势识别任务,进一步增强了模型的稳健性。

3)提出一种新的两阶段手势识别方法,充分结合YOLOv5s、VGG-16模型各自优势,并设计背景优化算法,能够精确区分在不同背景下不同手势的类别,对背景噪声具有较强的免疫力,有效提高了模型的准确性和可行性。

1 相关技术

1.1 YOLOv5

YOLO是一种基于深度学习的目标检测算法,具有识别快、精度高的特点。与上一代相比,YOLOv5的网络结构更深、更宽,同时加入了自适应锚框计算与Focus结构,从而提高了检测精度和速度。YOLOv5s是YOLOv5的轻量级版本,在保证检测效果的同时精简了网络参数,相较于其他版本具有更高的识别速度,其具体结构分为三个部分:主干网络、颈部网络、头部网络。主干网络采用CSPNet(Cross Stage Partial Network)[10]结构,利用分支连接的方式减少计算量,提高了特征的表达能力。颈部网络由特征金字塔网络(Feature Pyramid Network, FPN)构成,将主干网络中的特征图分为不同尺度,能更好地处理不同大小的目标。头部网络是对特征图进行分类和回归的模块,包括三个分支,分别用于检测大、中、小目标,并通过融合不同尺度的特征,提高检测的准确性。

YOLOv5常被看作单阶段目标检测算法的代表,其设计初衷是实现高速且相对准确的目标检测。但YOLOv5s具有实时、较强的特征提取能力、可扩展性和灵活性等特性,使其同样适用于基于两阶段检测的手势识别。将YOLOv5s直接输出的边界框集合视为潜在的候选框,作为第二阶段的输入,挑选出置信度较高的边界框作为候选框。这样能最大程度利用YOLOv5s的快速检测能力来确保在第一阶段有较少的时间开销,同时相对较高的精度也能保证筛选出的候选框质量。尽管如此,考虑到将YOLOv5s用于两阶段检测可能增加结构复杂性和计算开销,本文在权衡算法性能和复杂性后进行了改进,以更好地实现手势识别的快速性和准确率。

1.2 VGG-16

VGG-16由牛津大学视觉几何小组实验室的Karen Simonyan和Andrew Zisserman在2014年提出[9],在ImageNet数据集上取得了92.7%的Top5测试准确率。该网络由5个卷积堆栈和3个全连接层组成,能够提取更多、更复杂的特征。卷积堆栈包括2到3个卷积层与1个池化层,卷积层采用相对较小的3×3卷积核,步长为1,使网络获得更深的层数与更强的特征提取能力,池化核的尺寸为2×2,步长为2,用于降低数据的维度。网络的最后三层是全连接层,前两层分别具有4 096个神经元,以确保分类准确性,第三层接收1 000种不同的分类结果,并输出至最后的softmax层,以获得1 000个分类对应的概率。所有卷积层和全连接层都采用ReLU激活函数,以增强网络的非线性特性,提升其泛化能力。

VGG-16作为一种深度卷积神经网络,具有很强的特征提取能力与泛化能力。因此,在两阶段检测方法中,VGG-16的深度和复杂性使得它能够充分利用候选框的信息,并提取出对于分类和识别任务至关重要的特征。基于此,考虑将VGG-16用于两阶段手势识别方法的第二阶段精细识别手势,能够充分发挥其强大的特征提取和分类能力,提高整个识别方法的准确性和效率。但VGG-16体量较大且推理速度较慢,故本文基于VGG-16作为识别网络原型,并进行改进,实现对检测到的手部区域进行分类。

2 本文的手势识别算法

2.1 算法整体结构

基于深度学习的两阶段手势识别算法中,

中国知网 https://www.cnki.net

第一,二阶段具有明确的分工和相互依赖的关系。第一阶段的主要目标是快速而准确地从输入图像中筛选出可能包含手势的候选框,生成一系列候选边界框;所以应尽可能涵盖所有可能的手势位置,并减少无效的背景区域干扰,以便在第二阶段进行更精细的处理。第二阶段的目标即在前一阶段筛选出的候选框基础上,针对每一个候选框进行更为详细的特征提取和分析,判断其是否包含手势以及手势的具体类别,并对手势的边界框进行精确校正,以提高识别的准确度和定位精度。其中,YOLOv5s采用跨阶段部分网络(Cross Stage Partial Network,CSPNet)结构,结合空间金字塔池化(Spatial Pyramid Pooling,SPP-Block)等技术有效地提取了多尺度特征,提高了对不同大小手势的检测能力;并通过锚框(anchor boxes)机制可以根据不同尺度的手势自适应地生成边界框,能快速定位图像中的潜在手势区域,较好地满足第一阶段快速而准确地获取候选框的目标。而VGG-16网络的深层结构有助于提取高层次、抽象的特征,通过RoI Pooling或RoI Align等技术将前一阶段所得候选框的特征映射到固定尺寸,连接到VGG-16的后面几层或全连接层进行分类,能较好地区分不同手势类别;另外,VGG-16预训练在ImageNet等大型数据集上的权重,迁移至手势识别任务时能提供良好的初始化,有助于模型快速收敛和提高识别精度,使其在第二阶段精细分类和定位中发挥重要作用。基于上述分析,以YOLOv5s、VGG-16两种算法为主,所提出两阶段手势识别算法的整体框架如图1所示。

算法整体架构分为目标检测、手势分类两个阶段。实时手势识别任务需要在实时性的要求下对手部位置、手势动作等信息进行准确识别。因此,首先将输入的RGB视频流切分为帧,利用YOLOv5s构成的检测模块快速获取手部位置信息,通过非极大值抑制(Non-Maximum Suppression,NMS)得到目标框,并切分出手部区域。接着,手部区域被送入预处理模块进行处理,而预处理模块将手部区域与背景图像进行相减,弱化环境因素的影响,得到差分图像。然后,对差分图像进行增强,获取增强后的热噪声图像,以增强手部特征,提高识别准确率。最后,处理完成的热噪声图像被输入改进VGG-16构成的分类模块,利用其自身的学习能力和泛化能力,快速准确地提取图像特

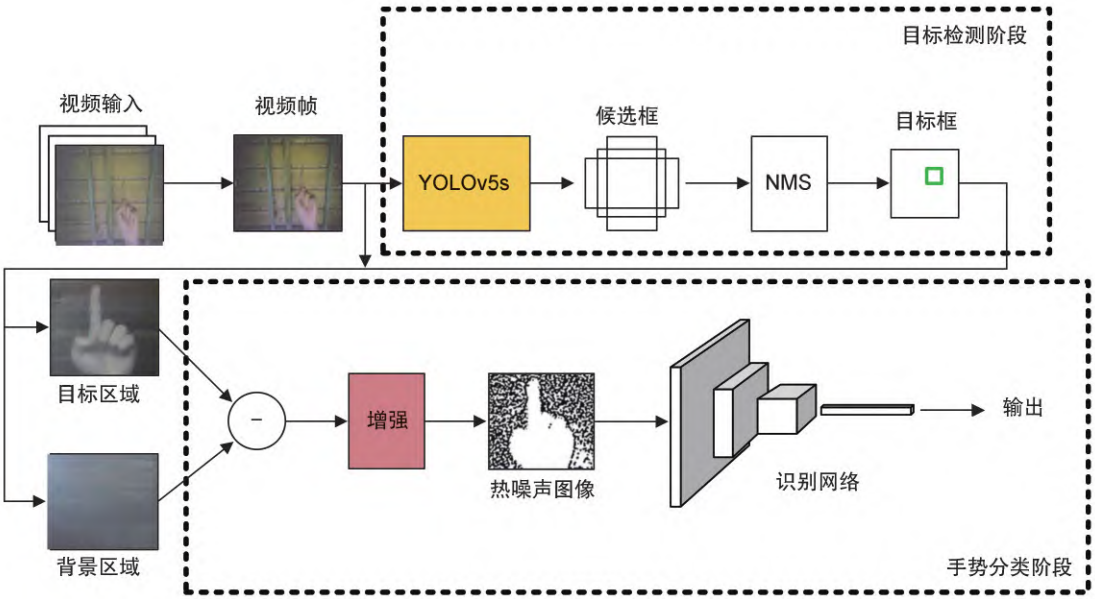

图1 静态手势识别算法整体架构图

(算法首先检测手部位置,再对目标区域应用背景优化算法,最后进行手势分类。)

Fig. 1 The overall architecture of the static hand gesture recognition algorithm

(The algorithm first detects the hand position, then applies a background optimization algorithm to the target region, and finally performs gesture classification.)

中国知网 https://www.cnki.net

征并进行分类识别,输出手势类别信息。该架构设计能够有效提高手势识别的精度和实时性,使之适用于实际场景。

2.2 目标检测

本文采用YOLOv5s作为检测模块,一方面可以避免在复杂场景下手势区域无法准确获取的问题,另一方面能够提高模型的识别速度,减少计算资源的开销。

首先,为适应网络结构,获取更精细的特征,输入图片尺寸被调整为1 280×736的固定大小;然后,为检测出不同尺寸和位置的目标物体,将图片划分成$S_h \times S_w$个网格,若目标的中心落在某一网格中,则此网格负责预测该目标。这样的设计使网络可以处理具有不同大小和长宽比的目标。同时,还可以减少目标与边界框之间的冗余信息,提高运算效率。需要预测的参数包括B个目标框的位置(x,y,w,h)、置信度C_i(Conference)共$B\times5$个值。置信度的计算方式为:

$$C_i = P(N_i|O)\times P(O)\times IoU = P(N_i)\times IoU, \quad (1)$$

其中i为类别数,O表示存在物体,IoU为预测框与目标框的相交面积与相并面积的比值,用于确定两个框的相似程度,比值越大相似度越高。此外,网格还要预测N个类别,因此输出尺寸为$S_h\times S_w\times B\times(5+N)$。最后通过NMS排除置信度较低的候选框,确定最终目标框。

原始YOLOv5s算法采用COCO(Common Objects in Context)数据集进行训练,共包括80种不同类别,一般用于一阶段识别。但同一个网络同时承担检测与识别的任务会导致分类性能的下降,以及训练难度的增大。这是因为将网络设计成同时具有检测和识别功能会引入额外的复杂性和不确定性,从而增加了网络的训练难度。在训练过程中,网络需要学习识别目标的同时还需要学习检测目标的位置和边界框,这可能会导致网络在处理两个任务时出现相互干扰或权衡的情况,从而降低了分类性能。于是,为了获得更好的分类性能和更高的泛化能力,通常会选择将检测和识别任务分解为单独的模块或网络来处理,以便更好地专注于每个任务,并避免两个任务之间的相互干扰。因此,本文将其类别数设置为1,仅用于手部位置的检测,不参与识别。

2.3 手势分类

在手势识别任务中,手势动作的表现形式可能有很大差异,且易受到光线、背景等环境因素的影响。因此,本文设计预处理算法以增强手部特征,提高识别准确率,再利用改进VGG-16实现分类模型用于手部区域分类。

2.3.1 背景优化预处理算法

在实际应用中,手势数据集的获取较为不便。例如,在同一场景、光照下录制、制作的数据集训练出的模型,当场景或光照变换后,其识别准确率大幅下降。此外,含有多种复杂背景的数据集如新加坡国立大学手势数据集II(National University of Singapore Hand Gesture Dataset II,NUS-II)[11]等往往无法满足具体手势类别的需求,如果需要数据集以外的手势,必须重新制作,工作量较大。

在手势识别任务中,形态特征和肤色特征是最重要的特征。肤色特征由于受到光照条件和用户个体差异的影响较大,且易与背景混淆。因此,其可靠性相对较低。相比之下,形态特征对于每一种手势来说都较为固定,且易于提取。因此,本文在预处理过程中,选择突出形态特征,以降低噪声的影响,以达到先进的识别性能。

噪声在实际应用中是不可避免的,但是,不同类型的噪声对模型训练产生的影响也有所不同。如图2所示,非随机的噪声(如重复的背景)会被模型学习并导致过拟合;而随机的噪声(如来自摄像头传感器的噪声)则不会被模型学习到。因此,在进行分类模块的训练前,选择对分类数据集进行增强,以模拟实际应用中的噪声,并训练出对噪声具有稳健性的模型,能够提高识别效果。

针对光照不均匀、背景明暗、色彩变化等干扰,以及手势信息集中于手部区域的特点,提出一种预处理算法,用于处理静态背景并压制非随机噪声,以提升模型对复杂背景的适应能力。该算法利用摄像头通用目标理解数据集(Common Objects in Context,COCO)传感器产生的热噪声填充手部区域之外的部分,优化分类数据集中的背景,模拟实际识别中可能遇到

中国知网 https://www.cnki.net

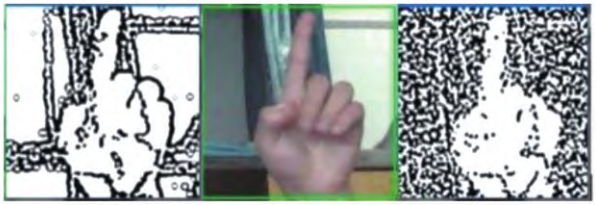

图2 同一场景中的噪声可视化

(非随机噪声(左侧黑白图像)来自背景中的边缘与纹理,呈现为规则的线条。随机噪声(右侧黑白图像)来自传感器分子的热运动,呈现为随机散点。)

Fig. 2 Noise visualization in the same scene

(The left grayscale image illustrates non-random noise, which originates from edges and textures in the background, appearing as structured lines. The right grayscale image shows random noise, caused by thermal motion of sensor molecules, manifesting as randomly scattered dots.)

的干扰,进一步提升模型对复杂背景的适应性。具体预处理流程如图3所示。

考虑到RGB图像包含了红、绿、蓝三个通道的信息,数据量较大。灰度图像仅有一个通道,数据量小,计算速度更快,更适用于实时性手势识别场景。故将RGB图像转为灰度图像。此外,本文并不依赖于肤色特征,而是着重于手势的形态特征,这进一步强调了灰度图像在手势识别中的优势。具体计算公式如下:

$$I_{\mathrm{Gray}}=0.229\times I_{\mathrm{Red}}+0.587\times I_{\mathrm{Green}}+0.114\times I_{\mathrm{Blue}} \tag{2}$$

其中I_{Red}、I_{Green}、I_{Blue}分别代表彩色图片的红、绿、蓝分量。

在实时手势识别任务中,由于复杂场景下噪声的存在,对原始图像进行预处理可以降低噪声对模型的干扰,提高模型的稳健性。故将目标图像与背景图像进行相减取绝对值,以消除背景对手部特征的影响,并将相减后的差值映射到正数范围内,作为后续图像增强操作的基础。具体计算公式如下:

$$I_{\mathrm{out}}=\left|I_{\mathrm{in}}-\frac{1}{n}\sum_{k=1}^{n}I_{\mathrm{bg}}^{(k)}\right|, \tag{3}$$

其中I_{out}为输出图像,I_{in}为输入图像,$I_{\mathrm{bg}}^{(k)}$为未检测到手部时捕获的图像,n为堆栈高度。通过模拟相机的长曝光,对一定时间范围内捕获的不包含手部的图像进行堆栈,不断更新背景图像并平滑其热噪声,可以获得相对稳定的背景图像,使算法在一定程度上适应动态背景,以及环境中的光线变化和噪声干扰。而对于静态背景,该操作可以捕获图像中动态的手部。

一般地,摄像头传感器产生的噪声数值很小,会被有效信号所淹没。而绝对值图像含有大量人眼不可见的微小灰度波动。故基于上一步操作,利用小阈值对绝对值图像进行处理,放大其中的灰度波动(即热噪声),使随机噪声

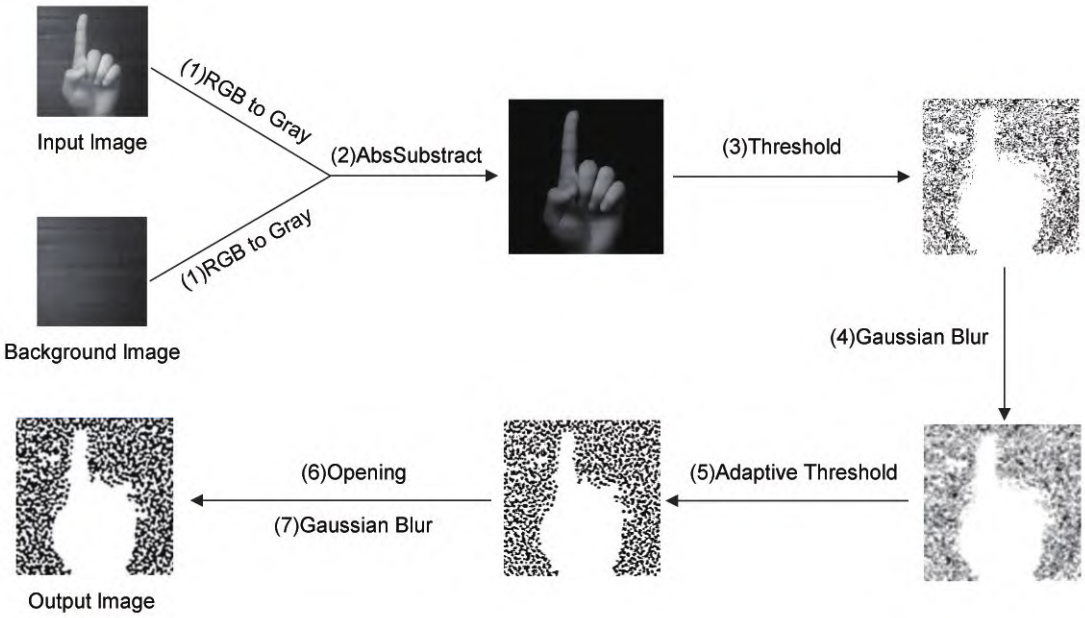

图3 背景优化算法流程图

Fig. 3 Flowchart of the background optimization algorithm

中国知网 https://www.cnki.net

淹没背景但不对手势部分产生影响,达到区分手势与背景的目的。计算公式如下:

$$I_{\text{out}}(x,y)=\begin{cases}0 & I_{\text{in}}(x,y)\leqslant T\\ \max Val, & I_{\text{in}}(x,y)>T。\end{cases}\quad(4)$$

其中 T 为灰度阈值,本文算法中 $T=2$,$\max Val$ 为灰度最大值,取255。阈值化后的图像含有大量锐利噪声,不利于识别。因此,采用高斯模糊对图像进行平滑处理,同时,保留图像的整体结构和重要特征。高斯模糊的公式如下:

$$I_{\text{out}}(x,y)=\sum_{j=-b}^{b}\sum_{i=-a}^{a}G(j,i)\times I_{\text{in}}(x+a-i,y+b-j),\quad(5)$$

其中 G 为高斯卷积核,a、b 的值为图像长度、宽度的一半。该操作使用 5×5,$\sigma=2$ 的高斯卷积核对图像进行卷积操作,以降低图像整体灰度梯度,但由于手部与背景之间灰度变化剧烈,因此主要特征将被保留。

自适应阈值化能够根据图像局部的灰度特征自适应地选择合适的阈值,有利于保留局部特征。具体计算公式如下:

$$I_{\text{out}}(x,y)=\begin{cases}0, & I_{\text{in}}(x,y)\leqslant T(x,y)\\ \max Val, & I_{\text{in}}(x,y)>T(x,y)\end{cases}。\quad(6)$$

其中 T 是为每个像素的单独计算的阈值,G 为高斯卷积核:

$$T(x,y)=\sum_{j=-a}^{a}\sum_{i=-b}^{b}G(i,j)\times I_{\text{in}}(x+i,y+j)。\quad(7)$$

在高斯模糊之后对图像进行自适应阈值化处理,能够将形状不规则的噪声转换为形状规则的点状随机噪声,起到加强随机噪声的作用。该操作有助于模型识别噪声特征与手部特征。

开运算能够去除二值图像中的小点、毛刺,保持物体的形状轮廓基本不变。因此,可以用于增强随机噪声,提升模型稳定性。其计算公式如下:

$$I_{\text{out}}=I_{\text{in}}\circ S=(I_{\text{in}}\ominus S)\oplus S。\quad(8)$$

其中 S 是 3×3,值全为1的结构元,$\circ$ 表示开运算,$\ominus$ 表示腐蚀操作,$\oplus$ 表示膨胀操作。

鉴于开运算会生成锐利的边缘,因此,再进行一次高斯模糊以平滑噪点。

该预处理步骤有助于将背景噪声的影响转化为对模型有利的增益,增强手部特征,提高识别准确率。图4展示了原始自建数据集经背景优化后生成的图像:

2.3.2 分类模型

分类模型是实现手势识别的核心,其将预处理模块处理后的手势图像输入到分类器中,以识别手势的具体含义。本文设计的分类模型结构如图5所示:

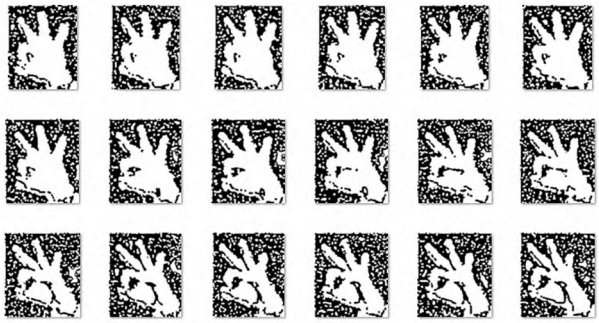

图4 经过背景优化处理后的部分数据集

Fig. 4 Subset of the dataset after background optimization processing

为了加速训练、改善过拟合问题,本文选择在卷积层后加入批量标准化(Batch Norm,BN)层。为使数据更具统计意义,该层在每一批次的训练过程中,都会更新网络的均值和方差,因此网络不会从单个训练样本生成确定性结果,可以在一定程度上改善过拟合。

为了防止出现神经元坏死的情况,本文选择将隐藏层中的激活函数从ReLU函数替换为指数线性单元(Exponential Linear Unit,ELU):

$$F_{\text{ELU}}(x)=\begin{cases}x, & x>0\\ e^{x}-1, & x<0\end{cases}。\quad(9)$$

由于ReLU函数在输入为负值时完全不激活神经元,即在反向传播中经过该处的梯度将被归零,因此存在导致神经元失效的可能性。而相比于LeakyReLU函数,ELU函数是负饱和的(对输入的负值存在最小输出),因此对噪声具有一定的稳健性,又由于其输出均值接近于零,因此模型能更快地收敛。

本文设计将模型用于10类手势的识别,因此根据实际应用的需要,将全连接层的神经元数量由4 096减少至1 024。最终参数量由原模型的134 301 514缩减至41 474 122,缩减了69.1%,实现了模型的轻量化,具体网络结构参数如表1所示。

中国知网 https://www.cnki.net

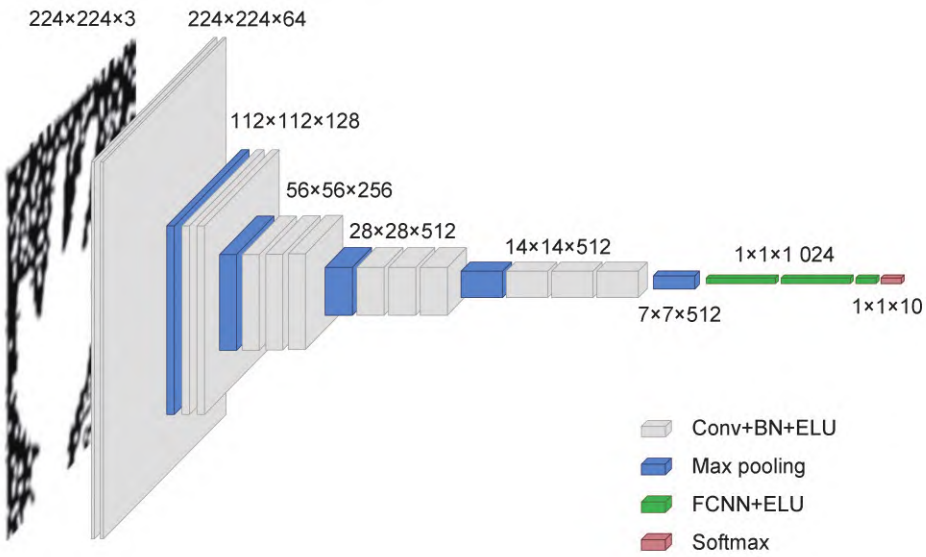

图5 改进后用于手势分类的VGG-16网络结构图

Fig. 5 Architecture of the improved VGG-16 network for hand gesture classification

模型采用交叉熵损失函数:

$$L=-\sum_{i=1}^{N} y^{(i)} \log \hat{y}^{(i)}+(1-y^{(i)}) \log (1-\hat{y}^{(i)}) \quad (10)$$

其中$y^{(i)}$为第i类样本的真实分布,$\hat{y}^{(i)}$为模型输出的样本分布,N为类别数。

表1 VGG-16网络结构参数

Table 1 Parameters of the VGG-16 Network structure

网络深度	卷积层数	归一化层数	卷积核大小	卷积核数	padding	步长
第一层	2	2	3×3	64	1	1
第二层	2	2	3×3	128	1	1
第三层	3	3	3×3	256	1	1
第四层	3	3	3×3	512	1	1
第五层	3	3	3×3	512	1	1
第六层	全连接层,输入尺寸7×7×512,经过1 024个神经元,输出至10个神经元					

3 实验与结果分析

3.1 实验环境与训练参数设置

实验用计算机的硬件环境配置为Intel i7-8750H CPU,NVIDIA GTX 1060 GPU 6 GB显存。软件环境配置为Windows 1064位操作系统,Python 3.9,PyTorch 1.10.1,为加速训练,安装Cuda 11.6利用GPU对计算进行加速。软件调试环境为Visual Studio Code。检测模块采用Adam[12]算法进行优化,初始学习率设置为0.001,动量参数为0.937,权重衰减参数0.000 5,批处理大小为30,训练100轮,为增强模型泛化能力,采用随机翻转和调整对比度的数据增强方法。分类模块的输入图像尺寸为224×224×3(像素),批处理大小为30,初始学习率设置为0.000 1,每训练10轮下降90%,loss不再下降时结束训练。

3.2 数据集

本文采用的数据集分为两个部分,公开数据集与自建数据集,旨在充分利用不同数据源的优势,以提升所提算法的性能和泛化能力。其中,公开数据集用于训练检测模块,该数据集通常覆盖了广泛且复杂的场景和变化,能够较好地帮助算法学习通用的特征和手势识别能力;而自建数据集则用于训练分类模块,从具体的应用场景和需求出发,设计了特定的手势识别图像集合,涵盖了多样化的姿势和不同视角,有助于算法在特定任务上进行更为深入的优化和调整,以提升分类准确性和模型的稳健性。

公开数据集包括TV-Hand、COCO-Hand[13]以及Handpose_x[14]数据集。这三个数据集中的大部分样本仅包含手部位置标签,因此,仅用于检测模块的训练。其中,TV-Hand包含从ActionThread数据集中提取的9 500图像帧的手部注释。COCO-Hand包含微软COCO数据集中约25 000幅图像的注释。Handpose_x包括14类手势,共2 850张图像,由来自网络、相机采集、kinect_leap_dataset数据集的图像组成,其手

中国知网 https://www.cnki.net

部占比较大。本研究在实验中发现,前两种公开数据集中的目标尺寸较小,训练出的检测网络难以检测较大的手势目标。因此,挑选出Handpose_x数据集中的800张图像进行标注后加入检测数据集作为补充,用于检测模块的训练任务。其中,公开数据集手部目标尺寸分布如图6所示。

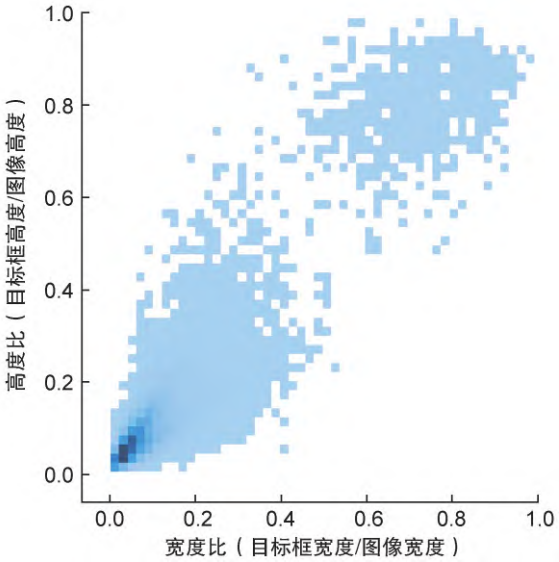

图6 公开数据集手部目标尺寸分布

(坐标数值为手部区域的宽(或高)占整幅图像的宽(或高)的比例,颜色越深代表该尺寸的手部目标在数据集中占比越高。)

Fig. 6 Distribution of hand targets' sizes in the public dataset (The coordinate values represent the ratio of the width (or height) of the hand region to the overall width (or height) of the image. Darker colors indicate a higher proportion of that size of hand targets within the dataset.)

为了证明在改进后,利用简单背景数据集训练出的模型能够对环境干扰具有较强的适应能力,进一步验证所提出的算法对模型泛化能力的有效提升,采用自建手势识别数据集对分类模块进行训练与评估。具体的,在构建过程中,特意选择简单背景下,由笔记本电脑摄像头以每秒20帧的速度采集了共计15 000张PNG格式的RGB静态图像,这些图像完整地涵盖了10类不同的手势。考虑到实际环境下手势姿态的复杂性,且识别过程中易存在目标手部无法持续保持正对摄像头的问题,为最大程度模拟真实世界中手势姿态的多样性,在自建数据集中引入了在三维空间中进行不同程度平移与旋转的手势图像,该设计旨在有效地探究算法在不同视角和位置下的稳健性,以验证其对手势姿态变化的泛化能力。部分自建数据集中的原始图像如图7所示。

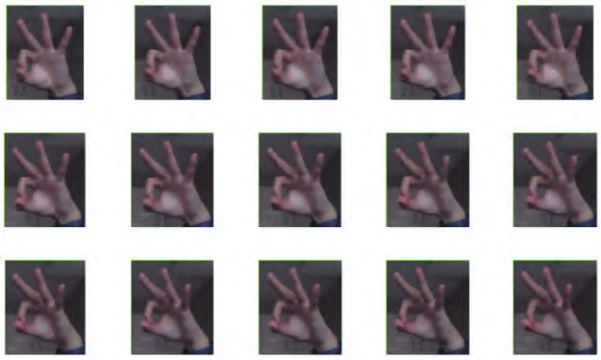

图7 部分自建数据集中的原始图像

Fig. 7 Raw images from subset of the self-built dataset

3.3 实验结果与分析

3.3.1 实时识别实验

为验证预处理算法对于模型识别性能的提升,本文对改进的VGG-16模型,分别采用预处理分类数据集与原始数据集进行训练。训练完成后,选取1类简单背景与4类干扰场景分别进行测试。每个测试场景的录制时长为6秒,检测模块检测到手部时开始计时,并记录识别结果。

实验结果如图8所示。图8(a)为YOLOv5s+背景优化+改进VGG-16模型的识别效果,图8(b)为YOLOv5s+无预处理+改进VGG-16模型的识别效果。结果显示,在简单背景下,模型均能正常识别,但背景出现干扰、光照发生变化时,使用原始数据集训练出的模型效果较差,甚至在干扰严重的情况下完全无法识别。在复杂背景及各种干扰下,改进的二阶段模型都能正确识别手势,表明经本文预处理算法处理后,单一场景下以较小工作量获取的手势数据集可以满足复杂场景下的识别需要。

3.3.2 预处理方法对比实验

为客观评价预处理方法的效果,将3.2节中自建数据集经肤色提取、高斯掩模、背景优化等不同方法处理后,与未经处理的原始图像分别送入改进VGG-16模型,使用相同超参数进行训练,并在验证集上进行验证。采用准确率(Accuracy)、$F1$值($F1$-score)、识别时间共3个

中国知网 https://www.cnki.net

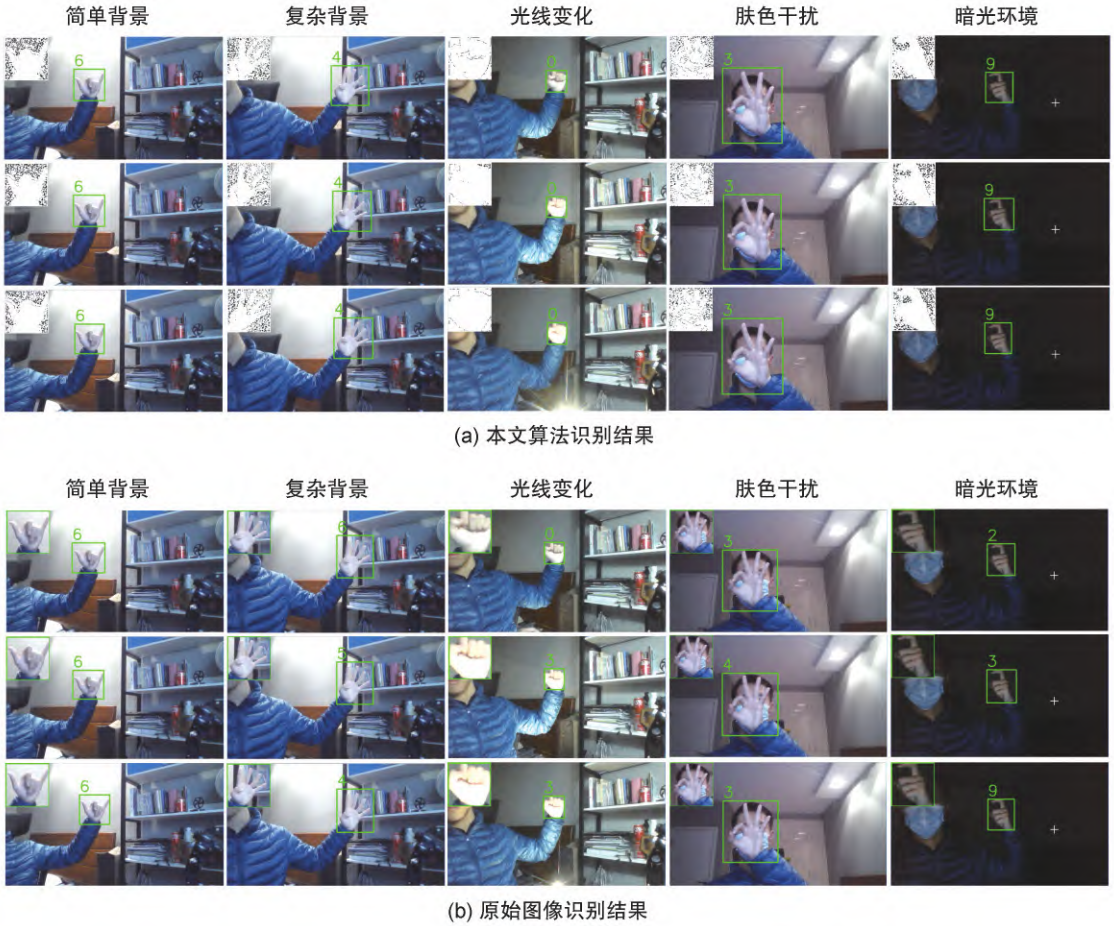

图8 不同干扰因素下,有无背景优化算法的实时识别实验结果对比图

((a) 为改进后的VGG-16对经过背景优化后的手部图像的识别结果;(b) 为改进后的VGG-16对原始手部图像的识别结果。输入识别模型的图像显示于画面左上角,手部检测框上方的数字为手势类别。)

Fig. 8 Comparison of real-time recognition results with and without background optimization algorithms under different interference factors

((a) Displays the recognition results of the improved VGG-16 on hand images processed with background optimization; (b) Shows the recognition results of the improved VGG-16 on the original hand images. The images input into the recognition model are displayed in the upper left corner, and the number above the hand detection box indicates the gesture category.)

指标对模型效果进行评价。设 TP、TN、FP、FN 分别代表:真阳性、真阴性、假阳性、假阴性的数量,则准确率与 $F1$ 值可表示为式(11)—(12),具体实验结构如表2所示。

$$A=\frac{TP+TN}{TP+FP+FN+TN} \tag{11}$$

$$F1=\frac{2P\times R}{P+R}=\frac{2\dfrac{TP}{TP+FP}\times\dfrac{TP}{TP+FN}}{\dfrac{TP}{TP+FP}+\dfrac{TP}{TP+FN}}。 \tag{12}$$

其中 A、P、R 分别代表准确率(Accuracy)、精确率(Precision)和召开率(Recall)。

表2中,train_Acc与val_Acc分别代表训练准确率与验证准确率。表中可见,未经预处理的分类数据集训练出的模型,过拟合严重,对不同场景的泛化能力很差,几乎不能正常识别。肤色提取方法将原始图像转换至色相-饱和度-明度颜色空间(Hue-Saturation-Value,

表2 采用不同预处理方法对识别结果的影响对比

Table 2 Comparison of the impact among different preprocessing methods on recognition results

预处理方法	train_Acc/%	val_Acc/%	识别时间/ms
无	99.9	16.9	**21**
肤色提取[15]	99.9	30.3	134
高斯掩模	99.4	87.7	27
背景优化(本文)	**99.9**	**97.9**	22

中国知网 https://www.cnki.net

HSV)色域,在HSV通道中通过阈值的方式提取出判定为肤色的像素,但时间复杂度高,对光照变化敏感,且不适合手部与背景颜色相似的场景,导致识别效果不理想。高斯掩模的方法通过高斯函数生成与原始图像相同尺寸的遮罩(掩模),像素值在0—1之间,由中心向四周衰减,将掩模与原始图像逐元素相乘以弱化边缘背景在图像中的权重,本文自建数据集中手部占图像比例较大,因此该方法的背景弱化效果不理想,且会弱化带有重要特征的手势局部,导致识别性能提升不明显。而采用背景优化方法处理后,模型对于实时识别场景的稳健性得到了显著提升。

3.3.3 识别模型对比实验

为充分评估改进后的VGG-16网络相对于原网络,以及其他分类识别算法的识别效果,采用方向梯度直方图(Histogram of Oriented Gradients, HOG)+支持向量机(Support Vector Machine, SVM)分类器、AlexNet、无修改的VGG-16与本文算法在实时识别场景下进行对比,实验结果如表3所示。

表中可见,SVM算法简单准确,识别迅速,但容易过拟合且泛化能力较差,难以用于复杂场景下的实时识别。AlexNet的网络表达能力不如VGG-16,而VGG-16的参数量过多,因此,在本文做出改进后,模型体量有所下降,且识别速度与准确率有所提升。ResNet-18采用了残差连接,训练、识别迅速,但是出现了轻微的过拟合现象,测试准确度不及本文模型。因此,改进VGG-16在泛化能力、识别精度等方面综合优于其他分类识别算法。

表3 不同识别算法的性能对比

Table 3 Performance comparison among different recognition algorithms

算法	Accuracy/%	$F1$/%	识别时间/ms
HOG+SVM[16]	84.2	83.7	10
AlexNet[17]	96.1	89.2	7
VGG-16	91.3	77.4	31
ResNet-18[18]	97.0	92.0	**10**
改进VGG-16	**97.9**	**92.3**	22

4 结语

本文针对传统实时手势识别模型在复杂环境下适应性差、泛化能力有限的情况,提出了一种基于YOLOv5与背景优化的二阶段静态手势识别算法。选用YOLOv5s网络作为检测阶段的核心,确保手部位置的快速而精准定位。在识别阶段,首先算法进行背景优化预处理,显著提升了模型对复杂多变背景的适应能力;随后,以VGG-16为基础进行改进,构建出更为简洁且计算高效的识别网络。在实时识别实验中,提出的模型在复杂背景、光照变化、肤色干扰及暗光环境下,能保持稳定的识别能力,达到了97.9%的准确率与92.3%的$F1$值。与单独使用YOLOv5,以及其他主流模型如EfficientNet、Faster R-CNN等进行手势识别的对比实验显示,本文算法具有更强的泛化能力。本文算法为手势识别技术提供了一种高效的解决方案,不仅能提升人机交互系统的用户体验,还为虚拟现实、智能家居控制等多种应用场景中手势操作的推广应用增加了可行性。在后续的工作中,拟在此基础上进一步融入时间序列信息,研究适用于连续动态手势识别的算法。

参考文献:

[1] 杨晨奕, 何玉青, 赵俊媛, 等. 面向嵌入式平台的轻量化神经网络手势识别方法[J]. 强激光与粒子束, 2022, **34**(3): 210335. DOI: 10.11884/HPLPB202234.210335.
YANG C Y, HE Y Q, ZHAO J Y, *et al*. Lightweight Neural Network Hand Gesture Recognition Method for Embedded Platforms[J]. *High Power Laser Part Beams*, 2022, **34**(3): 210335. DOI: 10.11884/HPLPB202234.210335.

[2] REDMON J, DIVVALA S, GIRSHICK R, *et al*. You only Look Once: Unified, Real-time Object Detection [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2016: 779-788. DOI: 10.1109/CVPR.2016.91.

[3] LI X L, ZHOU Y F, HUANG L, *et al*. Efficientnet Model Based Gesture Recognition Method Research[C]//2021 4th International Conference on Artificial Intelligence and Pattern Recognition. New York: ACM, 2021: 10.1145/3488933.3489024. DOI: 10.1145/3488933.3489024.

[4] MUJAHID A, AWAN M J, YASIN A, *et al*. Real-time Hand Gesture Recognition Based on Deep Learning YOLOv3 Model[J]. *Appl Sci*, 2021, **11**(9): 4164. DOI: 10.3390/app11094164.

[5] HUSSAIN A, UL AMIN S, FAYAZ M, *et al*. An Efficient and Robust Hand Gesture Recognition System of

中国知网 https://www.cnki.net

Sign Language Employing Finetuned Inception-V3 and Efficientnet-B0 Network[J]. *Comput Syst Sci Eng*, 2023, **46**(3): 3509−3525. DOI: 10.32604/csse.2023.037258.

[6] SOE H M, NAING T M. Real-time Hand Pose Recognition Using Faster Region-based Convolutional Neural Network[M]//Advances in Intelligent Systems and Computing. Singapore: Springer Singapore, 2018: 104−112. DOI: 10.1007/978-981-13-0869-7_12.

[7] 吴晓凤, 张江鑫, 徐欣晨. 基于Faster R-CNN的手势识别算法[J]. 计算机辅助设计与图形学学报, 2018, **30**(3): 468−476. DOI: 10.3724/SP.J.1089.2018.16435.
WU X F, ZHANG J X, XU X C. Hand Gesture Recognition Algorithm Based on Faster R-CNN[J]. *J Comput Aided Des Comput Graph*, 2018, **30**(3): 468−476. DOI: 10.3724/SP.J.1089.2018.16435.

[8] 胡宗承, 周亚同, 史宝军等. 结合注意力机制与特征融合的静态手势识别算法[J]. 计算机工程, 2022, **48**(04): 240−246, DOI: 10.19678/j.issn.1000-3428.0060912.
HU Z C, ZHOU Y T, SHI B J, *et al*. Static Gesture Recognition Algorithm Based on Attention Mechanism and Feature Fusion[J]. *Comput Eng*, 2022, **48**(4): 240−246. DOI: 10.19678/j.issn.1000-3428.0060912.

[9] SIMONYAN K, ZISSERMAN A. Very Deep Convolutional Networks for Large-Scale Image Recognition[EB/OL]. (2015−04−10) [2024−02−10]. https://arxiv. org/abs/1409.1556.

[10] WANG C Y, MARK LIAO H Y, WU Y H, *et al*. CSPNet: a New Backbone that can Enhance Learning Capability of CNN[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). New York: IEEE, 2020: 1571−1580. DOI: 10.1109/CVPRW50498.2020.00203.

[11] PISHARADY P K, VADAKKEPAT P, LOH A P. Attention Based Detection and Recognition of Hand Postures Against Complex Backgrounds[J]. *Int J Comput Vis*, 2013, **101**(3): 403−419. DOI: 10.1007/s11263-012-0560-5.

[12] KINGMA D P, BA J. Adam: a Method for Stochastic Optimization[EB/OL]. (2014−12−22) [2024−03−09]. https://arxiv.org/abs/1412.6980.

[13] NARASIMHASWAMY S, WEI Z W, WANG Y, *et al*. Contextual Attention for Hand Detection in the Wild [C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2019: 9566−9575. DOI: 10.1109/ICCV.2019.00966.

[14] ERICLEE.HANDPOSE_X[DB/OL].(2021−02−21)[2022−02−15]. https://codechina.csdn.net/ericlee/handpose_x.

[15] AITHAL C N, ISHWARYA P, SNEHA S, *et al*. Hand Gesture Recognition in Complex Background[M]//Communications in Computer and Information Science. Cham: Springer Nature Switzerland, 2022: 243−257. DOI: 10.1007/978-3-031-22405-8_19.

[16] SHEENA C V, NARAYANAN N K. Static Gesture Classification and Recognition Using HOG Feature Parameters and K-NN and SVM-based Machine Learning Algorithms[C]//Machine Vision and Augmented Intelligence: Theory and Applications. Singapore: Springer, 2021: 157−166. DOI: 10.1007/978−981−16−5078−9_14.

[17] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet Classification with Deep Convolutional Neural Networks[J]. *Commun ACM*, 2017, **60**(6): 84−90. DOI: 10.1145/3065386.

[18] HE K M, ZHANG X Y, REN S Q, *et al*. Deep Residual Learning for Image Recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2016: 770−778. DOI: 10.1109/CVPR.2016.90.

中国知网 https://www.cnki.net