华南理工大学
South China University of Technology

专业学位硕士学位论文

基于视觉的手势识别算法研究

作 者 姓 名 许冰媛

学 位 类 别 工程硕士（电子与通信工程）

指 导 教 师 周智恒 教授

陈曦 高级工程师

所 在 学 院 电子与信息学院

论文提交日期 2020 年 4 月

中国知网 https://www.cnki.net

Research on Hand Gesture Recognition Algorithm Based on Vision

A Dissertation Submitted for the Degree of Master

Candidate：Xu Bingyuan

Supervisor：Prof. Zhou Zhiheng

South China University of Technology

Guangzhou, China

中国知网 https://www.cnki.net

分类号：TP391.4 **学校代号：10561**

学　号：201721012093

华南理工大学硕士学位论文

基于视觉的手势识别算法研究

作者姓名：　许冰媛　　指导教师姓名、职称：　周智恒　教授

申请学位级别：　工程硕士　　学科专业名称：　电子与通信工程

研究方向：智能信息处理

论文提交日期：　2020 年 4 月 20 日　　论文答辩日期：　2020 年 6 月 6 日

学位授予单位：华南理工大学　　学位授予日期：　　年　　月　　日

答辩委员会成员：

主席：傅予力 教授

委员：唐杰 教授、向友君 副教授、余卫宇 副教授、周斯宁 高级工程师

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

摘　要

手势作为一种人机交互模式，与传统的键盘和鼠标相比，在人机交互中具有更佳的舒适度，目前已被广泛应用于智能家居、机器人控制、手语识别等方面，成为人机交互领域的研究热点。与基于数据手套的手势识别技术相比，基于视觉的手势识别技术仅需要摄像头便能完成人机交互任务，无需佩戴接触式的数据手套，不会给人以束缚感，具有交互自然、简单方便的优点，成为手势识别的主流方式。

基于视觉的手势识别技术利用单个或多个摄像头采集手势信息，采用特定的方法实现手势的识别。根据分类识别对象不同，可分为静态手势识别及动态手势识别。现实中手势交互背景环境复杂多变，不同的人表达同一手势时会有差异，这均为准确的手势识别带来困难，进而影响着用户体验。为了提高用户体验，构建一个鲁棒性较好的手势识别系统，本文对基于视觉的手势识别方法展开了研究。本文主要贡献如下：

（1）静态手势分割方法

手势分割是基于视觉的静态手势识别过程的第一个步骤，分割的效果影响着后期的手势分类结果。本文利用 Kinect 相机提供的深度信息结合手部的肤色信息进行手部分割，解决单目静态手势识别中存在的人手与复杂背景难以准确分离的问题。对于手部分割后存在冗余的手臂区域，本文创新性地采用距离变换操作并结合手掌分割圆，准确且快速地去除手臂区域。实验结果表明，该操作能够提高手势分类器的分类准确率。

（2）静态手势识别方法

对静态手势分割得到的手势二值图像提取特征并进行手势分类，本文探究不同的特征提取方式下手势分类器的分类性能。人工提取特征并输入到支持向量机进行训练，本文实现了一个传统的静态手势分类器。本文利用卷积神经网络对手势二值图像进行自动特征提取并分类，构建的手势分类器具有更好的识别效果。

（3）动态手势识别方法

本文利用 3D 卷积神经网络和卷积 LSTM 网络捕捉视频图像序列的时空特征，并利用 SPP 网络提取局部特征和全局特征，最终输入全连接网络实现了准确率高的动态手势识别。多模态视频图像序列作为动态手势分类器的输入，本文分别训练两种单模态网络并通过模型集成提高系统识别准确率，一定程度上避免了复杂背景环境的干扰。

关键词：静态手势识别；动态手势识别；支持向量机；卷积神经网络；3D 卷积

中国知网　https://www.cnki.net

Abstract

Gesture, as a human-computer interaction mode, has better comfort in human-computer interaction than traditional keyboard and mouse. It has been widely used in smart home, robot control, sign language recognition, etc., and has become a research hotspot in the field of human-computer interaction. Compared with gesture recognition based on data glove, vision-based gesture recognition only needs a camera to complete human-computer interaction tasks, does not need to wear contact data gloves, does not give people a sense of restraint, has the advantages of natural, simple and convenient interaction, and has become the mainstream method of gesture recognition.

Vision-based gesture recognition technology uses single or multiple cameras to collect gesture information and uses specific methods to implement gesture recognition. According to different recognition objects, it can be divided into static hand gesture recognition and dynamic hand gesture recognition. In reality, the background environment of gesture interaction is complex and changeable, and different people may express the same gesture differently, which make it difficult for accurate gesture recognition and affect the user experience. In order to improve the user experience and build a robust gesture recognition system under complex background, this paper researches vision-based gesture recognition methods. The main contributions of this paper are as follows:

(1) Method for static hand gesture segmentation

Gesture segmentation is the first step in the process of static hand gesture recognition based on vision. The effect of segmentation affects the later gesture classification results. In this paper, the depth information provided by Kinect camera is combined with skin color information of the hand to solve the problem that it is difficult to accurately separate the human hand from the complex background in monocular static hand gesture recognition. For the redundant arm area after hand segmentation, this paper innovatively uses distance transformation operation and palm segmentation circle to accurately and quickly remove the arm area. Experimental results show that this operation can improve the classification accuracy of the gesture classifier.

(2) Method for static hand gesture recognition

The features of the gesture binary image obtained by static hand gesture segmentation are extracted for gesture classification, this paper explores the classification performance of gesture classifiers under different feature extraction methods. Features are manually extracted

中国知网 https://www.cnki.net

and input to the support vector machine for training, this paper implements a traditional static hand gesture classifier. Convolutional neural network is used for automatic feature extraction and classification on binary images of gestures, the gesture classifier constructed in this paper has better recognition effect.

(3) Method for dynamic hand gesture recognition

This paper uses 3D convolutional neural network and convolutional LSTM network to capture the spatiotemporal features of video image sequences, and uses SPP network to extract local and global features. Finally, they are input into a fully connected network to achieve high-accuracy dynamic hand gesture recognition. Multi-modal video image sequences are used as the input of dynamic hand gesture classifiers. In this paper, two kinds of single-modal networks are trained separately and the system recognition accuracy is improved through model integration, which avoids the interference of complex background environments to a certain extent.

Keywords: Static hand gesture recognition; Dynamic hand gesture recognition; SVM; CNN; 3D convolution

中国知网 https://www.cnki.net

目　录

摘　要 I
Abstract II
目　录 IV
第一章　绪论 1
1.1　研究背景和意义 1
1.2　国内外研究现状 3
1.2.1　静态手势识别算法 4
1.2.2　动态手势识别算法 8
1.3　当前存在的问题 10
1.4　本文研究内容及结构 10
第二章　静态手势分割方法 13
2.1　引言 13
2.2　数据集采集 13
2.3　手部分割 14
2.3.1　图像平滑 14
2.3.2　光照补偿 15
2.3.3　深度阈值分割 16
2.3.4　肤色分割 17
2.4　手臂去除 19
2.4.1　距离变换 19
2.4.2　八连通判别算法 19
2.4.3　基于距离变换的掌心定位 20
2.4.4　基于一次距离变换的手臂去除 21
2.4.5　基于两次距离变换的手臂去除 22
2.5　实验结果与分析 25
2.5.1　手部分割实验 25
2.5.2　手臂去除实验 26
2.6　本章小结 28

中国知网　https://www.cnki.net

第三章　静态手势识别方法 29
3.1　引言 29
3.1.1　支持向量机（SVM） 29
3.1.2　卷积神经网络（CNN） 32
3.2　基于 SVM 的静态手势识别 42
3.2.1　SVM 数据集 42
3.2.2　手势特征提取 42
3.2.3　SVM 手势分类器 44
3.3　基于 CNN 的静态手势识别 48
3.3.1　CNN 数据集 48
3.3.2　CNN 手势分类器 49
3.4　本章小结 52
第四章　动态手势识别方法 53
4.1　引言 53
4.1.1　多模态动态手势数据集 53
4.1.2　3D 卷积神经网络 54
4.1.3　卷积 LSTM 网络 55
4.1.4　空间金字塔池化层 56
4.2　基于 3D 卷积和卷积 LSTM 的动态手势识别 57
4.2.1　网络结构设计 57
4.2.2　实验结果与分析 59
4.3　本章小结 62
总结与展望 64
1.　工作总结 64
2.　工作展望 65
参考文献 66
攻读硕士学位期间取得的研究成果 70
致谢 72

中国知网　https://www.cnki.net

第一章 绪论

1.1 研究背景和意义

随着计算机的全面普及，计算机技术迅猛发展，人机交互技术的研究成为了计算机学科领域的新热潮。人机交互是指人与计算机之间采用某种交互方式进行信息的传递、交流，该技术的实现主要依靠输入输出设备及相应的软件，从而完成某种特定的任务。人机交互的方式一般有键盘、鼠标及各种模式识别设备，人们可通过键盘、鼠标或是其他设备输入指令，人机交互技术便是接收并理解输入设备传送的指令信息，通过对指令进行解释并转换成相应的控制命令，进而控制相关设备的运行。键盘显示器的人机交互设备便是操作人员通过键盘键入所需的命令信息，操作系统接收、识别输入的信息并转换成相应的结果显示在显示器上。输入命令及其对应的输出是确定的，唯一的。鼠标、键盘的传统人机交互方式需要操作人员触碰设备从而实现所需的输出响应，该类方式并未考虑操作人员不熟悉计算机操作或是不方便使用键盘和鼠标，难以满足交互自然、便捷的现代人机交互系统的需要。对此，如何设计一种自然、友好的人机交互方式，逐渐引起了科研工作者的关注。

考虑人与人之间自然的交流方式包括语言、手势、姿态、微表情等，因此出现了基于语音识别、手势识别、姿态识别、微表情识别等在内的非接触式人机交互方式。语言是人与人之间最自然、有效的交流方式，基于语音识别的人机交互获得了广泛的关注，基于语音的人机交互系统已应用于很多触控式操作不适用的场合，比如车辆驾驶的过程中。然而，语言交流并不具有通用性，当处于一个陌生的语言环境时，语言的交流便成为一个难题。手势是除语言之外人类交流互动的重要方式，可以表达人类的情感及特定的语言内容，手势交流作为一种常见的肢体语言，即使在陌生的语言环境或是噪声较大的场合均适用。手势作为人机交互的重要方式之一，使人机交互由传统的鼠标、键盘等接触式交互转向空中操作控制交互，是一种更自然、更便捷、更友好的人机交互方式。

手势交互作为一种新型的交互方式，以其自然直观的特点为用户带来良好的交互体验，且随着技术的迅猛发展已被广泛应用于许多领域：

（1）聋哑人的手语沟通。对于聋哑人群体来说，由于身体的障碍使得他们听不到外界的声音，也无法像正常人一样使用语言交流，他们使用手势与外界进行交流，表达自己的心声。正常人需要学习手语才能与聋哑人进行沟通，由于手语的学习记忆较为繁琐，使得正常人与聋哑人之间的沟通交流较为不便。专用的手语识别设备可以识别聋哑

中国知网 https://www.cnki.net

人的手势并把手语转换为相应表达的内容的输出，使得未学过手语的人们也能够无障碍地与聋哑人交流，使得沟通更流畅。

（2）车载手势。在驾驶车辆的过程中，驾驶员和中控台之间的操作互动是要求驾驶员按按钮或是触屏，由于驾驶员需要看按钮在哪再控制，触屏也需要驾驶员盯着屏幕，这一传统的交互方式存在着极大的安全隐患。车载手势是指在开车的过程中用手势控制中控台的一些选项按键等，从而完成驾驶员和中控台之间的操作互动。相比于传统方式，车载手势不要求驾驶员每次都去按按钮或是触屏，是一种更安全、更智能、更方便的交互方式。汽车厂商通过将手势识别技术引入车载系统中，替代传统的人机交互方式，目前已有一些车载智能产品面世，比如 Ez more 智能手势控制精灵，可以通过手势控制音乐的切换等。

（3）智能家居。在家庭生活中，手势取代语音实现对智能电视、智能家具的控制，手势识别在该领域具有广阔的应用前景。

（4）游戏娱乐。在一些体感游戏中，人们可以使用手势来代替键盘、手柄进行游戏，游戏过程中带给用户一种身临其境的感受，给用户更好的沉浸感和游戏体验。

（5）虚拟目标操控。在虚拟现实中，利用手势识别技术判断人们的意图，进而实现对虚拟目标的操控，提高了用户的沉浸感。

手势识别是手势交互的一门关键技术，通过利用特定的机器学习、深度学习算法结合相应的设备实现对人体手势的识别。根据设备的不同，将手势识别技术分为：基于可穿戴数据手套和基于计算机视觉。前者利用具有多类传感器的数据手套进行识别，要求操作者佩戴数据手套进行交互，利用手套上的传感器采集操作者手指关节的运动数据，并将其传输给计算机处理，利用特定的算法达到识别的目的；后者不需要穿戴式设备，只需要利用摄像头采集用户的手势信息，然后利用机器学习、深度学习等技术进行手势特征提取及手势识别，进一步发出相应的指令从而达到交互的目的。可穿戴数据手套成本较高，用户携带及操作均不方便；而基于视觉的手势识别技术对设备的要求较低，只需要摄像头和计算机便能完成手势识别的过程，具有成本低、交互自然友好的特点，具有较好的应用前景，成为手势识别领域的研究热点。

基于视觉的手势识别技术可以分为基于视觉的静态手势识别和基于视觉的动态手势识别两部分，前者是指对输入的静态图像中手势表观形状进行识别，后者是指对输入的连续手势图像序列识别手势在时间与空间上形态与运动的变化。静态手势识别需要提取图像中手势的形状特征，在简单背景下较容易实现手势与背景的分离，在复杂背景下

中国知网 https://www.cnki.net

实现手势的准确分离容易受到背景环境的干扰，静态图像中提高手势与背景的识别度能够提高手势识别的准确率。动态手势识别需要识别判断输入图像序列中的手势运动轨迹，计算较为复杂。静态手势基于静态图像，能表达的语义较为有限，因此仅能用于比较简单的情景。腾讯云神图•手势识别是基于腾讯音视频实验室推出的新一代人机交互技术，可识别 25 种常见的静态手势，用于互动娱乐场景，比如：结合用户的手势（例如点赞、比心、拜年），实时增加相应的贴纸或特效。动态手势包括手部形状改变及手势的运动轨迹，可表达丰富的语义信息，是人们日常常用的沟通方式之一，因此适用于一些复杂的应用。2018 年 8 月上市的君马 SEEK 5，能够识别 9 种动态手势动作，实现接听电话、控制音量和地图等。

基于计算机视觉的手势识别技术克服了传统交互模式的不足，提高人机交互的效率，已经发展成为主要研究方向。基于视觉的静态手势识别和基于视觉的动态手势识别技术具有各自的优缺点，适用于不同的场景，在现实生活各种方向上有着很好的应用前景，如汽车辅助驾驶和未来沉浸式游戏等。同时，该技术仍有待发展，有着许多亟待攻克的技术难题，值得学者们去研究。

1.2 国内外研究现状

手势识别技术是指利用算法对用户表达的手势信息进行解释，用户可通过手势这门常用的肢体语言完成与机器设备的交互，达到机器理解人类行为的目的。最初的手势识别技术研究可以追溯到 20 世纪 70 年代，人们通常需要借助专用的机器设备采集人体手部胳膊等关节的角度和位置信息，从而获得完整的手势运动信息，其中最典型的是数据手套。数据手套是由多个传感器件组成，常见的传感器有六轴传感器和九轴传感器，利用配置的传感器检测人体手指关节的角度和弯曲信息，并进一步将信息传送到计算机系统中，对数据手套采集的手势样本数据进行手势建模，用于手势识别。一些先进的数据手套具有优秀的性能，能够检测到手指轻微的变化。基于数据手套的手势识别技术受环境的影响小，采集的数据置信度高，具有良好的检测效果，能够对大量手势进行建模和识别。1991 年诞生了一种名为 Cyber Glove 的数据手套，该数据手套集成了多类传感器，能够捕获用户的手势位置、方向、速度等信息，精度较高且稳定性强[1]。有研究者使用 Cyber Glove 进行三维手势信息的采集，利用神经网络对 50 个美国手语进行手势的建模和识别，该方法能够很好地识别单个的手语词汇[2]。在 1995 年，Christopher Lee 等人利用数据手套实现了一个手势控制系统，成功实现了对机器人的控制[3]。1999 年焦圣品等

中国知网 https://www.cnki.net

人使用数据手套采集 9 种静态手势，运用 BP 神经网络实现了静态手势识别[4]。2000 年，曾芬芳和王颖等人使用数据手套采集各个手指关节的弯曲角度信息，然后使用模糊神经网络对构建的手势样本集进行手势识别分类[5]。徐德友研究基于手势的虚拟现实交互技术，利用真实世界中手势的位置跟踪数据以及数据手套的传感器数据，运用神经网络和逻辑组合的方法对定义的手势进行识别，并形成相应的操作命令驱动虚拟世界中虚拟手的运动，最后该技术被应用于某型自行火炮的虚拟驾驶训练中[6]。哈尔滨理工大学的李辉利用数据手套采集手语手势运动过程中的空间状态、轨迹信息及手指各关节位置状态的信息，依据每种手语动作特征量的不同，通过 4 层决策树分类器完成对 6 种手语动作的识别[7]。

但是由于数据手套价格较为昂贵，难以对该类手势识别方式进行推广普及。此外，基于数据手套的手势识别方式要求使用者佩戴数据手套进行交互，由于需要佩戴数据采集设备，无法给用户带来自然、舒适的体验。人手佩戴光学标记的方式曾用于取代数据手套，该方式利用红外线可将人手的手势变化信息传送到系统屏幕上，虽能提供良好的检测效果，但该方式仍需借助外部设备。

为了摆脱辅助设备的束缚，科研工作者们开始转向基于计算机视觉的手势识别技术的研究。该方式利用单个或多个摄像头采集包含手势的图像，然后使用数字图像处理、机器学习等相关技术进行手势特征提取及手势分类。基于视觉的手势识别方法，按照手势数据的格式可以分为两类：静态手势识别方法与动态手势识别方法。

1.2.1 静态手势识别算法

基于视觉的静态手势识别是指对静态图像中的手势表观形状进行识别，如图 1-1 所示，典型的基于视觉的静态手势识别方式包括，首先检测并分割出输入图像的手势区域、然后提取图像中手势的形状特征、并利用某种算法进行识别，最终得到识别结果。如何准确分割输入图像中手势，并准确识别手势的含义是静态手势识别系统需要解决的关键问题。

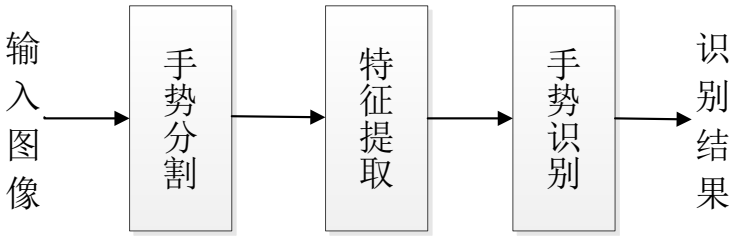

图 1-1 典型的基于视觉的静态手势识别方式

中国知网 https://www.cnki.net

手势分割是基于视觉的静态手势识别中关键的环节，分割的效果影响着特征提取，进而影响手势分类结果。在基于单目视觉的静态手势识别中，由于复杂背景环境的影响，实现图像中人手与背景的分离是一个难点。

常用的手势分割方法主要有：（1）利用手势的特征进行手势分割，例如手的肤色、手的轮廓、指尖、手的大小等。通常利用手势的肤色信息结合其几何特征对手势进行分割，但该方法易受外界光照强度和背景中的类肤色区域的干扰。（2）采用佩戴带标记的手套、或者复杂背景简单化等手段，制造易于实现手势与背景分离的环境从而获得较高的识别率，该方法虽然可以解决类肤色的干扰，但对环境要求较为苛刻，由于实际情况中环境往往难以预测，这种方法并不能满足现实条件下人机交互的需要。

随着 Kinect 相机的普及，许多研究者选择利用手势的深度信息解决复杂背景下的静态手势识别问题[8-11]。Kinect 是由微软开发，应用于 Xbox 360 和 Xbox One 主机的周边设备，通过利用实时身体骨架追踪、行为检测、图像识别、语音识别等技术，能够使用户摆脱传统游戏手柄的桎梏，利用肢体动作和语言指令等可以直接控制游戏目标，体现了更自然的人机交互方式。Kinect 一代（Kinect v1）是基于结构光原理的深度相机，Kinect v1（如图 1-2）的深度传感器包括投射红外线的红外发射器（左）和读取这个的红外摄像头（右），深度传感器中间还搭载了 RGB 摄像头，Kinect 可同时捕获 RGB 图像和深度图像数据。红外发射器发出的近红外激光照射到粗糙物体上时就会形成激光散斑，其会随着物体距离摄像头的远近而变换不同的图案，激光散斑标记了整个空间并被红外摄像头所捕获，传送至 Kinect 的图像处理器，通过分析散斑图案最终处理得到一幅深度图像，标记着空间中的点与摄像头的距离，即将获取的深度信息转换为像素值 0-255 的灰度图像。

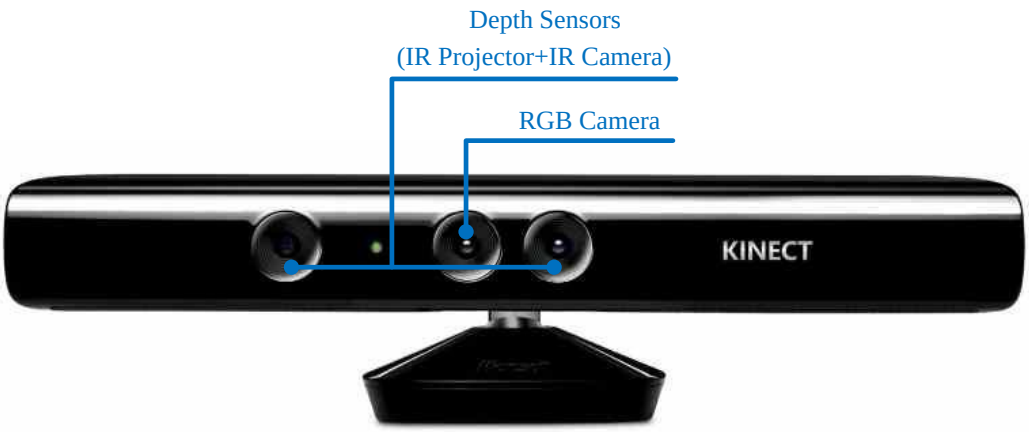

图 1-2 Kinect v1

中国知网 https://www.cnki.net

单独的利用深度图像虽然可以快速地分割出手势，但在复杂背景下手势检测准确率仍较低。文献[8]提出将 RGB 图像和深度图像信息结合起来进行手势分割，利用手势图像的深度信息并结合手势的肤色特征成功实现手势与复杂背景的准确分离。文献[9-10]提出了结合颜色和深度信息进行手势分割可以使系统更加鲁棒。

同一手势在不同时间拍摄得到的手势图像，经手势分割后结果会不同。本文静态手势是指手掌和手指的形态，通过手掌和手指即可表达手势信息，如图 1-3 所示手部分割后存在的手臂区域为冗余信息。由于手臂信息的有无、手臂的长短会造成特征的差异，进而干扰和影响手势识别的结果，因此在手部分割的基础上去除手臂干扰能提高系统的识别率。

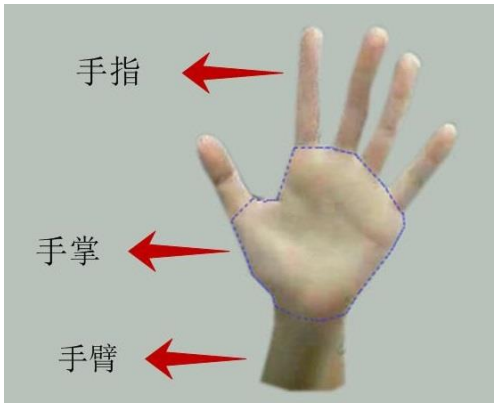

图 1-3 手部分割后的组成部分

很多静态手势识别方法中用于训练和分类的手势图像没有包含手臂或者手臂区域被衣袖遮挡，由于没有考虑裸露手臂的情形，这些算法难以推广应用到现实生活中。通过穿戴特殊颜色的手套[12]或者控制摄像头的视角范围来避免手臂区域的干扰，这两种方法虽然能有效排除手臂区域的影响，但降低了手势交互的自然性和实用性。

目前，已经出现了一些手臂去除的算法。文献[13]和[14]根据手腕处较窄，手掌和手臂较宽的特点设计的手臂去除算法。文献[13]介绍了一种基于边界宽度的手臂去除算法，该方法要求手掌位于图像的正上方，手臂位于图像的正下方，通过搜索确定水平手腕线位置，并除去该线段以下的手臂部分。但该方法存在一定局限性，不适用于手臂倾斜放置等特殊情形。文献[14]利用手部最小外接矩形的主轴搜索确定手腕线位置，进而去除手臂区域。该算法虽不受手臂旋转的影响，但运算速度慢效率低，无法快速去除手臂区域。文献[15]采用直径较大的结构元进行开运算操作腐蚀手指区域，但同时也会消除一部分手臂信息，该信息会影响手臂去除的效果，进而影响手势特征提取及分类识别结果。该算法虽简单，但手臂无法完整去除，导致系统识别率不高。文献[16]通过利用

中国知网 https://www.cnki.net

距离变换映射图和手掌切割圆，运用向量点积运算确定去除手臂的切割线段。该算法虽能有效去除手臂区域，但时间复杂度高，无法满足手势交互系统实时性的要求。文献[8]提出了一种基于深度相机的手掌检测算法，通过结合深度信息寻找拟合手掌区域的圆或椭圆，在手势分割的基础上能准确检测并提取出手掌和手指区域。文献[17-19]也对基于深度信息的手势识别算法进行了研究，这些算法需要使用 3D 传感器，例如 Kinect。

传统的基于手势特征提取的静态手势识别方法通过计算手势区域的色彩、纹理与几何特征用于手势分类，能够实现较稳定的静态手势识别[20-22]，但是识别效果很大程度上受特征提取方式是否准确的影响。现实中由于手势可能出现平移、旋转、缩放等情形，传统手势识别算法中提取的特征需要适用以上情形，并且能够容易区分不同的类型，才能将算法应用于实际的手势交互系统中。通常用于代表手势的特征包括：SIFT（Scale-invariant Feature Transform）、Hu 矩、方向梯度直方图（Histogram of Oriented Gradient，HOG）等。HOG 可以描述手势图像的灰度变化情况，但是 HOG 对手势旋转不具有不变性，利用 HOG 进行手势特征提取时需要采集各种旋转方向的手势样本图像，才能将训练得到的手势识别系统推广应用到实际生活中。Hu 矩、SIFT 都包含了平移、旋转以及尺度不变性等优点，但是 SIFT 算法需要计算大量的特征点导致运算时间长，SIFT 不适用于实时的手势识别系统，而 Hu 矩常被用于手势特征的提取。

基于传统特征提取的分类识别方法将提取的特征参数进行归类，进而达到识别图像中手势含义的目的，通常采用的方法有：模板匹配、BP 神经网络、支持向量机（Support Vector Machine，SVM）等。模板匹配算法虽然简单，但是分类的结果受原先的模板影响较大。邓志国[23]提取手势轮廓的傅里叶描述子特征并训练一个 3 层 BP 神经网络，该方法的静态手势识别准确率可以达到 98%。邹潇[22]等对手部灰度图像提取 HOG 特征，利用最小马氏距离分类器进行建模、分类，实现对剪刀、石头、布这 3 类静态手势的识别，平均识别率达到了 98.5%。甘志杰[24]利用 Hu 矩提取手势特征，并利用 SVM 进行静态手势的分类识别，该算法能够识别 10 种手势且识别率达 98.7%。

深度学习是机器学习领域中试图使用多重非线性变换对数据进行多层抽象的算法，广泛应用于计算机视觉领域。作为深度学习的一个重要分支，卷积神经网络（Convolutional Neural Networks，CNN）是一种基于卷积计算的深度神经网络，主要包括卷积层、池化层和全连接层等等，卷积层神经元能够从前一层输出的特征图中提取更加抽象的高层特征；池化层能够对卷积层输出结果进行降维压缩，减少数据冗余；全连接层能够整合提取的特征，并输入分类器得到最终的分类识别结果。CNN 具有权值共

中国知网 https://www.cnki.net

享的特点，能够大幅度减少网络参数，提高网络训练速度。CNN 能够对输入图像进行自动特征提取与分类识别，省去传统识别算法中需要人工设计特征提取器的复杂环节。近年来，CNN 已经成为图像识别领域的研究热点，并成功运用于人脸识别[25]、目标检测[26]等领域，在手势识别领域也逐渐兴起。在手势识别中，CNN 被用于手势的检测与分类[27-28]，通过对大量样本的学习得到手势区域的隐含特征，可以得到较好的识别效果。蔡娟[29]等使用 CNN 进行手势识别，直接将原始手势图像作为模型的输入，训练出的模型能准确识别多种手势且鲁棒性好。操小文[30]等通过引入噪声验证了其网络结构具有很强的鲁棒性，识别效果较好。但是两者研究存在的不足之处在于，输入的训练样本背景较为简单，单一背景下提取静态图像中的手势特征的计算复杂度较低，当背景变得复杂时提取的特征容易受到背景环境的影响，此时无法保证是否仍然具有以上的研究效果。杨文斌[31]将复杂背景下的手势样本作为网络的输入，通过提升网络卷积层和池化层的层数以获取更好的高维手势图像特征，由于网络参数增多导致模型训练时间较长。在静态手势识别中，提高静态图像手势与背景的识别度可以有效提高手势识别的效率。纪国华[27]提取各类背景下图像中的手势区域，将手势分割后的图像作为 CNN 分类器的输入样本，提高了 CNN 中静态手势的识别准确率，识别准确率达到 97.3%。

1.2.2 动态手势识别算法

基于视觉的动态手势识别以一组连续的手势动作作为研究对象，不仅关注手势形状，更关注手势在时空维度上的形状变化和运动轨迹。人手具有 27 个自由度，运动十分灵活、复杂，不同的人作出同样的手势时手的运动会存在差别，同一个人在不同时间作出同一手势也会不一样，由于动态手势本身存在着多样性、差异性和随机性，动态手势识别的分类准确率仍较低，是具有挑战性的一个研究方向。

在基于视觉的动态手势识别的研究中，机器学习是常用的方法之一，包括计算时间序列相似度的动态时间规整（Dynamic Time Warping，DTW）[32]、基于马尔科夫链与观测独立假设的隐马尔科夫模型（Hidden Markov Model，HMM）[33]以及条件概率分布模型条件随机场（Conditional Random Fields，CRF）[34]等，一般需要先提取图片特征，然后对得到的时间序列特征进行匹配或者预测出对应标签。动态时间规整 DTW 本质上是一个模板匹配的方法，将待测数据与模板数据进行匹配得到预测结果，基于 DTW 的方法能够很好地适应执行手势的速度变化，但该方法的识别准确度容易受到模板库数量的影响，且随着模板库数量的增多实时性变差。基于 HMM 的识别算法是直接通过时间序列特征预测出对应标签，该算法中将向量点的位置和旋转信息设置为 HMM 的可观测状

中国知网 https://www.cnki.net

态，而将速度与缩放信息设置为不可见的隐藏状态，HMM 的初值则由均匀分布给出。依赖于大型数据库的学习过程，基于 HMM 的方法通常是鲁棒的且能适应手势的各种变化，但是实时性通常较差。XWang[35]等人使用 Baum-Welch 算法训练的 HMM 模型，能够处理不同时间序列长度的信息，对动态手势具有很高的识别效率。随着交互应用的发展和对手势识别精度要求的提高，XY Wang 等[36]对单一的 HMM 模型进行改进以满足应用的需要，通过结合隐马尔科夫模型与模糊神经网络提出了基于 HMM-FNN 的模型结构，模糊规则的设立使得能够识别更加复杂的手势，进一步提高精确度。由于具有模糊规则，对于先验经验的依赖性以及较多隐含层结点导致其具有收敛速度不足等缺点。

随着深度学习的不断发展，深度神经网络也被用于基于视觉的动态手势识别的研究中。使用传统的 2D 卷积神经网络进行动态手势识别时，容易丢失手势在时间维度上的相关特征信息，由于无法有效捕捉手势在时空维度的变化信息，导致手势识别准确率降低。视频时空维度的特征学习是实现人体动态手势识别的关键，为了避免丢失手势时间维度特征，Simonyan 等人[37]提出时空双流卷积架构，利用 RGB 图像和叠加光流图像，其中前者更关注视频图像序列的空间维度特征，而后者更关注时间维度特征，融合时空特征后进一步分类，该算法性能优于先前大部分基于深度网络的视频分类识别方法；长期回归卷积网络（Long-term Regression Convolutional Network，LRCN）[38]首先从视频的每一帧中学习空间特征，然后将空间特征序列作为递归神经网络（Recurrent Neural Network，RNN）的输入，从而学习时间特征；VideoLSTM[39]使用卷积 LSTM（ConvLSTM）网络从先前提取的二维空间特征中学习时空特征，ConvLSTM 的当前输入会与历史信息中相同的空间区域进行作用，能够描述不同空间区域的局部变化，在考虑各种背景的情况下能够有效地学习动态手势的时空特征；Ji 等人[40]提出的 3D 卷积神经网络（3D CNN）用于人体动作识别，从输入帧中提取 5 个通道信息，分别使用 3D 卷积捕捉连续帧的时空特征，最终融合所有通道的特征信息实现较好的动作识别；Tran 等人[41]通过实验验证了 3D CNN 在视频的时空特征提取方面是有效的，并在原有 3D CNN 模型的基础上提出了 C3D 模型，找到了最优的 3D 卷积核结构为 3×3×3，能够同时捕捉时间和空间维度特征；文献[42]采用高分辨率网络（High-Resolution Network，HRN）和低分辨率网络（Low-Resolution Network，LRN）两个 3D CNN 相结合的方式识别驾驶员手势，结合多个空间尺度信息可以有效提高模型的泛化能力；Camgoz 等人[43]使用 Tran 等人[41]的工作对网络进行部分初始化，采用 3D 卷积操作从彩色视频序列中学习特征，训练了一个端到端的 3D CNN 模型，实现了连续的手势识别。

中国知网 https://www.cnki.net

1.3 当前存在的问题

手势分割是基于视觉的静态手势识别中关键的环节，分割的效果影响着特征提取，进而影响手势分类结果。在基于单目视觉的静态手势识别方法中，由于复杂背景环境的影响，手势分割的结果不太理想，在利用肤色模型提取复杂背景下手势图像中的肤色区域时，会将背景中的类肤色物体比如纸皮箱、颜色与肤色较为相近的水杯等等提取出来，需要对算法的应用情景加以限制，才能成功将手势从图像中分离开来。由于实际应用的情形变幻莫测，这是基于单目视觉的静态手势识别普遍存在的难以克服的问题，即对背景的要求较为苛刻。静态手势只由手掌和手指表示，手部分割后存在的手臂区域是冗余信息，会干扰和影响手势识别的结果，复杂背景下的静态手势识别准确率仍有待提高。对于静态手势识别过程中发生的手势平移、手势旋转、手势尺度变化等问题，选择用于描述手势的特征需具有平移、旋转、比例不变性。为了实现较高的分类准确性，很多静态手势识别方法选择的分类器需要花费较长时间、在很大的样本集上训练得到。此外，在分类过程中速度较慢，难以满足手势识别系统实时性的要求。

动态手势识别不仅关注手部形状，更关注手势在时空维度上的轨迹和形状变化。由于动态手势具有多变的形状，且手指间存在严重的重叠，使用单目摄像头难以捕捉丰富的动态手势信息，这限制了基于单目视觉的动态手势识别技术的发展。常见的 2D 卷积神经网络用于处理视频图像序列时，容易丢失目标在时间维度上的信息，如何有效提取手势在时空维度的变化信息，是实现人体动态手势识别的关键。

1.4 本文研究内容及结构

本文对基于视觉的手势识别算法进行研究，主要研究内容如图 1-4，具体研究内容可以总结为如下三点：

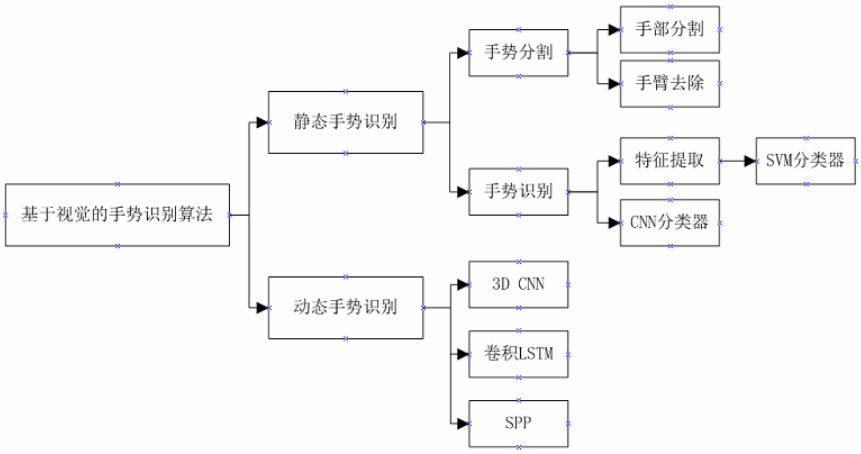

图 1-4 本文的主要研究内容

中国知网 https://www.cnki.net

（1）静态手势分割方法

基于单目视觉的静态手势分割方法中，由于复杂背景环境的影响，手势分割的结果不太理想，本文提出一种结合深度信息与肤色信息的手部分割方法，用 Kinect 采集 RGB 图像及深度图像，利用深度阈值和人体肤色信息进行手部分割，克服复杂背景中类肤色区域的影响；在实现手部与复杂背景分离的基础上，创新性地提出基于距离变换的手臂去除算法，该算法能有效减少手臂区域的冗余信息对手势分类器分类结果造成的影响。

（2）静态手势识别方法

在实现静态手势分割的基础上，本文探究不同的静态手势特征提取方式下手势分类器的分类性能。在众多的机器学习算法中，选择在类别比较少的分类问题中运算速度快的 SVM 作为手势的分类器，人工提取手势二值图像的 Hu 矩和指尖个数构成手势的特征向量，通过组合多种手势特征并训练 SVM，得到鲁棒性强、准确率高的手势分类器。对于能够自动提取特征并分类手势图像的深度卷积神经网络，若把采集的手势图像直接输入到 CNN 模型中会计算额外的背景像素区域，不仅增加计算代价而且对机器的配置要求也比较高。本文利用静态手势分割方法过滤掉手势的复杂背景，提取出有用的手势语义信息，将得到的手势二值图像样本送入 CNN 进行训练，生成手势识别模型。在现实场景中，本文提出的基于 CNN 的静态手势识别方法能够快速准确地识别出手势，且具有较好的鲁棒性。

（3）动态手势识别方法

针对如何有效提取动态手势在时空维度的变化信息，本文提出一种基于 3D 卷积和卷积 LSTM 的动态手势识别方法，利用 3D CNN 提取动态手势的短时空特征，在此基础上利用 ConvLSTM 提取动态手势的长时空特征，最后利用 SPP 网络同时提取局部特征和全局特征。本文在 SKIG 数据集上分别训练了基于 RGB 模态和基于 Depth 模态的网络，融合两种网络的预测以获得最终的预测结果，实现了准确率高的动态手势识别。

本文共包括 5 章内容，各章节内容概述如下：

第一章：绪论。简要介绍了手势识别技术的研究背景和研究意义，介绍了基于视觉的手势识别技术的研究方向，分别讨论了静态手势识别算法和动态手势识别算法的国内外研究现状，提出基于视觉的手势识别领域目前存在的问题，以及展示了本文研究内容和各章节的内容安排。

第二章：静态手势分割方法。介绍了图像预处理的一些操作，包括图像采集、图像平滑及光照补偿，提出一种结合深度信息与肤色信息的手部分割方法实现手部与复杂背

中国知网 https://www.cnki.net

景的准确分离，创新性地提出两种基于距离变换的手臂去除算法，与其他文献提出的手臂去除算法进行对比分析实验。

第三章：静态手势识别方法。本章选取 7 个不变矩和指尖个数组成了 8 维的手势特征向量训练 SVM 手势分类器，在静态手势分割的基础上构建并训练 CNN 手势分类器。

第四章：动态手势识别方法。本章将多模态视频图像序列作为网络模型输入分别训练两种单模态手势分类器，序列样本先后输入 3D 卷积神经网络、卷积 LSTM 网络和 SPP 网络进行动态手势特征的提取，通过模型集成得到最终的动态手势分类结果。

第五章：总结与展望。总结全文工作并分析当前存在的需要改进的地方，并对后续工作作出展望。

中国知网 https://www.cnki.net

第二章 静态手势分割方法

2.1 引言

本文利用 Kinect 相机同时捕获 RGB 图像和深度图像，从而构建静态手势样本集。如图 2-1 所示，本章静态手势分割方法包括手部分割和手臂去除。

在手部分割方面，提出了深度信息与肤色信息相结合的算法，解决手势与复杂背景难以准确分离的问题。利用获得的深度信息，通过设定深度阈值将 RGB 图像中靠近摄像头的手部分割开来。通过采取转换色度空间、光照补偿的方法避免光照强度对肤色分割的影响，然后利用手部的肤色特征检测图像中的肤色区域，得到肤色分割后的二值图像。利用多个肤色样本训练得到的肤色模型对于肤色具有较强的鲁棒性。

在手臂去除方面，创新性地提出了两种基于距离变换的手臂去除算法。在手部分割的基础上，利用距离变换操作能准确地定位掌心的位置，利用手掌切割圆结合距离变换操作和八连通判别算法，能准确去除冗余手臂区域。在本文静态手势样本集上，与其他文献提出的手臂去除算法进行对比实验，论证了本文提出的手臂去除算法在分割准确度及运算复杂度上具有明显的优势，能够满足实时手势交互系统的要求。

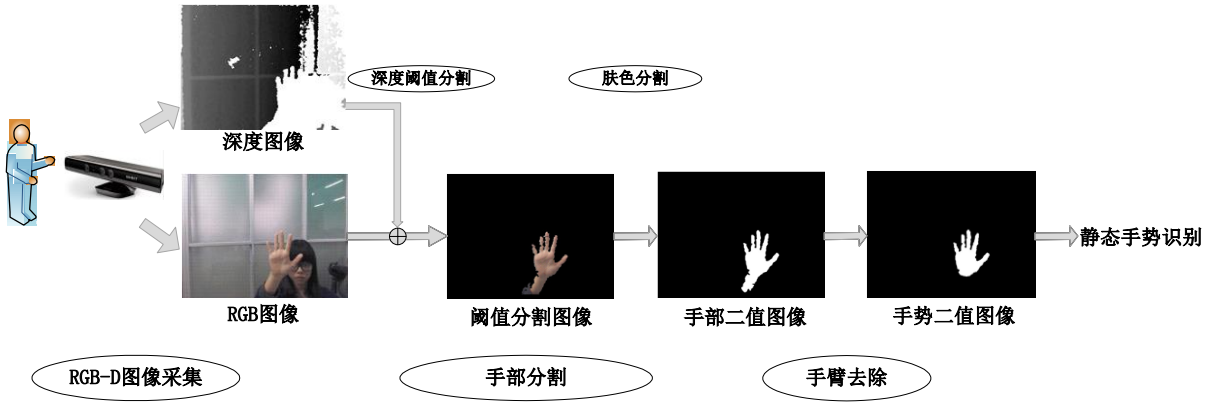

图 2-1 静态手势分割流程图

2.2 数据集采集

本文利用 Kinect 在实验室环境下同时采集静态手势的 RGB 图像及深度图像，得到 RGB 图像中所有像素点对应的深度信息，构建静态手势样本集。如图 2-2 为本文待识别的 0 到 7 八种静态手势。距离 Kinect 太近或者太远，计算的深度值精度就越低，这是因为激光散斑不能在后面做相关度的计算而不精确，因此在距离摄像头 200mm~3500mm 之间的空间采集静态手势样本，Kinect 位于被采集者身体的正前方，且被采集者手的位置距离 Kinect 最近。考虑到实际应用中背景环境往往难以预测，为了尽可能模拟各种不

中国知网 https://www.cnki.net

同的真实环境，提高模型的泛化能力，本文在光照强度、背景环境不同的情况下建立起3个对象的8种手势图库，其中训练集每种手势包括300张RGB图像和300张深度图像，共2400张手势RGB图像样本和2400张手势深度图像样本，测试集每种手势包括90张RGB图像和90张深度图像，共720张手势RGB图像样本和720张手势深度图像样本，采集的图像大小均为640×480。图2-3展示了本文采集的8种静态手势的RGB图像样本。

图2-2 本文待识别的8种静态手势

手势0 手势1 手势2 手势3 手势4 手势5 手势6 手势7

图2-3 本文采集的8种静态手势的RGB图像样本

2.3 手部分割

2.3.1 图像平滑

采集静态手势数据集的过程中，容易受外部光照强度、噪声及设备性能等客观因素的影响，导致获取的静态手势图片的质量难以达到正常识别的标准。对于本文中所采集的图像，图像中会存在大量的噪点，如果将采集到的图像在未经降噪处理的情况下直接用于手势识别，极有可能给手势识别研究工作带来麻烦。手势的边缘会因为噪声的存在而不平滑，这会影响后续的手势分割和手势特征提取，导致从手势图像中提取出的特征不能有效地代表手势，进而影响整个手势识别的性能。我们在进行手势识别前必须先对输入的图像进行去噪处理。值得注意的是，采取的去噪操作必须不能影响到我们对图像内容的理解。对于输入图像中不同的噪声，我们处理的方法也不相同，常采用的操作是：高斯滤波、均值滤波、中值滤波。

（1）高斯滤波

对于常见的高斯噪声（也称为正态噪声），一般采用高斯滤波器来去除。高斯噪声服从高斯分布，主要是由摄像机传感器元器件内部产生的，是一种加性噪声，即噪声直

中国知网 https://www.cnki.net

接加到原图像上。高斯滤波是一种线性平滑滤波，适用于消除高斯噪声。高斯滤波的具体操作是：高斯内核在图像上滑动，对内核确定的邻域内像素值进行加权平均，计算得到的数值取代内核中心点的原像素值，将内核扫描一遍图像可以得到高斯滤波的结果。

（2）均值滤波

均值滤波是一种线性滤波器，可以去除高斯噪声，主要思想为邻域平均法，即求输入像素邻域的灰度均值，其结果作为该像素点的取值，从而实现图像平滑。均值滤波处理速度相对较快，能够有效抑制加性噪声，但是会模糊图像的边缘信息和细节，会丢失很多特征。

（3）中值滤波

椒盐噪声主要是由图像切割引起的黑图像上的白点噪声或光电转换过程中产生泊松噪声，类似把椒盐撒在图像上，因此得名。椒盐噪声可认为是一种逻辑噪声，若用线性滤波器进行去噪，其效果并不好，通常使用中值滤波器进行滤波会有较好的结果。中值滤波器是统计排序滤波器中的一种，主要思想是对当前像素点邻域内像素值进行大小排序，然后取中值作为该像素点滤波后的结果，将滤波器窗口在图像上滑动，即可得到中值滤波后的整个图像。

本文选取滤波效果较好的高斯滤波对输入图像进行平滑处理。

2.3.2 光照补偿

光照是影响图像内容理解的关键因素之一，强烈光照或者是特别黑暗的环境使得图像颜色产生失真，从而影响后续利用肤色特征检测并分割图像的肤色区域。在不同的时间段采集手势图片，光照强度会有所不同，实时的手势识别系统应该适应各种光照条件的变化，我们需要减弱光照强度对系统性能的影响。由于强光引起的背景变化会影响肤色分割的效果，所以在建立肤色模型之前，本文利用灰度变换的光照补偿方法来弱化强光的影响。图 2-4 为灰度值的线性变换函数，其中 L 为灰度级数，灰度级范围为[0，L-1]，将输入图像中每个像素点的灰度取值由[0，L-1]线性映射为[0，4L/5]。采用线性变换可有效弱化强光，使肤色模型在强光下也能取得较好的分割效果，进而避免由于光照引起的背景变化而造成的误检。

中国知网 https://www.cnki.net

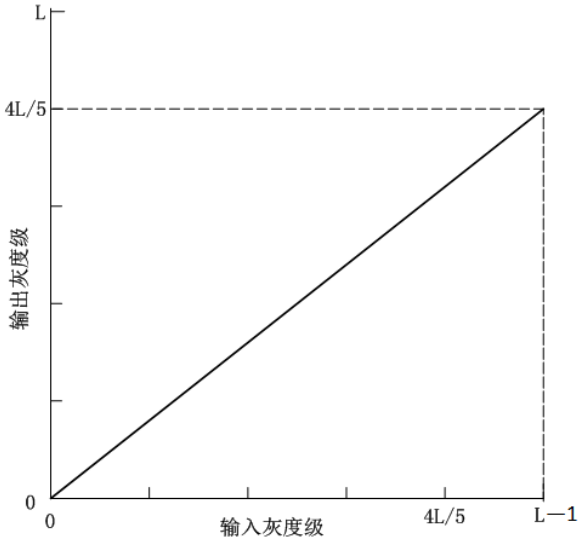

图 2-4 线性变换函数

2.3.3 深度阈值分割

本文静态手势样本集中对于同一手势，采集包括 RGB 图像及标识 RGB 图像中所有像素点与摄像头距离的深度图像。深度图像是一张灰度图像，其像素值表示场景中的点到 Kinect 的相对距离。如果该点越靠近 Kinect，其像素值越大，相应的像素点会更亮。在实际应用中，被采集者手的位置距离 Kinect 最近，因此深度图像可用于进行手部定位。本文定位深度图像中距离 Kinect 最近的像素点，并计算距离其 250mm 内的像素点，根据该深度阈值可以提取 RGB 图像中的相应像素点，并令 RGB 图像的其余像素点为黑色，从而可以获得包含手部的 RGB 图像（如图 2-5 所示）。通过深度阈值分割可以避免背景环境的影响，即避免复杂背景中肤色区域及类肤色区域对后续肤色分割效果的影响，可以准确地提取手部区域。

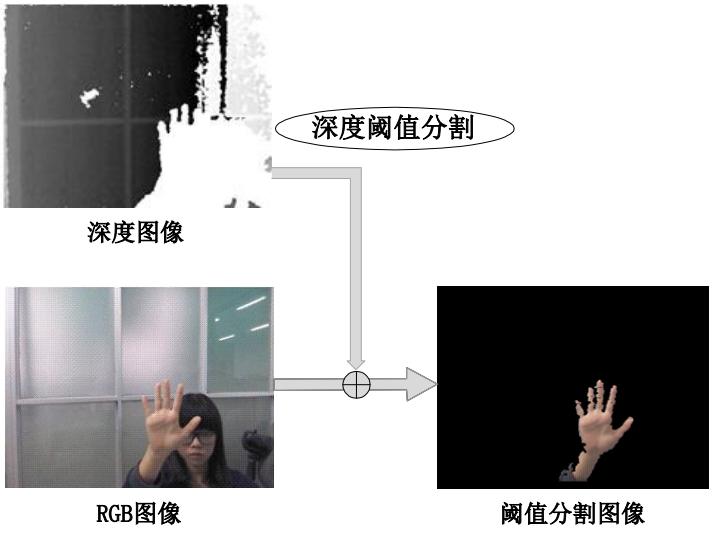

图 2-5 深度阈值分割

中国知网 https://www.cnki.net

2.3.4 肤色分割

如图 2-5 所示，通过深度阈值分割获得的 RGB 图像可能包含除手部以外的其它区域（例如袖子），这将影响后续手势特征提取及手势分类识别性能，因此肤色信息被用于进一步提取手部区域。肤色在自然色彩中具有聚类的性质，我们可以将其与其它色彩区分开。在色彩空间中，利用肤色的聚类特性可以分割出图像的肤色区域，由于类肤色区域的色彩性质与肤色相近，在肤色分割中类肤色区域也将被提取出来。目前，肤色分割算法已经比较成熟，在很多文献中也有将其应用到人脸识别、手势交互等领域。

2.3.4.1 色彩空间

肤色聚类空间的选择是肤色分割算法中比较重要的环节，色彩空间的选择会影响最终的肤色分割效果。已有很多文献对不同空间的肤色分割效果进行分析比较，常见的色彩空间有：RGB、HSV 和 YCrCb，不同空间描述颜色时具有不同的特点，因此我们需要找到比较适合肤色聚类的色彩空间。

很多文献通过实验得出结论：不同的肤色信息在色度上相近，但在亮度上却并不相近。由于 RGB 色彩空间中的三个颜色分量 r、g、b 均包含亮度信息，在不同的光照条件下采集相同肤色的图像会得到有较大差距的肤色信息。由于受光照强度影响较大，相同的肤色在不同条件下也会得到不一致的肤色检测结果，所以 RGB 色彩空间不适用于肤色分割的研究。

文献[44]提出了一个适用于肤色分割的非线性的 YCr'Cb'色彩空间，通过将亮度信息与色度信息分离开来，巧妙地避免了光照强度对肤色信息的影响，适用于肤色分割。YCr'Cb'空间的 y 代表亮度信息，cb'和 cr'共同代表色度信息。像素点亮度信息 y 由公式（2-1）求出。当 y 小于 200 时，该像素点的 cb'、cr'分量由公式（2-2）求出。当 y 大于 200 时，该像素点的 cb'、cr'分量则按照公式（2-3）进行变换。文献[44]通过实验得出结论：在不同光照条件下，YCr'Cb'空间中表征肤色的 cb'、cr'分量具有较强的聚类性。本文运用 YCr'Cb'色彩空间对肤色进行分割。

$$y = 0.299 \times r + 0.587 \times g + 0.114 \times b \tag{2-1}$$

$$\begin{aligned} cr' &= (r-y) \times 0.713 \\ cb' &= (b-y) \times 0.564 \end{aligned} \tag{2-2}$$

$$\begin{cases} cr' = (r-y)^2 \times 0.713 \times \left(-\dfrac{5000}{91} \times (y-200)^{-2} + 7 \right) \\ cb' = -(b-y)^2 \times 0.564 \times (125 \times (y-200)^{-2} - 3) \end{cases} \tag{2-3}$$

中国知网 https://www.cnki.net

2.3.4.2 肤色模型

将输入图像转换到 YCr'Cb'色彩空间之后，我们需要一套规则用于判断输入的颜色是否属于肤色，该判断规则就是指肤色模型。判断输入的颜色信息与我们之前训练的模型是否匹配，如果两者很相近，那么认为该颜色就是肤色。由于肤色具有聚类的特性，我们采用阈值法，直接设定一个阈值区间，如果颜色信息在该区间中，那么判定该颜色就是肤色。本文通过计算训练集中肤色区域的分量的边界范围，获得明确的肤色聚类的阈值区间，若输入图像中任一像素点的分量在该阈值范围内，则被认定为肤色像素点，否则将被视为非肤色像素点。

图 2-6 为本文肤色模型的训练流程，用不同肤色的样本对肤色模型进行训练，使肤色模型适用性更强。首先对输入的 RGB 图像样本进行平滑处理，防止摄像头本身的系统误差导致手势边缘存在锯齿，对后期手势特征的提取造成影响。利用灰度变换的光照补偿方法，减弱强光对图像内容的影响。将图像由 RGB 空间转为 YCr'Cb'空间之后，提取图像样本的肤色区域，计算该区域的像素点集的 cb'、cr'分量的边界范围，获得阈值区间$[cb'_{min},cb'_{max}]$、$[cr'_{min},cr'_{max}]$。

图 2-7 为对深度阈值分割获得的 RGB 图像进行肤色分割处理，若输入图像任一像素点的色度分量值同时满足肤色模型的阈值范围，则认为该像素点为肤色点，遍历整幅图像检测肤色区域及类肤色区域，得到一幅二值图像。本文建立的肤色模型能够快速准确判断输入的颜色信息，所以非常适用于对实时性要求较高的手势交互系统。

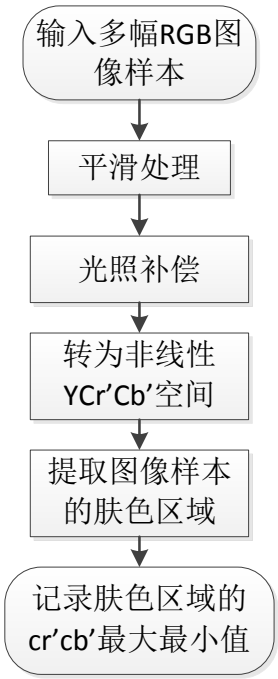

图 2-6 肤色模型的训练

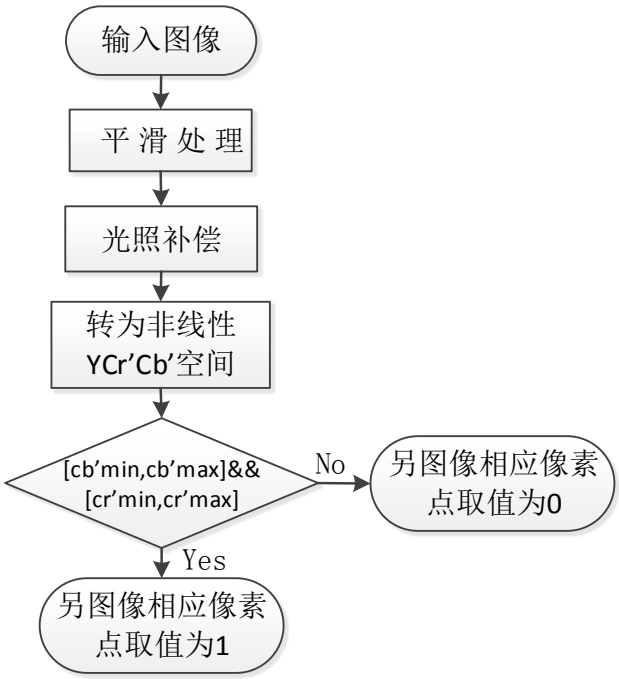

图 2-7 肤色区域的分割

中国知网 https://www.cnki.net

如图 2-8，以上操作得到的二值图像可能带有许多噪声点，需要对其进行形态学处理，先进行开运算操作，后进行闭运算操作，可以消除大量的孤立噪声。接着对二值图像按八连通判别原则进行连通区域的标记，计算不同连通区域的面积并保留面积最大的连通区域，认定为手部区域，其余区域认定为非手部区域并另为黑色。通过上述算法可以去除背景中小面积的类肤色区域，最终成功实现复杂环境下手部与背景的分离，如图 2-9 为肤色分割得到的手部二值图像。

图 2-8 肤色分割图像

图 2-9 手部二值图像

2.4 手臂去除

2.4.1 距离变换

距离变换于 1966 年被学者首次提出，是针对二值图像的一种变换操作，目前已被广泛应用于计算机视觉领域，常被用于目标细化、骨架提取等。二值图像包含两种元素：前景区域和背景区域，本文对手部分割后得到的二值图像采取距离变换操作，该操作的作用就是计算出前景区域的像素点到其边界的最小距离，最终将二值图像变换为灰度图像，若前景区域中某一点离边界越远，由定义可知，其变换后得到的数值就越大。研究中距离的测量方法有许多种，本文采取了常见的欧氏距离如公式（2-4），(r_1,c_1)，(r_2,c_2) 为两个点的坐标。二值图像采取距离变换操作后所得图像称为距离变换映射图，变换后像素点取值越大，表示其离背景区域越远，在该图中也越亮。

$$d=\sqrt{(r_1-r_2)^2+(c_1-c_2)^2} \tag{2-4}$$

2.4.2 八连通判别算法

在图像处理过程中，八连通判别算法常被用于对图像进行连通区域的提取操作，一张图中不同连通区域用不同的标签标记，算法效率高。图 2-10 a）为二值图像，黑色表示背景区域（像素值为 0），白色表示前景区域（像素值为 1），图中有两个相互独立的连通区域，采用八连通判别算法找出图中这两个连通区域，并按照一定顺序标记不同

中国知网 https://www.cnki.net

的标签，标签值为 1、2、num（连通区域的个数），同一个连通区域中的像素点标签相同（如图 2-10 b）所示）。具体地，一行一行地遍历图像，寻找该行的连通区域，八连通判别算法如下：

（1）判断当前点八邻域中最左、左上、最上和上右点的情况，如果都没有点，则表示一个新的区域的开始，标记新的标签；

（2）如果当前点八邻域中最左和上右都有点，则标记此点为这两个中的最小的标记点，并修改大标记为小标记；

（3）如果当前点八邻域中左上和上右都有点，则标记此点为这两个中的最小的标记点，并修改大标记为小标记；

（4）否则按照最左、左上、最上、上右的顺序，标记此点为四个中的一个。

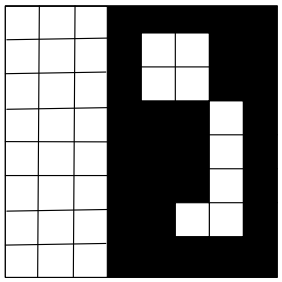

1	1	1	0	0	0	0	0
1	1	1	0	2	2	0	0
1	1	1	0	2	2	0	0
1	1	1	0	0	0	2	0
1	1	1	0	0	0	2	0
1	1	1	0	0	0	2	0
1	1	1	0	0	2	2	0
1	1	1	0	0	0	0	0

a) b)

图 2-10 八连通判别算法示意图

2.4.3 基于距离变换的掌心定位

本文对图 2-9 采取距离变换操作，得到距离变换映射图如图 2-11 所示，图中离边界越远的点越亮。无论手部分割后的二值图像是否存在手臂区域，其对应的距离变换映射图中最大距离值一般位于手掌中心，即图 2-11 中红点的位置 P_c，另该点所对应的取值为以 P_c 为圆心的内切圆半径 R_0。本文利用掌心所处位置的特点，通过采用距离变换操作能准确快速地跟踪定位掌心。

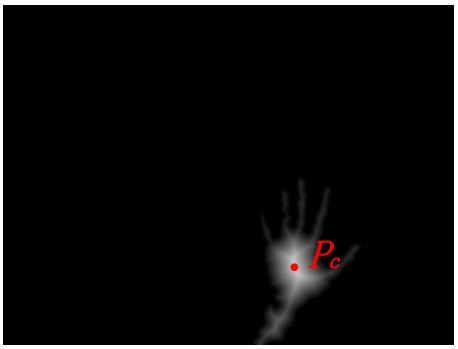

图 2-11 距离变换映射图

中国知网 https://www.cnki.net

2.4.4 基于一次距离变换的手臂去除

本文在图 2-11 距离变换映射图上作手掌切割圆，为了使得手掌被完全去除，即手掌被完整包含在手掌切割圆内，本文以 P_c 为圆心、$R_1 = factor1 \times R_0$为半径作圆，并另圆内像素点取值为 0，其中$factor1$取值为 1.35。

对图 2-11 进行上述操作后得到图 2-12，检测剩余区域中最大像素值 $P_{\max}$ 对应的像素点 P。当手臂区域存在时，P 通常位于手臂区域的中线位置，并且 $P_{\max}$ 较大；当不存在手臂区域时，P 通常位于手指区域的中线位置，并且 $P_{\max}$ 相对较小。

图 2-12 像素点 P 的定位

该手臂去除算法利用 $P_{\max}$ 取值特点来判断手臂区域的有无，计算$Ratio = P_{\max}/R_0$，若$Ratio$大于 0.35，则判定图 2-12 存在手臂区域，后面的步骤用于去除手臂区域；否则，图 2-12 不存在手臂区域，手部分割后的图像可以直接用于后续特征提取操作。

去除手臂区域：使用八连通判别算法标记剩余区域，如果连通区域的标记数值与像素点 P 的标记数值相同，移除该区域获得仅包含手指区域的二值图像。

如图 2-13 所示，进行一系列异或操作后，获得手势二值图像。

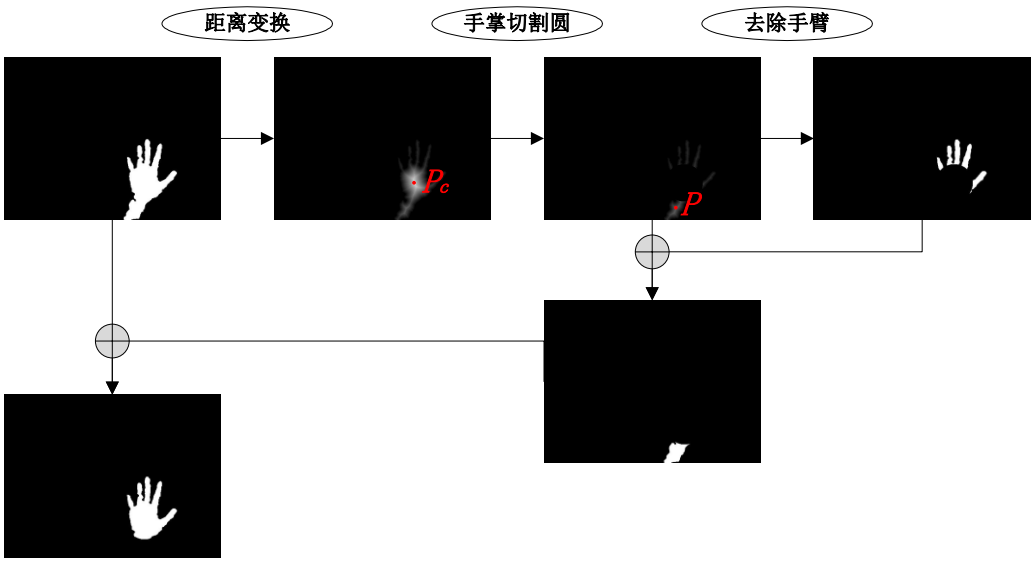

图 2-13 基于一次距离变换的手臂去除算法(包含手臂的手部二值图像，⊕代表异或操作)

中国知网 https://www.cnki.net

2.4.5 基于两次距离变换的手臂去除

基于一次距离变换的手臂去除算法虽然能够准确快速地去除手臂区域，但仍然存在一些问题导致图像的错误分割。图 2-14 列举两种情形下的手臂去除结果，手掌切割圆后的距离变换映射图中，剩余的手掌区域像素值 $P_{\max}$ 较大而被定位为 P 点，计算得到的 $Ratio$ 较大，最终导致手指区域的错误切除。具体地，子图（a）为存在手臂区域时的手部二值图像。子图（b）中像素值代表像素点到（a）中手部边界的最小距离，P 位于手指附近的手掌中，且 $P_{\max}$ 较大。子图（c）中去除的是（b）中 P 所在区域。子图（d）为不存在手臂区域时的手部二值图像。子图（e）中像素值代表像素点到（d）中手部边界的最小距离，P 位于手指附近的手掌中，且 $P_{\max}$ 较大。子图（f）中去除的是（e）中 P 所在区域。

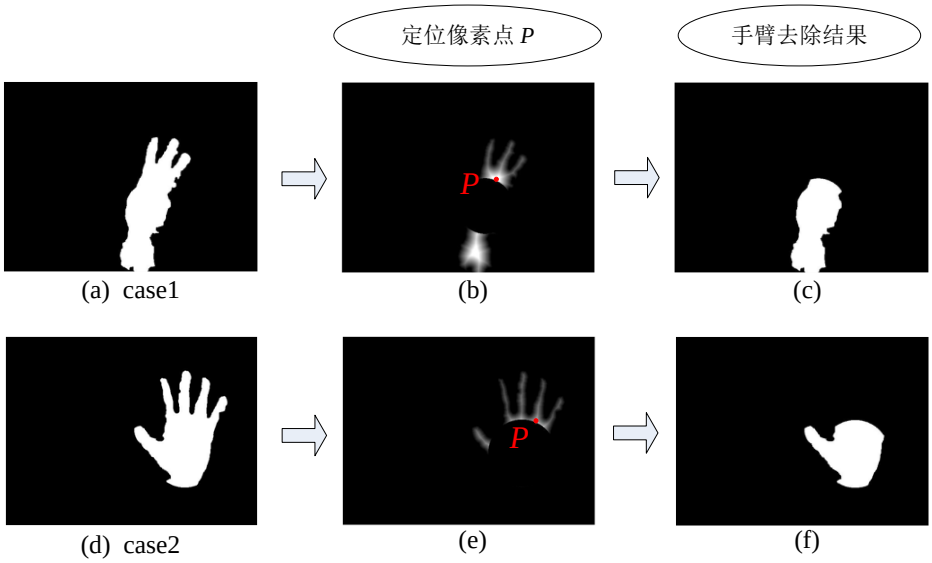

图 2-14 手臂去除算法 1 存在的问题

基于两次距离变换的手臂去除算法是对基于一次距离变换的手臂去除算法的改进，通过使用两次距离变换操作成功解决了上述问题。在手部分割得到的二值图像上，采用第一次距离变换操作成功定位掌心，然后在手部二值图像上以 P_c 为圆心、$R_2 = factor2 \times R_0$ 为半径作圆，并另圆内像素点取值为 0，其中 $factor2$ 取值为 1.35，得到图 2-15 所示的手掌切割圆后的手部二值图像。

图 2-15 手掌切割圆后的手部二值图像

中国知网 https://www.cnki.net

考虑不同情况下剩余前景区域的组成，上述获得的二值图像可分为以下四种情况：

（1）存在手臂区域时的手臂和手指区域

（2）存在手臂区域时的手臂、手指及部分手掌区域

（3）不存在手臂区域时的手指区域

（4）不存在手臂区域时的手指及部分手掌区域

对上述获得的二值图像采取第二次距离变换操作，获得的距离变换映射图表示了剩余的前景区域像素点到区域边界的最小距离，此时检测最大像素值 P_{max} 对应的像素点 P。图 2-16 (a)、(b)、(c)、(d)分别对应以上四种情况的处理过程，距离变换映射图中的红点即为所求 P 点的位置。

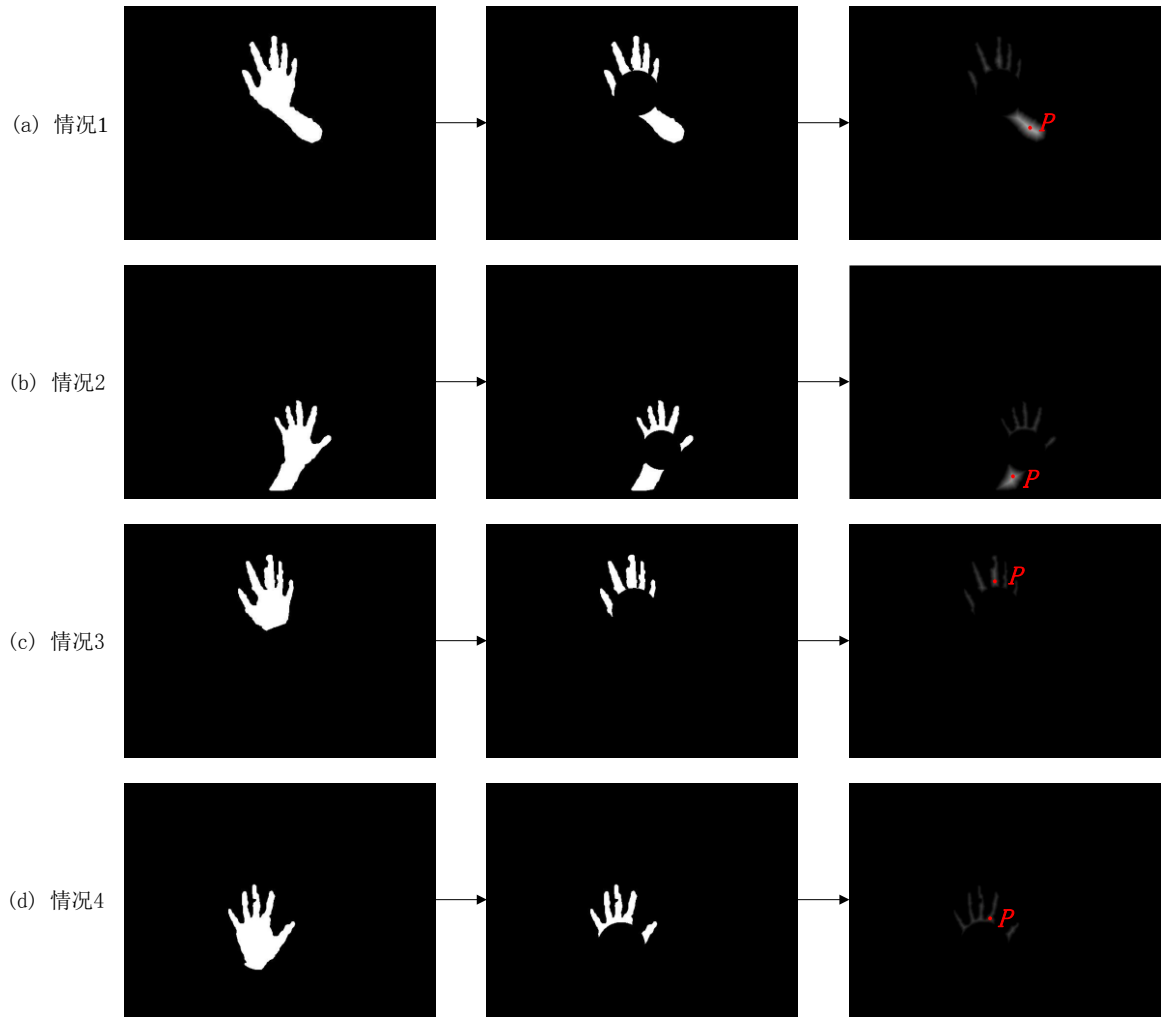

图 2-16 不同情况下 P 点的定位

对于情况 1 和情况 2，P_{max} 为手臂中点到手臂边缘的最小距离，取值较大；对于情况 3，P 应位于手指区域，且一般位于手指中线处，P_{max} 为手指中点到手指边缘的最小距离，取值较小；对于情况 4，P 位于手指或部分手掌区域，P_{max} 取值较小。

中国知网 https://www.cnki.net

对于情况 1 和情况 2，$P_{\max}$ 取值较大且需要去除手臂区域；对于情况 3 和情况 4，$P_{\max}$ 取值较小且不存在手臂区域。我们计算$Ratio = P_{\max}/R_0$，若$Ratio$大于 0.35，则判定存在手臂手臂区域，对应的手部二值图像需要采取后续操作去除手臂区域，否则判定为不存在手臂的情况且对应的手部二值图像可以直接用于手势特征提取。

在情况 2 和情况 4 下，若采用基于一次距离变换的手臂去除算法对 P 点定位，当 P 点位于手指附近的部分手掌区域时，$P_{\max}$ 取值可能仍较大，计算的$Ratio$取值较大，最终可能会错误地去除手指区域。

去除手臂区域的流程如图 2-17 所示，借助八连通判别算法去除 P 点所在的手臂区域，并采取一系列异或操作后获得手势二值图像。

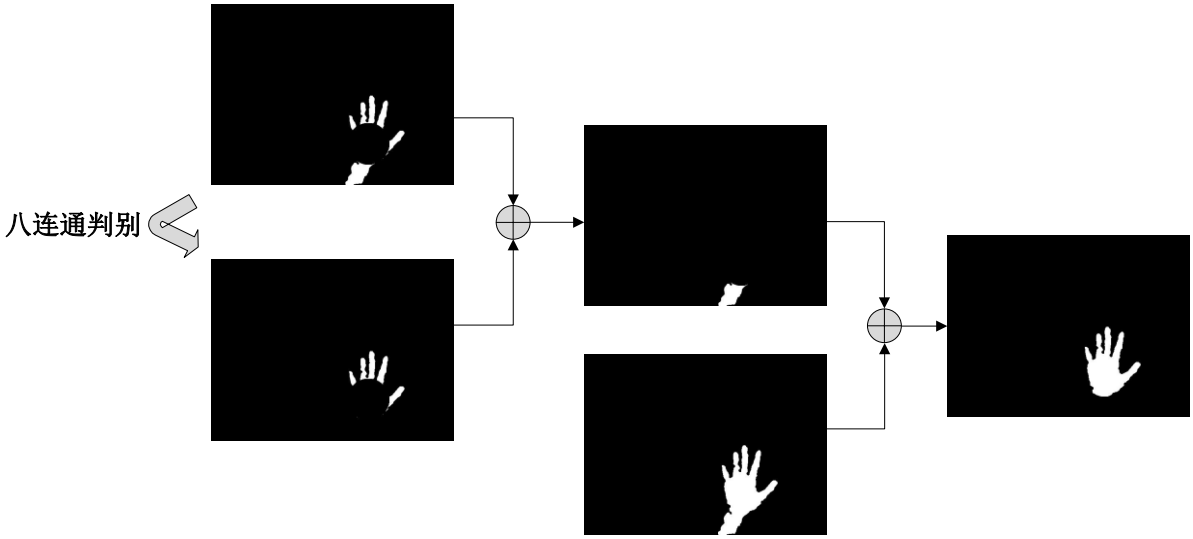

图 2-17 去除手臂区域的流程图(包含手臂区域的手部二值图像，⊕代表异或操作)

采用基于两次距离变换的手臂去除算法对图 2-14 列举的两种情形进行处理，结果如图 2-18 所示。在情形 1 下，P 位于手臂区域，$P_{\max}$ 较大且计算的比率$Ratio$较大，能够准确去除手臂区域。在情形 2 下，P 位于手指区域，$P_{\max}$ 不大且计算的比率$Ratio$较小，避免了在基于一次距离变换的手臂去除算法中出现的错误分割。

具体地，子图（a）为存在手臂区域时的手部二值图像。子图（b）中像素值代表剩余的前景区域像素点到区域边界的最小距离，一些像素点的取值比在手臂去除算法 1 中小，图像看起来更暗，P 位于手臂中线处，且 $P_{\max}$ 较大。子图（c）中去除的是（b）中 P 所在区域。子图（d）为不存在手臂区域时的手部二值图像。子图（e）中像素值代表剩余的前景区域像素点到区域边界的最小距离，一些像素点的取值比在手臂去除算法 1 中小，图像看起来更暗，P 位于手指区域，且 $P_{\max}$ 较小。子图（f）中$Ratio$较小，判定为不存在手臂区域，无需进行手臂去除操作。

中国知网 https://www.cnki.net

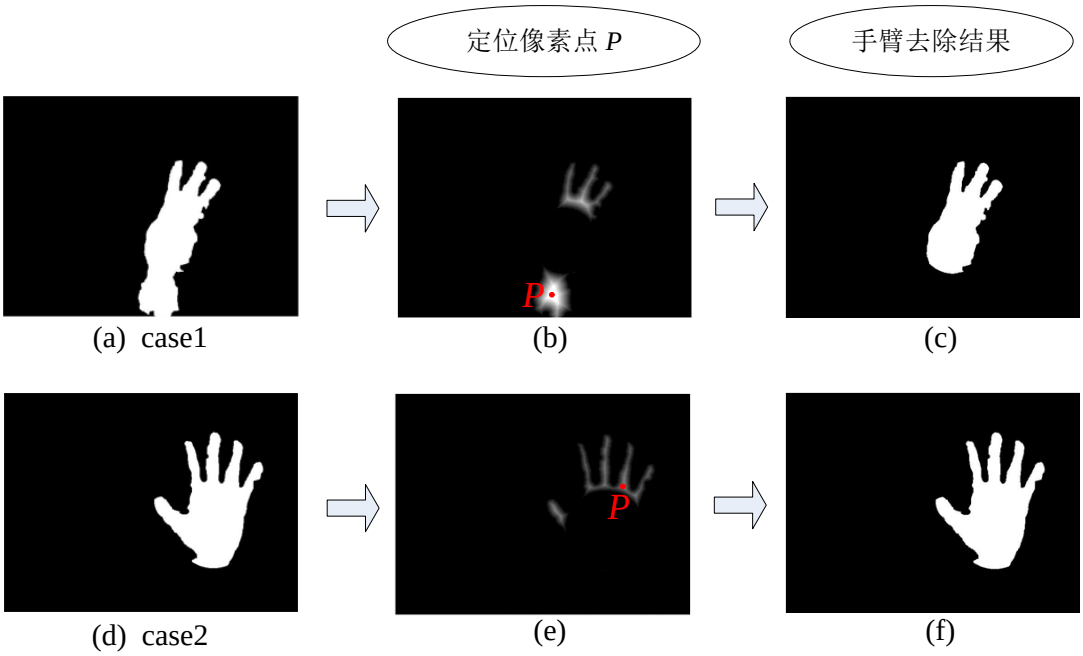

图 2-18 手臂去除算法 2 成功解决手臂去除算法 1 存在的问题

2.5 实验结果与分析

本文进行静态手势分割实验的实验环境如下：

处理器：Intel(R)Core(TM) i5-4440 CPU @ 3.10GHz

内存：8.00 GB

操作系统：Windows 7

实验工具：MATLAB2013b

2.5.1 手部分割实验

图 2-19 展示了本文手部分割算法对 8 种手势样本的处理过程。首先，深度阈值被用于提取 RGB 图像中的相应像素点，从而获得包含手部的 RGB 图像。由于图像中包含了满足深度阈值的袖子区域，因此肤色特征被用于进一步提取手部。实验结果表明，即使在复杂背景下，本文提出的手部分割算法也可以准确地检测出手部，这为手势识别奠定了基础。

为了验证本文手部分割算法在处理复杂环境中的优势，我们仅使用肤色信息处理相同的 8 张手势样本，结果如图 2-20 所示。通过肤色分割获得的二值图像包含了肤色区域和背景中的类肤色区域，需要借助其他特征才能进一步提取手部区域。该方法不够鲁棒，容易受到背景的影响，并且无法解决手部与肤色区域（如人脸、颈部等）或类肤色区域重叠的问题。

中国知网 https://www.cnki.net

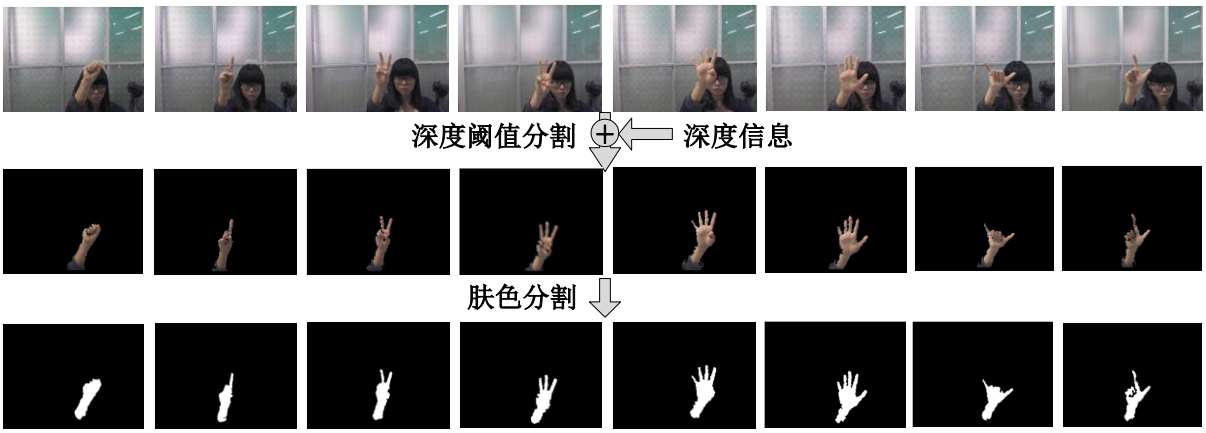

图 2-19 本文手部分割算法的处理过程

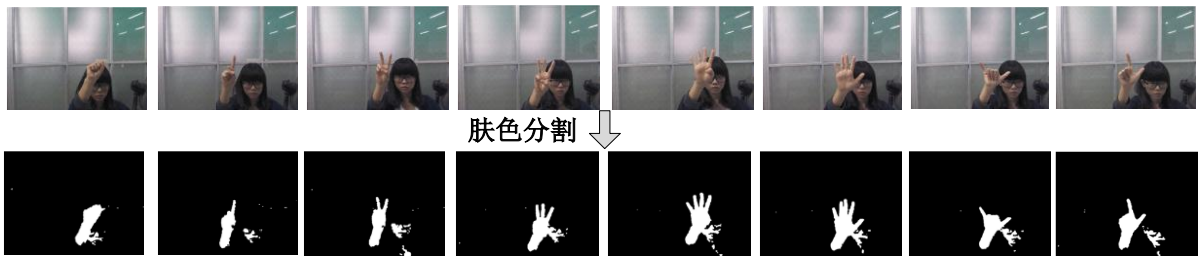

图 2-20 仅利用肤色信息进行手部分割

2.5.2 手臂去除实验

基于一次距离变换的手臂去除算法可能出现图像错误分割，基于两次距离变换的手臂去除算法通过使用两次距离变换操作成功解决了该问题，因此本文后续提及的手臂去除算法均指的是基于两次距离变换的手臂去除算法。如图 2-21 所示，采用本文提出的手臂去除算法处理手部分割后的二值图像，能够准确去除冗余的手臂区域，得到由手指和手掌组成的手势二值图像。采用本文的手部分割算法和手臂去除算法处理测试集，手势分割准确率高达 100%。

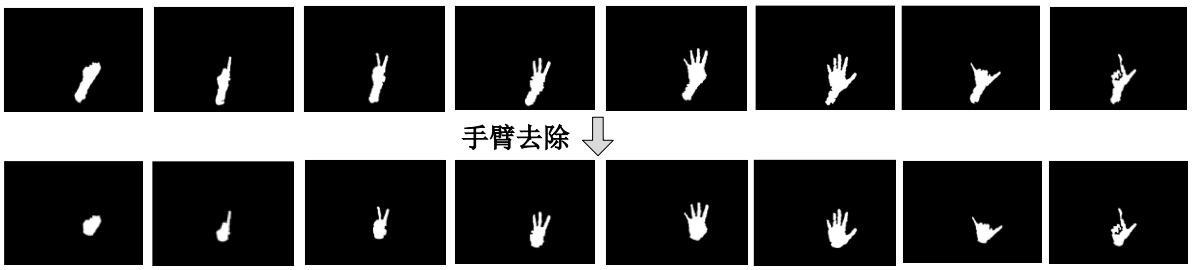

图 2-21 本文的手臂去除算法

使用文献[15]的手臂去除算法处理相同的 8 张手部二值图像，结果如图 2-22 所示。对于手势 0、手势 2、手势 3 和手势 7，处理后得到的手势二值图像中存在许多独立噪声，这将影响后续的特征提取和手势识别。对于手势 1、手势 4、手势 5 和手势 6，采用的结

中国知网 https://www.cnki.net

构元直径太大，导致无法成功移除手臂区域。

图 2-22 文献[15]的手臂去除算法

使用文献[16]的手臂去除算法处理相同的 8 张手部二值图像，结果如图 2-23 所示。[16]算法使用距离变换映射图和手掌切割圆确定手臂的中线，并遍历手部边缘以找到与手臂中线相垂直的手臂去除线（矢量点积运算为 0），然后去除手臂区域。与[15]算法相比，[16]算法可以准确地去除手臂干扰。

图 2-23 文献[16]的手臂去除算法

采用本文的手部分割算法处理采集的手势样本集，然后从得到的数据集中随机选择 400 张手部二值图像（每种手势 50 张图像）以构建数据集 2，采用不同的手臂去除算法来处理数据集 2，运算时间如表 2-1 所示。

表 2-1 不同手臂去除算法在数据集 2 上的运算时间

手势类别	测试数目	总用时（s）			平均每张用时（s）		
		[15]算法	[16]算法	本文算法	[15]算法	[16]算法	本文算法
0	50	12.302	43.158	5.628	0.246	0.863	0.113
1	50	12.907	77.183	5.642	0.258	1.544	0.113
2	50	12.240	38.514	5.688	0.245	0.770	0.114
3	50	12.519	66.872	5.704	0.250	1.337	0.114
4	50	12.721	84.750	5.656	0.254	1.695	0.113
5	50	12.492	46.985	5.732	0.250	0.940	0.115
6	50	12.364	64.398	5.691	0.247	1.288	0.114
7	50	12.336	57.266	5.654	0.247	1.145	0.113
总共	400	99.881	479.126	45.395	0.250	1.198	0.113

文献[16]的手臂去除算法的运算时间与输入的手部二值图像前景区域的像素点个数密切相关，前景区域的像素点越多，算法花费的时间越长。因此，手部二值图像中是否存在手臂区域以及手部距离 Kinect 的远近，[16]算法的运算时间将会有很大不同。从图 2-24 可以看出，文献[16]的手臂去除算法处理数据集 2 的 8 种手势时，该算法对各种手

中国知网 https://www.cnki.net

势的平均处理时间会因手势的不同而有很大的波动，对每张图像的平均处理时间为1.198s（表 2-1 中所示），该算法不适合对稳定性要求较高的实时系统。

使用本文提出的手臂去除算法和文献[15]的手臂去除算法处理数据集 2 的 8 种手势，平均处理时间对应着图 2-24 的两条平缓曲线。本文提出的手臂去除算法处理每张手部二值图像需要花费大约 0.113s，这个时间还少于文献[15]的手臂去除算法平均处理时间的一半（如表 2-1 所示）。本文提出的手臂去除算法可以快速且有效地去除手臂区域，满足实时手势识别系统的要求。

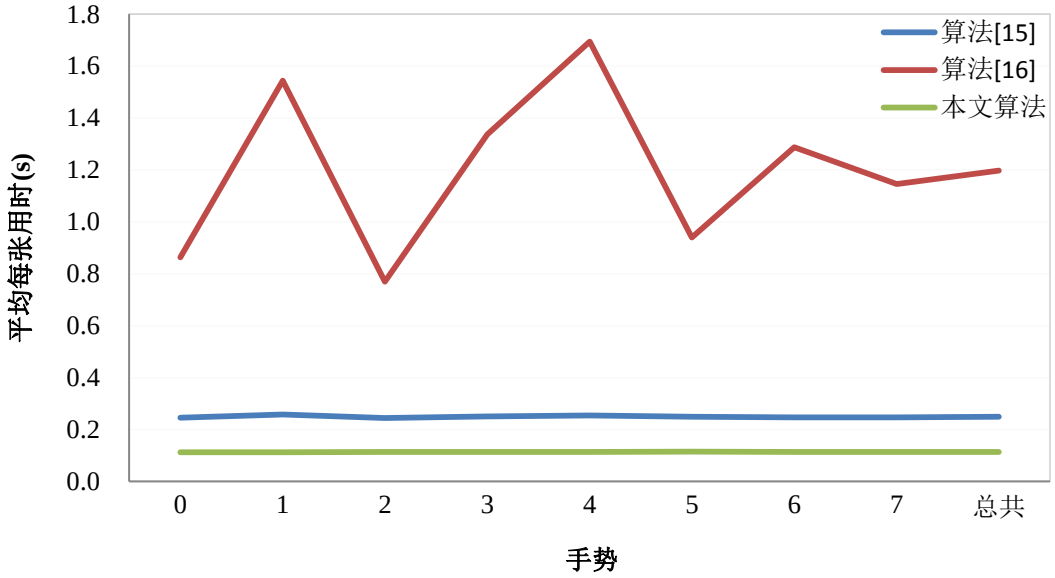

图 2-24 不同手臂去除算法的平均处理时间

2.6 本章小结

本章利用 Kinect 采集 RGB 图像及其对应的深度图像，通过图像平滑、光照补偿、转换色度空间等方法避免噪声及光照强度对建立的肤色模型的影响，采用肤色特征结合深度信息的手部分割算法，提高系统对外界光照强度、背景环境及肤色的鲁棒性，实现手部与复杂背景的准确分离；在手部分割的基础上，本章提出了基于距离变换的手臂去除算法，采用一次距离变换操作可以精确定位手掌中心，再次利用距离变换操作并结合手掌切割圆能有效去除手臂区域。与其它手臂去除算法相比，本章提出的手臂去除算法计算复杂度低，可以有效、快速地去除手臂而不受手势旋转的影响。

中国知网 https://www.cnki.net

第三章 静态手势识别方法

3.1 引言

第二章经过图像采集、图像平滑、光照补偿、深度阈值分割、肤色分割和手臂去除这六个步骤，已提取出手势二值图像。基于第二章的工作，本章研究不同的手势特征提取及手势分类方式，具体研究采用 SVM 和 CNN 两种算法进行静态手势识别。

3.1.1 支持向量机（SVM）

支持向量机（Support Vector Machine，SVM）是 1992 年到 1995 年间提出的一种以概率统计理论为基础的机器学习算法，是一种基于结构风险最小化的模式识别方法，在解决小样本和非线性的模式识别问题方面具有许多独特的优势，在模式识别领域有着广泛的应用。本文的静态手势识别问题属于小样本和非线性分类问题，因此我们在众多的机器学习算法中选择具有优异分类性能的 SVM 作为手势的分类器。此外，SVM 在分类类别数较少的问题中运算速度快，适合于本文对 8 种静态手势的识别。

3.1.1.1 SVM 基本原理

本小节以二分类问题为例，以便于讲解 SVM 的原理。

SVM 的最终目的是，在特征空间中寻找一个最优分类超平面，可以将两种类别的数据集合尽可能分开，即两类数据到该分类超平面的垂直距离都尽量大。分类超平面所在的特征空间很有可能是高维度空间，该高维空间由样本空间或特征空间经非线性变换得到。如图 3-1 所示，可以看出这两类数据是线性可分的，且存在许多可将这两类数据正确划分的分类面，我们希望在两类数据之间找到一个最优分类超平面 H，该超平面能够使得两类数据的分类间隔最大（即 H1 和 H2 之间的距离最大），从而获得最好的分类效果。平面 H1、H2 均与 H 平行，且与 H 的距离相同，分别经过两类数据中距离 H 最近的数据，这些数据被称为 SVM 的支持向量，支撑了最优分类面 H。

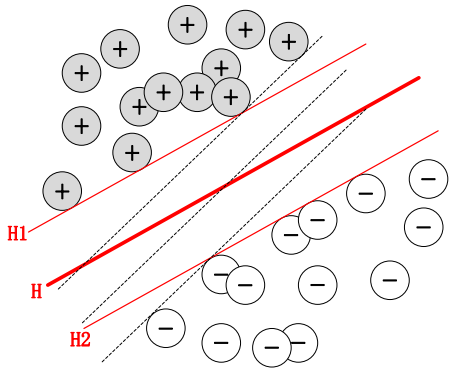

图 3-1 最优分类面的示意图

中国知网 https://www.cnki.net

设训练样本集$\{(x_i, y_i), i = 1,2,\ldots,num\}$，其中$x_i \in R^n$，$y_i \in \{-1,+1\}$，-1 表示负样本，+1 表示正样本。H 用函数表示为：$wx_i + b = 0$，H1 表示为：$wx_i + b = +1$，H2 表示为：$wx_i + b = -1$，此时 H1、H2 的间距可表示为：$margin = 2/\|w\|$，$\|w\|$越小则间距越大。

训练 SVM 的主要目的是，找到能使分类间隔取到最大值的分类超平面 H，此时还需满足条件如（3-1）：

$$\begin{aligned} wx_i + b \le -1, \forall y_i = -1 \\ wx_i + b \ge +1, \forall y_i = +1 \end{aligned} \tag{3-1}$$

该约束条件可以进一步改写为式（3-2）：

$$y_i(wx_i + b) - 1 \ge 0 \tag{3-2}$$

综上，获得 SVM 的最终优化目标函数如（3-3）：

$$\begin{aligned} &\min_{w,b} \frac{1}{2}\|w\|^2 \\ &s.t. \quad y_i(wx_i + b) \ge 1, i = 1,2,\ldots,num \end{aligned} \tag{3-3}$$

以上求解得到的 SVM 称为硬间隔 SVM，只能用于线性可分问题。通过引入松弛变量$\xi_i \ge 0$，可以求解得到软间隔 SVM，用于处理线性不可分和数据出错问题。原有方程转化为式（3-4）：

$$\begin{aligned} &\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{num} \xi_i \\ &s.t. \quad \begin{aligned} &y_i(wx_i + b) \ge 1 - \xi_i, \\ &\xi_i \ge 0, i = 1,2,\ldots,num \end{aligned} \end{aligned} \tag{3-4}$$

其中，ξ_i为松弛变量，C 为平衡结构风险最小化和经验风险最小化的平衡因子，该问题的对偶问题为式（3-5）：

$$\begin{aligned} &\min_{\alpha} \frac{1}{2}\sum_{i=1}^{num}\sum_{j=1}^{num} y_i y_j (x_i \cdot x_j)\alpha_i \alpha_j - \sum_{j=1}^{num} \alpha_j \\ &s.t. \quad \begin{aligned} &\sum_{i=1}^{num} y_i \alpha_i = 0, \\ &0 \le \alpha_i \le C, i = 1,2,\ldots,num \end{aligned} \end{aligned} \tag{3-5}$$

其中，α_i为拉格朗日乘子。

最终，可得线性问题的决策函数如（3-6）：

$$f(x) = sign(\sum_{i=1}^{num} \alpha_i y_i \cdot (x_i \cdot x) + b) \tag{3-6}$$

中国知网 https://www.cnki.net

为了解决非线性问题，利用映射函数$x \to K(x) \in H$将数据由低维度映射到某个高维度的 H 空间，以使得数据达到线性可分的目的，通过非线性映射可以将原样本空间中的非线性问题转化为特征空间中的线性可分问题。这一过程是通过核函数 $K(u,v)$完成的，经过核函数映射后的决策函数表示为式（3-7）：

$$f(x) = sign(\sum_{i=1}^{num} \alpha_i y_i \cdot K(x_i, x) + b) \tag{3-7}$$

上述 SVM 算法解决了二分类问题，找到了界定两种数据的最优分类超平面。本文利用 SVM 识别 8 种静态手势的含义属于多分类问题，需要在二分类 SVM 算法的基础上构造多分类的 SVM 算法。本文使用了 libsvm 软件的 1 v 1 分类算法来实现多分类，具体地，为任意两种类别的样本训练一个 SVM 二分类器，对于本文 8 种静态手势的识别任务需训练的 SVM 二分类器个数为$8(8-1)/2 = 28$，在执行分类任务时则通过投票的方式将票数最多的类别作为最终的分类结果。

3.1.1.2 SVM 核函数

SVM 利用核函数 $K(u,v)$就可以处理非线性问题，不同的核函数在构造非线性决策面时使用的方法不相同，最终 SVM 的分类效果也会有所不同。核函数的选择影响着 SVM 算法的性能，目前比较常用的核函数包括样条、RBF、多项式、sigmoid 核函数：

（1）样条核函数，见式（3-8）：

$$K(x_i, x_j) = B_{2n+1}(x_i - x_j) \tag{3-8}$$

（2）RBF 核函数，见式（3-9）：

$$K(x_i, x_j) = \exp(-\gamma \left\| x_i - x_j \right\|^2) \tag{3-9}$$

其中，$\gamma = 1/\sigma^2$为参数。

（3）多项式核函数，见式（3-10）：

$$K(x_i, x_j) = (\gamma x_i \bullet x_j + r)^d \tag{3-10}$$

其中，γ、r、d 为参数。

（4）sigmoid 核函数，见式（3-11）：

$$K(x_i, x_j) = \tanh(\gamma x_i \bullet x_j + r) \tag{3-11}$$

其中，γ和 r 为参数。

RBF 核函数具有适用面广、稳定性好、收敛域宽的优点，不管输入空间是高维或者低维，不管数据集是大规模或是小规模，RBF 都是比较理想的核函数，本文选择 RBF

中国知网 https://www.cnki.net

核函数使静态手势分类识别问题转向高维特征空间求解。

3.1.1.3 参数优化算法

RBF 核函数的参数 γ 和惩罚因子 C 是影响本文 SVM 分类器性能的两个重要参数，本文利用网格搜索算法来自动调整惩罚因子和核函数参数的取值，寻找 SVM 分类器性能最好时的最优参数组合 C 和 γ 。网格搜索算法是一种最基本的参数优化算法，目前已应用于很多领域，其基本原理为：根据经验设定好参数的待搜索范围及步长，在设定的范围内按照搜索步长将待搜索参数划分为网格，遍历网格中的所有点来寻找使模型性能最优的参数组合。本文采用 SVMcgForClass 函数进行参数网格搜索，可以得到 SVM 算法在各种参数组合下的识别率，并输出识别结果的等高线图。

3.1.2 卷积神经网络（CNN）

人手具有 27 个自由度[45]，是人体最灵活的部位之一，人们可以很容易地做出形态各异的手势，这导致手势识别具有复杂性和多样性。此外，由于每个人的手型不太一致，行为习惯也不一样，导致不同人做同一手势的表观不尽相同，甚至同一个人在不同时间所做的同一手势也会有所不同，这给手势识别增加了不少难度。在传统的手势识别算法中，需要人工设计手势特征来描述手势形状，选择用于描述手势的特征在一定程度上影响着手势识别的效果，然而上述情况使得我们很难找到真正适用于描述手势形状的特征。

卷积神经网络（CNN）是深度学习的代表算法之一，主要包括卷积层、池化层和全连接层等等，层与层之间根据一定的规则来计算。CNN 具有三个关键特性：权值共享、局部感知和下采样，权值共享能够大幅度减少网络参数，提高训练速度；局部感知能够检测到图像局部的细节特征，比如物体边缘、角点等特征；下采样能降低特征的分辨率，提高 CNN 模型的鲁棒性。CNN 通过使用卷积操作来实现图像区域特征的提取，与传统图像特征提取的区别在于，使用多层网络的卷积自动提取输入图像的高维特征，而不需要人工设计特征。通过不断地迭代训练 CNN，我们可以获取较好的表征图像的特征。

为了提高 CNN 进行静态手势识别的效率，本章在排除复杂背景干扰的情况下将手势分割后的二值图像作为 CNN 分类器的输入样本，实现图像中静态手势特征的自动提取及静态手势的分类识别。由于分割后的手势图像前景突出，减少了神经网络识别的计算量，可以直接作为 CNN 分类器的输入样本进行分类识别。

中国知网 https://www.cnki.net

3.1.2.1 人工神经网络

采用传统的机器学习算法构建机器学习模型完成分类或者回归任务时，往往需要人工设计特征提取器，从原始数据（如图像的像素值）中提取合适的特征向量，这使得我们在处理原始数据时受到限制。表示学习是指可以从原始数据中自动提取所需特征的一类方法的集合。深度学习是多个具有不同表示级别的表示学习方法，非线性变换操作将一个级别的特征表示转换到一个更加抽象的特征表示，深度学习通过使用一系列简单的非线性变换操作从原始数据中提取低层特征和局部模式进行组合，得到高维语义特征，这些高维特征相比低层模式无疑更加抽象，信息量更丰富。深度学习的关键在于这些特征表示不是人工设计得到的，而是由原始训练数据中学习得到的，采用足够多的非线性变换的组合，深度学习就可以实现非常复杂的功能。

深度学习作为机器学习的一个新领域，其源头是人工神经网络。人工神经网络是由简单神经单元加权连接而成的一种高性能的结构，神经网络中的各个节点都是在模仿人类大脑中的神经元。通过构造多层神经网络、模拟人脑进行分析学习来解释数据（如图像，声音和文本），人工神经网络可被应用于视觉场景分析、语音识别、机器人控制等多个领域。

用于人工神经网络的反向传播算法（也称 BP 算法）发明于 20 世纪 80 年代末期，该算法通过输入大量的训练样本，使人工神经网络学习到隐含的统计规律，实现对于与训练样本分布相似的未知事件，能够做到拟合真实情况的预测。与更早的基于人工规则设计的方法相比，基于统计学习客观规律的机器学习方法在许多方面都有所超越，掀起了基于统计模型的机器学习热潮。

神经网络结构

一个经典的人工神经网络如图 3-2 所示，包含 3 个部分：输入层、隐藏层与输出层，第一层为输入层，最后一层为输出层，输入层与输出层中间的均为隐藏层，每层均包含许多神经元，其中输入层有 3 个输入单元，隐藏层有 4 个单元，输出层有 2 个单元。每个人工神经网络都仅有一个输入层和一个输出层，输入层中神经元的数量即为输入数据中输入变量的数量，输出层中神经元的数量即为每个输入相关联的输出变量的数量，而隐藏层的层数、每层中神经元的数量则是由待解决问题的复杂度决定的。类似地，根据需要我们可以拓展为含有多个隐藏层的深度神经网络。

中国知网 https://www.cnki.net

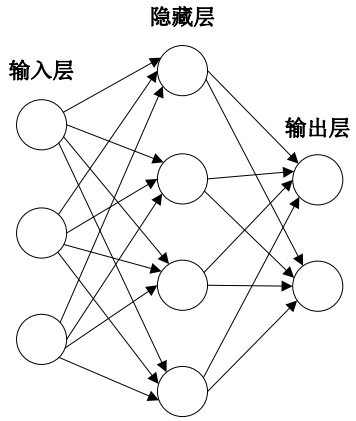

图 3-2 神经网络结构图

隐藏层中的每个神经元仅仅与其前后两层中的神经元相连，同一层中的神经元是独立的，没有连接关系。输入层中的神经元在接收输入数据之后被激活，输出层及隐藏层中的神经元则是由上一层与之相连的权重连接激活，单个神经元的结构如图 3-3 所示，上一层神经元的输出作为该层神经元的输入，再通过激活函数可以得到最终的分类，一个神经元可以有多个输入单个输出。

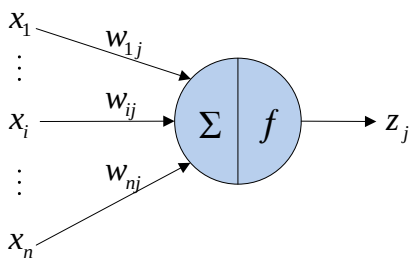

图 3-3 神经元结构示意图

如图 3-3，x_1、x_2、…、x_n代表神经元的 n 个输入，w_{1j}、w_{2j}、…、w_{nj}代表该神经元与上一层神经元之间的连接权重，b_j 为该神经元的偏置项，可表达为式（3-12）、（3-13）：

$$y_j = \sum_{i=1}^{n} w_{ij} x_i + b_j \tag{3-12}$$

$$z_j = f(y_j) \tag{3-13}$$

其中，z_j表示该神经元的最终输出，$f(\cdot)$表示激活函数，激活函数可以对输入起到非线性化的作用，能够增加神经网络的非线性表达能力，通常采用 sigmoid 函数，tanh 函数以及 ReLU 函数等，其中 sigmoid 函数表达式为式（3-14）：

$$\sigma(x) = \frac{1}{1+e^{-x}} \tag{3-14}$$

tanh 函数表达式为式（3-15）：

中国知网 https://www.cnki.net

$$\tanh(x)=\frac{(e^{x}-e^{-x})}{(e^{x}+e^{-x})} \tag{3-15}$$

ReLU 函数的数学表达式如式（3-16）：

$$f(x)=\max(x,0) \tag{3-16}$$

如果计算的值 x 大于 0，则保持原来的值不变，否则另计算结果为 0。ReLU 函数可直观表示为图 3-4：

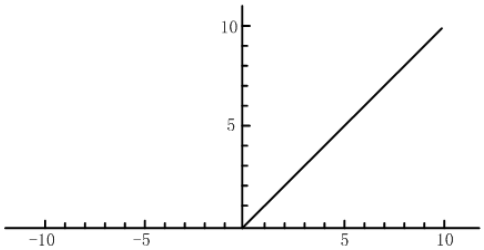

图 3-4 ReLU 函数示意图

从神经网络的结构可以看出，其就是在模拟人类大脑神经元，对输入信息进行处理、加工和提取的过程。

反向传播算法

神经网络实质上是通过大量样本训练得到输入输出之间映射关系，是一种有监督训练。反向传播算法是一种优化神经网络中参数的方法，该算法可以对网络中每一层的梯度进行迭代的计算，从而提高网络训练的效率。使用反向传播算法训练神经网络是一个调参的过程，包括两个阶段：前向传播阶段和反向传播阶段，算法运行步骤如图 3-5 所示。

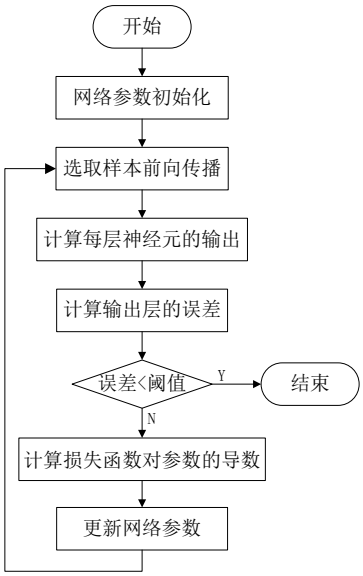

图 3-5 反向传播算法示意图

中国知网 https://www.cnki.net

开始训练时，用不同的小随机数对网络参数进行初始化；前向传播阶段：从输入到输出，可以计算输入数据经网络中每一层处理后到达输出层的运算结果，求出输出层的误差；反向传播阶段：从输出到输入，利用误差反向传播对网络中每一层参数进行优化更新。对神经网络进行迭代训练，直至计算的输出层误差小于某一设定阈值为止。

如图 3-6 所示，我们以一个三层人工神经网络（包括一个输入层、一个隐藏层和一个输出层）为例子，网络使用 Softmax 输出层和交叉熵损失函数，使用梯度下降法优化神经网络参数，我们的重点在于如何计算损失函数对网络参数的导数，在图中可以表示为 *dloss*/*dW*1，*dloss*/*dW*2，*dloss*/*db*1 和 *dloss*/*db*2。

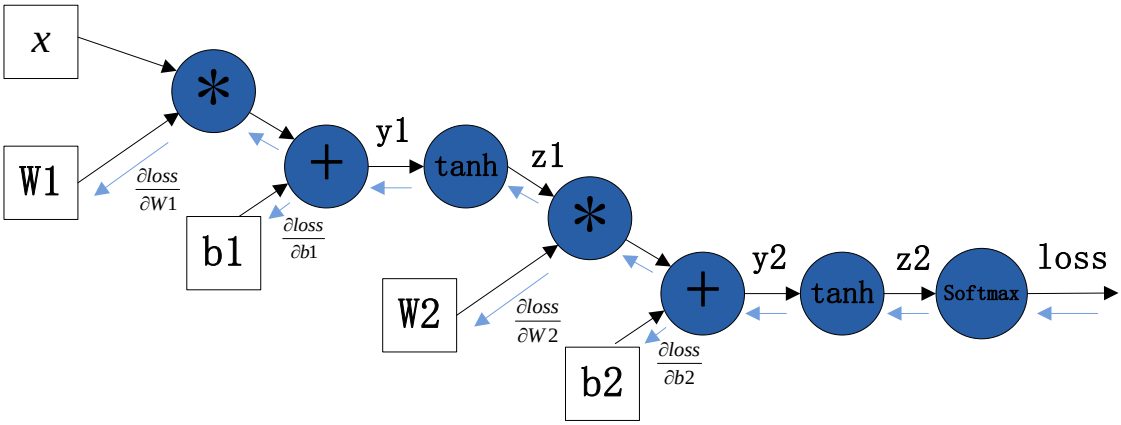

图 3-6 反向传播算法举例

1）前向传播与损失函数

在每一轮迭代中，首先进行前向传播，从训练样本集中抽取输入样本 x 及其对应的标签 y，输入到神经网络中，由公式（3-17）、（3-18）、（3-19）、（3-20）计算神经网络中每个节点的状态：

$$y1 = x * W1 + b1 \tag{3-17}$$

$$z1 = \tanh(y1) \tag{3-18}$$

$$y2 = z1 * W2 + b2 \tag{3-19}$$

$$z2 = \tanh(y2) \tag{3-20}$$

我们需要计算损失函数，用于衡量真实值与网络估计值的误差，损失函数可用于评估网络的性能，损失函数越小说明网络性能越好。在神经网络的反向传播中，根据损失函数调整网络中的参数，调整过参数的网络再通过前向传播得到损失函数，迭代训练网络直至损失函数足够小，整个网络模型趋于稳定。

损失函数有多种形式，这里采用的是交叉熵损失函数，通过前向传播计算得到，见

中国知网 https://www.cnki.net

式（3-21）：

$$loss = soft\max_loss(z2) \tag{3-21}$$

2）反向传播与参数更新

开始训练时，我们随机初始化网络参数，因此在训练初期网络表现较差，需要通过误差反向传播不断调整网络参数进行网络优化。一般通过梯度下降法对网络参数进行调整更新，更新公式如（3-22）、（3-23）：

$$W_{new}^{l} = W_{old}^{l} - \eta \frac{\partial loss}{\partial W_{old}^{l}} \tag{3-22}$$

$$b_{new}^{l} = b_{old}^{l} - \eta \frac{\partial loss}{\partial b_{old}^{l}} \tag{3-23}$$

其中，$loss$ 为损失函数，W 为权值，b 为偏置项，η 表示梯度下降的学习率，它的大小直接影响着梯度下降的速度，我们需要计算每个节点相对于损失函数 $loss$ 的导数，这里需要用到求导的链式法则。

3.1.2.2 CNN 基本理论

深度学习的出现极大地促进了一些领域的发展，例如目标检测、无人驾驶等等，特别是 CNN 的极速发展促进了计算机视觉进入了历史性的狂潮。区别于传统的人工神经网络，CNN 是一种基于卷积计算的深度神经网络，拥有较多的网络层数，是深度学习的代表算法之一，擅长处理图像相关的模式识别问题。CNN 能够通过多层计算来处理庞大的图像数据，不断降维并提取有效的图像特征，并通过反向传播算法来求得模型的内部参数。

CNN 包含不同种类的层结构。如图 3-7 所示，Yann LeCun[46]于 1998 年提出的 LeNet5 网络是最早的 CNN 结构之一，成功地运用于手写数字的识别问题。LeNet5 网络也是经典的 CNN 结构，虽然近些年来对 CNN 的研究越来越多，增加了许多新的功能层，但 CNN 最基础的层结构依然是卷积层、池化层以及全连接层（如 LeNet5 网络所示）。接下来我们主要是对 CNN 的基础进行介绍，包括卷积层、池化层、全连接层、输出层和损失函数。

中国知网 https://www.cnki.net

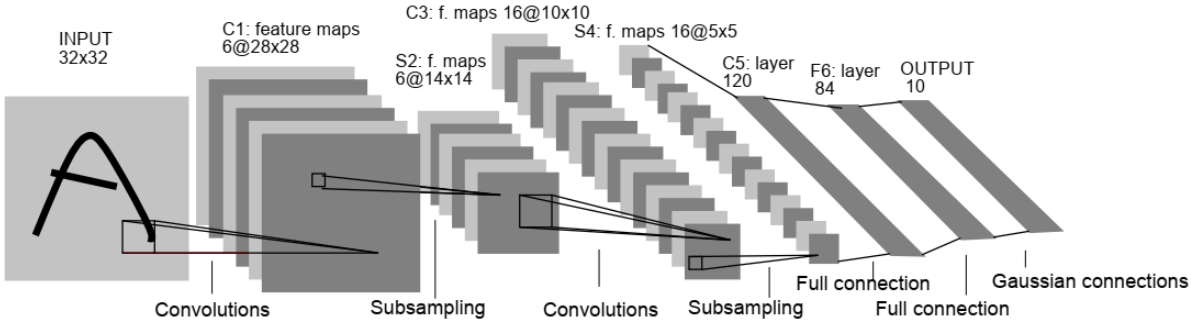

图 3-7 LeNet5 网络结构

卷积层

作为 CNN 核心的层结构，卷积层通过对输入图像进行卷积操作，提取图像的各种局部特征，提取的特征图的好坏直接影响后续层的处理。卷积层通过卷积核与对应像素组成的矩阵进行局部连接，采用卷积操作提取出图像的局部特征，并通过权值共享的方式得到一幅特征图。具体地，卷积层上的每个神经元利用一定大小的滤波器（卷积核）与前一层特征图的局部区域相连接，提取局部区域（局部感受野）的特征，然后利用卷积核在前一层特征图上滑动，遍历所有区域并提取每个局部区域的特征，获得的所有特征值构成一张特征图，即完成了一次特征学习。权值共享是指卷积层中的每个神经元使用同一个卷积核去卷积前一层特征图，即使用同一组权值参数与前一层进行局部连接，这种方式可以减少网络训练的权值参数，提升网络训练的效率。卷积层的意义就是局部感知和权值共享。使用不同的卷积核分别遍历卷积前一层输出的特征图，最终重构成不同的特征图输出。

如图 3-8 所示，卷积层的计算公式可表示为式（3-24）：

$$x_j^l = f(\sum_{i=1}^{N} x_i^{l-1} \otimes w_{ij} + b_j^l), j = 1,2,...,M \tag{3-24}$$

其中 N 是第 l-1 层的特征图个数，第 l 层的特征图个数为 M，第 l 层的第 j 个特征图写作 x_j^l，第 l-1 层的第 i 个特征图写作 x_i^{l-1}，w_{ij}代表 i 和 j 之间的卷积核，即权值，$\otimes$代表卷积操作，b_j^l 代表偏置，$f(\cdot)$ 表示神经元的激活函数，图 3-8 所示的 x_i^{l-1}是 10×10 大小的特征图，w_{ij}为 5×5 大小的卷积核，w_{ij}以步长为 1 在 x_i^{l-1}上滑动，再经过以上计算可得到 x_j^l 整个特征图。具体的卷积操作过程如图 3-9 所示。

中国知网 https://www.cnki.net

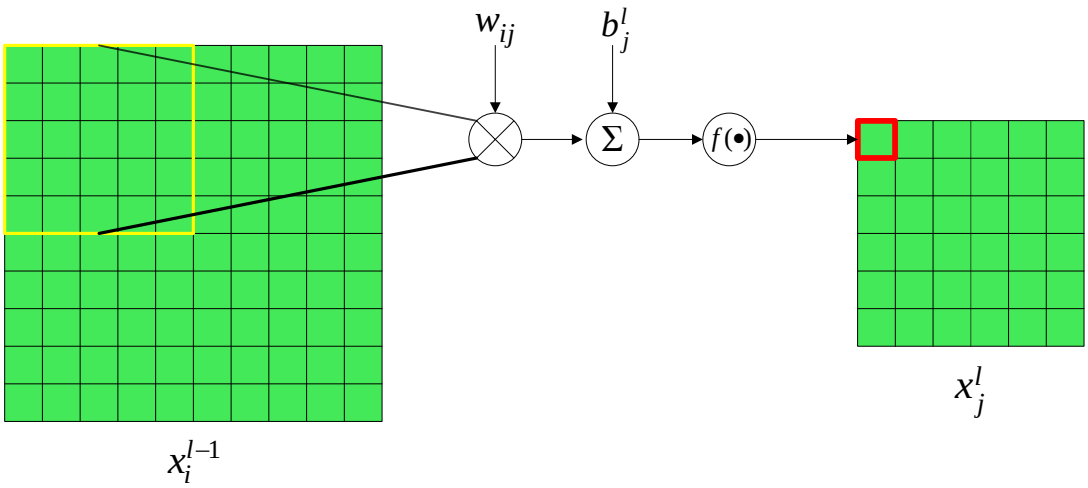

图 3-8 卷积层卷积示意图

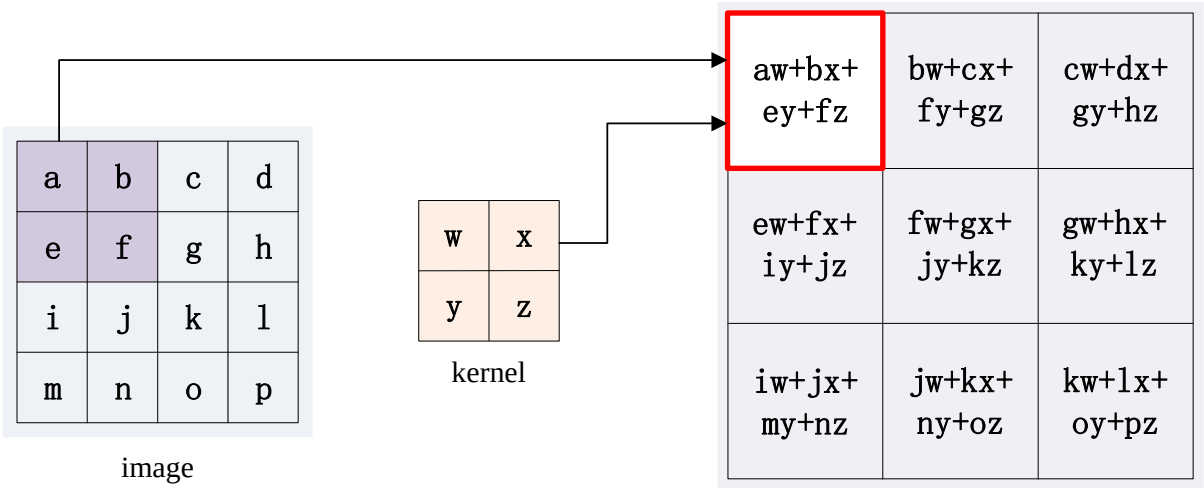

图 3-9 卷积操作

池化层

池化层也称作下采样层，一般将该层放在卷积层之后。随着卷积网络的加深，特征图的通道数一般也会增加，因此卷积后得到的特征维数也会变大，池化层的作用在于降低卷积特征图的维数，并且压缩表达其特征信息，通过下采样操作，降低后续环节计算量。经池化层输出的值是对上一层卷积特征图邻域内的特征点进行统计得到的，统计方式可以是取均值，或者是取最大值。认为池化层提取了上一层特征图中更关键、更具有代表性的特征，这样的降维压缩方式显著降低了模型训练的参数数量，加快模型的收敛速度的同时提升模型预测准确率。池化层可以使特征获得不变性：平移不变性、旋转不变性、尺度不变性，可以扩大感受野。根据不同需求，池化层有不同的池化方式，一般分为最大池化和均值池化这两种方式，池化操作过程的计算公式为式（3-25）：

$$x_j^l = down(x_j^{l-1}),\ j = 1, 2, \ldots, M \tag{3-25}$$

中国知网 https://www.cnki.net

其中，l 表示当前层数，x_j^l 表示第 j 个特征图，$down(\cdot)$表示池化函数。

假设将卷积层得到的特征图划分成 2×2 的区域，最大池化操作是对每个区域计算最大值作为新特征图的特征，均值池化操作则是对每个区域计算均值作为新特征图的特征。若图像稍有偏移，经池化操作后结果不会随之改变，因此池化操作可以增强网络对位移的鲁棒性。本文中我们采用最大池化方式，如图 3-10 为一个最大池化的例子。

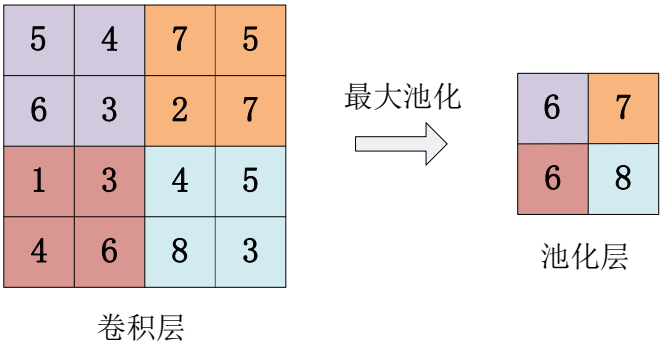

图 3-10 最大池化示意图

全连接层

全连接层实际上也是卷积层的一种，但是全连接层的“全连接”意义在于：该层的每个节点与前一层的所有节点有关，却与同层其他节点相互独立。全连接层连接着特征图与输出层，将前一层得到的特征图中代表图像局部特征的数值组合起来，即将每一个特征图转换为一维数组，之后再将所有特征图的一维数组拼接成一个特征向量，作为手势图像的完整表示并输入全连接层，作用是整合有鉴别能力的特征。全连接层的一般表达式为式（3-26）：

$$x_j^l = f(\sum_{i=1}^{N} x_i^{l-1} \cdot w_{ji}^l + b_j^l), j = 1, 2, ..., M \tag{3-26}$$

其中，l 为当前层数，第 l 层节点数量为 M，第 l-1 层节点数量为 N，l 层第 j 个节点与上一层第 i 个节点之间的连接权值为w_{ji}^l，l 层第 j 个节点的偏置记作b_j^l，$f(\cdot)$ 为激活函数。

只使用一层全连接层有时候不能很好地解决非线性问题，此时我们可以采用多层全连接层，并使用 ReLU 激活函数来解决非线性问题。全连接层中神经元个数较多，为了防止模型过拟合，我们可以在全连接层间使用 Dropout 算法，该算法思想就是在每一次训练迭代中对每一层中的神经元（假设总数为 N）以概率 P 进行随机冻结，只使用余下的(1-P)×N 个神经元所构成的网络来训练本次迭代中的数据（batch size 个样本），这样就能减小网络规模，避免特征之间的相互作用对网络模型造成的影响，缓解了过拟合。

中国知网 https://www.cnki.net

输出层

网络的最后一层为输出层，输出手势图像属于每一种手势的概率，选取概率值最大的类别作为输入图像中手势的类别，该层起到分类器的作用。本文的静态手势识别是一个多分类问题，因此在该层我们采用 Softmax 作为激活函数，该函数的表达式为（3-27）：

$$y_j^l = \frac{e^{x_j^l}}{\sum_i e^{x_i^l}}, j = 1, 2, ..., M \tag{3-27}$$

其中，M 为多分类的类别总数，y_j^l 表示输出层第 j 个神经元的输出值，即输入图像属于第 j 类的概率值，可以发现y_j^l 始终为正数并且$\sum_j y_j^l = 1$。

损失函数

CNN 的训练分为两个阶段：前向传播阶段将输入数据由低层向高层传播，计算网络损失；反向传播阶段将前向传播计算得到的网络损失从高层向低层传递，利用优化算法更新网络参数。计算网络损失即是将前向传播得到的网络预估值与真实值进行对比，计算预估值与真实值之间的距离，损失值大小很大程度上反映了网络模型在训练时的性能。损失值越大，说明在设定的目标下网络不能很好的满足设计期待拟合真实结果，需要对网络参数进行优化使损失值下降；损失值越小，则表示网络预估值与真实值之间差距较小，在设定的目标下，网络模型越拟合真实结果。

针对不同的任务往往选取不同的损失函数，常用的损失函数有：

（1）平方损失函数

平方损失函数通常用于回归问题中，度量的是估计值与样本真实值之间差的平方。它直接测量估计值和真实值之间的距离，并经平方计算放大，加大了对偏离真实值的输出的惩罚。这里定义模型的输出为$f(x)$，实际的结果为 Y，平方损失函数可以具体表示为式（3-28）：

$$L(Y, f(x)) = (Y - f(x))^2 \tag{3-28}$$

（2）对数损失函数

对数损失函数通常用于二分类问题中，Logistic 回归就是使用对数损失。Logistic 回归有这样一个先验假设，那就是数据服从 0-1 分布（伯努利分布，Bernoulli Distribution），将求解极大似然函数转化为最小化负的对数似然，具体表示为式（3-29）：

$$L(Y, P(Y|x)) = -\log P(Y|x) \tag{3-29}$$

（3）交叉熵损失函数

中国知网 https://www.cnki.net

交叉熵损失函数通常用于多分类问题中，是对数损失函数的一种推广。一般使用交叉熵作为损失函数时，在网络模型的输出层总会接一个 Softmax 函数，Softmax 将输出结果进行处理，使多个分类的预测结果求和为 1，再通过交叉熵来计算损失。交叉熵的值越大，说明预测概率越偏离真实标签；反之，交叉熵的值越小说明模型预测效果越好。

在本文 CNN 模型中采用了交叉熵损失函数，可以具体表示为式（3-30）：

$$L = -\log y_j \tag{3-30}$$

其中，j 表示当前输入样本的真实标签，y_j 表示经 Softmax 处理后输出层的第 j 个值，即表示该样本属于第 j 个类别的预测概率。

对网络的每一次迭代训练中，利用前向传播计算得到的误差进行反向传播，利用梯度下降法进行网络参数优化，以降低网络损失，常采用如式（3-31）、（3-32）方法来更新网络参数 w 和 b：

$$w_{ji}^{l} \leftarrow w_{ji}^{l} - \eta \frac{\partial loss}{\partial w_{ji}^{l}} \tag{3-31}$$

$$b_{i}^{l} \leftarrow b_{i}^{l} - \eta \frac{\partial loss}{\partial b_{i}^{l}} \tag{3-32}$$

3.2 基于 SVM 的静态手势识别

3.2.1 SVM 数据集

利用 Kinect 采集的静态手势样本集，经第二章手势分割后得到的手势二值图像作为基于 SVM 的静态手势识别的数据集，共计 8 种手势，每种手势共 390 张图像，其中 300 张为训练图像，90 张为测试图像，图像大小为 640×480。

3.2.2 手势特征提取

3.2.2.1 Hu 矩

由 7 个不变矩组成的 Hu 矩是由 Hu[47]在 1962 年提出的，在图像中手势发生平移、尺寸缩放或者旋转时具有保持其值不变的特性，适用于描述手势的整体形状。另外，Hu 矩受噪声影响较小，可以用于复杂背景下的静态手势识别。本文选取 Hu 矩作为描述手势形状的特征，能够使整个手势识别系统更加鲁棒。

手势二值图像是一个二维的离散图像，此处另其为$f(x,y)$。对于二值图像，其像素值$f(x,y)$为 0 或 1。由公式（3-33）、（3-34）定义该二维的离散图像$f(x,y)$的$(p+q)$阶矩 m_{pq} 和$(p+q)$阶中心矩 u_{pq}：

中国知网 https://www.cnki.net

$$m_{pq}=\sum_{x=1}^{M}\sum_{y=1}^{N}x^{p}y^{q}f(x,y) \tag{3-33}$$

$$u_{pq}=\sum_{x=1}^{M}\sum_{y=1}^{N}(x-\bar{x})^{p}(y-\bar{y})^{q}f(x,y) \tag{3-34}$$

其中 M、N 分别为手势二值图像的宽度和高度，p、q 分别对应着 x 方向和 y 方向上的矩，且 p 和 q 均为非负整数。公式（3-34）中，$\bar{x}=m_{10}/m_{00}$，$\bar{y}=m_{01}/m_{00}$，即$(\bar{x},\bar{y})$代表手势二值图像$f(x,y)$的重心坐标。m_{pq} 与函数$f(x,y)$是一一对应的，但其不具有平移不变性，中心矩 u_{pq} 则具有平移不变性。

由于手势二值图像的尺度变化会导致所求的矩值发生变化，即 u_{pq} 不具有缩放不变性，我们需要对其进行归一化处理，从而减轻对手势识别过程的影响。表达式如（3-35）：

$$n_{pq}=\frac{u_{pq}}{(u_{00})^{\gamma}} \tag{3-35}$$

其中，$\gamma=(p+q+2)/2$，p+q=2,3...

根据 Hu 氏理论，为使该特征具有很好的特性，我们需要进行进一步的处理，通过对归一化中心矩 n_{pq} 的组合，可以得到 7 个具有平移、尺寸缩放、旋转不变性的 Hu 矩。本文采用的 7 个不变矩的具体表达式如（3-36）：

$$\begin{gathered}
\varphi_1=n_{20}+n_{02}\\
\varphi_2=\left(n_{20}-n_{02}\right)^2+4n_{11}^2\\
\varphi_3=\left(n_{30}-3n_{12}\right)^2+\left(3n_{21}-n_{03}\right)^2\\
\varphi_4=\left(n_{30}+n_{12}\right)^2+\left(n_{21}+n_{03}\right)^2\\
\varphi_5=\left(n_{30}-3n_{12}\right)\left(n_{30}+n_{12}\right)\left[\left(n_{30}+n_{12}\right)^2-3\left(n_{21}+n_{03}\right)^2\right]+\left(3n_{21}-n_{03}\right)\left(n_{21}+n_{03}\right)\left[3\left(n_{30}+n_{12}\right)^2-\left(n_{21}+n_{03}\right)^2\right]\\
\varphi_6=\left(n_{20}-n_{02}\right)\left[\left(n_{30}+n_{12}\right)^2-\left(n_{21}+n_{03}\right)^2\right]+4n_{11}\left(n_{30}+n_{12}\right)\left(n_{21}+n_{03}\right)\\
\varphi_7=\left(3n_{21}-n_{03}\right)\left(n_{30}+n_{21}\right)\left[\left(n_{30}+n_{12}\right)^2-3\left(n_{21}+n_{03}\right)^2\right]-\left(n_{30}-3n_{12}\right)\left(n_{21}+n_{03}\right)\left[3\left(n_{30}+n_{12}\right)^2-\left(n_{21}+n_{03}\right)^2\right]
\end{gathered} \tag{3-36}$$

3.2.2.2 指尖个数

文献[48]提到多个特征的组合能够提高算法的准确性和鲁棒性。本文除了对手势二值图像提取 7 个 Hu 不变矩外，还将计算手势包含的指尖个数，这两种特征组合成一个 8 维特征向量用于表示手势，作为后续 SVM 分类器的训练样本和测试样本。

在去除手臂后的手势二值图像上以 P_c 为圆心、$R_3=factor3\times R_0$为半径作手掌切割圆，即令圆内像素点取值为 0。需注意的是，$factor3$ 的取值必须能够使得手掌被完整包含在手掌切割圆之内，且处理后仅剩下指尖部分。为了得到指尖的个数，本文利用

中国知网 https://www.cnki.net

大量样本进行实验，最终确定$factor3$取为 1.95 最合适。如图 3-11 所示，此时二值图像只剩下手指区域，利用八连通判别算法可计算得到剩余连通区域的个数，即为指尖个数。

图 3-11 计算指尖个数

3.2.3 SVM 手势分类器

3.2.3.1 分类器的训练

本文提取手势二值图像的 7 个 Hu 不变矩和指尖个数，组合成一个 8 维的手势特征向量并输入 SVM 分类器中，训练 SVM 分类器以实现对 8 种静态手势的分类识别。无论在训练阶段还是在测试阶段，均需要对输入特征向量的每一维度进行归一化。

SVM 训练阶段：首先对训练样本的每一维数据进行归一化处理，将每一维数据都映射到区间[0,1]，然后利用台湾大学林智仁教授开发的 libsvm 工具箱进行多分类实验，同时结合 SVMcgForClass 函数进行参数的优化选择。首先给定参数 C 和 γ 的搜索范围及每一个参数的步长，SVMcgForClass 函数对每一个可能的参数组合进行实验，最后返回分类性能最佳时的参数组合 C 和 γ，并将所有组合下得到的分类准确率画成一张等高图。

在本文中，我们进行了两次参数搜索实验，第一次粗略搜索后输出识别结果的等高线图，根据该图能够找到合适的参数取值范围，然后修改参数的取值范围及步长后进行第二次精细搜索，最终得到识别率最高时的最佳参数组合 C 和 γ。第一次粗略搜索设置 C 为[5,30]，其步长为 1，γ 为[-2,10]，其步长为 1。图 3-12 为参数搜索的过程，图中展示了某一参数组合训练得到的 SVM 模型参数，部分参数的含义如下：#iter 为迭代的次数，Total nSV 为支持向量总的个数，nSV 为每类支持向量的个数。图 3-13 为第一次参数粗略搜索的输出结果，在参数 C 取值范围为[5,30]和 γ 取值范围为[-2,10]时得到的参数组合下，训练得到的 SVM 模型的识别率都比较高，由图可看出大致在 99%左右。根据图 3-13 的输出结果，调整 C 的取值范围为[10,30]，C 的步长为 0.5，γ 的取值范围为

中国知网 https://www.cnki.net

[-1,9]，γ 的步长为 0.5，并进行第二次参数的精细搜索。图 3-14 为第二次参数精细搜索的输出结果，得到最佳的参数组合 C=2097152 和 γ =5.65685，在该最优化参数组合下系统的识别率达 99.625%，此时系统识别率已较高，本文不再进行第三次精细搜索。利用得到的最优化参数组合，在 MATLAB2013b 平台上调用 libsvm 库的 svmtrain 函数进行 SVM 模型的训练，得到最佳的模型 model 输出（如图 3-15 所示），并保存得到的模型参数文件，以便在测试阶段调用。图 3-15 的 SVM 模型参数的具体含义如图 3-16 所示。

```
optimization finished, #iter = 28
nu = 0.000000
obj = -16.670832, rho = 1.247813
nSV = 4, nBSV = 0
*
optimization finished, #iter = 83
nu = 0.000000
obj = -295.313384, rho = 3.530870
nSV = 5, nBSV = 0
*
optimization finished, #iter = 195
nu = 0.000000
obj = -53.165575, rho = -0.194353
nSV = 9, nBSV = 0
Total nSV = 262
```

图 3-12 参数搜索的过程

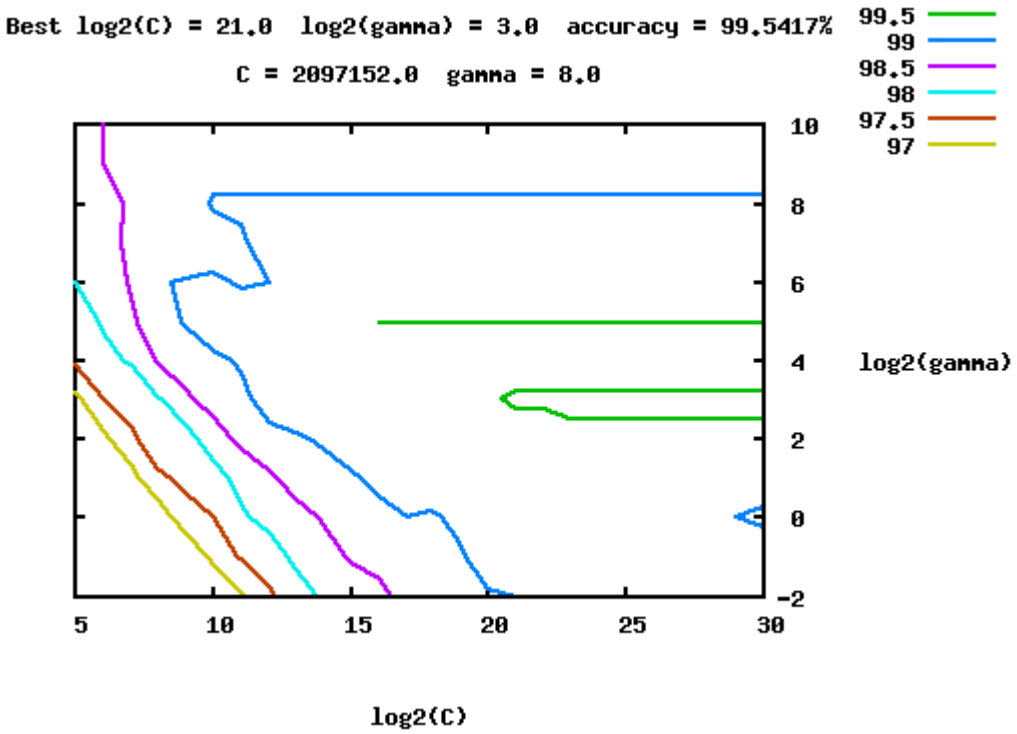

图 3-13 第一次参数粗略搜索的输出结果

中国知网 https://www.cnki.net

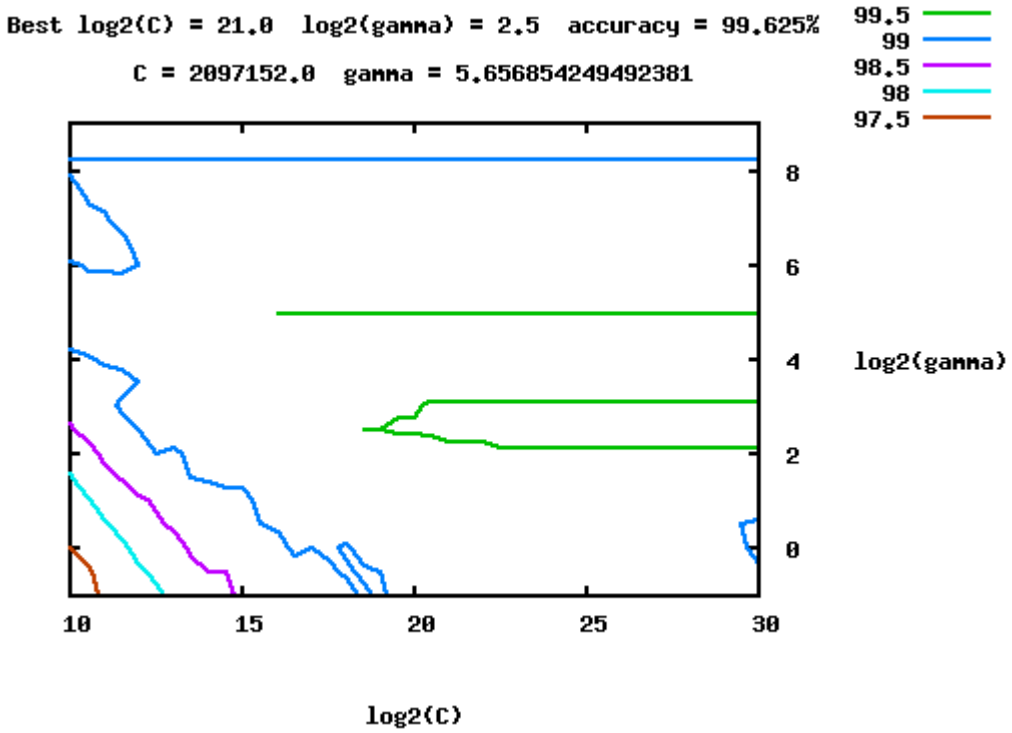

图 3-14 第二次参数精细搜索的输出结果

```
svm_type c_svc
kernel_type rbf
gamma 5.6568542494923806
nr_class 8
total_sv 262
rho 0.21125455392041842 -0.34465095850613614 -0.276951345750
label 0 1 2 3 4 5 6 7
nr_sv 16 43 53 45 23 17 11 54
SV
0 0.10960020953686131 0.048150985811994826 0 0 0 0 1:-0.98564
0 0 0.044593198318003839 0 0 3.6207176605572897 0 1:-0.84929
```

图 3-15 SVM 模型参数

svm_type：表示设置 SVM 的类型
kernel_type：表示设置核函数的类型
gamma：表示核函数中γ的设置
nr_class：表示分类样本的类别数
total_sv：支持向量总的个数
rho：决策函数中的常数项 b 的相反数
label：分类样本的标签
nr_sv：每类样本支持向量的个数
SV：存放所有支持向量

图 3-16 SVM 模型参数的具体含义

中国知网 https://www.cnki.net

SVM 测试阶段：首先对测试样本的每一维数据进行归一化处理，将每一维数据都映射到区间[0,1]，然后导入最佳模型 model 的模型参数文件，在 MATLAB2013b 平台上调用 libsvm 库的 svmpredict 函数对输入的测试样本进行手势分类，得到预测的输出结果。

3.2.3.2 实验结果与分析

本文进行 SVM 实验的实验环境如下：

处理器：Intel(R)Core(TM) i5-4440 CPU @ 3.10GHz

内存：8.00 GB

操作系统：Windows 7

实验工具：MATLAB2013b

本文基于 SVM 的静态手势识别算法在测试集上的识别结果如表 3-1 所示，该算法能够比较准确地识别手势 0、手势 1、手势 2、手势 3、手势 6 和手势 7，而对于手势 4 和手势 5 的识别准确性稍差。在测试的 720 个手势样本中，该算法能够准确识别 694 个手势样本，识别率达 96.39%。

表 3-1 SVM 分类器测试结果

手势类别	测试样本数	识别正确数	识别错误数	识别率（%）
0	90	89	1	98.89
1	90	90	0	100.00
2	90	88	2	97.78
3	90	86	4	95.56
4	90	83	7	92.22
5	90	83	7	92.22
6	90	88	2	97.78
7	90	87	3	96.67
总计	720	694	26	96.39

在同一数据集上，分别采用文献[15]的手臂去除算法、文献[16]的手臂去除算法以及不去除手臂区域，结合本文的手部分割、特征提取及 SVM 分类器进行静态手势识别的对比实验，从而说明本文提出的手臂去除算法在提高手势识别准确率和图像处理速度上的优势。不同手势识别算法的识别结果直方图如图 3-17 所示。从直方图可以看出，在不去除手臂区域的情况下，算法在测试集上的识别率仅为 90.00%，验证了手臂冗余信息对识别结果的影响。

中国知网 https://www.cnki.net

采用文献[15]的手臂去除算法实现的手势分类器，在测试集上的识别率为 89.44%（如图 3-17 所示），比不去除手臂区域的识别率低 0.56%，比采用本文手臂去除算法的识别率低 6.95%。尽管需要去除手臂区域，但准确地去除手臂区域也很重要。与不去除手臂区域相比，错误地去除手臂区域会增加手势识别的干扰并影响识别结果。

与文献[15]的手臂去除算法相比，[16]算法可以准确地消除手臂干扰。采用文献[16]中的手臂去除算法实现的手势分类器，在测试集上的识别率达到 92.36%，仍然比采取本文手臂去除算法的识别率低 4.03%，但是比采用[15]算法的识别率高 2.92%，比不去除手臂区域的识别率高 2.36%（如图 3-17 所示）。

基于相同的手部分割，特征提取和手势识别方法，手势识别系统的运算速度很大程度上取决于手臂去除算法的复杂性。尽管采用文献[16]中的手臂去除算法实现的手势分类器的识别率高达 92.36%，但其对每张手部二值图像的平均处理时间为 1.198s（表 2-1 中所示），文献[16]中的手臂去除算法不适合对实时性要求较高的手势识别系统。

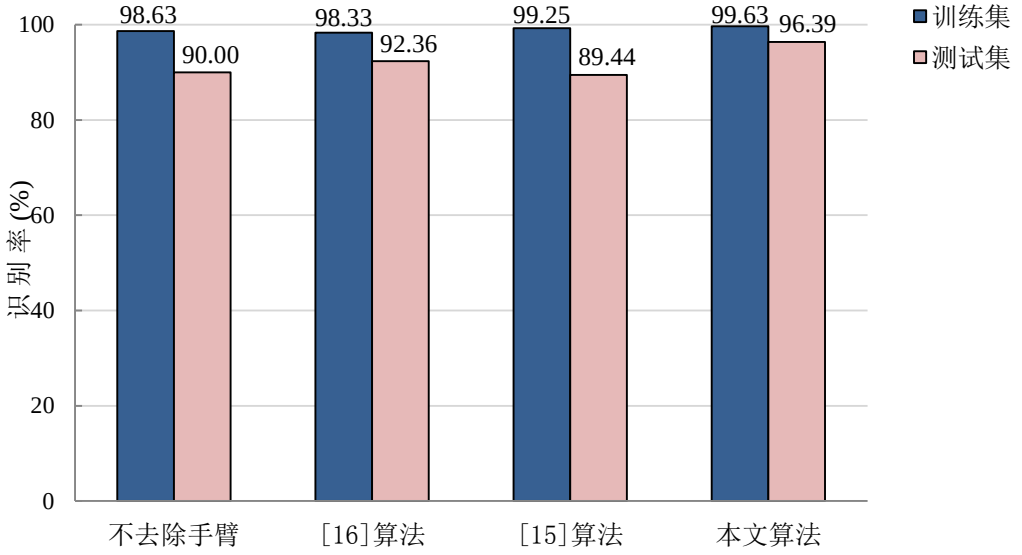

图 3-17 使用不同手臂去除算法的手势识别结果

3.3 基于 CNN 的静态手势识别

3.3.1 CNN 数据集

利用 Kinect 采集的静态手势样本集，经第二章手势分割后得到手势二值图像数据集，包括 8 种手势，每种手势共 390 张图像，其中 300 张为训练图像，90 张为测试图像，图像大小为 640×480。

本文使用 CNN 构建基于手势二值图像的分类模型，由于手势交互系统中捕捉的手势往往是图像中的一个小区域，为适应 CNN 分类器，我们首先对手势二值图像进行尺

中国知网 https://www.cnki.net

寸预处理，从手势二值图像中裁剪手势区域，将手势重心作为中心，裁剪大小为 56×56 的图像区域作为 CNN 分类器新的数据集。

对于 CNN，数据量的大小影响着网络模型的训练效果，数据量较小可能出现模型过拟合，本文使用数据增广，增加样本的复杂程度，减轻过拟合。为了使 CNN 手势分类器具有更强的表达能力，本文对手势二值图像进行旋转和翻转的数据增强操作。对于同一手势，每个人可能使用左手或右手进行表达，此时左手和右手所采集的图像不一样，此外人们采集的手势图像具有不同的角度偏差，因此本文对手势二值图像进行水平翻转、垂直翻转、水平和垂直方向同时翻转、每 30 度角旋转一次等共 15 种变换。如图 3-18，(a)图为原始的手势二值图像，(b)图为经过 15 种变换后的手势二值图像。最终用于 CNN 分类器的数据集包含 46800 张手势二值图像，每种手势均包含 5850 张图像，本文将 80%的图像用于训练网络，其余 20%的图像进行测试。

(a)

(b)

图 3-18 数据增强操作示意图

3.3.2 CNN 手势分类器

3.3.2.1 网络结构设计

本文设计的 CNN 用于 8 种静态手势的识别，网络结构如图 3-19 所示，不算输入层和输出层一共有 8 层，包含 3 个卷积层、3 个池化层和 2 个全连接层。从网络结构图可以看到，C1、C2、C3 为卷积层，S1、S2、S3 为池化层，网络的前 6 层由卷积层与池化层轮流组成，之后接 2 层全连接层 FC1 和 FC2，全连接层后接 1 个 Softmax 回归层，输

中国知网 https://www.cnki.net

出手势二值图像的分类结果。

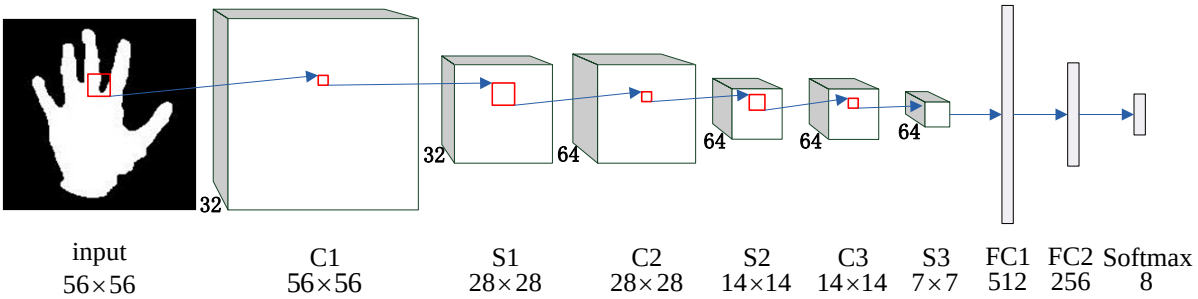

图 3-19 CNN 网络结构示意图

卷积层 C1 的卷积核大小为 5×5，卷积核数量为 32 个，各方向上的步长都为 1，padding 设置为"SAME"使得输出特征图与输入图像大小一致，输入的手势二值图像经卷积层 C1 后可提取出 32 个不同的手势特征图，代表不同的手势特征。为了加快训练速度和防止过拟合，池化层 S1 采用大小为 2×2 的不重叠采样，经池化层 S1 后特征图的分辨率将减小一半，而特征图的数量与池化前相同，得到 32 个特征图。卷积层 C2、C3 的卷积核大小分别为 5×5、3×3，卷积核数量均为 64，C2 和 C3 的其它设置均与 C1 相同，池化层 S2、S3 均采用与 S1 相同的设置，且均采用最大池化方式。CNN 输入图像的大小为 56×56，经卷积层和池化层之后，可得到大小为 7×7 的 64 个不同的特征图，这些抽象特征更能表示手势的特点。全连接层 FC1 的神经元个数设置为 512，与池化层 S3 进行全连接，全连接层 FC2 的神经元个数设置为 256，与 FC1 进行全连接，全连接层 FC2 后接 Softmax 回归层，包含 8 个神经元，用于对全连接层 FC2 输出的特征进行分类，最终分类结果输出到一列向量中。

本文设计的网络结构中 C1、C2、C3、FC1、FC2 均用非线性的 ReLU 作为激活函数，另外为了防止 CNN 出现过度拟合并保留全连接层节点的数量，本文在 FC1 和 FC2 之间加入了 Dropout，Dropout 值设置为 0.5，即让神经元以 50%的概率随机失活。

3.3.2.2 实验结果与分析

本文基于 CNN 的静态手势识别算法是基于 Python 和 TensorFlow 深度学习框架开发的，并使用 TITAN X 作为计算硬件，本文使用随机初始化权重系数的方法从头开始训练网络模型，选用交叉熵损失函数作为模型的损失函数，使用 Adam 算法对网络参数进行优化，学习率设置为 0.001。本文随机打乱 CNN 分类器的训练集，从中选取 128 个样本作为 CNN 的输入数据，进行一次网络参数更新。本文训练的周期数为 5 个，每迭代训练一个周期，对测试集进行一次测试。

中国知网 https://www.cnki.net

图 3-20 显示了 CNN 训练过程中代价函数、训练集识别率随迭代次数的变化以及每个训练周期时测试集的识别率。由图 3-20 可以看出，在前 200 次迭代中，代价函数在不断地下降，且下降的速度比较快，同时训练集识别率在不断地上升，网络还在学习不同手势的特点，此时网络参数还不稳定，仍需进一步训练。当网络迭代到 1000 次左右时，代价函数下降到足够小，手势识别率增长缓慢，此时网络中的参数趋于稳定的状态。

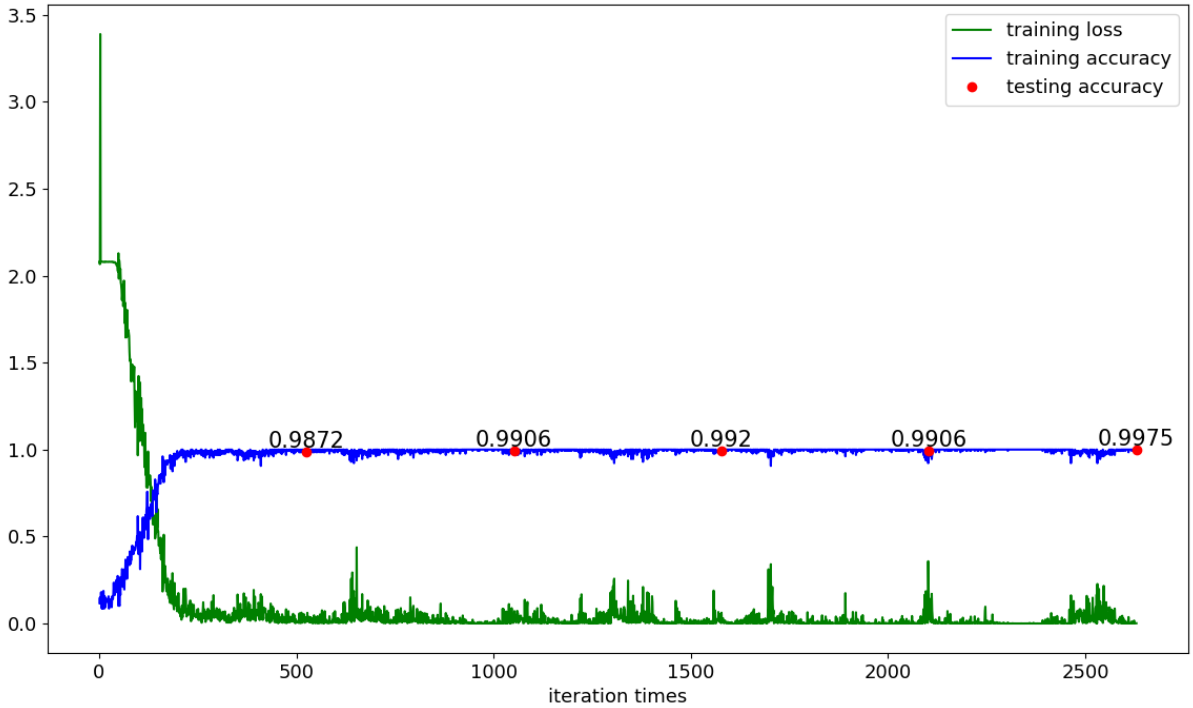

图 3-20 CNN 训练过程

表 3-2 CNN 分类器测试结果

手势类别	测试样本数	识别正确数	识别错误数	识别率（%）
0	1170	1165	5	99.57
1	1170	1170	0	100.00
2	1170	1167	3	99.74
3	1170	1170	0	100.00
4	1170	1164	6	99.49
5	1170	1169	1	99.91
6	1170	1166	4	99.66
7	1170	1166	4	99.66
总计	9360	9337	23	99.75

本文基于手势二值图像训练得到的 CNN 分类器，在测试集上的平均识别率达到 99.75%，对每种手势的识别率均高于 99%，如表 3-2 所示。手势二值图像作为 CNN 分

中国知网 https://www.cnki.net

类器的输入，避免了复杂背景对 CNN 手势特征提取的影响，CNN 能够自动地捕捉手势区域的特征，能更好地学习不同手势的特点从而使得 CNN 手势识别率更高，数据增强操作也提高了 CNN 手势分类器的泛化能力。相比于传统的依赖人工设计特征实现的 SVM 手势分类器，CNN 手势分类器提取的特征更可靠、实现效率更高、识别率更高。

3.4 本章小结

本章主要研究了两种不同的静态手势识别方法，分别训练了基于人工设计特征的 SVM 分类器和基于自动特征提取的 CNN 分类器，研究不同的手势特征提取及手势分类方式对手势识别效果的影响。

本章首先介绍了 SVM 的基本原理，SVM 核函数的选择，并介绍了本章 SVM 采取的参数优化算法。本章介绍了传统的人工神经网络，以经典的人工神经网络为例详细介绍了网络结构，介绍神经网络中参数优化的反向传播算法，神经网络采用这种算法不断调整网络参数，以达到网络的最优状态。继而对 CNN 的基本理论进行了阐述，包括卷积层、池化层、全连接层、输出层和损失函数。

本章研究了基于 SVM 的静态手势识别方法，主要介绍了 Hu 不变矩的定义，利用手掌切割圆并结合八连通判别算法计算指尖个数，将人工提取的 7 个不变矩及指尖个数组合成长度为 8 的静态手势特征向量，然后选取在静态手势分类问题上性能卓越的 SVM 进行手势分类器的训练。利用网格搜索算法寻找识别率最高时的参数组合 C 和 γ，在该最优参数组合下根据输入的训练样本训练 SVM 模型，实现了一个识别率高的 SVM 手势分类器。在同一数据集上，利用其它手臂去除算法进行 SVM 分类实验，实验结果证明采用本文手臂去除算法实现的 SVM 手势分类器对 8 种静态手势的识别率高，且运算时间短。

随后，本章研究了基于 CNN 的静态手势识别方法，本章设计的 CNN 是由卷积层、池化层、全连接层等层结构组成，用于对 8 种静态手势的分类识别。为了提高 CNN 分类器的鲁棒性和表达能力，本章采用数据增强的方式扩充数据集，CNN 通过对大量样本的学习能够自动地提取合适的手势高维特征，训练得到的 CNN 手势分类器相比于传统方法实现的 SVM 手势分类器具有更好的识别效果。

中国知网 https://www.cnki.net

第四章 动态手势识别方法

4.1 引言

在前一章中，我们基于静态手势分割后得到的手势二值图像分别采用 SVM 和 CNN 构建手势分类器，实现准确率高的静态手势识别。动态手势相比于静态手势更复杂、种类更多，能传达更丰富的信息，因此动态手势识别具有很重要的研究意义。传统的动态手势识别采用人工设计的特征和隐马尔科夫模型，效果不是很好。2D 卷积神经网络是基于静态图像提取的空间特征，无法捕捉目标在时空维度的特征信息，因此用于动态手势识别时分类准确率较低。在本章中，我们提出一种基于 3D 卷积和卷积 LSTM 的动态手势识别方法，使用 3D 卷积核提取手势图像序列的短时空特征，然后将提取的短时空特征输入到 ConvLSTM 网络进行动态手势的长时空特征学习，最后利用 SPP 网络和全连接层网络实现动态手势的分类。对单模态训练较好的网络模型，最终集成多模态手势识别模型，提高识别准确率。

4.1.1 多模态动态手势数据集

本章实验所用的 SKIG（Sheffield KInect Gesture）数据集[49]的手势图像序列由两种模态构成，分别是 RGB 模态与深度模态，两种模态的视频图像序列各含 1080 个，是由 6 个对象利用 Kinect v1 在不同光照及不同背景下同步捕获得到。图 4-1 展示了 SKIG 数据集的 10 种动态手势（包括 RGB 模态及对应的 Depth 模态）：画圆形（顺时针）、画三角形（逆时针）、上下、左右、挥动、画“Z”形、画“十”字形、过来、转身和拍打，每种手势均采用 3 种手姿态采集：握拳、伸食指和张开手掌。所有手势图像序列是在两种光照强度（强光和弱光）以及三种背景（木板、白纸和带字符的纸）下采集，因此对于每个对象采集的手势图像序列有 360 个(2×2×3×3×10)。

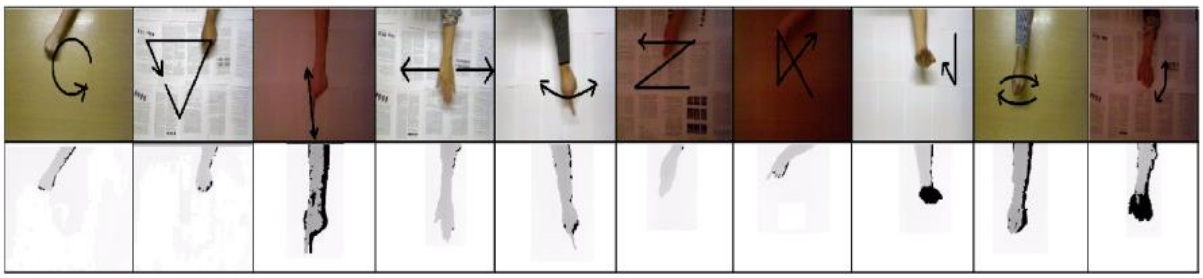

Circle　Triangle　Up-down　Right-left　Wave　“Z”　Cross　Comehere　Turn around　Pat

图 4-1 SKIG 的 10 种动态手势

中国知网 https://www.cnki.net

4.1.2 3D 卷积神经网络

在第三章的基于 CNN 的静态手势识别中，我们讲解了 2D 卷积的基本理论，并利用 2D 卷积有效提取输入静态手势二值图像的局部空间特征。对于本章动态手势识别来说，动态手势特征分布于两个维度：图像的空间维度及时间维度，即我们需要捕捉输入的视频图像序列中手势在时空域的特征信息。若采用 2D 卷积对视频图像序列进行处理，容易丢失手势在时序上的信息，这里我们将 2D 卷积扩展为 3D 卷积，采用 3D 卷积神经网络（3D CNN）来进行动态手势特征提取。图 4-2 是 2D 卷积与 3D 卷积操作的对比，3D 卷积的卷积核是三维的，由蓝黑红色表示，对输入的第 1、2、3 帧图像卷积，输出第一个卷积特征图，对第 2、3、4 帧图像共享 3D 卷积核，输出第二个卷积特征图，并以此类推完成 3D 卷积操作，3D 卷积处理视频图像序列得到的特征也是三维的，该特征既包含图像空间上的信息，也包含时间上下文信息。3D 卷积具体表示为式（4-1）：

$$v'_{xyt} = f\left(\sum_{i,j,k} w_{ijk} v_{(x+i)(y+j)(t+k)} + b\right) \tag{4-1}$$

其中，v 表示输入的视频图像序列，w 为 3D 卷积核，b 为偏置项，f 为激活函数。对输入的手势图像序列使用多个不同的 3D 卷积核经过多层 3D 卷积操作，可以得到多个三维特征，经组合得到的三维特征可以表示完整的动态手势。

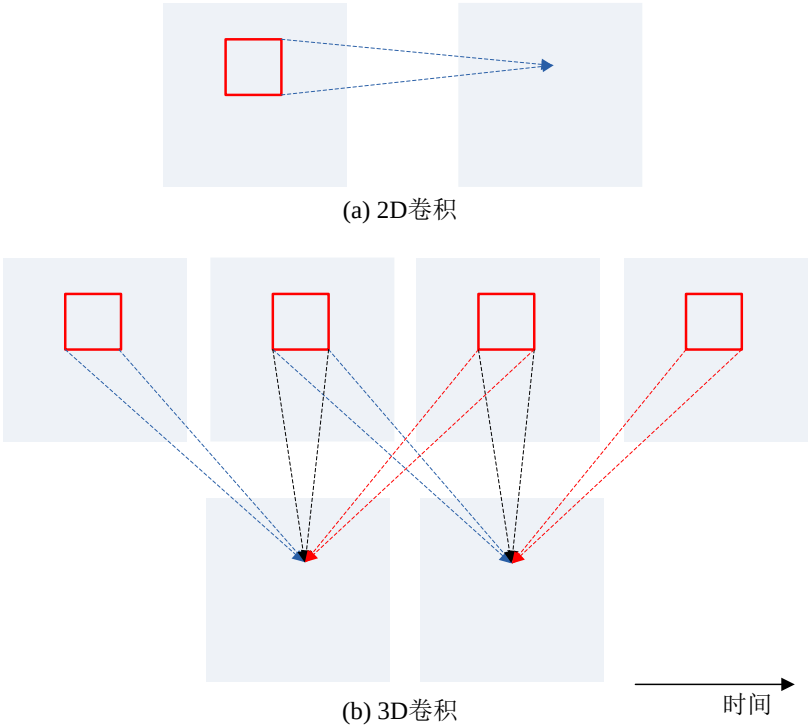

图 4-2 2D 卷积与 3D 卷积的对比

中国知网 https://www.cnki.net

4.1.3 卷积 LSTM 网络

循环神经网络（RNN）也叫时序神经网络，是一种用于处理包含时间序列数据的神经网络。与一般神经网络相比（如 DNN），RNN 能够对时间序列上有变化的数据进行处理。由于存在梯度消失/梯度爆炸的问题，传统 RNN 无法从时间序列数据中学习到长期依赖关系。长短期记忆（Long short-term memory, LSTM）是在传统 RNN 的基础上加入了记忆单元来存储信息，解决了长序列训练过程中的梯度消失和梯度爆炸问题，因此 LSTM 在更长序列中的表现比 RNN 更好。传统 LSTM 不考虑空间相关性，卷积 LSTM（ConvLSTM）集合了 CNN 的图像空间特征提取能力和 LSTM 的时序学习能力，在传统 LSTM 的输入-状态和状态-状态转换中采用卷积结构，可以很好地模拟时空关系，在对视频图像序列的处理中能够更好地捕捉目标的长距离运动信息。因此，本文在使用 3D 卷积提取视频图像序列的短时空特征的基础上，利用 ConvLSTM 捕捉动态手势的长时空运动信息。

ConvLSTM 网络的计算公式如下（4-2）、（4-3）、（4-4）、（4-5）、（4-6）：

$$i_t = \sigma(W_{xi} * X_t + W_{hi} * H_{t-1} + b_i) \tag{4-2}$$

$$f_t = \sigma(W_{xf} * X_t + W_{hf} * H_{t-1} + b_f) \tag{4-3}$$

$$o_t = \sigma(W_{xo} * X_t + W_{ho} * H_{t-1} + b_o) \tag{4-4}$$

$$C_t = f_t \circ C_{t-1} + i_t \circ \tanh(W_{xc} * X_t + W_{hc} * H_{t-1} + b_c) \tag{4-5}$$

$$H_t = o_t \circ \tanh(C_t) \tag{4-6}$$

其中，输入表示为$X_1, X_2, \ldots, X_t$，记忆单元状态表示为$C_1, C_2, \ldots, C_t$，隐藏状态表示为$H_1, H_2, \ldots, H_t$，σ 表示 sigmoid 激活函数，$W_{x\sim}$和$W_{h\sim}$均为 2D 卷积核，‘*’表示卷积运算，‘∘’表示 Hadamard 乘积。输入门、遗忘门和输出门状态分别表示为 i_t、f_t、o_t，均为 3 维张量，最后两个维度是空间维度（行和列）。我们可以将公式中的输入、记忆单元状态、隐藏状态想象为在空间网格上的向量，ConvLSTM 通过邻域的输入和过去的状态来确定网格中某个单元格的未来状态。如果将状态视为运动对象的隐藏表示，那么采取较大的过渡核时 ConvLSTM 可以捕获较快的运动，采取较小的过渡核时 ConvLSTM 可以捕获较慢的运动。

如果状态与输入的维度不对应，将无法应用卷积操作，因此应当先进行填充确保两者行列数相同。通常在第一个输入到来之前，将 ConvLSTM 的所有状态初始化为零，通过对状态执行零填充表示了对外部世界不具有先验知识。

中国知网 https://www.cnki.net

4.1.4 空间金字塔池化层

空间金字塔池化层（Spatial Pyramid Pooling，SPP）用于对同一特征图进行不同尺度的特征提取，即将卷积层输出的特征图划分为不同的尺寸，然后对于每一尺寸提取相应固定维度的特征，最终将不同尺寸提取的特征进行拼接，获得一个固定维度的特征向量。比如，可以对任意大小的特征图划分成 1 份、4 份、16 份，在每个划分区域采取最大池化得到输出的特征值，拼接所有划分区域的特征值得到 1+4+16=21 维的特征向量。如图 4-3 所示，卷积层输出了 384 个特征图，SPP 层对每一个特征图进行 4 种不同尺寸的特征提取，将每一个特征图分别映射成 1 份、4 份、16 份和 49 份，然后对每一划分区域采取最大池化操作，经过 SPP 层提取得到 1×384+4×384+16×384+49×384=26880 维特征向量。

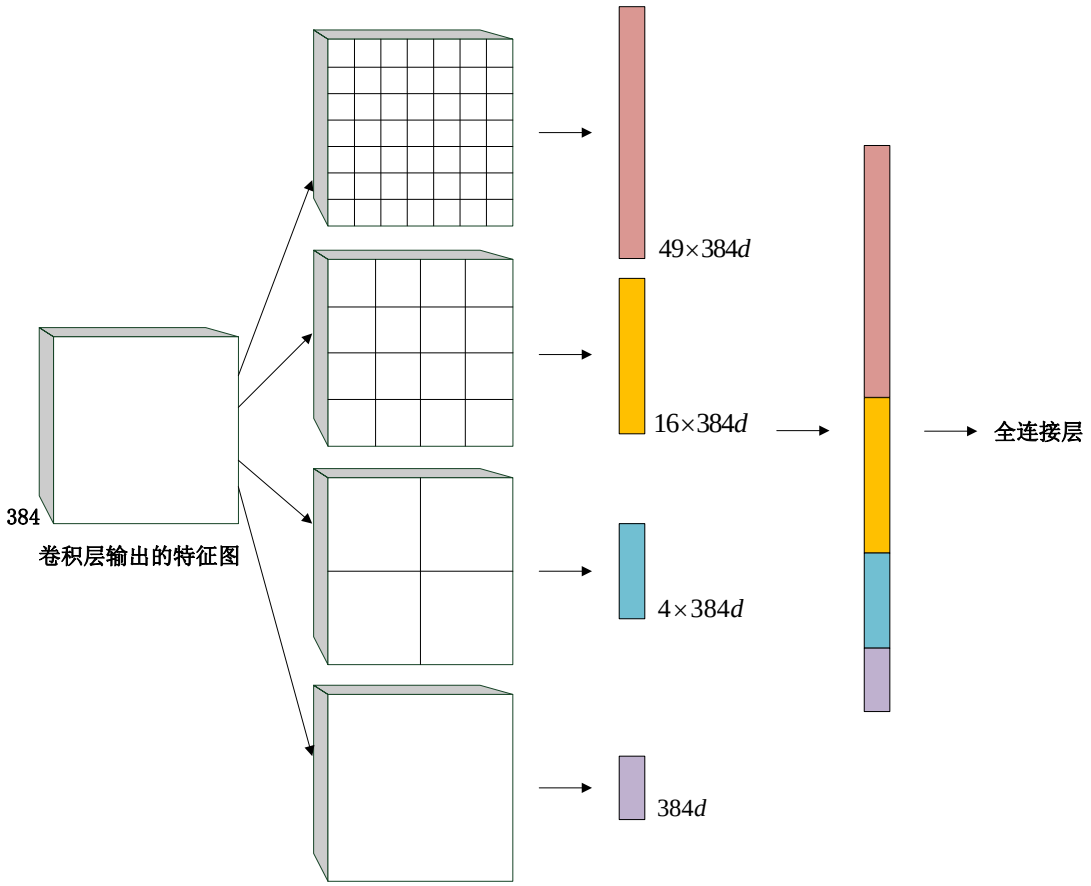

图 4-3 空间金字塔池化层

SPP 的本质是不同的窗口大小和移动步长的最大池化，计算方式具体如下：假设经卷积层输出的一个特征图尺寸为 h*w，将特征图划分为 n*n 份进行最大池化，每一池化操作的窗口为$ceil\left(\frac{h}{n},\frac{w}{n}\right)$，步长的大小为$floor\left(\frac{h}{n},\frac{w}{n}\right)$，*ceil* 表示向上取整操作，*floor* 表示向下取整操作。

中国知网 https://www.cnki.net

SPP 对于任意尺寸的特征图输入都能产生固定维度的特征输出，因此我们无需将输入放缩到指定大小，SPP 的输出可以满足全连接层的需要。此外，SPP 方式可以兼容多种尺寸的特征，可以提高动态手势识别的精度。SPP 还可用于降维，在卷积层和全连接层之间插入 SPP 可以使得全连接层具有较少的参数。

4.2 基于 3D 卷积和卷积 LSTM 的动态手势识别

4.2.1 网络结构设计

本文采用多模态视频图像序列作为模型的输入，分别训练不同的单模态网络模型，最终进行模型融合提高动态手势识别的准确率。本文采用的单模态网络模型结构如图 4-4 所示，基于视频图像序列的动态手势识别涉及时间和空间因素，需要同时学习视频图像序列中手势的时空域特征，本文采用 3D CNN 学习手势的短时空域特征，然后采用 ConvLSTM 进一步学习手势的长时空域特征，在全连接层前使用 SPP 层进行降维，全连接层的输出接 Softmax 得到手势分类的预测结果。

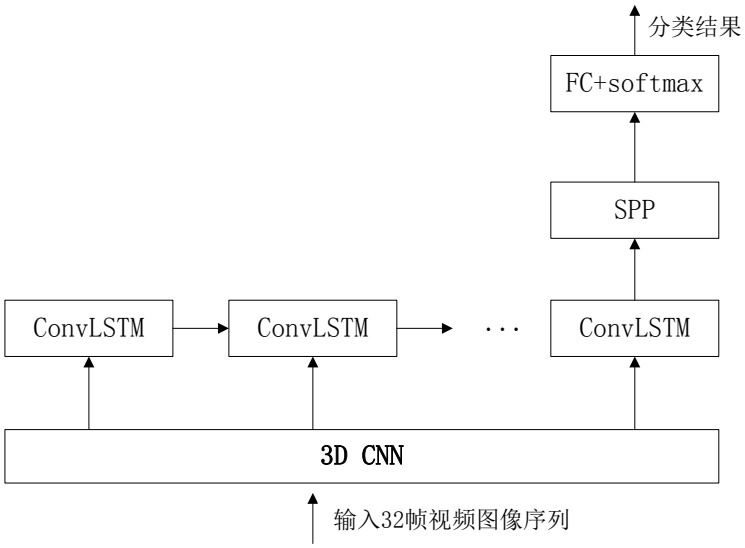

图 4-4 单模态网络模型的整体结构

本文以 C3D 网络结构[41]为基础，构建的 3D CNN 的具体结构如图 4-5 所示，包含 4 个 3D 卷积层、2 个 3D 池化层，3D 卷积核的尺寸与 3D 池化核相同，均为 $t\times k\times k$，其中 t 代表时间长度而 k 指的是平面上核的大小。3D 卷积层 C1 的卷积核个数为 64，C2 为 128，C3 为 256，C4 为 384，所有 3D 卷积层设置为相同的核大小（t=3，k=3），步长设为 1，填充至与输入相同大小。为了提高模型训练的稳定性和收敛速度，本文在 3D 卷积层 C1、C2、C4 的单次卷积操作之后使用批量归一化（BN）优化深度网络模型，然后使用 ReLU 作为激活函数，一定程度上缩短了网络训练的时间。3D 池化层 P1、P2

中国知网 https://www.cnki.net

采用最大池化方式，3D 池化核大小分别为 1×2×2、2×2×2，池化核步长大小分别为 1×2×2、2×2×2，P1 层采用 1×2×2 大小进行最大池化是为了在一开始尽可能保留时间维度上的信息，从而较完整地捕捉视频图像序列间的运动信息。

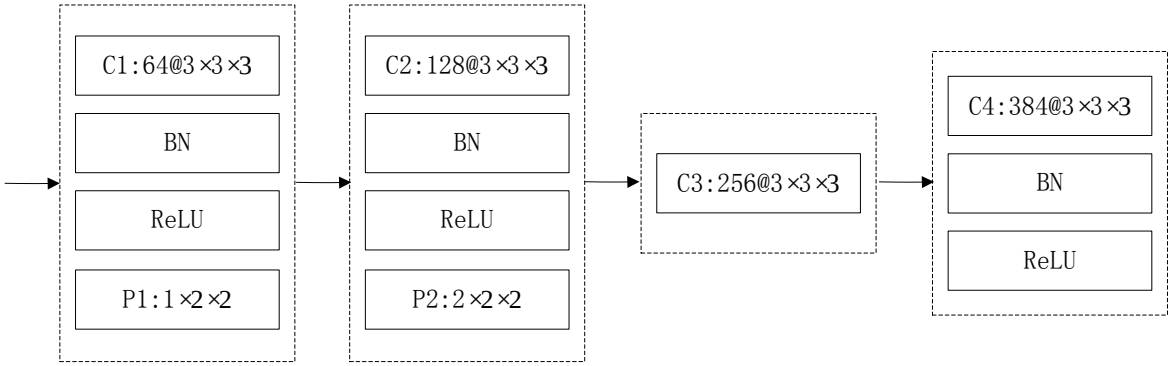

图 4-5 3D CNN 具体结构

本文对视频采样得到的 32 帧视频图像序列作为网络的输入，对于单通道而言输入的数据大小为 32×112×112；通过 C1 层 64 个 3D 卷积核进行卷积操作得到 64@32×112×112 的特征图，时空尺寸保持不变，然后利用 P1 层 1×2×2 池化操作，时间维度不变而空间维度尺寸缩小为原来的 1/4；通过 C2 层 128 个 3D 卷积核进行卷积操作得到 128@32×56×56 的特征图，然后利用 P2 层 2×2×2 池化操作进行降维得到 128@16×28×28 的特征图；通过 C3、C4 层 3D 卷积操作后最终得到 384@16×28×28 的输出特征，作为后续 ConvLSTM 的输入。

本文 ConvLSTM 层的卷积核数量设为 512，卷积核的大小均为 3×3，卷积核步长大小均为 1×1，采用"SAME"的 padding 方式使得卷积过程中得到的时空特征图具有相同的空间尺寸，ConvLSTM 层输出 512@1×28×28 的特征图，时间长度变为 1。这里我们只保留 ConvLSTM 最后时刻输出的特征图，该输出的时空特征图的时间长度为 1，这相当于将整个视频图像序列压缩成 2 维的特征图，该特征图代表着动态手势的长时空特征，隐含了该动态手势在每个时刻的状态信息。

ConvLSTM 层不会改变 3D CNN 输出特征图的空间尺寸，该层最终输出的特征尺寸为 512@1×28×28，由于总的维度太高，若直接作为全连接层的输入会导致全连接层参数过多、网络训练缓慢且容易过拟合。本文对 ConvLSTM 层输出的每个特征图进行降维处理，采用 4 级空间金字塔池化：1×1、2×2、4×4、7×7 结构，每个特征图经 SPP 层后最终生成 1+4+16+49=70 维特征。因此 ConvLSTM 层输出的特征图经 SPP 层降维处理后得到 70×512=35840 维特征，再与全连接层相连。多级 SPP 降维提取的多种尺度特征还可以在一定程度上提高网络识别精度。全连接层包含 10 个神经元，将神经元的输出

中国知网 https://www.cnki.net

使用 Softmax 进行分类，得到单模态网络最终的手势分类预测结果。

多模态融合是常用的提升模型准确度的方法，本文的网络模型融合结构如图 4-6 所示。RGB 视频图像序列和深度视频图像序列对彼此是一种有效的信息补充，本文将采样得到的 32 帧 RGB 视频图像序列和 32 帧深度视频图像序列分别作为单模态网络模型的输入，分别训练两个独立的深度神经网络，将两个单模态训练好的网络的 Softmax 层输出结果相加除以 2，选取向量中数值最大的概率所对应的类别作为最终分类结果，该方式能够有效地集成 RGB 信息和深度信息，从而提升网络识别准确率。

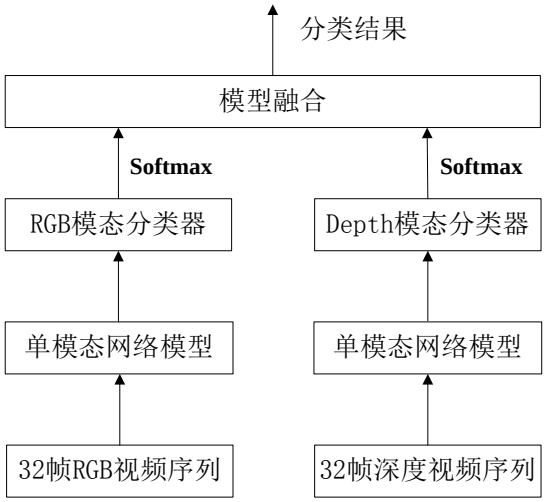

图 4-6 本文的网络模型融合结构

4.2.2 实验结果与分析

本文动态手势识别算法是基于 Python 和 TensorFlow 深度学习框架开发的，并使用 TITAN X 作为计算硬件，实验环境如下：

Ubuntu 16.04 操作系统 Python 3.5.6 版本

tensorflow-gpu 1.3.0 版 tensorlayer 1.3.0 版

CUDA8.0.44 版 cuDNN6.0.21 版

人们采集手势样本的速度不同导致数据集中手势图像序列具有不同的帧数，为了便于处理本文统一输入帧数，提取手势图像序列的 32 帧作为网络的输入，每帧大小为 112×112。具体地，对帧数大于 32 的手势样本进行随机采样，而对帧数小于 32 的手势样本我们随机选取帧进行复制。将预处理好的 32 帧 RGB 视频图像序列和 32 帧深度视频图像序列分别输入相同的网络结构，选用交叉熵损失函数作为网络模型的损失函数，分别训练两个单模态网络，最终集成两个网络的输出结果实现手势判别。

本文从头训练 RGB 模态网络模型和 Depth 模态网络模型，两种模型训练参数相同

中国知网 https://www.cnki.net

但相互独立，输入批次构建为每次随机选择训练集中 13 个样本，使用 Adam 优化，初始学习率设为 0.0001，每经过 10000 次迭代训练学习率下降为原来的 1/10，权重衰减系数设为 0.00004，训练的周期数为 165 个，对应 9000 左右的迭代次数，每迭代训练 300 次，对测试集进行一次测试。

本文根据采集对象不同将 SKIG 手势数据集划分为 3 个子集，其中子集 1 为：对象 1+对象 2，子集 2 为：对象 3+对象 4，子集 3 为：对象 5+对象 6，采用 3 折交叉验证评估本文提出的动态手势识别算法，每一组样本集均包含 RGB 视频图像序列及对应的深度视频图像序列，本文共训练 6 个单模态网络模型，在网络训练的过程中交叉熵损失不断下降，训练集识别率、测试集识别率在不断上升，网络并未发生过拟合，本文选择测试集识别率高的单模态网络模型用于后续的模型融合。本文训练的单模态网络模型的实验结果如下：

样本集 1：训练集为子集 1+子集 2，测试集为子集 3，在样本集 1 下分别训练两种单模态网络，训练结果如图 4-7 所示。在 7800 次迭代时，Depth 模态网络模型在测试集上识别率达 99.15%。在 7500 次迭代时，RGB 模态网络模型在测试集上识别率达 94.87%。本文保存以上两个模型参数，用于模型融合。

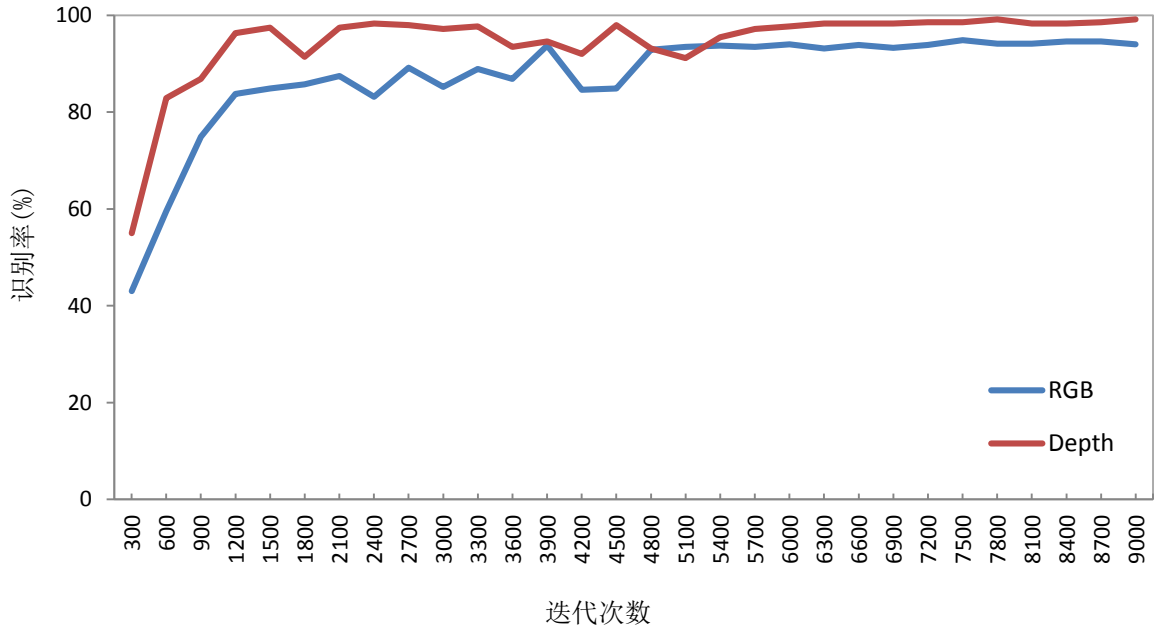

图 4-7 样本集 1 下单模态网络的训练结果

样本集 2：训练集为子集 1+子集 3，测试集为子集 2，在样本集 2 下分别训练两种单模态网络，训练结果如图 4-8 所示。在 6900 次迭代时，Depth 模态网络模型在测试集上识别率达 97.15%。在 8400 次迭代时，RGB 模态网络模型在测试集上识别率达 95.16%。

中国知网 https://www.cnki.net

本文保存以上两个模型参数，用于模型融合。

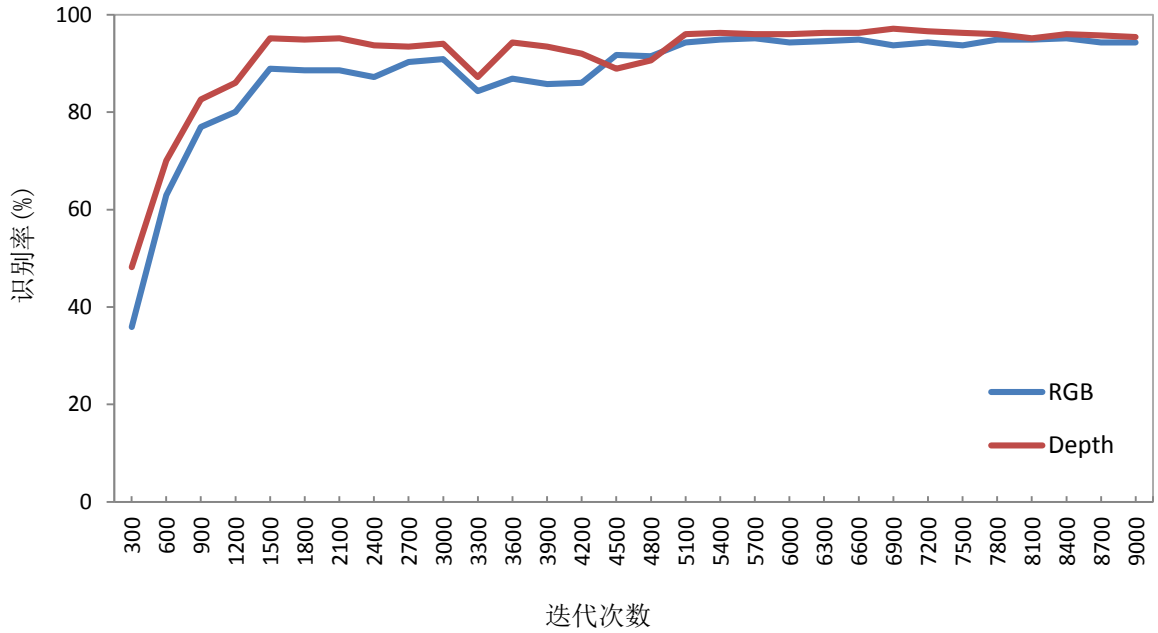

图 4-8 样本集 2 下单模态网络的训练结果

样本集 3：训练集为子集 2+子集 3，测试集为子集 1，在样本集 3 下分别训练两种单模态网络，训练结果如图 4-9 所示。在 8100 次迭代时，Depth 模态网络模型在测试集上识别率达 98.29%。在 7200 次迭代时，RGB 模态网络模型在测试集上识别率达 90.88%。本文保存以上两个模型参数，用于模型融合。

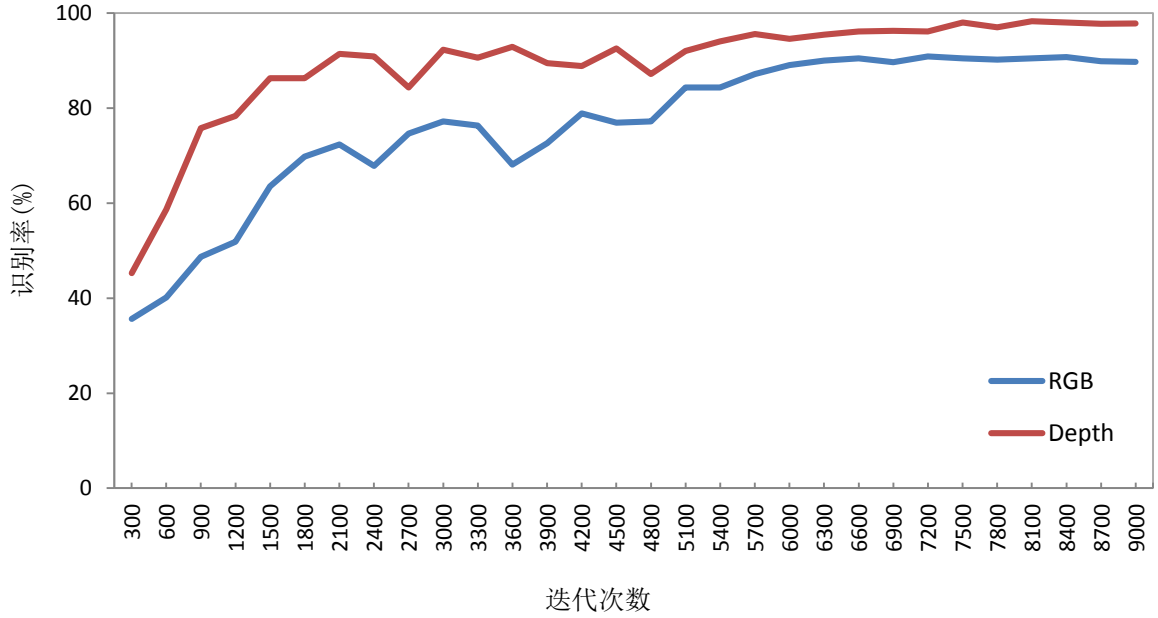

图 4-9 样本集 3 下单模态网络的训练结果

对每个样本集训练好的两种单模态网络模型进行多模态融合，得到各个样本集最终的识别结果如表 4-1 所示。由表 4-1 可以看出，集成 RGB 特征和深度特征的网络模型比

中国知网 https://www.cnki.net

单独使用一种特征的单模态网络模型的识别率高。不同模态数据能够提供关于动态手势不同方面的有效信息，且包含互补信息，以多模态融合的方式将这些信息结合起来可以构建鲁棒性更强的动态手势分类器。本文构建的多模态网络模型提升了动态手势识别准确率，识别率达到 98.67%，该实验结果验证了本文提出的网络模型的有效性。

表 4-1 不同模态的动态手势分类器的识别率（%）

	Depth 模态	RGB 模态	多模态融合
样本集 1	99.15	94.87	99.72
样本集 2	97.15	95.16	97.72
样本集 3	98.29	90.88	98.58
总计	98.20	93.64	98.67

为体现本文工作，本节在 SKIG 数据集上与其他方法进行了实验对比，如表 4-2。本文方法在该数据集上有着更高的识别率，为 98.67%。而表中的其他方法，如 RGGP+RGB-D[49]，是一种结合了受限图形遗传编程（Restrict Graphic Genetic Programming，RGGP）的方法，这类方法能够自动提取视频流中的时空特征，并融合 RGB 数据和深度数据进行动态手势分类，训练得到模型的识别率为 88.70%，比本文方法的低 9.97%。MRNN[51]方法采用传统的 2D 卷积学习单张图像的空间特征，然后将提取的特征输入 RNN 网络，最终训练得到的动态手势分类器的识别率为 97.80%，比本文方法的低 0.87%，该结果说明了本文基于 3D 卷积和卷积 LSTM 的方法更适合于处理具有时空域特征的动态手势识别。

表 4-2 不同方法在 SKIG 数据集上的识别率对比

方法	识别率（%）
RGGP+RGB-D[49]	88.70
4DCOV[50]	93.80
MRNN[51]	97.80
本文模型	98.67

4.3 本章小结

本章主要研究了动态手势识别问题，设计实现了基于 3D 卷积和卷积 LSTM 的动态手势分类器。对于输入的视频图像序列中动态手势的特征分布于时空域的问题，使用 3D CNN 和 ConvLSTM 分别捕捉动态手势的短时空特征和长时空特征。针对全连接层参数过多网络容易过拟合的问题，在 ConvLSTM 和全连接层之间插入多级 SPP，对特征图降

中国知网 https://www.cnki.net

维的同时提取了多种尺度特征。本章实现的多模态手势识别模型融合了不同的单模态网络模型，在 SKIG 数据集上具有较好的识别结果，识别率达到 98.67%。通过与 RGB 模态网络模型和 Depth 模态网络模型的识别效果进行对比，验证了多模态融合能够较好地提升动态手势的分类准确率。通过与其他方法在 SKIG 数据集上的识别结果进行对比，说明本文提出的动态手势识别方法具有较好的分类识别性能。

中国知网 https://www.cnki.net

总结与展望

1. 工作总结

在人机交互应用越来越频繁的今天，手势交互作为一种自然而直观的模式，与其他模式相比能增加交互过程的自然性和高效性，为用户带来良好的交互体验，已被广泛应用于聋哑人的手语沟通、车载手势、智能家居、游戏娱乐以及虚拟目标操控等领域。手势识别作为手势交互领域的核心技术，扮演着及其重要的作用，引起了科研工作者的广泛关注。基于视觉的手势识别技术具有成本低、交互自然友好的特点，具有较好的应用前景，已成为手势识别领域的研究热点。本文的研究工作主要是基于视觉的手势识别技术，包括基于视觉的静态手势识别和基于视觉的动态手势识别技术，并取得了如下成果：

（1）利用 Kinect 相机采集静态手势样本，包括 RGB 图像及其对应的深度图像，构建 8 种静态手势的样本集，用于本文静态手势识别算法的研究。

（2）在手部分割方面，提出了一种结合深度信息与肤色信息的手部分割算法，解决手部与复杂背景难以准确分离的问题。通过利用多个肤色样本训练得到的肤色模型对于肤色具有较强的鲁棒性。通过图像平滑、光照补偿、转换色度空间等方法避免噪声及光照强度对肤色分割效果的影响。本文手部分割算法在不同光照强度的复杂背景下仍能准确地检测出手部，通过实验验证了该算法在处理复杂环境的优势。

（3）在手臂去除方面，提出了基于距离变换的手臂去除算法，创新性地利用两次距离变换操作并结合手掌分割圆和八连通判别算法，能准确地定位掌心的位置，快速且有效地去除手部分割后存在冗余的手臂区域。通过与其它文献介绍的方法进行对比实验，论证了本文手臂去除算法在运算复杂度及分割准确度上具有明显的优势，能够准确去除手臂的同时也符合手势交互系统对实时性的要求。

（4）在静态手势识别方面，研究不同的手势特征提取方式及手势分类方式对手势识别效果的影响，具体地研究基于传统人工设计特征的 SVM 分类器和基于自动特征提取的 CNN 分类器的性能差别。在相同的手势二值图像数据集上进行本文静态手势识别实验，本文利用手掌切割圆及八连通判别算法计算指尖个数，该特征与提取的 Hu 矩一起构成静态手势的特征向量，最终训练得到识别率为 96.39%的 SVM 手势分类器。对于相同的静态手势分类任务，本文设计了一个 10 层的 CNN 用于自动提取合适的手势特征并分类，采用数据增强的方式能够提高 CNN 分类器的鲁棒性和表达能力，本文训练得到的 CNN 手势分类器识别率为 99.75%，与 SVM 手势分类器相比具有更好的识别效果。

中国知网 https://www.cnki.net

同时，本文也借助 SVM 算法对比了不同的手臂去除算法的分割效果对分类器性能的影响，进一步论证了手臂去除操作的重要性，能够提高手势分类器的分类准确率。实验结果证明采用本文手臂去除算法实现的 SVM 手势分类器对 8 种静态手势的识别率高。

（5）在动态手势识别方面，提出了基于 3D CNN 和 ConvLSTM 的网络模型，该模型能够很好地捕捉输入视频图像序列中手势在时空域的特征信息。在 SKIG 公共数据集上，本文将不同模态数据作为该网络模型的输入，分别训练两种单模态网络模型，实验证明该网络能够很好地识别不同模态数据下的动态手势，最后通过模型融合的方法能够进一步提升动态手势的分类准确率，达到 98.67%。

本文手势识别算法并不局限于数据集中定义的手势类型，我们可以将其推广应用到更多的手势类型。丰富的手势类型对应着丰富的控制指令输出，进而提高了手势交互系统的实用性。

2. 工作展望

本文主要研究的是基于视觉的手势识别技术，在一定程度上取得了成果，但仍然存在着不足之处，后续可以从以下几个方面进行完善：

（1）本文的静态手势样本集只由三个对象采集得到，由于数据采集的对象比较少可能导致数据集提供的信息不够全面，后续可以增加不同肤色、不同年龄层的对象进行数据采集，提供更加全面的样本信息。

（2）在训练 SVM 分类器时，可以尝试提取更多有效的手势特征，采用多特征融合的方式能够进一步提升 SVM 分类器的性能。

（3）本文均利用 Kinect 捕捉的多模态数据进行手势识别算法的研究，解决复杂背景下手势识别率不高的问题。由于需要用到 Kinect，本文提出的手势识别算法并不总适用于一些系统中，如谷歌眼镜。因此，复杂背景下基于单目视觉的手势识别技术有着重要的研究意义。

中国知网 https://www.cnki.net

参考文献

[1] Bartlett, Joel F. . Rock 'n' Scroll Is Here to Stay[J]. IEEE Comp.graph.ap, 2000, 20(3):40-45

[2] CemilOz, Leu M. C. . American Sign Language word recognition with a sensory glove using artificial neural networks[J]. Engineering Applications of Artificial Intelligence, 2011, 24(7): 1204-1213

[3] Lee C. , Xu Y. . Online, Interactive Learning of Gestures for Human/Robot Interfaces[J]. Proceedings IEEE International Conference on Robotics & Automation, 1999, 4:2982-2987

[4] 焦圣品，徐大海，白英彩. 手势识别的神经网络方法[J]. 微型电脑应用，1999, (05):28-30+65

[5] 曾芬芳，王颖，黄国建, et al. 基于模糊神经网络的手势识别[J]. 小型微型计算机系统, 2000, 21(7):706-709

[6] 徐德友. 虚拟现实训练系统中基于手势的人机交互[J]. 系统仿真学报，2006, 018(z2):386-389

[7] 李辉. 基于数据手套的手语手势识别及应用[D]. 2018

[8] Dominio F. , Donadeo M. , Zanuttigh P. . Combining multiple depth-based descriptors for hand gesture recognition[J]. Pattern recognition letters, 2014, 50(dec.1):101-111

[9] Pugeault N. , Bowden R. . Spelling it out: Real-time ASL fingerspelling recognition[C]. IEEE International Conference on Computer Vision Workshops28, 2011:1114-1119

[10] Dong L. , Wang H. , Hao Z. , et al. Robust hand posture recognition based on RGBD images[C]. Chinese Control and Decision Conference, 2014:2735-2740

[11] Chan C. , Mirfakhraei S. S. . Hand Gesture Recognition using Kinect[D]. Boston: Boston University, 2013

[12] Bowden R. , Windridge D. , Kadir T. , et al. A Linguistic Feature Vector for the Visual Interpretation of Sign Language[J]. 2004

[13] 高静雅. 人机交互中的手势识别技术研究[D]. 西安电子科技大学, 2013

[14] 覃文军. 基于视觉信息的手势识别算法与模型研究[D]. 东北大学, 2010

[15] Padam Priyal S. , Bora P. K. . A robust static hand gesture recognition system using geometry based normalizations and Krawtchouk moments[J]. Pattern Recognition, 2013, 46(8):2202-2219

[16] 成信宇. 基于手臂去除的静态数字手势识别[D]. 西南大学, 2014

中国知网 https://www.cnki.net

[17] Cheng H. , Dai Z. , Liu Z. , et al. An Image-to-Class Dynamic Time Warping Approach for both 3D Static and Trajectory Hand Gesture Recognition[J]. Pattern Recognition, 2016, 55(C):137-147

[18] Ibañez R. , Soria, álvaro, Teyseyre A. , et al. Approximate String Matching: A lightweight approach to recognize gestures with Kinect[J]. Pattern Recognition, 2016, 62:73–86

[19] Miranda L. , Vieira T. , Martínez, Dimas, et al. Online gesture recognition from pose kernel learning and decision forests[J]. Pattern Recognition Letters, 2014, 39:65-73

[20] 李云峰, 张澎悦. 基于 GLCM 和 Gabor 纹理特征的手势识别算法[J]. 计算机应用与软件, 2019, (7)

[21] 张晓燕. 基于肤色和模板匹配的静态手势识别[J]. 电子世界, 2019, (15)

[22] 邹潇, 郑庆庆, 李冰. 基于 Kinect 传感器和 HOG 特征的静态手势识别[J]. 软件导刊, 2018

[23] 邓志国. 基于 BP 神经网络的静态手势识别方法[J]. 华东交通大学学报, 2005, 22(05):92-93+112

[24] 甘志杰. 基于 Hu 矩和支持向量机的静态手势识别及应用[D]. 青岛科技大学, 2008

[25] Lawrence S. , Member, IEEE, et al. Face Recognition: A Convolutional Neural-Network Approach[J]. IEEE Transactions on Neural Networks, 2002, 8(1):98-113

[26] Ren, Shaoqing, He, Kaiming, Girshick, Ross, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2015, 39(6):1137-1149

[27] 纪国华.基于组合色彩空间和卷积神经网络的手势识别算法[J].现代计算机, 2019, (29):52-55+67

[28] 吕华富. 基于卷积神经网络的静态手势识别研究[J]. 现代计算机(专业版), 2018, (6)

[29] 蔡娟, 蔡坚勇, 廖晓东, et al. 基于卷积神经网络的手势识别初探[J]. 计算机系统应用, 24, (4)

[30] 操小文, 薄华. 基于卷积神经网络的手势识别研究[J]. 微型机与应用, 2016, 35(9):55-57, 61

[31] 杨文斌, 杨会成. 基于卷积神经网络的手势识别方法[J]. 安徽工程大学学报, 2018, 33(1): 41-46

[32] 任海兵, 祝远新, 徐光祐, et al. 连续动态手势的时空表观建模及识别[J]. 计算机学报, 2000, 23(8):824-828

[33] 于美娟, 马希荣. 基于 HMM 方法的动态手势识别技术的改进[J]. 计算机科学, 2011,

中国知网 https://www.cnki.net

38(1):251-252

[34] 魏佳. 基于条件随机场的动态手势识别技术研究[J]. 才智, 2011, (07):80-81

[35] Wang X. , Xia M. , Cai H. , et al. Hidden-Markov-Models-Based Dynamic Hand Gesture Recognition[J]. Mathematical Problems in Engineering, 2012, 2012(PT.5):p.13.1-13.11

[36] 王西颖, 戴国忠, 张习文, et al. 基于 HMM-FNN 模型的复杂动态手势识别[J]. 软件学报, 2008, (09):142-152

[37] Simonyan K. , Zisserman A. . Two-Stream Convolutional Networks for Action Recognition in Videos[J]. Advances in neural information processing systems, 2014

[38] Donahue J. , Hendricks L. A. , Guadarrama S. , et al. Long-term recurrent convolutional networks for visual recognition and description[C]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2015

[39] Li Z. , Gavrilyuk K. , Gavves E. , et al. VideoLSTM Convolves, Attends and Flows for Action Recognition[J]. Computer Vision and Image Understanding, 2017, S1077314217301741

[40] JI S. W. , XU W. , YANG M. , et al. 3D convolutional neural networks for human action recognition[J]. IEEE Transac-tions on Pattern Analysis and Machine Intelligence, 2013, 35(1) : 221-231

[41] Tran D. , Bourdev L. , Fergus R. , et al. Learning Spatiotemporal Features with 3D Convolutional Networks[J]. 2014

[42] Molchanov P. , Gupta S. , Kim K. , et al. Hand gesture recognition with 3D convolutional neural networks[C]. 2015 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). IEEE, 2015

[43] Camgoz N. C. . Using Convolutional 3D Neural Networks for User-Independent Continuous Gesture Recognition[C]. IEEE International Conference of Pattern Recognition. IEEE, 2016

[44] 曹建秋, 王华清, 蓝章礼. 基于改进 YCrCb 颜色空间的肤色分割[J]. 重庆交通大学学报自然科学版, 2010, 29(3):488-492

[45] Koura G. E. , Singh K. . Handrix: Animating the Human Hand[C]. Eurographics/sigraph Symposium Computer Animation, 2003

[46] Lecun Y. , Bottou L. , Bengio Y. , et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324

[47] Hu M. K. . Visual Pattern Recognition by Moment Invariants[J]. Information Theory, IRE Transactions on, 1962, 8(2):179-187

中国知网 https://www.cnki.net

[48] Zhou Y. , Jiang G. , Lin Y. . A novel finger and hand pose estimation technique for real-time hand gesture recognition[J]. Pattern Recognition, 2016, 49(C):102-114

[49] Liu L. , Shao L. . Learning discriminative representations from RGB-D video data[C]. Twenty-third International Joint Conference on Artificial Intelligence. AAAI Press, 2013

[50] Cirujeda P. , Binefa X. . 4DCov: A Nested Covariance Descriptor of Spatio-Temporal Features for Gesture Recognition in Depth Sequences[C]. International Conference on 3D Vision. IEEE, 2014

[51] Nishida N. , Nakayama H. . Multimodal Gesture Recognition Using Multi-stream Recurrent Neural Network[C]. Pacific-Rim Symposium on Image and Video Technology. Springer International Publishing, 2016

中国知网 https://www.cnki.net

攻读硕士学位期间取得的研究成果

一、已发表（包括已接受待发表）的论文，以及已投稿、或已成文打算投稿、或拟成文投稿的论文情况（只填写与学位论文内容相关的部分）：

序号	作者（全体作者，按顺序排列）	题　　目	发表或投稿刊物名称、级别	发表的卷期、年月、页码	相当于学位论文的哪一部分（章、节）	被索引收录情况
1	许冰媛、周智恒、陈曦、杨溢、杨志伟	Arm removal for static hand gesture recognition	Journal of Intelligent and Fuzzy Systems	2018 年 11 月 Vol.35, pp:6489-6500	第二、三章	SCI
2	许冰媛、周智恒、黄俊楚、黄宇	Static Hand Gesture Recognition Based on RGB-D Image and Arm Removal	Fourteenth International Symposium on Neural Networks	2017 年 5 月 Vol.10261, pp:180-187	第二、三章	EI
3	黄俊楚、周智恒、许冰媛、黄宇	Accelerating Stochastic Variance Reduced Gradient Using Mini-Batch Samples on Estimation of Average Gradient	Fourteenth International Symposium on Neural Networks	2017 年 5 月 Vol.10261, pp:346-353		EI

二、与学位内容相关的其它成果（包括专利、著作、获奖项目等）

[1]　实用新型：基于 Qt 图形界面的老人跌倒检测装置，申请号 CN201721667030.3，申请日 2017-12-04，周智恒，许冰媛，授权日 2018-07-13

[2]　发明专利：一种基于多特征融合的单目静态手势识别方法，申请号 CN201810900949.5，申请日 2018-08-09，周智恒，许冰媛

[3]　发明专利：一种结合深度信息与肤色信息的静态手势识别方法，申请号 CN201810900948.0，

中国知网　https://www.cnki.net

申请日 2018-08-09，周智恒，许冰媛

[4] 发明专利：一种基于 Leap Motion 的动态手势识别方法，申请号 CN201811264834.8，申请日 2018-10-29，周智恒，许冰媛，陈曦

[5] 发明专利：一种基于多尺度特征切割与融合的行人重识别方法，申请号 CN201910014322.4，申请日 2019-01-08，张昱晟，黄昌正，周智恒，许冰媛，陈曦，肖芸榕

[6] 发明专利：基于 3D 卷积和 SPP 的多模态动态手势识别方法，申请号 CN2019114233531，申请日 2019-12-27，彭永坚，汪壮雄，许冰媛，周智恒，彭明，朱湘军

[7] 发明专利：一种高效率的双频平面无线能量传输系统，申请号 CN201610463153.9，申请日 2016-06-21，章秀银，许冰媛，林杰凯，李斌，授权日 2019-08-20

中国知网 https://www.cnki.net

致谢

时光飞逝，转眼三年的华工研究生生涯即将结束。这三年里，我收获颇丰，指引我前行的良师，给予我鼓励与帮助的益友，都是这段旅程中宝贵的财富。在这段旅程结束之时，我将带着这些温暖，开始新的旅程。

首先向我的导师周智恒老师表达真挚的感谢。研究生期间，周老师严谨的治学态度、实事求是的工作作风以及诲人不倦的教学品德都深深的影响着我，让我在学习工作中能够严格要求自己，用心对待每一件事情。同时也感谢周老师在生活上对我给予关怀与帮助。在以后的职业生涯中谨记周老师的指导，在这里再次向尊敬的周老师表示衷心的感谢和崇高的敬意。

同时感谢实验室的傅予力老师、李波老师、向友君老师、唐杰老师、余卫宇老师的指导与关怀，他们的言传身教将铭记于心。

感谢实验室的师兄师姐们志辉、雨锟、曹前、立军、鹏宇、汝正、俞政、楷怡、沛江、江慧等的关心和帮助。感谢实验室同窗昱晟、黄宇、俊楚、芸榕、静慈、邱昱、汉铿、维翔、郑涛、凯敏、嘉旭的一路陪伴与共同成长。感谢增群、怡凡、丹阳等师弟师妹们的支持与关怀。

感谢我的舍友子娟、立姣、杨莲，你们在生活、学习以及工作中都给予我很多帮助，让我的研究生生活充满欢声笑语。

感谢一直支持鼓励我的家人们和亲朋好友，感谢我的父母、爷爷、奶奶、哥哥、嫂子、侄子以及男友，你们对我的包容、理解和支持，是我不断进步的动力。

最后，感谢审阅这篇论文的各位老师和专家。

祝愿我的老师、同学、家人都能有一个健康快乐的人生。

中国知网 https://www.cnki.net

3.答辩委员会对论文的评语

（主要内容包括：1.对论文的综合评价；2.对论文主要工作和创造性成果的简要介绍；3.对作者掌握基础理论、专业知识程度、独立从事科研工作能力以及在答辩中表现的评价；4.存在的不足之处和建议；5.答辩委员会结论意见等）

该论文着重对基于视觉的手势识别技术展开研究。

论文主要工作有：

（1）利用 Kinect 相机提供的深度信息结合手部的肤色信息进行手部分割，解决单目静态手势识别中存在的人手与复杂背景难以准确分离的问题。

（2）对静态手势分割得到的手势二值图像提取特征并利用卷积神经网络进行手势分类。

（3）利用 3D 卷积神经网络和卷积 LSTM 网络捕捉视频图像序列的时空特征，并利用 SPP 网络提取局部特征和全局特征，最终输入全连接网络实现了准确率高的动态手势识别。

（4）搭建手势识别测试环境对算法性能进行了测试，验证提出算法的有效性。

论文资料收集齐全，条理清楚，论证充分，结论和数据可信，论文撰写规范，在答辩过程中，作者表述较为清楚，条理清晰，能描述论文的研究成果，回答问题基本准确。

经答辩委员会讨论表决，认为该生的论文达到了工程硕士专业学位论文水平，通过论文答辩，建议授予工程硕士学位。

论文答辩日期：2020 年 6 月 6 日　　答辩委员会委员 5 人

表决票数：同意毕业及授予学位（5）票

同意毕业，但不同意授予学位（　）票

不同意毕业（　）票

表决结果（打"√"）：同意毕业及授予学位（√）

同意毕业，但不同意授予学位（　）

不同意毕业（　）

答辩成员签名	（主席）		
答辩秘书签名			

中国知网 https://www.cnki.net