南京大學
NANJING UNIVERSITY

研 究 生 毕 业 论 文

（申请硕士专业学位）

论 文 题 目 手势行为的识别及语义表征技术

作 者 姓 名 白云超

专 业 名 称 控制工程

研 究 方 向 智能信息处理与智能系统

指 导 教 师 周献中 教授

2020 年 5 月 28 日

中国知网 https://www.cnki.net

学　　号：MF1715036

论文答辩日期：2020 年 5 月 28 日

指 导 教 师：

中国知网 https://www.cnki.net

Recognition and Semantic Representation Techniques of Gesture Behavior

A Dissertation Submitted to Nanjing University for the Professional

Degree of Master of Control Engineering

By

BAI Yun-chao

Supervised by

Prof. ZHOU Xian-zhong

School of Management & Engineering

Nanjing University

May 2020

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

南京大学研究生毕业论文中文摘要首页用纸

毕业论文题目：手势行为的识别及语义表征技术

控制工程 专业 2017 级硕士生姓名：白云超

指导教师（姓名、职称）：周献中 教授

摘要

随着科技的发展，人机交互技术的应用越来越广泛，而“以人为本”的交互理念也慢慢得到关注。人机交互中的手势交互是主流的交互方式之一，通过视觉进行的手势交互广泛应用在汽车、医疗以及体感游戏等诸多领域中。与此同时，人工智能的飞速发展，将基于视觉的手势识别技术提升了一个新的高度。因此，本文将人工智能、认知科学和虚拟现实等多个领域的技术进行融合，实现了基于普通二维摄像头图像的手势动作识别，并用自然的手势动作控制虚拟系统中的无人机飞行。

为了实现二维摄像头下的手势识别，本文采用深度学习技术提取人体的骨骼关节点，设计出 Pose-Hand 模型，能将人体的关节点以及手部的关节点全部提取出来，这为手势识别奠定了较好的基础。在手势识别算法设计上，利用基于位置关系和基于深度学习这两种方法进行识别，无论对简单手势还是对复杂手势都能够有效快速的识别。同时，为了体现“以人为本”的观念，本文研究了手势动作的语义表征技术，通过手势控制无人机的行为实验，采集大量实验数据，建立了手势控制无人机的语义表征模型。最后，为了验证手势识别模型的准确率以及手势语义表征模型，搭建了手势控制无人机的虚拟交互系统，通过虚拟交互系统展示了手势控制无人机的效果。

关键词：关节点获取，手势识别，手势语义表征，虚拟现实

中国知网 https://www.cnki.net

南京大学研究生毕业论文英文摘要首页用纸

THESIS: Recognition and Semantic Representation Techniques of Gesture Behavior

SPECIALIZATION: Control Engineering

POSTGRADUATE: BAI Yun-chao

MENTOR: Prof. ZHOU Xian-zhong

Abstract

With the development of science and technology, the application of human-computer interaction technology has become more and more widespread, and the "people-oriented" interaction concept has gradually attracted attention. Gesture interaction in human-computer interaction is one of the most mainstream interaction methods. Gesture interaction through vision is widely used in many fields such as automotive, medical and somatosensory games. At the same time, the rapid development of artificial intelligence has taken vision-based gesture recognition technology to a new level. Therefore, this paper integrates technologies in many fields such as artificial intelligence, cognitive science, and virtual reality to realize gesture recognition based on ordinary two-dimensional camera images, and use natural gestures to control drone flight in virtual systems.

In order to realize gesture recognition under the two-dimensional camera, this paper uses deep learning technology to extract human bone joint points. And this paper designs a Pose-Hand model, which can extract all joint points and joint hands of the human body, which lays a good foundation for gesture recognition. In the design of gesture recognition algorithms, two methods based on positional relationship and deep learning are used for gesture recognition, which can effectively and quickly recognize simple gestures and complex gestures. At the same time, in order to reflect the "people-oriented" concept, this paper also studies the gesture semantic

中国知网 https://www.cnki.net

representation technology of gesture-controlled drones. Through the behavior experiments of gesture-controlled drones, a large amount of experimental data is collected to establish a semantic representation model of gesture-controlled drones. Finally, in order to verify the accuracy of the gesture recognition model and the gesture semantic representation model, a virtual simulation system for gesture-controlled drones was also built, and the effect of gesture-controlled drones was demonstrated through the virtual simulation system.

Keywords: Get Skeleton-Image, Gesture Selection, Gesture Semantics, Virtual Reality

中国知网 https://www.cnki.net

目录

摘要 I

Abstract II

目录 IV

第一章 绪论 1

1.1 研究背景及意义 1

1.2 国内外研究现状 2

1.2.1 手势识别技术研究现状 2

1.2.2 手势语义表征研究现状 4

1.2.3 虚拟人机交互系统研究现状 5

1.3 研究内容与章节安排 6

1.3.1 研究内容 6

1.3.2 章节安排 7

1.4 本章小结 8

第二章 人体骨骼数据的获取 9

2.1 基于 Kinect 骨骼信息的获取 9

2.2 基于深度学习的骨骼检测方法 10

2.2.1 单人骨骼关节点检测 10

2.2.2 多人骨骼关节点检测 12

2.3 Pose-Hand 全身骨骼点检测模型 13

2.3.1 Pose-Hand 模型流程架构 14

2.3.2 Pose-Hand 模型网络结构 15

2.3.3 Pose-Hand 模型训练 16

2.4 本章小结 18

第三章 基于骨骼信息的动态手势识别研究 19

3.1 基于位置关系的手势识别研究 19

3.2 基于深度学习的动态手势识别模型建立 20

3.2.1 视频关键帧提取 21

中国知网 https://www.cnki.net

3.2.2 动态手势识别模型设计 23
3.3 手势行为识别的动态模型 28
3.5 本章小结 29
第四章 手势语义表征建模以及手势识别实验 31
4.1 手势操控无人机行为实验设计 31
4.2 基于操控无人机的手势语义表征建模 32
4.2.1 手势语义的行为分析 32
4.3.2 构建手势语义信息表 34
4.3 操控无人机相关手势的识别 35
4.3.1 简单手势的识别 35
4.3.2 复杂手势的识别 37
4.5 本章小结 40
第五章 虚拟环境搭建以及手势控制演示 41
5.1 虚拟无人机交互系统设计 41
5.2 虚拟场景搭建 42
5.3 实时通信模块设计 44
5.4 功能显示模块设计 46
5.5 本章小结 48
第六章 总结与展望 50
6.1 工作总结与创新点 50
6.2 工作展望 51
致谢 52
参考文献 53
攻读硕士学位期间的学术成果和参与的科研项目 59

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

随着时代的发展，人机交互受到越来越多人的关注，手势交互作为人机交互的主要通道之一，是交互领域重要的研究话题[1]。手势动作灵活多变，所表达的语义规律性强，因此手势交互相比其他人机交互方式有非常大的优势。例如手势交互相比眼动交互使用更方便，表达的信息更丰富；手势交互相比语音交互的使用环境更广泛；手势交互相比脑电交互更准确、高效[2]；甚至手势交互在某些方面相比传统的鼠标，键盘和触屏等交互方式也更直接方便[3]。因此手势交互现在已经应用于多个领域，例如智能驾驶、体感游戏、虚拟现实和指挥控制等等。

传统的交互方式都是以机器为“主体”，人类要按照相应的规定去操作，实际上在机器面前人类更像“机器”。而未来的交互方式要转换为“以人为本”，即人与机器之间实现更自然的交流，这需要让机器更好的理解人类的意图。手势交互也正朝着“以人为本”的方向发展，目前已经出现了非常多的智能设备和智能算法来实现手势交互。但是这些只是在表层加速手势交互的发展，如何从根本上解决“以人为本”的发展瓶颈，是目前人机交互的迫切之需。语义表征是高度双边的，具有功能对称性，在自然语言处理（NLP）和认知心理学中都有重要的作用[4]。而人机交互或者手势交互也是人与机器双边理解的，即人要知道机器的功能，机器要理解人类的动作。因此，将语义表征技术运用在人机交互方向中是未来发展的必然所需。

作为手势交互的关键技术，手势识别受到了越来越多的关注[5]。其中，手势是指手部或手臂的各种姿态和动作，它包括静态手势和动态手势，静态手势可以表示成一个姿态，在空间中可以看作一个点[6]，而动态手势可以表示成在一定时间内完成的一个手势动作，在空间中对应着一条轨迹，是拥有时间变化的动作特征。而手势识别是指通过智能算法或者智能设备来识别人类手势，将手势动作转换成机器可以理解的信息，从而实现手势与机器之间的交互[7]。目前，手势主要是基于图像基础上进行识别的，无论是二维图像还是三维图像，几乎都是通过各种摄像头采集得到的[8]。近年来，随着深度学习的不断发展以及计算机配置不断

中国知网 https://www.cnki.net

提高，基于深度学习中的图像算法成为手势识别的关键技术[9-12]。基于深度学习的手势识别算法可以利用普通的二维摄像头实时识别动态手势，这是传统的动态手势识别算法无法比拟的，虽然这方面已经取得了一些成果，但是手势动作多样性和复杂性等因素的影响，仍然有很大的进步空间。

与此同时，随着虚拟仿真系统的不断进步和发展，虚拟人机交互技术也逐渐渗透到生活中，成为人们日常生活中的一部分。在现代生产生活体系里，随着社会对人机交互技术能力的需求不断增加，为了能够更加直观、真实和形象的模拟人机交互的场景，越来越多的人选择利用虚拟人机交互技术进行模拟训练[13]。这一技术可以提高训练效果，降低训练成本，为在真实场景操作提供充足的准备。同时，在娱乐场所中，虚拟人机交互技术得到广泛的应用，它能使人们在有限的空间中体验各种娱乐场景，进行各种操作，是娱乐场所中最受欢迎的项目之一。甚至，在军事演习中，虚拟人机交互技术也广泛的应用到各国军队。但是目前虚拟人机交互系统中大都采用穿戴式设备，使用者体验感在某些方面将受到很大的影响，因此基于非接触式的虚拟人机交互技术将得到广泛的推广。

综上所述，将基于普通二维摄像头下的动态手势识别与手势语义表征技术结合，将是手势交互主要发展方向。利用虚拟人机交互系统将手势行为识别算法和语义表征技术进行验证和推广，将加速人机交互技术的迭代更新。

1.2 国内外研究现状

随着科技的发展，手势行为已经在人机交互、临床诊断以及虚拟现实等诸多领域表现出巨大的应用价值，很多国内外学者、机构都已经对手势行为的识别和手势行为的语义表征技术进行了不同深度的探索。

1.2.1 手势识别技术研究现状

随着人机交互技术的不断发展，基于人机交互技术的手势动作识别研究吸引了众多研究者的关注。人体姿态识别最早由 Johansso 等人研究，他们将荧光标签贴在人体的关节点处，然后采集人体的动作样本，并探索关节点的旋转特性与人体动作之间的关系，最后通过大量的实验数据说明利用人体骨骼关节点能够很

中国知网 https://www.cnki.net

好的预测人体的动作[14]。目前，最常用的手势识别方法是基于接触式识别和基于计算机视觉识别。

其中，基于接触式手势识别的方法主要包括利用数据手套和 MYO 臂环，如图 1-1 所示。目前，市场上已经出现多款数据手套，它们主要是通过在手套中嵌入多款传感器，利用这些传感器测量出每个手指的指关节和顶部关节的手部方向，以及拇指方向和弯曲方向，进而准确的识别出手势动作[15]。MYO 臂环是由加拿大一个创业公司研发的，它的内部安装的有陀螺仪、加速计和磁场计等传感器，当用户执行不同手势时，前臂上的肌肉会发出不同的电子信号，MYO 臂环可以检测出这些电子信号，从而判断出手势动作[16]。无论是数据手套还是 MYO 臂环在使用时都必须保持手部干燥清洁，如果手部容易出汗，则不适合使用这些设备。

(a) 数据手套 (b) MYO 臂环

图 1-1 数据手套和 MYO 臂环

基于计算机视觉的手势识别主要利用深度摄像机和普通二维摄像机采集动作图像。Neuman 等人采用基于激光技术的深度相机获取人体的深度图像，并对深度图像中的手部进行三维重构建，从而实现对手势识别的功能[17]。Kinect 作为经典的深度摄像机，已经有多人利用 Kinect 研究手势识别[18-22]，例如 Rodrigo 等人提出了一种基于 Kinect 的多层手势识别方法，该方法根据不同手势动作的关节骨骼姿态不同，并利用加权动态时间规整算法（DTW）对手臂关节进行定位，从而确定手势动作的类型[18]。同时 Shotton 等人提出一种利用 Kinect 深度图像识别人体动作的方法，通过对 Kinect 采集的每帧深度图片进行初始化处理，通过对比学习相邻两帧图片的差别，识别出人体的姿态动作，相比于其他手势识别的方法，该方法鲁棒性更强，手势识别准确率更高[22]。

在利用普通的二维摄像机识别手势动作时，主要是基于传统的识别算法和基

中国知网 https://www.cnki.net

于深度学习的识别算法。基于传统的算法识别手势时，需要对采集的图像进行多次处理，首先需要将手部分割出来，然后在对分割出来的手部进行跟踪处理，进而提取出手势的特征，最后识别出手势的类型[23-24]。Carmona 等人利用传统的手势识别算法研发了一个可以识别手势的工具，在识别手势类型时，同时支持动态时间规整算法和隐马尔科夫识别算法，利用封装好的工具，极大的简化了手势识别的过程[24]。基于深度学习的手势识别算法主要是利用卷积神经网络对图像进行处理分类[25-27]。其中，Sunmok 等人基于目标检测中 YOLO(You Only Look Once)算法实现对静态手势的识别，他们首先利用区域检测的方法分割出手势所在的区域，然后识别出该区域手势的类型[25]。同样张勋等人利用改进的 SSD(Single Shot MultiBox Detector)算法实现静态手势识别，他们将原方法的特征提取网络 VGG16 用改进的卷积神经网络 AlexNet 取代，将手势作为一个目标进行检测识别[26]。而对于动态手势识别，Molchanov 等人做了大量工作，开始先将手势动作的多模态数据进行融合，即利用普通图像、深度图像和雷达数据进行融合，然后在用基于卷积神经网络进行训练识别[8]。后来 Molchanov 等人又使用 3D 卷积神经网络训练动态手势，并且他们将手势识别模型分为高分辨率和低分辨率两个子网络，最终结果是将两个子网络的识别结果融合得到的[10]。基于深度学习的手势识别算法虽然对计算机性能要求较高，但是简化了手势识别的过程，极大的促进了手势识别的发展。

1.2.2 手势语义表征研究现状

在人机交互中，手势行为的语义表征是一种特殊的语义对象，是指操作者通过手势对某个物体在执行交互任务过程中，根据操作者与物体双方的响应和反馈，产生的规律习惯[28]。因此，在研究手势行为的语义表征时需要在规定的任务场景下，对应着某一类的交互目标而产生具有特殊含义的手势动作。交互目标根据识别出的手势语义信息做出不同的交互反应，即交互目标不仅参考手势识别的结果，还要了解这类手势的语义，进而形成相关指令。

在手势交互的实际应用中，主要是把指令与规定好的手势结合，使用者必须严格按照操作手册完成相应的动作指令[29]。例如利用手势控制无人机起飞，不同人的操作方式不同，有人习惯右手抬起，有人习惯左手抬起等等，并没有一个

中国知网 https://www.cnki.net

标准的手势指令[30]。目前对于大多数涉及语义表征技术的相关研究主要是通过检测结果-语义分类的方式进行简单的概况分类，然而这样的分类其实并不能有效解决人机交互中的实际问题[31]。同样，目前有不少研究者将手势语义表征与手势识别相结合，例如张延芳等人提出了一种认知行为模型，他们将任务与手势动作分解，通过分析手势语义建立状态转移概率矩阵，进而建立了基于认知行为模型的语义手势识别算法[4]。乔宇等人提出了一种多种手势到同一语义的映射模型，在实际手势交互系统中，考虑手势识别设备识别错误或者没有识别出手势时，会影响交互系统，甚至导致错误的交互指令，因此他们将多种手势映射到同一语义中，使手势交互系统准确率更高、更流畅[32]。

1.2.3 虚拟人机交互系统研究现状

虚拟人机交互系统是指利用虚拟现实仿真技术构建三维虚拟场景，并利用人机交互技术生成一个实时的测控系统，使用户能够通过自然的人机交互完成操作内容[33]。近年来，虚拟人机交互系统飞速发展，已经广泛应用在军事领域、教育领域、医疗领域以及相关工业领域等[34]。随着5G的到来，虚拟人机交互系统再次迎来新的发展空间，与人机交互技术相结合，促进了科技的进步。

随着科技水平不断提高，国内外越来越多的研究学者以及科研机构也加速了对虚拟人机交互系统的研究，并且取得了众多实用性的研究成果[35-38]。瑞典的BTH实验室研发了一套虚拟电路仿真系统，登录该系统的用户在虚拟系统中进行任意的电路设计和连接，同时用户还可以测量电路中每个节点的参数[35]。胡素芸等人根据宇航员在地面训练的要求，设计了一套宇航员虚拟训练的人机交互系统，并开发了具有真实感和存在感的多自由度臂力反馈装置，使宇航员在虚拟训练环境中实现了抓握、推拉等各种交互操作，增强了虚拟环境的沉浸感，提高了模拟训练的逼真度[36]。浙江大学开发了一套基于桌面现实的虚拟漫游交互系统，该系统不仅满足了用户对立体视觉的要求，而且还结合了先进的交互工具，使得用户在沉浸感和参与感上达到了很高的水准[37]。王兴鲁等人提出利用Kinect与Unity3D结合的方式，将人体动作与虚拟人物同步，利用骑行交互平台装置，实现在虚拟场景中骑行的任务[38]。

中国知网 https://www.cnki.net

虚拟人机交互系统已经慢慢从理论逐步推广到人们的日常生活中，而手势交互相较于其他非接触式交互应用的场景也比较多，因此利用虚拟人机交互系统与手势识别相结合，具有较大的发展空间和应用场景。

1.3 研究内容与章节安排

1.3.1 研究内容

本文主要对动态手势识别技术、手势语义表征的建模分析以及虚拟人机交互系统进行充分研究。其中，动态手势识别算法是在普通摄像头采集的二维图像视频下识别的，首先将人体动作视频转换成骨骼动作视频，然后利用基于位置关系和深度学习模型两种方法进行手势识别。手势语义表征模型是根据手势操作无人机行为实验采集的数据搭建的，通过对实验数据分析，得到手势动作与无人机操作指令的关系，进而分析手势的语义行为，最后与手势识别技术相结合，实现手势控制无人机的语义表征模型。虚拟人机交互系统是利用Unity 3D软件设计一个虚拟无人机操作环境，然后将动态手势识别算法与手势语义表征模型相结合应用到无人机的控制系统中，实现虚拟人机交互的演示。本文研究的主要内容如下：

（1）设计 Pose-Hand 全身骨骼关节点检测模型。本文是基于普通二维摄像头图像下进行手势动作识别的，考虑到图像中的冗余信息较多，将利用 Pose-Hand 模型提取图像中人物身体和手部的骨骼关节点，利用骨骼关节点信息进行手势动作识别。

（2）设计基于位置关系和深度学习的动态手势行为识别算法。针对手势动作多样性的特点，不同的手势动作利用不同的算法识别。对于简单的手势动作是直接通过骨骼关节点空间关系信息进行识别，而复杂的动态手势是利用深度学习技术设计的手势识别算法识别的。

（3）构建手势语义表征模型。为了促进人机交互朝着“以人为本”的方向发展，通过手势控制无人机的行为实验，研究控制无人机的手势行为语义表征方法，探索不同手势下行为语义的表征机理，从而建立手势行为语义的表征技术模型。

（4）搭建虚拟人机交互系统。将手势识别算法，手势语义表征模型与虚拟

中国知网 https://www.cnki.net

系统中的无人机相结合，因此需要利用虚拟仿真软件搭建虚拟无人机飞行环境，从而实现手势控制无人机的飞行。

1.3.2 章节安排

如图 1-2 所示，本文一共分为六章，每一章具体的研究内容介绍如下：

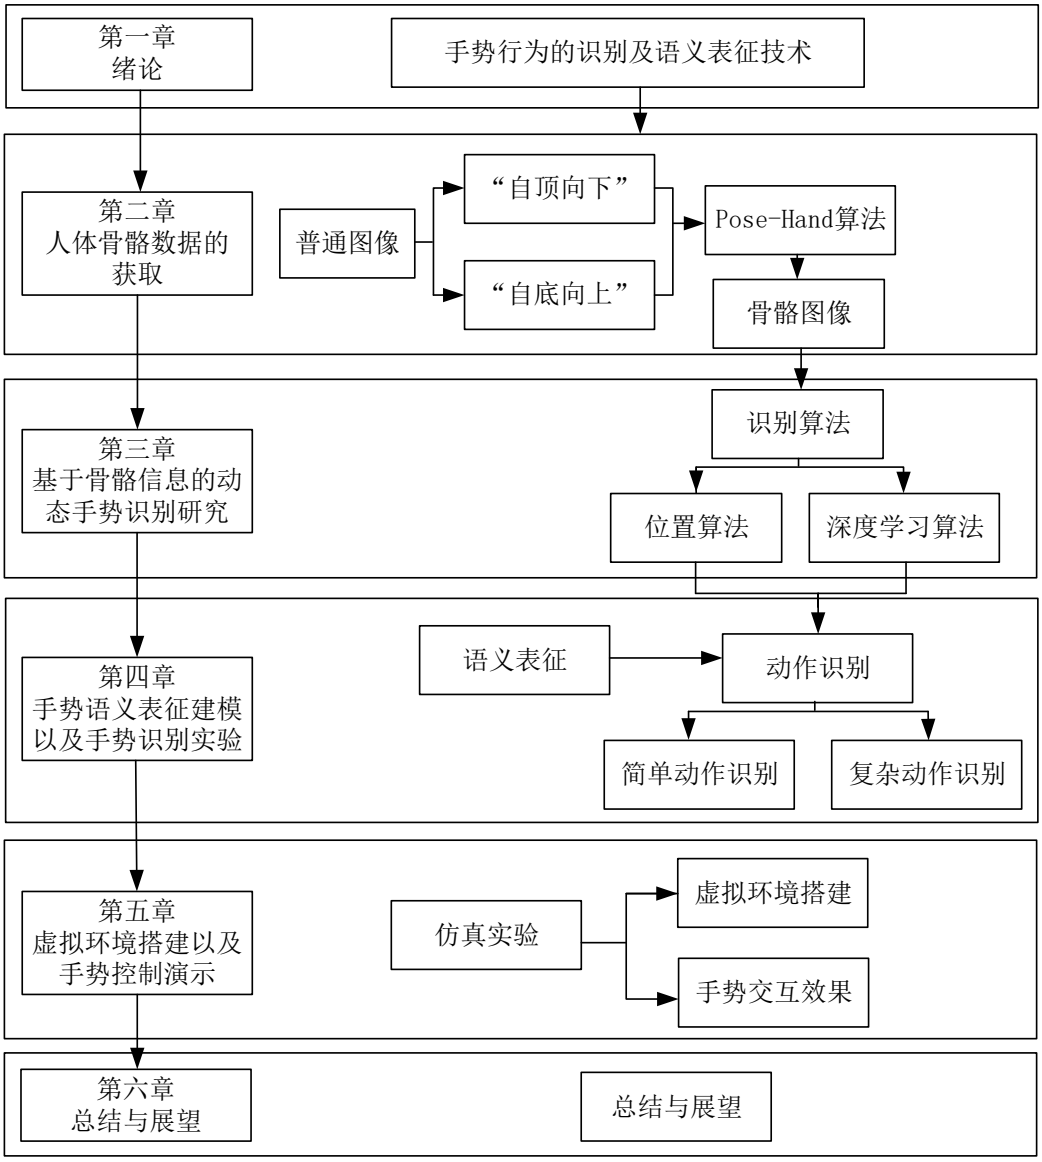

图 1-2 本文章节安排

第一章，绪论。主要介绍本文的研究背景和意义，以及手势识别、手势语义表征与虚拟人机交互系统的研究状况，并提出基于语义表征与手势识别结合的方法，引出本文的研究内容和章节安排。

中国知网 https://www.cnki.net

第二章，人体骨骼数据的获取。首先介绍目前提取人体骨骼关节点数据的方法，接着综合基于深度学习技术提取关节点的优势以及本文的需求，设计 Pose-Hand 模型，并对 Pose-Hand 模型进行详细的介绍。

第三章，基于骨骼信息的动态手势识别研究。介绍如何对人体手势动作进行识别，主要从两个方法研究：基于位置关系的方法和基于深度学习的方法。对简单的手势动作是通过骨骼关节点的位置关系信息进行识别；对于复杂动态手势是利用深度学习技术设计的具有注意力机制的手势识别算法识别的。最后对手臂和手掌的动作建立相应的手势识别动态模型，使得两种算法进行有效融合。

第四章，手势语义表征模型及手势识别实验。首先设计手势控制无人机的行为实验，然后利用实验数据，研究手势控制无人机的语义表征方法，探索不同手势行为语义的表征机理，从而建立手势行为语义的表征技术模型。最后确定待识别的手势后，验证手势识别算法识别简单手势动作和复杂手势动作的准确性。

第五章，虚拟环境搭建以及手势控制演示。详细介绍虚拟无人机场景搭建的过程和手势控制无人机的机理。首先对 Unity3D 虚拟场景搭建和手势识别模型的开发过程进行说明，然后介绍了手势识别模块与无人机之间的通信机理，最后，介绍虚拟场景中的无人机控制方法，结合手部动作实现对无人机运动轨迹的控制。

第六章，总结和展望。本章节主要对本文的研究内容和创新点做整体性的总结，并对在研究过程中存在的问题和不足给出解决办法，对未来的研究工作进行展望。

1.4 本章小结

本章主要介绍了本文的研究背景及意义，介绍了国内外机构和学者对手势识别技术、手势语义表征技术和虚拟人机交互系统的研究状况，并阐述了本文的研究内容和章节安排。

中国知网 https://www.cnki.net

第二章 人体骨骼数据的获取

针对基于彩色图像手势识别算法效率太低，无法做到实时识别手势动作的问题，本文采用人体骨骼关节点进行手势动作识别，这样既可以避免光照变化的影响，也可以免去外部场景、背景环境等因素的干扰[39-40]。本章首先介绍了目前人体骨骼数据获取的主流方法，然后根据本文手势识别的需求设计出 Pose-Hand 模型，并用该模型获取人体骨骼关节点和手部骨骼关节点。

2.1 基于 Kinect 骨骼信息的获取

Kinect 是微软公司研发的一款体感设备，主要用于人体动作的采集识别，Kinect 生成的骨骼图像是在深度图像的基础上获取的[41]。对于深度图的生成，Kinect v2 则采用了先进的 TOF 技术。该技术主要利用 Kinect 上的红外发射器的近红外光线，由于红外光线照到物体上就会发生反射，红外相机接收反射回来的红外线，通过计算近红外光线发射和反射的时间差或相位差，从而确定物体到 Kinect 的距离，进而产生深度图像[42]。然后 Kinect 利用分隔策略把深度图像中的人与背景区分开，在对分割出来的人体图像进行处理。当 Kinect 获取到人体的深度图像之后，利用 Exemplar 模型对人体各个节点进行检测定位。最后利用机器学习中决策树算法确定人体的各个关节点位置，并将其连接成人体形状。其具体流程如下图 2-1 所示，最终 Kinect v2 可以识别出人体的 21 个骨骼关节点。

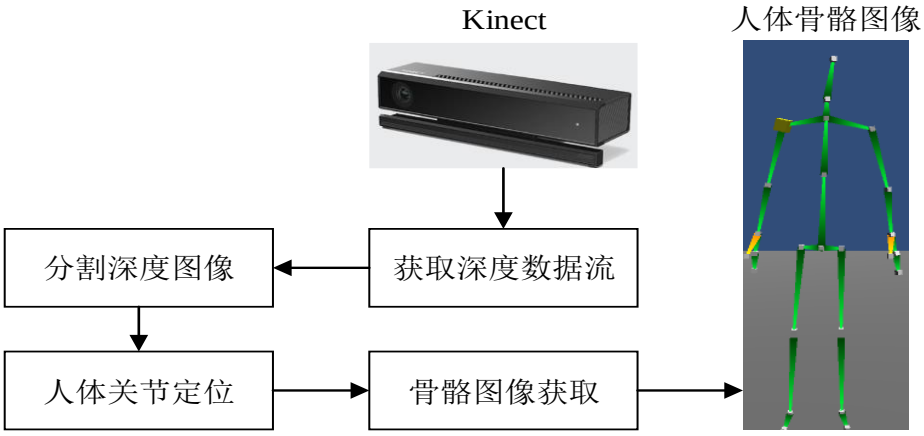

图 2-1 Kinect 骨骼图像获取流程

中国知网 https://www.cnki.net

Kinect 设备使用比较麻烦，普通用户接触不到 Kinect，微软公司也不在生产该设备。而普通的二维摄像头在大众生活中普遍存在，利用二维摄像头获取骨骼图像必将是发展趋势。

2.2 基于深度学习的骨骼检测方法

深度学习中的一些方法可以在普通二维摄像头采集的人物图像上直接获取骨骼关节点图像。而基于深度学习的人体骨骼检测的方法从单人的骨骼检测发展到多人的骨骼检测。其中，单人骨骼关节点检测的方法主要包括基于坐标回归和基于热图（HeatMap）检测这两种方式[43]。多人骨骼关节点检测的方法包括自底向上和自顶向下两种思路[31]。骨骼关节点检测的关键在于准确的定位出各个关节点的位置以及将各个关节点之间的正确连接。而多人骨骼关节点检测的核心来源于单人骨骼关节点检测，因此我们先介绍单人骨骼关节点检测的方法。

2.2.1 单人骨骼关节点检测

基于深度学习的单人骨骼关节点检测的方法早期基本都是利用基于坐标回归的方法，基于坐标回归的方法是直接将人体关节点的二维坐标作为标签输入网络进行训练，最后利用训练好的网络可以直接根据人体图像确定每个关节点的坐标。Deep Pose 作为早期的人体骨骼关节点检测的算法，它将人体骨骼关节点估计问题由原本的图像处理和模板匹配问题转化为卷积神经网络（CNN）中图像特征提取和关键点坐标回归问题，并使用了一些回归准则来估计被遮挡或者未出现的人体骨骼关节点。该算法在初始阶段可以基于整幅图像进行上下文推理得到关节点的大概位置，然后在后面阶段对得到的坐标进行多级回归，不断的将关节点的坐标优化，最终达到更高的准确率[44]。由于基于坐标回归方法的可扩展能力不强，而人的运动较为灵活，因此在基于 HeatMap 检测出现之后，很少人再用这种方法。

基于 HeatMap 检测的方法是用热图的形式来表示骨骼关节点的坐标[45]，其原理是将每个像素点给一个概率值，将越接近关节点的像素点给定的概率值越接近 1，越远离关节点的像素点的概率值越接近 0，如图 2-2 所示。

中国知网 https://www.cnki.net

图 2-2 肩关节点的 HeatMap 图

由于 HeatMap 图不仅可以反应像素点属于各个关节点的概率分布，还提供了各个关节点之间的图像特征，因此基于 HeatMap 的检测方法得到广泛应用。例如，Shih-En Wei 等人提出的 Convolutional Pose Machines(CPM)，它是采用一系列序列化卷积架构来预测关节点的种类和位置[46]，网络结构如图 2-3(a)所示。CPM 采用迭代检测的方式，利用前一个卷积网络预测的结果作为下一个状态预测输入的一部分，通过对输入输出结果的不断合并，将得到更准确的关节点预测结果。随着网络深度的增加，梯度消失的问题也随之而来，CPM 在每个状态输出后面强制加入目标损失函数，通过对每个阶段的参数的调整，来抑制训练过程中梯度消失的问题。Newell 等人的提出的 Stacked Hourglass Networks（SHN），SHN 是采用沙漏的网络结构来预测关节点位置和结构[47]。SHN 通过多分辨率的 HeatMap 图学习骨骼关节点的位置特征，网络结构的特点是不断的重复图片从高分辨率降到低分辨率，再从低分辨率提升到高分辨率的过程，SHN 的网络结构如图 2-3(b)所示。SHN 算法结构是由多个平行的预测分支构成，类似残差结构，并采用中间监督的机制计算中间 HeatMap 图的损失。SHN 通过利用不断的重复 bottom-up、top-down 的机理，并结合图片的初始检测结果，将精确的定位出关节点的位置以及它们之间的结构信息。

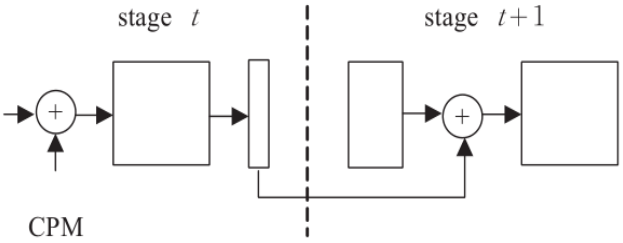

(a) CPM 网络结构图

中国知网 https://www.cnki.net

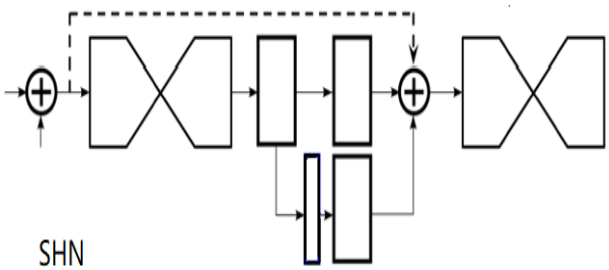

(b) SHN 网络结构图

图 2-3 CPM 和 SHN 网络结构图

2.2.2 多人骨骼关节点检测

当多人在一起时，使用单人骨骼关节点检测的方法会将不同人的关节点连接，因此为了避免发生这种错误，需要加入额外的技术作为指导。目前，多人骨骼关节点检测的方法主要有两种思路：自顶向下（Top-Down）和自底向上（Bottom-Up）[43]。其中，自顶向下的思路主要包括两个步骤，首先通过普通的目标检测算法将人体从环境中检测出来，然后在对检测出来的每个人物做关节点检测。而自底向上的思路是先检测出图片中所有人的关节点，然后利用关节点聚类的方法，将关节点聚类成相应的个体[48]。

自顶向下的关节点检测的方法是按照人物检测、单人关节点识别和多人关节点追踪的顺序进行的，这三个模块独立运行。利用这种策略的有 G-RMI，MASK-RCNN，RMPE，CPN 等模型[49-52]。G-RMI 是 Google 提出的多人体态估计方法，他们首先使用 FAST-RCNN 做人物检测，并将检测到的人物分割出来，然后将分割出来的人物再利用残差网络做高斯 HeatMap 和坐标偏置，最后通过融合高斯 HeatMap 和坐标偏置预测出关节点的精确位置[49]。He K 等人提出的 MASK-RCNN 也是在 FAST-RCNN 的基础上加入分割网络，从而实现检测、分类和分割的任务[50]。MASK-RCNN 将分割出来的人物在关节点位置处建模成为类似 HeatMap 的二进制单点，进而实现关节点的预测。Fang H S 等人提出的 RMPE 模型同样包括两部分，先检测出人体，然后做关节点预测，并且 RMPE 网络设计了专门针对人体姿态的非极大值抑制，用来消除冗余的检测结果[51]。该算法使得单人关节点检测能够有效的用在多人关节点检测的算法中。Chen Y 等人提出的 CPN 模型采用数据增强，soft NMS 等技巧，并采用级联两个子阶段

中国知网 https://www.cnki.net

网络 GlobalNet 和 RefineNet 的方法，其中，GlobalNet 负责关节点的预测，RefineNet 负责关节点的修正[52]。

自底向上的关节点检测方法包括关节点检测和关节点聚类连接两个模块。首先将图片中所有人的关节点检测出来，然后将检测出来的关节点进行聚类处理，即将每个人物身上的关节点连接在一起。例如，Cao Z 等人提出的 OpenPose 就是利用的这种策略[53]，OpenPose 的模型结构如图 2-4 所示。该模型由 PCM 和 PAF 两个模块级联而成，PCM 模块负责检测人体的骨骼关节点，PAF 模块负责关节点之间的连接，因此该算法可以在检测到人体的关节点的同时也能将各个关节点进行连接匹配。

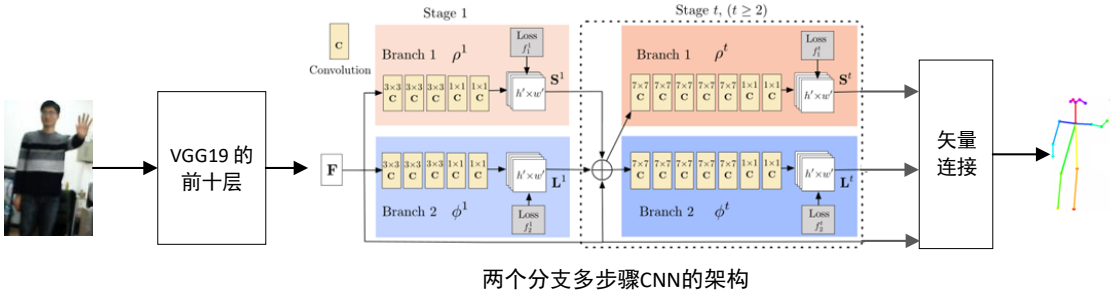

图 2-4 OpenPose 网络结构图

OpenPose 开始由 VGG19 的前十层网络生成特征图，然后将生成特征图送入多阶网络中进行处理，并生成人体的关节点和关联区域，具体生成过程如公式 2-1 和 2-2 所示：

$$S^t = \rho^t(F, S^{t-1}, L^{t-1}), \forall t \geq 2, \tag{2-1}$$

$$L^t = \phi^t(F, S^{t-1}, L^{t-1}), \forall t \geq 2, \tag{2-2}$$

其中，F 代表输入的特征图，S^t 代表关节点，L^t 代表关联区域，例如胳膊、头部等。最后，根据关节点、关联区域和输入的特征图将人体的骨骼关节点进行矢量拼接，形成人体的骨骼关节点模型。

2.3 Pose-Hand 全身骨骼点检测模型

手势动作包括手臂动作和手部动作，然而目前，大部分国内外学者对于手势识别的研究都是将手臂姿态和手掌部分分开的。但是人体姿态中的手臂部分和手掌部分都属于手势识别的范围，单方面研究不利于手势识别发展，而且很难达到

中国知网 https://www.cnki.net

用户满意度的需求。因此我们提出一种 Pose-Hand 模型，该模型主要用于提取人体关节点的骨骼图像和手部关节点的骨骼图像，是基于骨骼状态下手势识别算法的基础。

2.3.1 Pose-Hand 模型流程架构

Pose-Hand 模型是综合 Top-Down 和 Bottom-Up 策略改进得到的，利用 Top-Down 策略识别手掌关节点，利用 Bottom-Up 识别人体关节点。因此，该模型主要包括两部分：一是基于改进的 OpenPose 算法做人体关节点识别；二是根据 Top-Down 结构的手部骨骼关节点检测算法识别手部关节点。该模型的流程如图 2-5 所示，输入待检测的图片后，人体关节点检测模块和手部关节点检测模块同时对输入的图片进行检测。这两个模块并行运行，将有助于提高 Pose-Hand 模型的检测速度。

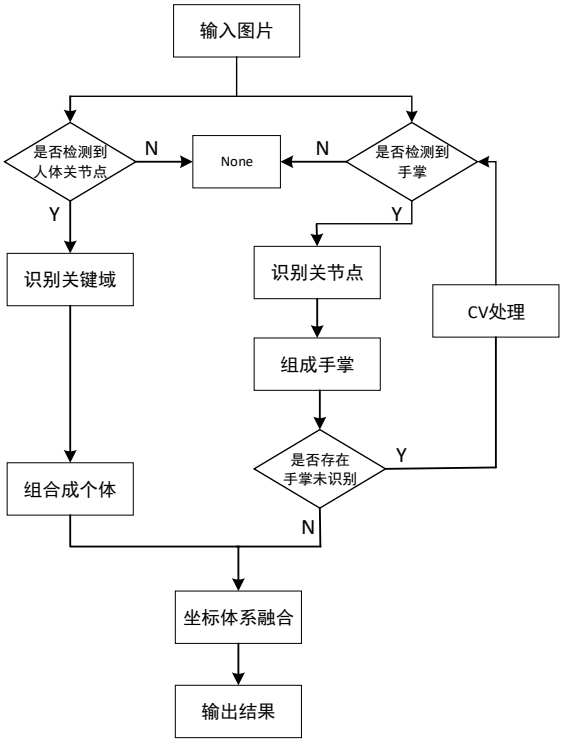

图 2-5 Pose-Hand 模型流程图

Pose-Hand 模型中的人体关节点检测模块检测到人体关节点后，它将继续识别判断出人体的关键域，然后形成人体的骨骼图，此过程可以识别出单人的骨骼图像，也可以同时识别多人的骨骼图像。与此同时，Pose-Hand 模型中的手部关节点检测模块检测到人体的手掌后，单独对手掌图像处理形成相应的骨骼图像，

中国知网 https://www.cnki.net

由于手部关节点检测模块每次只能形成一个手掌骨骼图像，因此如果图像中有多个手掌，需要利用 OpenCV(CV)对图像进行简单处理，可以根据实际的应用情况，选择输出手掌骨骼图像的数目。最后将人体关节点检测模块和手部关节点检测模块的输出融合到同一坐标体系下，将手掌的骨骼关节点连接在手臂末端，形成全身骨骼关节点图像。

如果 Pose-Hand 模型中的人体关节点检测模块没有检测到关节点，该部分将直接输出 None，但是不影响手部关节点检测模块，最终的输出可能只有手部关节点检测的结果。同样，如果未检测到手掌时，并不影响人体关节点检测模块，Pose-Hand 模型还是有可能输出人体的关节点。当只有一个模块有输出结果时，将不再需要坐标融合，直接将结果输出。

2.3.2 Pose-Hand 模型网络结构

Pose-Hand 模型主要应用于手势识别，因此该模型需要识别出多人的骨骼关节点和所有的手部骨骼关节点。对于识别多人的骨骼关节点上节主要介绍了 Top-Down 和 Bottom-Up 两种策略，由于 Top-Down 策略的算法检测多人时，运行时间成倍增加，难以达到实时要求，并且当人物距离摄像头较近时，会经常出现漏检情况，而 Bottom-Up 策略的算法在保证精度的同时能够达到实时检测的效果，因此我们选择 Bottom-Up 策略的算法做多人关节点检测算法。由于我们要求识别手臂以及手部的动作，因此对于手部关节点检测属于远距离小目标操作，为了达到更高的精度，我们采用 Top-Down 策略的算法，先检测出手掌部位，在对切割出来的手掌部位单独进行手部标志预测。

Pose-Hand 模型主要包括人体关节点检测模块和手部关节点检测模块，其网络结构如图 2-6 所示。其中，手部关节点检测模块包括手掌检测模型（BlazePalm）和手部标志模型（Landmark），其中，BlazePalm 是一种单帧图像的目标检测模型，针对手掌的尺度变化较大，它结合了 MobileNet 算法和 SSD 算法，同时针对手掌容易被遮挡，例如握手等操作，通过采用非极大值抑制的算法可以较好的解决。Landmark 是一种利用坐标回归的方式检测手部关节点的模型，为了更好地覆盖可能的手势，并提供对手势的几何形状的附加监督，Landmark 模型在训练时还在不同的背景上渲染了一个高质量的合成手部模型，并将其映射到相应的

中国知网 https://www.cnki.net

坐标体系中。然而，单纯的合成数据很难推广到更广泛的领域。为了克服这个问题，Landmark 模型使用了一个混合训练模式，该混合训练模式结合了真实数据和人工合成数据，因此对可见的手和部分遮挡的手都表现出了较好的鲁棒性。

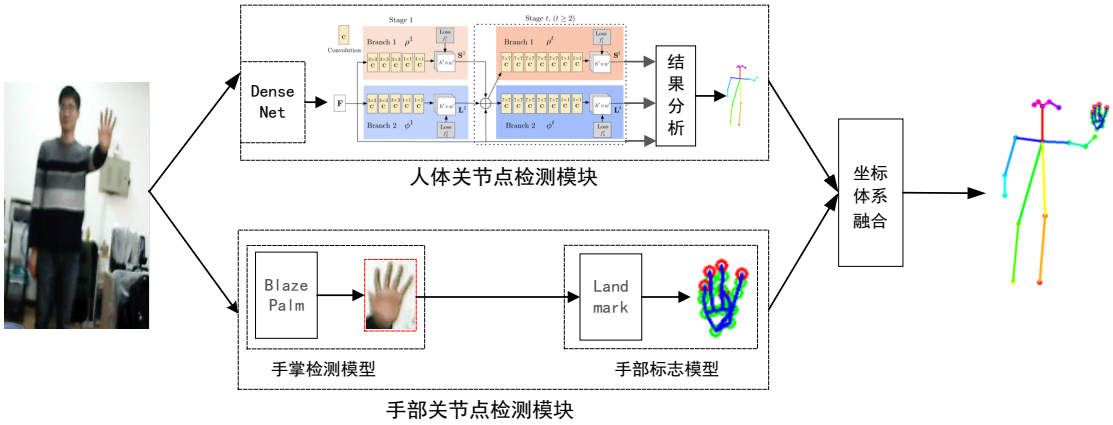

图 2-6 Pose-Hand 模型网络结构

人体关节点检测模块是利用改进的 OpenPose 算法，我们将 OpenPose 算法前期的特征图提取网络更换成 DenseNet，其中，DenseNet 网络结构如图 2-7 所示，它使用密集连接机制，即互相连接所有的层，具体来说就是每个层都会接受其前面所有层作为其额外的输入[54]。与 VGG19 相比，它保持了低复杂度的特性，同时能够学到更加多样化的特征，学习的网络参数却明显减少。因此我们使用的人体关节点检测模块与原来的 OpenPose 相比，较显著的提高了检测的准确率，并且降低了检测时间。

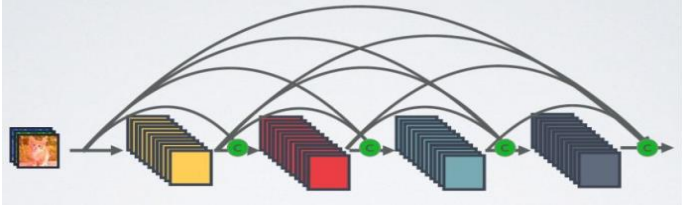

图 2-7 DenseNet 网络结构

2.3.3 Pose-Hand 模型训练

Pose-Hand 模型中的人体关节点检测模块的网络是利用 MSCOCO 人体关键点检测数据集训练的，该数据集中每个人的关键点个数为 17，样本数量超过 30 万张。在使用 MSCOCO 数据集时，需要更改 MSCOCO 数据集中关键点的标注，将{0-nose，1-Leye, 2-Reye , 3-Lear, 4Rear, 5-Lsho, 6-Rsho, 7-Lelb, 8-Relb, 9-Lwri, 10-Rwri, 11-Lhip, 12-Rhip, 13-Lkne, 14-Rkne, 15-Lank, 16-Rank}转换成了如下顺

中国知网 https://www.cnki.net

序：{0-'nose', 1-'neck', 2-'Rsho', 3-'Relb', 4-'Rwri',5-'Lsho', 6-'Lelb', 7-'Lwri', 8-'Rhip', 9-'Rkne', 10-'Rank', 11-'Lhip', 12-'Lkne', 13-'Lank', 14-'Leye', 15-'Reye', 16-'Lear', 17-'Rear', 18-'pt19'}。其中 1-'neck'是人体关节点检测模型增加的一个，可以认为是人体中心点，18-'pt19' 是背景类，最后会被去除。本文在 MSCOCO 数据集上进行再次训练，在训练之前，首先加载的预训练模型，由于模型的基础网络更改，因此只能加载网络没有变化的部分，根据变量的名字进行加载模型数据。同时在网络训练过程中，增加了一系列的数据增强操作：

（1）左右镜像操作：主要是考虑到一些电脑摄像头采集的图片是左右镜像的，与手机或摄像机拍摄的图片不同，并且镜像操作是不能由旋转图片得到的，因此在网络训练中对数据随机加入左右镜像操作。

（2）旋转操作：由于拍摄角度不同，人物图像会发生不同角度的旋转，在网络训练中对数据随机加入负 90 度到 90 度旋转操作。

（3）亮度操作：由于模型会在不同亮度环境下检测人体姿态，因此图片的亮度同样也会影响网络检测的准确率，在网络训练中对数据随机加入增加或者降低亮度操作。

（4）降噪操作：目前大多数摄像头都自带人物美颜功能，因此实测环境中人物的噪声很低，对训练数据随机加入各种降噪处理有利于提高模型的鲁棒性。

（5）模糊操作：由于摄像机曝光影响以及抖动的影响，运动模糊和高斯模糊会发生在使用环境中，因此对训练数据随机加入运动模糊和高斯模糊处理。

Pose-Hand 模型中的手部关节点检测模块的网络主要利用 CMU Hand Keypoints Detection Dataset 数据集，该数据集包含三个部分，分别是手动标注数据集、人工合成数据集以及全景拍摄数据集。其中，手动标注数据集里的图片都是由真实的图片制作而成，一张图片对应一个标签。人工合成数据集中的图片全是人造图片，同样也是一张图片对应一个标签。而全景拍摄数据集是利用全景摄像机对同一个手势动作在不同角度拍摄而成的，多张图片对应一个标签。利用 BlazePalm 模型网络和 Landmark 模型网络在训练时同样采用了数据增强的方法。Pose-Hand 模型中的网络都是使用学习率自适应优化算法（Adma）训练，batch_size 都设为 16，同时设置“早停”机制，即在训练的过程中，当发现 loss 相比上一个 epoch 训练没有下降，将停止训练，保留此时的模型。

中国知网 https://www.cnki.net

2.4 本章小结

本章主要从采集设备方面和模型算法方面介绍了人体骨骼数据获取的方法。首先，介绍了 Kinect 设备获取人体骨骼关节点的原理及流程。其次，说明了基于深度学习的骨骼关节点获取方法，并详细介绍了获取单人骨骼关节点的方法和获取多人骨骼关节点的方法。由于本文的手势识别是在普通二维摄像头下进行的，最后，根据手势识别算法的需要，设计了 Pose-Hand 全身骨骼关节点检测模型，详细描述了 Pose-Hand 模型的设计流程和算法结构，并对 Pose-Hand 模型在训练时使用的数据集和训练过程进行了简单的介绍。本章中 Pose-Hand 模型不仅能够识别出全身骨骼关节点，还能提供每个关节点的坐标，这为第三章中基于骨骼信息的动态手势识别奠定基础。

中国知网 https://www.cnki.net

第三章 基于骨骼信息的动态手势识别研究

本文利用普通的二维摄像头采集人体的动作，利用骨骼信息研究动态手势类型。因此本章中利用第二章提出的 Pose-Hand 模型将摄像头下的人物图像转换成骨骼图像，在骨骼图像下提出相关的动态手势识别算法，其中，对于动态手势识别算法包括基于位置关系的方法和基于深度学习的方法。

3.1 基于位置关系的手势识别研究

在日常生活中见到的简单手势行为动作是有一定规律的，比如，右手上举时，右手的关节点 y 坐标值将大于头部关节点的 y 坐标值；右手向左挥动时，右手的 x 坐标值将更接近脊骨的 x 坐标值，其中 x 轴是指左右方向，y 轴是指上下方向，对于人体姿态的坐标原点是人体中心处，而手掌坐标原点是手掌下部。对于手部关节点的运动，可以先计算指关节到指尖的向量和指关节到手掌底部的向量，再计算两个向量的余弦距离。根据余弦距离判断手指的弯曲程度，把每个手指的状态（弯曲，伸直）映射到一组预定义的手势上即可识别。同样对于手臂的运动，也可以由关节的累积角度决定，如图 3-1 所示。

图 3-1 手臂关节角度图

此时刻关节角度计算公式如下所示：

$$\alpha^{'}=\arctan\frac{|x_1-x_2|}{|y_1-y_2|}, \tag{3-1}$$

$$\alpha^{''}=\arctan\frac{|x_3-x_2|}{|y_3-y_2|}, \tag{3-2}$$

$$\alpha_1=\alpha^{'}+\alpha^{''}, \tag{3-3}$$

通过将关节点的状态集映射到一组预定义的手势中 $A=\{\alpha_1,\alpha_2,\alpha_3,...,\alpha_n\}^T$，当与

中国知网 https://www.cnki.net

预定义的模板相匹配时，确定手势动作类型。

本文主要根据关节点坐标位置和关节点之间的角度识别简单手势动作的。图3-2 展示了人体骨骼的各个关节点图以及手掌骨骼的各个关节点图。手势运动特征可以通过关节点之间的位置反映出。即使不同年龄、不同性别的人都是可以用同一骨骼模型展现的，关节之间的变化可以不受人体结构差异的影响。所以可以推测，手臂和手指关节点的角度或者位置信息决定人体的手臂和手掌在空间中的形状，而角度信息或位置信息可以由关节点的坐标得到。而 Pose-Hand 全身骨骼点检测模型不仅能够得到骨骼图像，还能够得到各个关节点的坐标，因此这为手势识别带来了极大的便利。

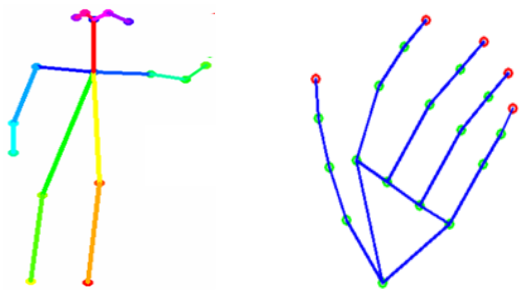

人体骨骼关节点图　　手掌骨骼关节点图

图 3-2 骨骼关节点图像

基于位置关系的手势识别算法只针对人体简单的手势动作进行研究识别，这种方法可以快速准确的识别出一些简单手势，但是部分手势动作是无法利用位置关系识别的，因此本文重点解决复杂手势动作的识别算法。

3.2 基于深度学习的动态手势识别模型建立

近些年来深度学习的技术迅猛发展，深度学习中的卷积神经网络是仿造生物的视觉和神经细胞传输设计的一个非线性模型，它能够在高层次语义信息下理解图像的特征，因此利用深度学习技术研究复杂的动态手势是较好的选择[39]。一般来说，对于动态手势包含三个时间重叠的阶段：准备，核心和撤回，因此动态手势具有时间的连贯性，同时也具有时间的不确定性[24]。其中，时间连贯性是指任何人完成一个手势动作需要一定时间，时间不确定性主要表现在同一个人做不同手势动作花费的时间不同以及不同人做相同动作的速度不同。对于动态手势

中国知网 https://www.cnki.net

识别的前提就是在核心时间段中准确找出与手势动作相关的帧，利用这一帧或者多帧来预测手势动作，因此视频关键帧提取是手势识别的重要一步。本节从视频关键帧提取和动态手势识别模型设计两个方面来介绍研究的过程。

3.2.1 视频关键帧提取

动态手势以视频的形式展现，虽然视频的信息非常丰富，但是冗余信息也很多，即视频中很多帧与手势动作无关。只有将这些动作的关键帧提取出来用于训练动作识别的分类器，这样才可以免受噪声数据的干扰，更加聚焦在动作本质上。但是在动作识别的模型没有训练出来之前又很难提取到动作的关键帧。关键帧提取对于手势动作识别非常重要，因此将进一步介绍视频中关键帧提取的方法。

基于抽样的视频关键帧提取算法比较简单，一般是通过给定视频随机抽取帧数或者设定相同的抽样间隔进行抽取，也可以是根据设定好的需求和视频的时长进行等时间间隔抽取[54]。还有一种情况是首先将视频分成 N 个视频段，然后在每个视频段中随机抽取一帧。基于抽样的方法在动作识别中应用非常广泛，尤其对数据集中的动作检测非常高效，但是这种方法在实际应用中存在极大的弊端，它可能会丢失手势动作的关键帧并且收集到一些无效帧。

基于聚类的关键帧提取方法是将采集的视频按照聚类的算法分为几部分，然后在从每个部分中选取一帧当作关键帧[55]。该算法实现的步骤如下：第一步：假设输入的视频 X 包含 n 帧图像，可以表示为：$X=\{x_1,x_2,...,x_n\}$,其中每个 x 分别代表的是第 i 帧图像，基于视频帧的颜色直方图的特征差异来提取集合 X 中的特征值，预定义一个阈值 δ 控制聚类的密度。第二步:分别计算视频中每一帧 x_i 与聚类算法得到的多个聚类中心之间的相似度，如果得到的计算值小于 δ，则 x_i 与该聚类中心的之间的距离较远，因此，x_i 不能加入该聚类中。如果得到的计算值大于 δ，则将 x_i 加入该聚类中。如果 x_i 与视频 X 中所有聚类中心的相似度均小于 δ，则 x_i 形成一个新的聚类。第三步:通过利用第一步和第二部将视频 X 所包含的 n 帧图像分别归类到相应的聚类中，此时，视频将会分成几个部分，然后在从每个部分中提取出距离中心最近的帧作为这一部分的关键帧，最后将所有提取出

中国知网 https://www.cnki.net

来的图像就组成了视频 X 的关键帧。基于聚类的关键帧提取方法虽然效率较高，而且能够提取出视频中颜色突出的帧，但是运动视频中颜色突出的特征不多，也不一定是关键帧，因此该方法不适用于运动视频中关键帧提取。

基于运动信息的关键帧提取方法是根据视频中运动目标的相关特点分析得到的。该方法通过分析视频镜头中物体运动的光流量，然后每次选择视频镜头中光流移动次数最少的图片作为关键帧[56]。利用光流法计算视频帧的运动量公式如 3-4 所示：

$$M(k)=\sum\sum||L_x(i,j,k)|+|L_y(i,j,k)||, \tag{3-4}$$

式中，$M(k)$ 表示第 k 帧的运动量，$L_x(i,j,k)$ 表示第 k 帧像素点 (i,j) 处光流 X 的分量，$L_y(i,j,k)$ 表示第 k 帧像素点 (i,j) 处光流 y 的分量。计算完成后，取局部最小值作为所要提取的关键帧。计算公式 3-5 如下所示：

$$M(k_i)=min(M(k)), \tag{3-5}$$

基于运动信息的关键帧提取方法可以从视频中提取恰当数量的关键帧，提取到的关键帧也能体现出视频运动的特性。但是，这种方法本身的鲁棒性较差，而且计算过程也较为复杂，在时间上的开销代价较大。

深度学习思想的关键帧提取方法是利用卷积神经网络判断每帧图片是否为关键帧。这种方法主要与基于深度学习的动作识别模型相结合使用的，因为基于深度学习的动作识别模型也需要卷积神经网络提取特征，这样关键帧提取便可以使用相同的特征层进行判别，而不需要使用额外的卷积神经网络[24]。具体过程就是将动作识别和关键帧提取放在同一个模型中去训练，在将每帧图片进行卷积运算的过程中，加入一个额外的分类器，判断图片是否为关键帧，在挑选出关键帧后，将关键帧送到另外一个分类器中去识别动作的种类。该方法能够准确的找出关键帧，且都是对运动识别较为重要的帧，但是只有将该部分嵌入到识别的网络中，才比较高效，单独使用耗时较长。综上，对视频中关键帧提取方法的总结如表 3-1 所示。

中国知网 https://www.cnki.net

表 3-1 视频中关键帧提取的方法

方法	优点	缺点
基于抽样方法	简单，高效	易丢失关键帧
基于聚类方法	提取颜色突出的关键帧	不适用于运动特征提取
基于运动信息方法	适用于运动特征提取	鲁棒性差，计算复杂
基于深度学习的方法	准确提取关键帧	与其他深度学习算法结合使用，单独使用耗时

本文采用基于深度学习思想的关键帧提取与基于抽样的关键帧提取结合的方法。对于摄像头采集的动作视频，首先利用间隔一帧采集一张图片的抽样方式，这样基本不会丢失动作信息，还可以提高识别速度。然后由于本文采用深度学习的方法检测动态手势，所以我们借鉴基于深度学习思想的关键帧提取方法，用来提取识别动态手势的关键帧。基于深度学习思想的关键帧提取方法是通过改进手势检测网络，对每张图片在经过共享卷积层和逻辑回归之后都会有一个得分，根据得分判断是关键帧的概率。对于视频中所有图片的得分 S，可以表示为：

$$S=\{S_{k,n}\},\ k=1,...,K,n=1,...,N, \tag{3-6}$$

其中，k 代表帧，K 是视频的总帧数，n 代表动作类别，N 是动作类别的总数，$S_{k,n}$ 代表第 k 帧图片代表的动作类别 N。我们根据 S 的得分来挑选关键帧，如果 S 超过设定的阈值，该帧图片将会进入手势识别模块中，从而完成手势识别任务。

3.2.2 动态手势识别模型设计

手势的活动范围只占人体的小部分，只有让模型的注意力集中在手势运动的这块区域才能更有效的识别手势动作。因此本文先利用目标检测的技术将手臂活动区域检测出来，然后在判断手势的类型。动态手势不仅包括手势姿态的空间信息还包括时序信息，对于动态手势识别的最好方法是让识别模型连续学习手势的空间特征和时序特征，而由卷积神经网络搭建的模型只能学习图像的空间特征，不能学习时序信息。循环神经网络（RNN）能够处理一定长度的时序数据，但是普通的 RNN 只具有短期的记忆功能，在处理长序列时，会产生梯度爆炸或梯度

中国知网 https://www.cnki.net

消失问题。为了缓解这个问题，本文利用卷积长短期记忆网络（ConvLSTM）处理动态手势识别中的时序问题，ConvLSTM 是一种特殊的 RNN，它不仅能够处理长序列问题，还能处理二维图像信息。因此本文将目标检测网络与 ConvLSTM 结合，进而设计动态手势识别模型。

基于深度学习的目标检测技术是目前机器学习领域发展最成熟的技术之一，按照网络结构可以分为双阶段检测算法和单阶段检测算法。其中双阶段检测算法是在第一阶段生成目标的稀疏候选区域，然后在将这些候选区域进行卷积操作，第二阶段将提取出的特征信息进行回归和分类，确定目标的位置和种类，具有代表性的网络结构有 R-CNN，Fast R-CNN，Faster R-CNN 以及 Mask R-CNN 等。单阶段检测算法是指直接生成目标的边界框和类别，不需要候选框操作，具有代表性的网络结构有 SSD 和 YOLO 等。

双阶段检测算法中，以 Faster R-CNN 的算法为例，它是在 Fast R-CNN 基础上改进得到的，其网络架构图如图 3-3 所示，首先利用建议区域网络（RPN）生成建议区域，然后使用全连接层对候选区进行分类和回归，并对目标的位置信息进行修正[59]。Faster R-CNN 针对 Fast R-CNN 运行速度慢的问题做了一些调整，例如将 Fast R-CNN 的全连接层替换成卷积操作，将 Fast R-CNN 的选择性搜索候选框的策略改成由 RPN 生成候选框。通过这些改进，Faster R-CNN 无论在精度还是在速度上都提升了一个档次，但是这种网络依旧不能做到实时检测，利用 Faster R-CNN 做手臂区域检测速度仍然达不到我们需求。

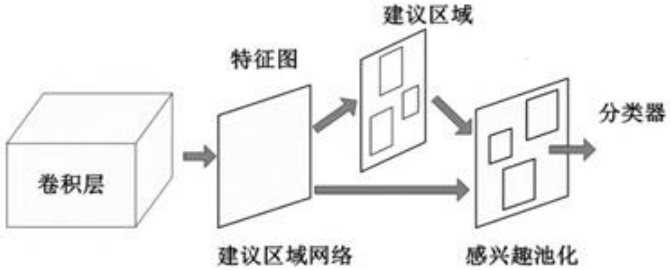

图 3-3 Faster R-CNN 网络架构图

单阶段检测算法中的 SSD 网络是在 VGG16 的基础上又增加了五个卷积层，最后用五个特征层的结果输入进损失函数，从而可以实现多尺度下的目标检测，但是该方法精确度不是很高[60]。YOLO 系列的网络已经更新了三个版本，YOLO 的初始版本是将图片分成多个区域，如果检测目标的中心落在某个区域中，然后在利用该区域估计目标的具体位置。YOLO v2 网络采用锚点预测边界框机制，

中国知网 https://www.cnki.net

对检测目标位置的准确率得到较高的提升，同时加入批量归一化处理，加速了网络的收敛性。YOLO v3 网络融合前两个版本的优点，同时又有新的设计。与之相同的是 YOLO v3 依旧使用“分而治之”的思想，只是与前面版本划分区域的数量不同。同时，YOLO v3 将 Batch Normalization（BN）作为正则化、加速收敛和避免过拟合的方法，还把 BN 层和 Leaky Relu 层接到每一层卷积层之后，这样可以进一步抑制过拟合[61]。与之不同的是 YOLO v3 采用 DarkNet-53 作为基础网络，并利用多尺度特征做目标检测，同时最后采用逻辑回归损失函数，YOLO v3 的结构图如图 3-4 所示。图中 DBL 是指卷积操作、BN 操作和 Leaky Relu 的结合体；图中的 res1、res2 以及 res8 是类似 ResNet 中的残差结构；concat 是张量拼接操作；conv 是普通的卷积操作；y1，y2 和 y3 分别是 YOLO v3 三个特征尺度下的输出。YOLO v3 无论在精度还是在速度上都相比前两代有较高的提升，因此本文利用 YOLO v3 网络提取手势目标。

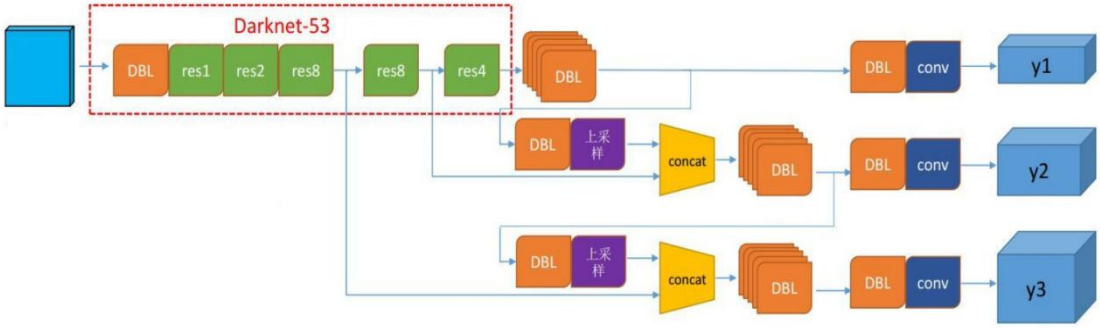

图 3-4 YOLO v3 结构图

由于动态手势包含时空特征，仅仅用目标检测网络是不能有效提取到这些特征的，因为目标检测网络是由卷积操作搭建的，只能学习空间特征，不能学习时间特征。因此本文引入 ConvLSTM 来学习动态手势的时间特征。由于普通的 RNN 网络容易产生梯度消失和梯度爆炸，在训练模型时存在极大的困扰。而长短期记忆网络（LSTM）可以很好的缓解 RNN 所遇到的问题，原因在于 LSTM 细胞状态的保留和每个细胞中门的作用。通过 LSTM 中三个门的作用，它可以学到更长更准确的的序列信息。然而 LSTM 主要解决一维序列的问题，不能直接用于二维状态的图像，而 ConvLSTM 刚好解决了这个问题。ConvLSTM 核心本质还是和 LSTM 一样，将上一层的输出作为下一层的输入。不同的地方在于 ConvLSTM 加入了卷积操作，这样不仅能够得到时序关系，还能够像卷积层一样

中国知网 https://www.cnki.net

提取空间特征，并且状态与状态之间的切换也换成了卷积运算[62]。ConvLSTM 的结构和 LSTM 非常相似，也是有三个门组成：输入门，输出门和遗忘门[63]，其结构如图 3-5 所示。

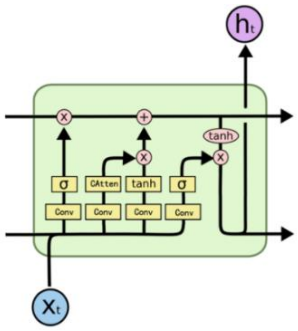

图 3-5 ConvLSTM 单元结构图

其中，ConvLSTM 的运算过程公式如下所示：

$$i_t = Sigmoid(Conv(x_t; w_{xi}) + Conv(h_{t-1}; w_{hi}) + b_i)\,, \tag{3-7}$$

$$f_t = Sigmoid(Conv(x_t; w_{xf}) + Conv(h_{t-1}; w_{hf}) + b_f)\,, \tag{3-8}$$

$$o_t = Sigmoid(Conv(x_t; w_{xo}) + Conv(h_{t-1}; w_{ho}) + b_o)\,, \tag{3-9}$$

$$g_t = Tanh(Conv(x_t; w_{xg}) + Conv(h_{t-1}; w_{hg}) + b_g)\,, \tag{3-10}$$

$$c_t = f_t c_{t-1} + i_t g_t\,, \tag{3-11}$$

$$h_t = o_t \operatorname{Tanh}(c_t)\,, \tag{3-12}$$

x_t 代表当前单元输入，i_t 代表输入门，f_t 代表遗忘门，o_t 代表输出门，h_{t-1} 代表前一个单元输入，c_{t-1} 前一个单元的状态，c_t 当前细胞状态。

根据动态手势的应用背景以及时空特征，动态手势识别模型是基于骨骼状态下进行识别的，包括关键帧提取、手势检测、手势识别和动态手势类型确定。动态手势识别模型的架构如图 3-6 所示，其中基于深度学习思想的关键帧提取和手势检测由手势检测模型完成，该模型可以输出移动的手臂位置以及当下手臂作为关键帧的得分。在手势检测模型判断是否为关键帧时，我们设定一个阈值，当图片得分高于阈值，则判断为关键帧；反之，则舍弃该帧图片。因此，对于动态手势的核心区域是从检测到关键帧开始，到持续检测不到关键帧结束。当手势检测模型检测手臂时，它会框选出处于非落手状态的手臂，为识别网络提供手臂的图

中国知网 https://www.cnki.net

片。在整个手势识别过程中，手势检测模型作为一个检测和筛选的作用，将作为关键帧的手势图片筛选出来送到手势识别模型中。手势检测模型在训练时，首先将采集的动态手势视频分解成一帧一帧的图片，然后将移动的手臂用 labellmg 标记并给与是否为关键帧的标签。

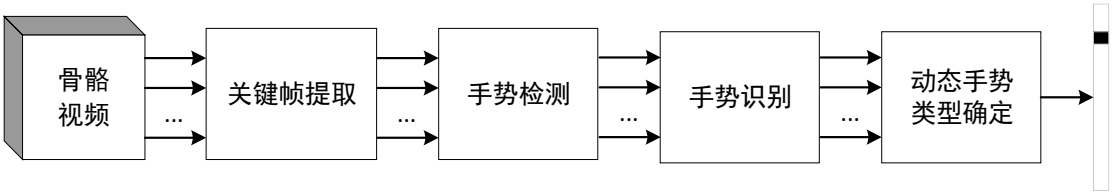

图 3-6 动态手势识别模型的架构图

动态手势识别是利用手势识别模型对连续的手势骨骼图像进行分类识别，最后根据每帧图片识别的结果进行加权求和，并确定手势的类型。由于不同动态手势总存在手势姿态不同的骨骼图像，即使存在关键帧有相同的姿态，但是利用 ConvLSTM 搭建的网络模型在对连续帧识别时，会预测下一帧图片中手臂的走势，如果是同一类别手势的连续帧，识别的结果更具有亲和力。由于动态手势的速度不是固定的，因此可以根据实际应用的环境，调节关键帧的阈值，从而保证每种手势都能采集到足够多帧的图像。当连续一段时间检测不到关键帧时，便可确定此类手势动作完成，此时，需要计算从第一个关键帧的检测结果到最后一个关键帧的结果，最后根据计算的结果确定手势类型。手势识别模型在训练时，需要手势检测模型对每种手势的检测结果切割出来的图像作为一组训练集，训练的标签为手势动作类型。

基于深度学习的动态手势识别总体算法流程如图 3-7 所示，对于待识别手势动作的视频先经过一个简单的抽样，然后将剩余的每帧图像送入 Pose-Hand 模型中转变成骨骼图像。进入动态手势识别环节后，首先利用手势检测模型将人体的手臂提取出来，同时给予检测出来的手臂一个是否为关键帧的得分。如果检测的手臂是关键帧，将检测出来的手臂切割下来送入手势识别模型中，并将识别结果记录，等到手势撤回时，输出检测结果。其中，手势检测算法是更改的 YOLO v3 模型，因为 YOLO v3 的准确率和速度都能符合本文的要求，同时我们将 YOLO v3 最后的 Logistic 回归分类改成 softmax 分类，是因为我们只需要判断是否为关键帧的二分类问题，使用 softmax 分类会更准确同时更快。手势识别算法的模型开始由一个卷积层、BN 层和一个激活函数构成，然后后面连接 6 层 ConvLSTM，

中国知网 https://www.cnki.net

最后由 softmax 损失函数分类。

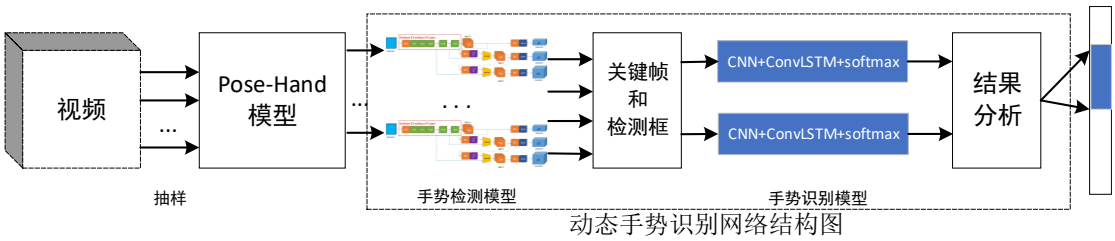

图 3-7 基于深度学习的动态手势识别算法流程图

3.3 手势行为识别的动态模型

手势行为包括手臂动作以及手部动作，因此通过建立手势行为识别的动态模型，将手势行为与手势识别模型结合，利用基于位置关系的方式和深度学习的方式来识别这些手势行为。本文主要分析两类动态的手势行为：（1）基于位置关系方式来识别手臂动作和基于位置关系方式来识别手部动作；（2）基于深度学习的方式来识别手臂动作和基于位置关系方式来识别手部动作。对于第一种类型的手势处理较为简单，可以将手臂识别的结果与手部识别的结果进行结合，便可得出最后的手势动作，在手势识别过程中，当基于位置关系的方法没有识别出手势动作类型时，将会触发基于深度学习的识别算法。对于第二类方法，具体过程如下：假设识别过程中有 n 类动态手势，对于其中第 i 类动态手势 $G_i=\{X:x_1,x_2,\cdots,x_m;\ Y:y_1,y_2\cdots,y_m\}$，其中 $x_1,x_2,\cdots,x_m$ 是动态手势中手肘关节的姿态图，$y_1,y_2,\cdots,y_m$ 是动态手势中手部关节的姿态图。基于深度学习的动态手势识别算法会对动态手势中每张图进行检测识别。对于第 m 张手肘关节的姿态图 x_m，基于深度学习的手势识别算法预测其属于每一类的概率为 $P_m=(P_{1m},P_{2m},...,P_{nm})^T$，其中 P_{nm} 是预测 x_m 属于第 n 类的概率。因此对于动态手势 G_i 中的手肘关节姿态，可以得到概率矩阵 $P=\{P_1,P_2,...,P_m\}$。综合在每个姿态上的预测概率，可以得到在动态手肘上整体预测概率：

$$\overline{P}=\frac{1}{m}\sum_{i=1}^{m}P_m\ , \tag{3-13}$$

中国知网 https://www.cnki.net

令 $\overline{P}=(\overline{p}_1,\overline{p}_2,\cdots,\overline{p}_n)$，其中 $\overline{p}_n$ 是算法预测手肘动作属于第 n 类的概率。$\overline{P}$ 中概率最大的一类即为算法的预测类：

$$C = \underset{j=1,2,...n}{\arg\max}\left\{\overline{P_j}\right\}, \tag{3-14}$$

对于手部的手势动作本文主要是利用基于位置关系的方法来识别的，因此对于每张图片同样有一个识别结果 $\overline{P}'=(\overline{p}_1',\overline{p}_2',\overline{p}_1',\cdots,\overline{p}_n')$，其中 $\overline{p}_n'$ 是算法预测手部动作属于第 n 类的概率。$\overline{P}'$ 中概率最多的一类即为算法的预测类：

$$C' = \underset{j=1,2,...n}{\arg\text{most}}\left\{\overline{P}_j'\right\}, \tag{3-15}$$

假设手势 G_i 的真实类标为 z，算法在正确类标的上整体预测概率 P^* 可以表示为：

$$P^* = \overline{p}_z \oplus \overline{p}_z', z\in[1,n], \tag{3-16}$$

例如，当动态手势 G_i 的真实类标为 1 时，则 $P^*=\overline{p}_1\oplus\overline{p}_1'$。动态手势识别算法在正确类标上预测的概率越高，算法的决策风险就越小。一般情况下，使用动态手势中的关键帧越多，算法判断的准确率越高。但是，过多的图片会导致识别时间过长。因此，选择适当数目的关键帧进行识别，才能使算法达到最优水平。为了平衡识别精度和识别时间，本文设计了一种手势识别的综合指标（R^{WSM}），并采用加权和法推导出综合指标：

$$R^{WSM} = w_1[\alpha'(1\text{-}P^*)]+w_2 t, \tag{3-17}$$

其中，w_1 代表用户给出的识别精度权重，w_2 代表用户给出的时间权重，α' 代表归一化参数，t 表示识别时间。在不同的场景下，用户关注点不同，给出的权重和参数也不同。在 R^{WSM} 最小时，手势识别的效果达到最优，得到最佳的判断关键帧阈值。

3.5 本章小结

本章研究的是动态手势识别算法。首先，本章介绍了基于位置关系的动态手势识别算法和基于深度学习的动态手势识别算法。在研究基于位置关系的识别算

中国知网 https://www.cnki.net

法时，主要利用了基于手掌与其他关节点的坐标的位置关系和手臂以及手指的运动夹角关系。在研究基于深度学习的识别算法时，考虑到视频具有冗余性，首先采用对关键帧检测的方法，介绍了提取关键的方法，并设计本文所采用的提取关键帧的方法。接着介绍本章设计的基于深度学习的动态手势识别模型的架构和算法流程。最后，建立手势行为识别的动态模型，将动态手势转换成数学模型，并详细阐述了本章的手势识别算法对动态手势识别的具体过程。

中国知网 https://www.cnki.net

第四章 手势语义表征建模以及手势识别实验

手势行为的语义表征是指在特定的场景中具有特殊含义的手势动作，它是一种特殊的语义对象。本章主要描述了手势操控无人机的语义表征模型，通过手势控制无人机的行为实验，采集手势控制无人机的语义表征数据，实现手势语义表征模型的搭建，在利用手势识别算法实现相关手势的识别实验。因此首先设计手势控制无人机的行为实验，接着进行手势语义建模，然后构建手势行为控制无人机的信息表，根据手势行为关于行为语义的信息表和第三章提到的手势识别算法做相应的手势识别实验，并验证手势识别算法的准确性。

4.1 手势操控无人机行为实验设计

为了得到更准确的手势动作与无人机之间的语义表征，需要采集一些真实有效的数据。本文通过设置手势操控无人机行为实验，并通过现场实验和问卷调查两种方式采集相关数据。

本次实验中，无人机的指令集包括{上升，下降，左转，右转，前进，后退，巡航}七种，被试者站在无人机面前时，计算机会随机播报无人机的任意一个指令，被试者要求在规定的时间内做出与自己意向度最高的手势动作，计算机播报的指令不重复，直到所有指令播报完。实验主要包括以下四个部分：（1）挑选被试者，挑选 60 名左右的实验人员，要求男女大致均等。（2）培训被试者，首先让被试者了解无人机的指令，熟悉手势动作类型，避免在实验过程中因为紧张做错。（3）实验过程以及相关注意事项，实验是由电脑随机播报无人机的一种指令，然后被试者做出相应手势动作。如果被试者在 10s 内没有做出反应，则该组实验数据无效。如果不同指令被试者做出相同手动作，同样该组数据无效。（4）采集实验数据，被试者在完成试验后，需要采集被试者对应的手势动作以及反应时间。问卷调查主要是针对现场实验的被试者，为了纠正被试者在实验过程中的误操作，排除他们的一些无意识的动作，确认被试者的行为是否与实验中的动作一致。

中国知网 https://www.cnki.net

实验完成后，对实验数据的整理，删去无效数据和残缺数据，整理出的手势控制无人机的动作集包括{右手握拳向上移动、右手张开向左移动，右手张开向右移动，右手张开向前移动，右手张开向后移动，左手张开向左移动，左手张开向右移动，右手握拳画方框，右手握拳画圆圈}九种。接着我们对手势的语义进行建模分析。

4.2 基于操控无人机的手势语义表征建模

在用手势行为控制无人机的任务中，最经常涉及到的是人对无人机的运动操控，例如控制无人机飞行到指定位置处或控制无人机降落。在控制无人机运动时，针对手势行为语义具有不同模糊倾向的特点，构建手势行为关于行为语义的信息模型。

4.2.1 手势语义的行为分析

手势语义行为是指在特定的交互场景中，系统根据通过对手势行为的语义表征进行一定的处理分析，最终确定手势动作将与哪些指令结合。例如，使用手势控制无人机在在空旷地带自由巡航，有人会单手在面前竖着挥动一个圈，有人会在头顶挥动一个源泉示，还有人会挥动一个方框的方式表示，但是这都表达出让无人机巡航的指令。因此，只有构建好手势语义表征模型，才能更好的实现人机交互技术。

考虑到手势行为语义与控制无人机任务的内在关联，本文从不同粒度的角度研究它们之间的关联机理及任务分解技术。首先构建子任务库并实现手势行为语义与无人机子任务的匹配，然后构建手势行为关于控制无人机行为语义的信息表，最后根据行为实验获取信息表的相关数据。

根据手势行为的特征，首先借助二维摄像头设备获取手势通道信号特征数据，进而采用相关算法构建信号特征数据到通道行为的映射模型，以便建立反映通道信号特征的行为及行为库，进而建立手势行为语义信息表。手势行为语义研究内容的分析如图 4-1 所示。

中国知网 https://www.cnki.net

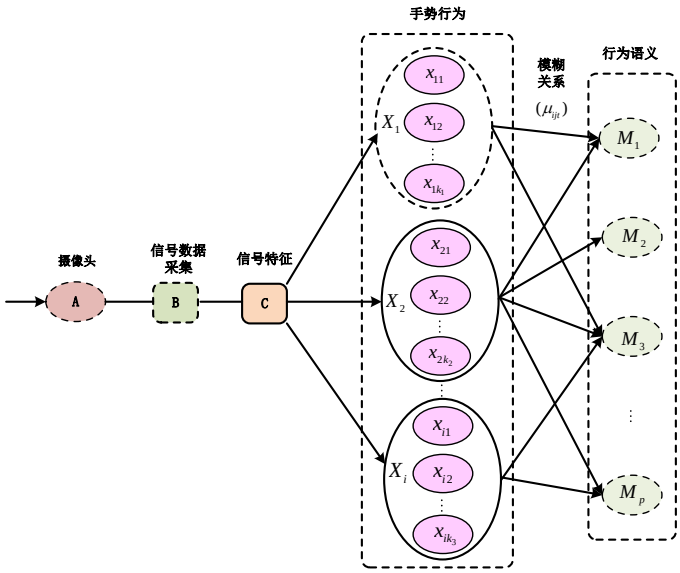

图 4-1 手势行为语义分析图

其中，A 为手势通道集；B 为采集的手势数据集；C 为提取的特征集；$X=\{X_1,X_2,...,X_i\}$ 为信号特征集 C 中包含的行为集，其中 X_i 由诸多手势行为构成的一个集合，进而构成一个手势行为库。$X_i=\{x_{i1},x_{i2},...,x_{ix}\}$ 为第 i 个行为集，其具有 k_i 个行为构成。$M=\{M_1,M_2,...,M_p\}$ 为行为集 X 所蕴含的行为语义集，其中 p 为行为语义的个数，因此语义集与手势行为集进而构成一个手势行为语义库。

根据集合理论，从认知角度将手势通道的信号特征所具有的行为进行提取，使得信号特征与行为之间存在映射关系。故存在一个规则 $f_{C\to X}$，对于每一个 $x\in C$，可唯一确定一个 $y\in X$ 与之对应，则 $f_{C\to X}$ 为从信号特征集合 C 到行为集合 X 的一个映射。考虑到不同手势的行为可能蕴含相同的行为语义，因此由行为到行为语义之间为一对一、多对一或一对多的映射关系，同时对于每一种行为可能隶属于不同的行为语义，据此，我们采用模糊集方法描述这种模糊倾向。假设 μ_{ijt} 为行为 x_{ij} 隶属于行为语义 M_t 的程度，其中 $\mu_{ijt}\in[0,1]$，（ij 表示具有 j 个行为的手势动作 i，$t=1,2,...,p$，表示具有 p 个行为语义）。特别地，如果行为 x_{ij} 表达的就是行为语义 M_t 的含义，那么 $\mu_{ijt}=1$；如果行为 x_{ij} 没有行为语义 M_t 的含义，则 $\mu_{ijt}=0$。

中国知网 https://www.cnki.net

4.2.2 构建手势语义信息表

根据手势行为语义的分析，可以看出手势语义所涉及的关键问题在于行为语义与手势行为之间的映射关系的确定，我们可以通过构建手势行为语义信息表来表现映射关系。然后在根据实验数据进行完善修正，根据手势行为与行为语义生成相应的信息表。以手势控制无人机运动为例，根据收集的行为实验数据，构建手势行为关于无人机行为语义的信息表，如表 4-1 所示。

表 4-1 手势行为关于无人机行为语义的信息表

μ_{ijt}		行为语义						
		上升	左转	右转	前进	后退	下降	巡航
手势行为	右手握拳向上移动	0.88	0	0	0.05	0	0	0
	右手张开向左移动	0	0.75	0	0	0	0	0
	右手张开向右移动	0	0	0.77	0	0	0	0
	右手张开向前移动	0	0	0	0.84	0	0	0
	右手握拳向后移动	0	0	0	0	0.92	0	0
	右手张开向下移动	0	0	0	0	0	0.91	0
	左手握拳向上移动	0.08	0	0	0	0	0	0
	左手张开向左移动	0	0.25	0	0	0	0	0
	左手张开向右移动	0	0	023	0	0	0	0
	左手张开向前移动	0	0	0	0.08	0	0	0
	左手握拳向后移动	0	0	0	0	0	0	0
	左手张开向下移动	0	0	0	0	0.08	0.09	0
	双手张开向上	0.04	0	0	0.03	0	0	0
	右手握拳画圈	0	0	0	0	0	0	0.66
	右手握拳画方框	0	0	0	0	0	0	0.33
	右手握拳画 Z 型	0	0	0	0	0	0	0.01

本次实验中，对于手势行为 $X=\{X_1,X_2,...,X_{16}\}$，对于行为语义 $M=\{M_1,M_2,...,M_7\}$。利用手势行为关于行为语义的信息表便可以得到直接的对应关系。根据表中信息可以观察到，无人机的上下左右移动，基本符合手势的上下左右移动。不同的是有些人习惯用左手，有些人习惯用右手。对于无人机巡航这样的复杂指令，可以分解成简单指令的集合，在对应到多个手势动作上。这样相当于进行多次手势识别，在算法层次上会增大误差的积累，不利于完成相关指令。对于巡航这样的指令如果集合成一个手势动作，根据表中数据可以观察到，手势动作集包含的种类也增多。因此对于手势行为 X 中包含的子集越多，表明

中国知网 https://www.cnki.net

该动作的复杂程度越高，同样对应的行为语义也越多。

4.3 操控无人机相关手势的识别

根据手势的语义信息表以及实际操作需求，我们需要识别 μ_{ijt} 在 10%以上的手势行为，因此我们需要识别的控制无人机的手势的行为有：右手握拳向上移动、右手张开向左移动，右手张开向右移动，右手张开向前移动，右手张开向后移动，左手张开向左移动，左手张开向右移动，右手握拳画方框，右手握拳画圆圈这 9 种手势，其中右手握拳向上移动、右手张开向左移动，右手张开向右移动，右手张开向前移动，右手张开向后移动，左手张开向左移动，左手张开向右移动，属于第一类的动态手势，手臂动作可以用基于位置关系的方法来识别。而右手握拳画方框和右手握拳画圆圈属于第二类动态手势，手臂动作需要用深度学习的方法来识别。

4.3.1 简单手势的识别

对于简单的手势动作是利用 Pose-Hand 模型识别到人体骨骼点，然后对骨骼点的空间位置进行计算判断，进而识别手势动作。本文将提取 HandRight，HandLeft，Head，SpineMid，ShoulderLeft，ShoulderRight，SpineMid 和 21 个手指关节点的位置坐标。其中需要判断的手势行为有：右手握拳向上移动（右手向上）、右手张开向左移动（右手向左），右手张开向右移动（右手向右），右手张开向前移动（右手向前），右手张开向后移动（右手向后），左手张开向左移动（左手向左），左手张开向右移动（左手向右），这些手势行为都属于第一类，手臂和手掌的动作都是利用基于位置关系的方法识别。实验通过 50 名志愿者来验证算法模型的准确性，其实验结果如表 4-2 所示，是基于位置关系算法的混淆识别矩阵。

中国知网 https://www.cnki.net

表 4-2 基于位置关系混淆识别矩阵

输出标签 / 手势行为	右手向上	右手向左	右手向右	右手向前	右手向后	左手向左	左手向右
右手向上	44	2	1	2	1	0	0
右手向左	0	48	0	2	0	0	0
右手向右	0	0	47	2	1	0	0
右手向前	0	2	4	44	0	0	0
右手向后	3	3	0	0	43	0	0
左手向左	0	0	0	4	0	46	0
左手向右	0	7	0	2	1	0	47

在对每个手势动作测试时，同时记录测试时间，测试时间是根据对每种手势正确识别的实验求平均得到的，如表 4-3 所示，是每类手势动作识别的准确率和时间。

表 4-3 识别准确率和识别时间

手势动作	右手向上	右手向左	右手向右	右手向前	右手向后	左手向左	左手向右
准确率	88%	96%	94%	88%	86%	92%	94%
时间（s）	1.4	1.6	1.4	1.5	1.5	1.5	1.6

为了验证本文手势识别算法的性能，在相同的条件下利用 DTW 算法与之对比，其中，DTW 算法是将待识别的手势与手势模板库进行相似度的匹配，即将检测样本里每一个时间点的特征与模板样本里的任意时刻的特征进行相似度的计算。我们在 50 名志愿者外，随机挑取一人，采集他的手势动作当作手势模板库，还是利用相同的 50 名志愿者的手势动作进行测试实验，其实验结果如表 4-4 所示。

中国知网 https://www.cnki.net

表 4-4 DTW 算法识别率及识别时间

手势动作	右手向上	右手向左	右手向右	右手向前	右手向后	左手向左	左手向右
准确率	72%	67%	75%	67%	64%	74%	68%
时间（s）	1.1	1.0	1.3	1.2	1.1	1.1	1.2

对于简单的手势动作识别，本文提出的手势识别算法识别的准确率均高于 DTW 算法，但是时间也略长于 DTW 算法。本章中简单的手势动作种类较多，同时每个手势动作还包括手掌部分的动作，这对于 DTW 算法具有较大的挑战性，因此 DTW 算法识别的准确率普遍偏低，而 DTW 算法识别时间主要受手势动作时间影响，因此，识别时间比较快速。本文提出的手势识别算法不受手势种类影响，因此对每种手势识别的准确率都较为稳定和准确，但是由于本文提出的识别算法需要把普通图像转换成骨骼图像，因此花费的时间略多于 DTW 算法。

4.3.2 复杂手势的识别

为了验证深度学习的动态手势识别算法的有效性，首先要建立右手画方框和右手画圆的手势动作数据库。为了使手势数据库更具有可靠性，我们对同一个动作让不同的志愿者来操作多遍，选取符合要求的手势动作存放在数据库中作为训练集。在测试阶段，为了区别训练数据集，又随机找了多名志愿者，按照相同的指导说明，分别让他们做右手画圆圈和右手画方框两组动作。

在测试阶段，为了得到最佳的关键帧阈值，我们做了多组测试实验，通过改变基于深度学习思想的关键帧提取方法的阈值，得到不同的识别准确率和识别时间。为了消除随机误差，每组实验重复 10 次记录平均值，实验结果如图 4-2 所示，图中的横坐标表示基于深度学习思想的关键帧提取方法的阈值，最小设置为 0.3，最大设置为 0.75，图 4-2（a）表示基于深度学习的手势识别算法识别手势的准确率，图 4-2（b）表示该算法识别手势的时间。

中国知网 https://www.cnki.net

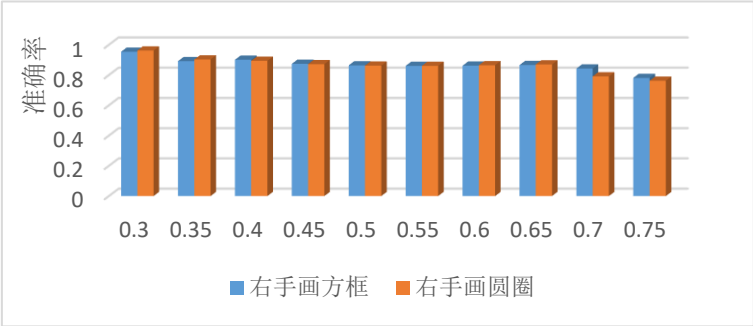

(a) 准确率

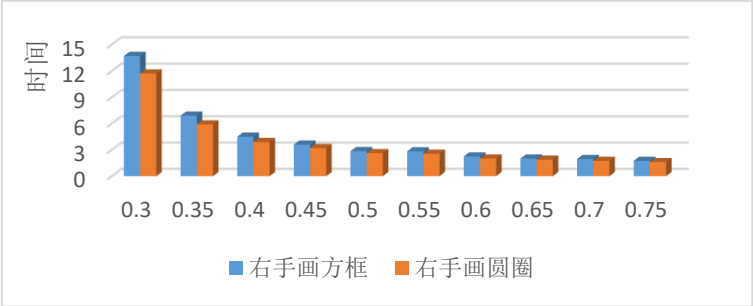

(b) 识别时间（s）

图 4-2 实验结果

根据实验数据可得，阈值越小，该算法识别的准确率越高，但是检测时间会变长。阈值越大，识别精度变低，但是检测时间较短。实验结果符合前文的预期假设。抽样阈值在一定的变化范围内，识别准确率的变化不大。当阈值的范围大于等于 0.65 时，右手画圆圈和右手画方框的识别准确率都在 80%以上；当阈值小于 0.65 时，识别精度在 80%以下。而识别时间在阈值大于 0.65 之后，基本稳定。因此我们将手势识别模型中关键帧抽取的阈值设为 0.65。此时，我们根据式 3-17 计算两种手势的综合指标值，当识别精度权重在 0.6，识别时间权重为 0.4 时，当阈值为 0.65 时，计算的综合指标的值最小。

同时，我们利用 DTW 算法识别右手画方和右手画圆这两种手势，比较 DTW 算法和基于深度学习算法的优劣。我们分别采用基于深度学习的算法和 DTW 算法对右手画圆圈和右手画方框动态手势进行检测识别，比较两种方法的识别准确率和时间。其中，基于深度学习的算法设置关键帧提取的阈值为 0.65。与简单手势实验相同，在利用 DTW 算法时，将任意一位志愿者的手势动作作为测试序列模板，将 50 名志愿者的手势动作作为测试集进行识别测试，DTW 算法识别结果的混淆识别矩阵如表 4-5 所示。

中国知网 https://www.cnki.net

表 4-5 DTW 算法识别结果的混淆识别矩阵

输出标签 / 期望标签	右手画方框	右手画圆圈
右手画方框	28	22
右手画圆圈	25	25

DTW 算法识别结果的准确率和时间如表 4-6 所示。

表 4-6 DTW 算法识别准确率和时间

手势动作	右手画方框	右手画圆圈
准确率	56%	50%
时间（s）	3.1	2.4

同时，我们将基于深度学习的手势识别算法与传统 DTW 算法对右手画圆圈和右手画方框这两组手势动作的识别结果进行对比分析，如图 4-3 所示，其中，图 4-3（a）是将识别准确率进行对比，图 4-3（b）是将识别时间进行对比，图 4-3（c）是按照式 3-17 计算的综合指标进行对比，其中，式 3-17 中的α'=100，$w_1 = 0.6$，$w_2 = 0.4$。

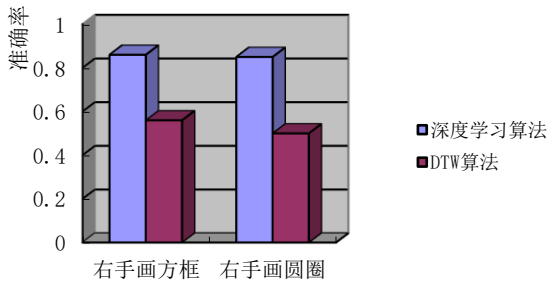

(a) 准确率

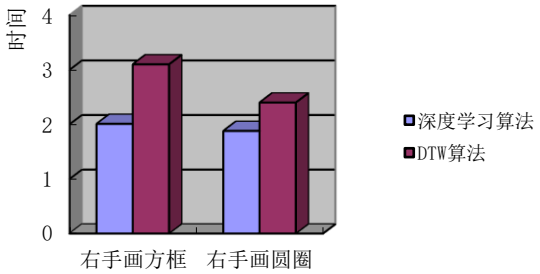

(b) 识别时间(s)

中国知网 https://www.cnki.net

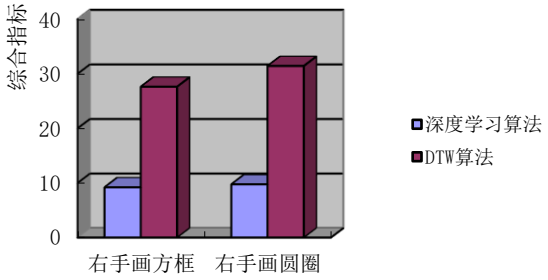

(c) 综合指标

图 4-3 对比结果

通过实验的对比结果可以看出，在识别右手画方框和右手画圆圈两组易混淆动作时，基于深度学习的手势识别算法的准确率在 85%以上，识别时间在 1.88s-2.01s 左右。而 DTW 算法的识别准确率仅仅在 50%左右，可以看出 DTW 算法几乎不能区分这两组手势动作，识别时间也在 2.1s-3.1s 左右。在相同参数下，对比手势识别的综合指标可以看出，本文提出的手势识别方法具有明显优势。

4.5 本章小结

本章主要研究的是手势语义表征建模技术和手势识别实验分析。根据手势控制无人机的需求，研究手势控制无人机的语义表征。首先，设计手势控制无人机的行为实验，并分析手势的行为语义，建立手势语义的表征模型。然后采集到手势控制无人机的相关手势，并简单分析了手势行为与行为语义之间的关系。最后利用这些手势验证本文的手势识别模型，并给出识别这些手势的准确率。

中国知网 https://www.cnki.net

第五章 虚拟环境搭建以及手势控制演示

为了验证手势识别的效果以及手势语义表征模型的实际应用性，本章以虚拟无人机操控为演示场景，设计基于手势操作的无人机仿真系统。首先搭建虚拟无人机飞行环境，了解手势操作无人机的方法。由于采用本文的手势动作来操控无人机飞行，因此要建立手势识别模型与虚拟平台之间的通信。最后将手势识别模型识别的结果通过通信协议传到虚拟仿真系统中，进而控制无人机。

5.1 虚拟无人机交互系统设计

本章设计的基于手势操作的无人机仿真系统，是一种将手势识别技术与虚拟仿真技术相结合的人机交互系统。该系统即可以方便的验证手势操控无人机的可行性，也可以作为无人机使用者的训练平台。基于手势操作的无人机仿真系统整体设计流程如图 5-1 所示，可以分为手势交互控制模块、实时通信模块、虚拟场景模块和功能显示模块。

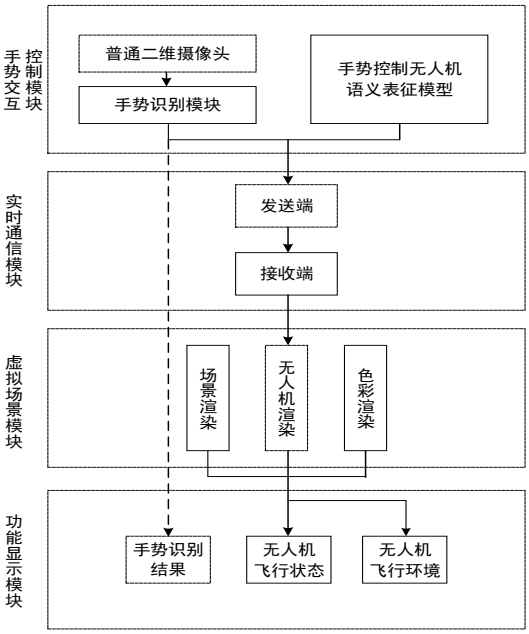

图 5-1 基于手势操作的无人机仿真系统设计流程图

基于手势操作的无人机仿真系统中的手势交互控制模块包括本文中第二章的 Pose-Hand 模型、第三章的手势识别模块和第四章中手势操控无人机的语义表征模型。手势交互控制模块可以利用普通二维摄像头直接采集识别用户的手势动

中国知网 https://www.cnki.net

作，与手势控制无人机的语义表征模型结合，将手势动作转换成无人机的飞行指令。实时通信模块采用 TCP 通信协议，将手势交互控制模块中的飞行指令传递给虚拟场景模块，实现指令与无人机之间的通信。虚拟场景模块中包括对整个场景的渲染、无人机的渲染和色彩的渲染。功能显示模型主要以第三视角展示无人机的飞行状态以及无人机所在的虚拟环境，根据需求还可以选择性显示手势的识别结果。

5.2 虚拟场景搭建

本章中的虚拟场景是由 Unity3D 软件搭建，它是一款专业做虚拟场景的软件，用户可以利用该软件创建三维场景可视化的项目。基于手势操作的无人机仿真系统的虚拟场景主要包括场地、障碍物和无人机等。本章节设计并实现了无人机的渲染、场景的渲染以及色彩的渲染，同时，为了让虚拟环境更加具有真实感，在本系统中也加入碰撞效果。当无人机接触到障碍物或者边界时，会发生碰撞摩擦现象。

1) 虚拟场景渲染

在 Unity3D 导入矩形方块当作障碍物，导入长方形当作边界。如图 5-1 所示，该训练场景为一个封闭的空间，四周为蓝色的幕墙。空间中设置多个矩形和圆柱体障碍物，通过控制无人机在障碍物中飞行。同时在空间中加入多个跨越框，可以控制无人机在飞行的过程中穿过跨越框，虚拟场景如图 5-2 所示，分别为（a）正视图，（b）侧视图和（c）俯视图。

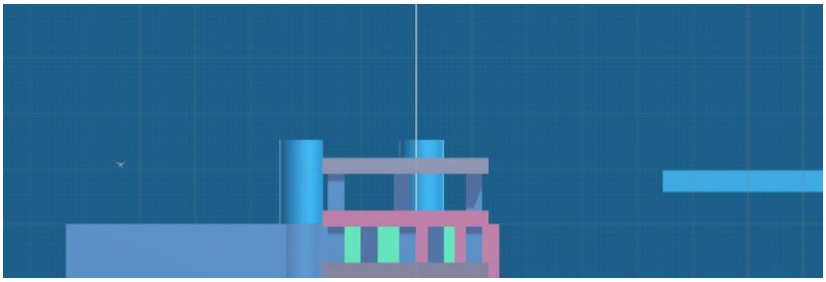

(a) 正视图

中国知网 https://www.cnki.net

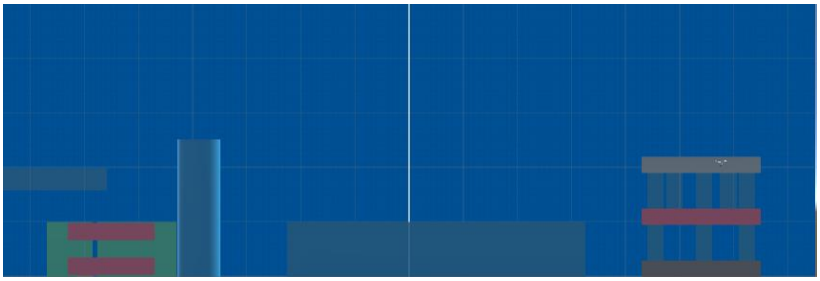

(b) 侧视图

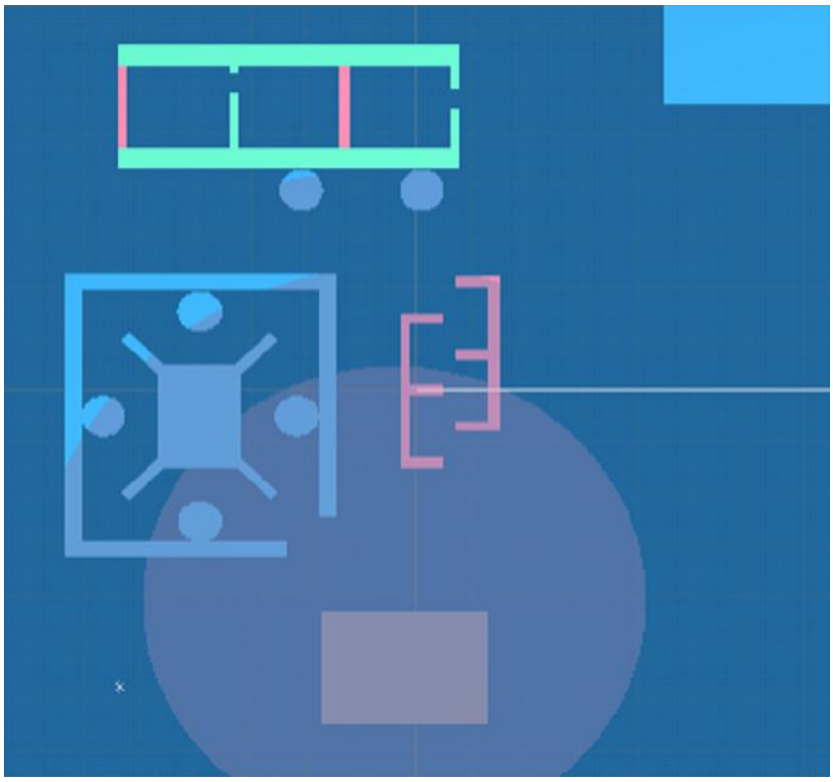

(c) 俯视图

图 5-2 虚拟环境场景

2) 无人机渲染

无人机包括无人机的基本框架和扇叶，由于无人机的扇叶可以旋转，因此扇叶与无人机的基本框架是分开的。在安装好无人机扇叶后，对扇叶设置速度，使扇叶保持为旋转状态。最后，将无人机设置成一个刚体，使其在阳光下产生阴影。同时，设置无人机运动的速度，本系统中设置无人机前进的速度是 10，左右移动的速度是 5，上下移动的速度是 3。无人机在飞行时，设置成倾斜状态，如图 5-3 所示，图（a）是无人机静止状态时的状态，图（b）是无人机飞行时的状态。

中国知网 https://www.cnki.net

(a)无人机静止状态

(b)无人机前进状态

图 5-3 无人机效果图

3) 色彩渲染

色彩渲染主要是对光源的调整和运动细节的处理。其中，虚拟场景的效果受光源影响比较大，光源过亮或者过暗，对观察无人机的飞行都有影响，因此对光源的恰当应用，可以使虚拟场景的视觉效果更好。同时，对无人机加入碰撞效果，当无人机碰到边界或者障碍物时，会发生摩擦碰撞效果，如图 5-4 所示。对无人机加入声音效果，当无人机启动时，会发出嗡嗡声。

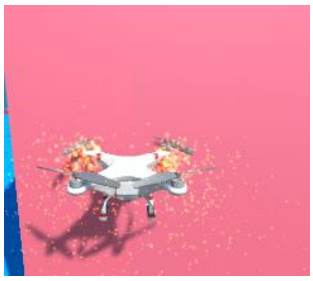

图 5-4 碰撞效果

5.3 实时通信模块设计

基于手势操作的无人机仿真系统是人机交互的一个展示系统，如何将手势与虚拟仿真环境中的无人机有效结合是该系统中的重要一步。为了实现手势交互控制模块与虚拟场景模块之间的通信，我们采用 TCP 通信协议，把手势交互控制模块输出的结果放入发送端，把接收端输出的结果传递给虚拟场景模块的无人

中国知网 https://www.cnki.net

机。其中，TCP 通信协议具有传输数据快、传输稳定等优势，从而保证该仿真系统的有效运行[66]。TCP 通信协议有以下几个特点：

（1）面向连接运输层协议：在使用 TCP 通信协议之前，发送端和接收端要建立连接，即手势交互控制模块与虚拟场景模块建立连接，然后才能开始数据的读写。

（2）面向字节流服务：TCP 的字节流服务的表现形式主要体现在发送端执行的写操作次数和接收端执行的读操作次数之间没有任何数量关系，如图 5-5 所示，当 TCP 模块的发送端即手势交互控制模块开始发送控制指令的时候，发送缓冲区中这些等待发送的指令可能被封装成一个或多个 TCP 报文段发出。

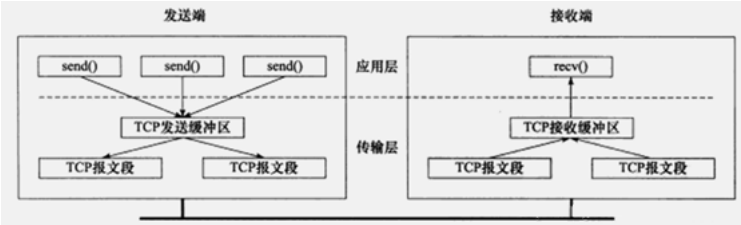

图 5-5 TCP 字节流服务

（3）TCP 协议采用超时重传机制，当发送端在发送出一个报文段后，将有一个计时器被启动，如果在规定的时间内发送端没有收到接收端的回复，它将重发该报文段，直到收到回复为止。

TCP 通信协议是通过四步完成一次通信传输的，如图 5-6 所示，主要包括四个步骤，分别是：（1）服务器初始化；（2）建立连接过程；（3）数据传输过程；（4）断开连接过程。

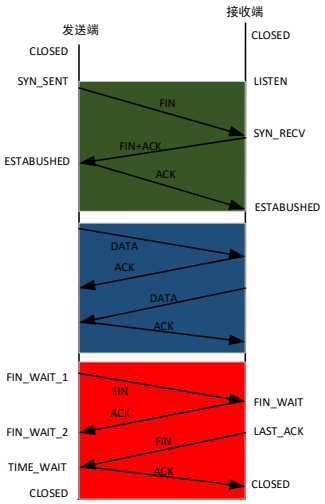

图 5-6 TCP 通信协议流程

中国知网 https://www.cnki.net

其中，服务器初始化（LISTEN）是 TCP 通信协议运行前的准备阶段，首先发送端需要建立一个通信文件，并将该文件与接收端的端口号绑定在一起，然后在将此文件作为发送端的文件描述符，最后等待接收端建立通信连接。

建立连接的过程主要包括三次握手，如图 5-6 中的绿色部分，第一次握手是接收端使用 connect 函数向发送端发起通信连接请求，然后等待发送端应答。第二次握手是发送端接收到接收端请求之后，会做出表示同意建立连接回应。第三次握手是发送端在建立连接之后向接收端回应消息。

数据传输的过程如图 5-6 中的蓝色部分，在 TCP 通信协议建立连接后，开始进行数据传输。在数据传输时，发送端先发送通信数据，然后等待接收端应答，如果没有收到应答数据就会一直等待。同时接收端会发送请求指令给发送端，当发送端收到指令后会做出回应。发送端再次等待读取通信数据，然后按照上述步骤循环下去。

断开连接的过程包括四次挥手，如图 5-6 红色部分，四次挥手分别是：第一次是如果发送端没有的请求,就调用 close 函数关闭连接，同时发送端会向接收端发送‘FIN’指令。第二次接收端收到‘FIN’后会回应一个‘ACK’指令。第三次接收端会将数据清零，然后给发送端发送‘FIN’指令。第四次客户端收到‘FIN’后，再返回一个‘ACK’指令给接收端，通信连接终止。

本文利用 TCP 通信协议，实时将手势交互控制模块中的无人机指令以数字编码的形式，由发送端发送，接收端接收，接收到数字之后在解码成无人机的控制指令，从而实现手势控制无人机的效果。

5.4 功能显示模块设计

功能显示模块主要描述基于手势操作的无人机仿真系统的使用环境和手势控制无人机的动态过程，属于人机交互的终端设计。本次实验采用的是普通二维摄像头和 Unity3D 5.6 进行开发的，所使用的开发环境如下表所示：

中国知网 https://www.cnki.net

表 5-1 开发环境

CPU	Intel(R) Core(TM) i5-4460 CPU @3.20GHz
内存	16GB
显卡	GTX 1060
是否支持 DirectX11	是
操作系统	Microsoft Windows 10 专业版 (64 位)
集成开发环境	Visual Studio 2017 和 Pycharm 2019 2.5

本次实验我们定义了 7 种无人机的指令，是无人机操作的一些基本的操作指令。根据手势控制无人机的语义表征模型，查找无人机指令对应的手势动作，如表 5-2 所示。

表 5-2 动作指令表

无人机操作指令	对应手势动作
上升	右手向上
下降	右手向下
左转	右手向左
右转	右手向右
前进	右手向前
后退	右手向后
巡航	右手画方或者画圆

本文所设计的基于手势操作的无人机仿真系统是利用手势动作操作无人机的，首先需要打开并运行 Pycharm 和 Unity3D 两个软件，其中 Pycharm 主要运行手势识别算法和实时通信模块的发送端程序，Unity3D 主要运行虚拟仿真系统和实时通信模块的接收端程序。当用户进行交互测试时，摄像头会将采集的视频传输到手势识别算法中，同时将采集的图像画面在电脑屏幕上展示，根据屏幕中的画面调整用户位置，当检测到用户时会跳出骨骼图像视频。当用户的右手向上时，骨骼图像视频中会显示手势动作的类型，功能显示模块中的无人机会向上飞行。只有当无人机起飞后，才能执行其他操作，如果无人机未起飞，做其他手势

中国知网 https://www.cnki.net

动作，无人机将不会做出任何反应。无人机的控制流程如图 5-7 所示，当无人机起飞后，继续接收手势操作指令，例如当右手向右挥动时，无人机将会向右飞行。如果无人机在接收不到任何指令时，会从上一个状态按照一定的速度下降，在下降过程中但是未落地前仍然可以接收指令并执行。当无人机落地后，此次无人机操作完成。

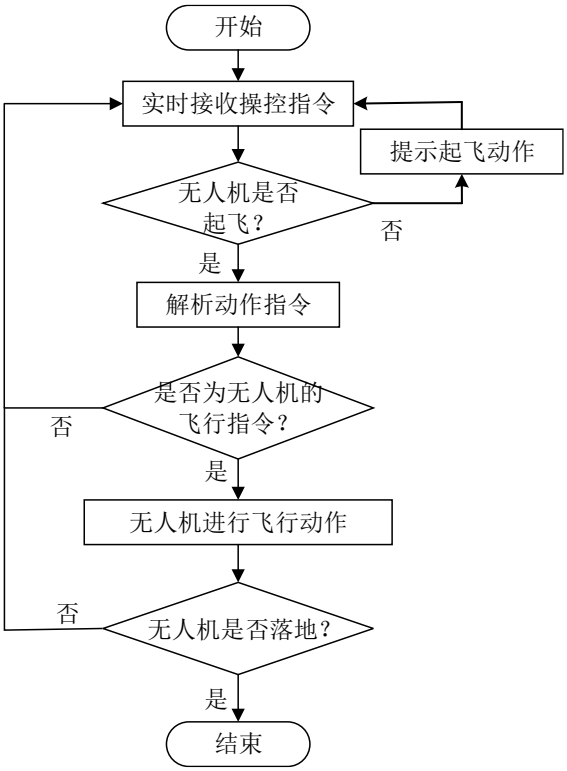

图 5-7 无人机控制流程图

当无人机碰到障碍物时，会发生碰撞现象，此时无人机也会出现下落趋势，如果无人机离开障碍物，会继续执行原来操作。无人机操作指令中的巡航操作是指让无人机按照顺时针沿着虚拟环境飞行一周，如果手势交互控制模块检测到右手在做画圆或者画方框的动作，该指令将会被激活。用户可以通过观察屏幕中无人机的飞行动作实时对其进行操作，由于手势识别模块时刻检测手势动作，因此对于简单的手势动作和无人机指令（表 5-2 中前六种指令）都是实时改变的。但是如果无人机在执行巡航任务时，又接收到新的指令，此时无人机将执行新的指令从而覆盖掉原来的指令，如果想要完成巡航任务，只需将手势落下。

5.5 本章小结

本章主要介绍了基于手势操控无人机的虚拟仿真环境的设计。首先在

中国知网 https://www.cnki.net

Unity3D 里完成无人机飞行环境的虚拟场景搭建，并导入无人机，完成虚拟场景模块的设计。然后将手势交互控制模块与虚拟场景模块利用实时通信模块进行通信连接，并介绍了实时通信模块中的 TCP 通信协议的特点及原理。最后利用功能显示模块详细介绍了手势控制无人机的流程。

中国知网 https://www.cnki.net

第六章 总结与展望

6.1 工作总结与创新点

手势交互作为自然人机交互中最常用的方式之一，得到了广泛的应用。如何将手势交互进一步推广，如何高效准确的识别出手势动作，以及如何自然的实现人机交互等问题，是影响手势交互未来发展的关键。因此，面对这些问题，本文的主要工作如下：

（1）设计 Pose-Hand 全身骨骼关节点检测模型。为了将手势交互进一步推广，本文是基于普通二维摄像头图像下进行手势动作识别的，考虑到图像中的冗余信息较多，将利用 Pose-Hand 模型提取图像中人物身体和手部的骨骼关节点，并详细介绍了 Pose-Hand 模型的流程、结构和训练过程；

（2）设计基于骨骼信息的动态手势行为识别算法，构建手势行为识别的动态模型。针对手势动作的时空特性，对于简单的手势动作，设计了基于骨骼关节点位置关系的识别算法；对于复杂的手势动作，设计了一个基于深度学习的动态手势识别模型；并通过实验验证了基于骨骼信息的动态手势行为识别算法的准确性；

（3）设计并进行了手势控制无人机的行为实验。据此研究了手势控制无人机的行为语义表征方法，探索不同手势下行为语义的表征机理，并建立了手势行为语义的表征模型。

（4）使用普通二维摄像头、Unity3D 软件和 Pycharm 2019 开发平台搭建了一个手势操作的无人机仿真系统。根据手势语义表征模型和手势识别算法与无人机之间的通信，设计了手势动作与无人机指令的对应手势交互机制，实现了手势控制虚拟环境中的无人机飞行。

本文的创新点如下：

（1）设计 Pose-Hand 全身骨骼关节点检测模型。考虑普通二维摄像头采集的图像中冗余信息较多，通过 Top-Down 和 Bottom-Up 两种策略分别检测手部骨骼关节点和人体的骨骼关节点，采用两种算法并行运算机制，减少了算法的阻塞和检测时间。

中国知网 https://www.cnki.net

（2）设计并实现了基于深度学习的动态手势识别模型。对于复杂手势的识别，利用基于抽样和深度学习思想的关键帧提取方法提取视频中手势动作的关键帧图片，采用注意力机制将移动的手臂从人体骨架中提取出来，搭建具有时空特性的网络模型识别提取出来的手臂动作。

6.2 工作展望

本文围绕手势动作识别及语义表征技术展开研究，利用虚拟人机交互系统对研究内容进行验证。虽然取得了一些研究成果，但是仍然有些问题值得继续研究：

首先，本文在利用普通摄像头获取的骨骼关节点的数据信息时，只是获取的二维骨骼数据，并没有设计更复杂的网络获取三维骨骼数据，因此在对于简单动作识别上有一定的影响。在对复杂动作识别上没有利用3D卷积神经网络，而是设计了一系列的复杂数据处理操作，虽然提高了精度但是在识别时间上有一定的影响。

同时，本文只利用一个摄像头去采集手势动作，获得运动信息量较少，影响手势识别的准确率，如果采用多个摄像头从不同角度相结合的方式将有利于提高手势识别的准确率。

其次，对于手势的语义表征模型研究比较简单。本文只是根据操作无人机的行为实验进行研究手势语义表征的模型，没有进行更多的手势行为实验。

最后，本文搭建的基于手势操作的无人机仿真系统的真实感不够强，操作环境略显简单，与真实环境相差较大，交互对象定义较少。因此在后期的研究中需要对虚拟人机交互系统进一步优化。

中国知网 https://www.cnki.net

致谢

时光似箭，一眨眼研究生三年很快就过去了，虽然新冠病毒阻挡了我们迫切回校的计划，但是并没有阻挡我们对学习的渴望。在家中，我严格按照国家和学校的规定，认真学习。回想研究生三年，在这历史悠久的学校中让我收获了很多，学习了很多，更成长了很多。在这里，我希望借此机会向我的老师以及同学表达我深深的谢意。

首先，我要感谢我的导师周献中教授，在我的科研道路上为我指引方向，扫除障碍。还记得一开始因为自己电脑配置无法完成满足实验需求时，周老师立刻为我们更新了所有的配置，从而使我的科研道路上少了很多障碍。同时，周老师对我学术生涯的细心指导，教会了我怎么对待科研，如何去研究问题，同时教导我们学以致用，让我们在实战中提升自己的能力。

接着我要感谢我的家人和朋友，感谢您们对我学业的支持、生活的关怀。在未来的日子里，我会带着您们对我的期盼继续努力，同时我也会努力让您们生活的更美好。

最后我要感谢一起学习生活的同学们，特别是我的博士师兄孙宇祥，张里博，王天行等对我论文的指导和科研的帮助。感谢同门的李东坡、张殊伟、戴迪、郝可，彭轶轩等同窗好友在硕士期间的一路陪伴。感谢刘昕、朱兆全等师兄师姐在项目和生活上对我的帮助。感谢于佳慧，徐成成等师弟师妹在项目和实验方面的帮助与支持。因为有了大家，实验室变的更团结，三年的学习生活也变得多姿多彩。

人生新的旅途即将开始，让我们一起加油吧！

中国知网 https://www.cnki.net

参考文献

[1] Soumi Paul, Arpan Bhattacharyya, Ayatullah Faruk Mollah. Hand Segmentation from Complex Background for Gesture Recognition[M]. Emerging Technology in Modelling and Graphics, 2020.

[2] Susan Vorwerg, Cornelia Eicher, Heinrich Ruser. Requirements for Gesture-Controlled Remote Operation to Facilitate Human-Technology Interaction in the Living Environment of Elderly People[M]. International Conference on Human-Computer Interaction, 2019.

[3] Hwang J, Kim J, Ahmadi A, et al. Dealing With Large-Scale Spatio-Temporal Patterns in Imitative Interaction Between a Robot and a Human by Using the Predictive Coding Framework[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2018, (99):1-14.

[4] 冯志全, 乔宇, 冯仕昌. 多种手势对应同一语义的柔性映射交互算法的研究[J]. 电子学报, 2019, 047(008):1612-1617.

[5] M. Caon, Y. Yue, J. Tscherrig, O. A. Khaled, and E. Mugellini. Democratizing 3D dynamic gestures recognition[J]. Proceedings of the IEEE Work-shop on User-Centered Computer Vision, 2013: 7-12.

[6] R. Kjeldsen and J. Kender. Toward the use of gesture in traditional user interfaces[J]. Proceedings of the International Conference on Automatic Face and Gesture Recognition, 1996: 151-156

[7] 刘奇琴. 基于视觉的手势识别技术研究[D]. 大连理工大学, 2014.

[8] Molchanov P, Gupta S, Kim K, et al. Multi-sensor system for driver's hand-gesture recognition[C]. IEEE International Conference & Workshops on Automatic Face & Gesture Recognition, 2015, 1: 1-8.

[9] Murthy G R S, Jadon R S. Hand Gesture Recognition using Neural Networks[C]. Advance Computing Conference (IACC), 2010: 134-138.

中国知网 https://www.cnki.net

[10] Molchanov P, Gupta S, Kim K, et al. Hand gesture recognition with 3D convolutional neural networks[C]. 2015 IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2015: 1-7.

[11] Yan S, Xiong Y, Lin D. Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition[J]. ThirtySecond AAAI Conference on Artificial Intelligence, 2018: 34-41.

[12] Li G, Tang H, Sun Y, et al. Hand gesture recognition based on convolution neural network[J]. Cluster Computing, 2019, 22(2): 2719-2729.

[13] 王乘, 周均清, 李利军. Creator 可视化仿真建模技术[M]. 华中科技大学出版社, 2005: 2-3.

[14] 赵飞飞. 基于 Kinect 骨骼信息的手势识别及应用[D]. 太原理工大学, 2016.

[15] Conn M A, Sharma S. Immersive telerobotics using the oculus rift and the 5DT ultra data glove[C]. 2016 International Conference on Collaboration Technologies and Systems (CTS), 2016: 387-391.

[16] 程璐璐, 李传江, 王朋. 基于 MYO 和 Android 的肌电假肢手控制系统设计与实现[J]. 计算机测量与控制, 2017, 25(9): 64-67.

[17] Mo Z, Neumann U. Real-time hand pose recognition using low-resolution depth images[C]. 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2006, 2: 1499-1505.

[18] Rodrigo Ibanez, Soria A, Teyseyre A, et al. Easy gesture recognition for Kinect[J]. Advances in Engineering Software, 2014, 76: 171-180.

[19] Hernández-López J J, Quintanilla-Olvera A L, López-Ramírez J L, et al. Detecting objects using color and depth segmentation with Kinect sensor[J]. Procedia Technology, 2012, 3(1):196-204.

[20] 沈小康. 基于 Kinect 的人体步态跟踪与识别技术[D]. 山东大学, 2016.

[21] 况鹰. 基于 Kinect 运动捕获的三维虚拟试衣[D]. 华南理工大学, 2012.

[22] Shotton J, Sharp T, Kipman A, et al. Real-time human pose recognition in parts from single depth images[J]. Communications of the ACM, 2013, 56(1): 116-124.

[23] Cao Z, Simon T, Wei S E, et al. Realtime multi-person 2d pose estimation using part affinity fields[C]. Proceedings of the IEEE Conference on Computer Vision

中国知网 https://www.cnki.net

and Pattern Recognition, 2017: 7291-7299.

[24] J. M. Carmona and J. Climent. A Performance Evaluation of HMM and DTW for Gesture Recognition[J]. Lecture Notes in Computer Science, 2012, 7441: 236–243.

[25] 李杰, 基于深度卷积神经网络的动态手势识别[D]. 山东大学, 2019.

[26] 张勋, 陈亮, 胡诚. 一种基于深度学习的静态手势实时识别方法[J]. 现代计算机(专业版), 2017(34): 8-13.

[27] Zhu W, Hu J, Sun G, et al. A key volume mining deep framework for action recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1991-1999.

[28] 陈谦. 基于神经网络的自然语言语义表征方法研究[D]. 中国科学技术大学, 2018.

[29] 董士海. 人机交互的进展及面临的挑战[J]. 计算机辅助设计与图形学学报.2004, 16: 1-13.

[30] 李辉, 芦利斌, 金国栋. 基于手势识别的四旋翼控制系统[J]. 现代计算机, 2015(17):56-59.

[31] 徐守祥, 徐人凤, 于成龙. 基于流演算智能体构建三维语义实体及其交互感知[J]. 深圳信息职业技术学院学报, 2018, 58(02):47-55.

[32] 乔宇. 多种手势到同一语义的柔性映射交互模型与算法研究[D], 济南大学, 2018.

[33] Fothergill S, Mentis H, Kohli P, et al. Instructing people for training gestural interactive systems[C]. Proceedings of the SIGCHI Conference on Human Factors in Computing Systems, 2012: 1737-1746.

[34] 周士胜. 基于多通道交互方式的互动影院游戏系统的设计与实现[D]. 山东大学, 2017.

[35] 杨萍萍. 基于 Kinect 的手势动作识别研究及其在虚拟仿真系统中的应用[D]. 南京大学, 2018.

[36] 李欢. 面向作战保障的海战场环境信息集成与应用关键技术研究[D]. 国防科学技术大学, 2009.

中国知网 https://www.cnki.net

[37] 胡素芸, 邵斌澄, 李坤. 面向航天员虚拟训练的人机交互系统研制和测试[J]. 电子测量与仪器学报, 2017, 31(12): 1902-1911.

[38] 喻学锋, 杨宣东, 李凯扬. 一种基于 B/S 模式的 PACS 的研究与实现[J]. 生物医学工程学杂志, 2004, 21(3): 391-393.

[39] 王兴鲁. 基于 Unity3D 与 Kinect 的体感交互技术应用研究[D]. 兰州交通大学, 2017.

[40] 皮览月. 基于 3D 骨骼数据的动态手势识别研究[D]. 郑州大学, 2019.

[41] 刘飞. 基于 Kinect 骨架信息的人体动作识别[D]. 东华大学, 2014.

[42] Z. Ren, J. Yuan, J. Meng, Z. Zhang, Robust part-based hand gesture recognition using Kinect sensor, multimedia, IEEE Trans. Multimed, 2013: 1110–1120.

[43] Smisek J, Jancosek M, Pajdla T. 3D with Kinect[M]. Consumer depth cameras for computer vision. Springer, London, 2013: 3-25.

[44] 邓益侬, 罗健欣, 金凤林. 基于深度学习的人体姿态估计方法综述[J]. 计算机工程与应用, 2019(19): 22-42.

[45] Toshev A, Szegedy C. Deeppose: Human pose estimation via deep neural networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2014: 1653-1660.

[46] Bulat A, Tzimiropoulos G. Human pose estimation via convolutional part heatmap regression[C]. European Conference on Computer Vision. Springer, 2016: 717-732.

[47] Wei S E, Ramakrishna V, Kanade T, et al. Convolutional pose machines[C]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, 2016: 4724-4732.

[48] Newell A, Yang K, Deng J. Stacked hourglass networks for human pose estimation[C]. European conference on computer vision. Springer, 2016: 483-499.

[49] 关韬. 基于深度学习的行人姿态识别与行为预判算法研究[D]. 西安电子科技大学, 2018.

[50] Papandreou G, Zhu T, Kanazawa N, et al. Towards accurate multi-person pose estimation in the wild[C]. Proceedings of the IEEE Conference on Computer

中国知网 https://www.cnki.net

Vision and Pattern Recognition, 2017: 4903-4911.

[51] He K, Gkioxari G, Dollár P, et al. Mask R-CNN[C]. Proceedings of the IEEE international conference on computer vision, 2017: 2961-2969.

[52] Fang H S, Xie S, Tai Y W, et al. Rmpe: Regional multi-person pose estimation[C]. Proceedings of the IEEE International Conference on Computer Vision, 2017: 2334-2343.

[53] Chen Y, Wang Z, Peng Y, et al. Cascaded pyramid network for multi-person pose estimation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 7103-7112.

[54] Cao Z, Hidalgo G, Simon T, et al. OpenPose: realtime multi-person 2D pose estimation using Part Affinity Fields[J]. arXiv preprint arXiv:1812.08008, 2018.

[55] Huang G, Liu S, Van der Maaten L, et al. Condensenet: An efficient densenet using learned group convolutions[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2752-2761.

[56] 郭冲宇，杜慧敏，蒋忭忭. 视觉背景提取算法关键技术研究[J]. 计算机应用研究, 2017, 34(5): 1548-1552.

[57] 白慧茹，吕进来. 基于聚类方法改进的关键帧提取算法[J]. 计算机工程与设计, 2017, 38(7): 1929-1933.

[58] Kalal Z, Mikolajczyk K, Matas J. Tracking-learning-detection[J]. IEEE transactions on pattern analysis and machine intelligence, 2011, 34(7): 1409-1422.

[59] 刘玉鹏. 动态手势识别和跟踪算法研究[D]. 山东大学, 2019.

[60] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[C]. Advances in neural information processing systems, 2015: 91-99.

[61] Liu W, Anguelov D, Erhan D, et al. SSD: Single shot multibox detector[C]. European conference on computer vision, 2016: 21-37.

[62] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.

中国知网 https://www.cnki.net

[63]梁黄黄. 融合时空特征的端到端驾驶决策算法及仿真实现[D]. 电子科技大学, 2019.

[64]Mitra S, Acharya T. Gesture recognition: A survey[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part C, 2007, 37(3): 311-324.

[65]Zhu G, Zhang L, Shen P, et al. Multimodal gesture recognition using 3-D convolution and convolutional LSTM[J]. Ieee Access, 2017, 5: 4517-4524.

[66]彭露茜. 基于机器视觉的动态手势识别研究[D]. 重庆大学, 2017.

[67]刘爽, 史国友, 张远强. 基于 TCP/IP 协议和多线程的通信软件的设计与实现[J]. 计算机工程与设计, 2010, 31(7): 1417-1420.

中国知网 https://www.cnki.net

攻读硕士学位期间的学术成果和参与的科研项目

硕士期间发表/录用的论文及专利成果：

[1] **Yunchao Bai** , Libo Zhang , Tianxing Wang , Xianzhong Zhou，A Skeleton Object Detection-Based Dynamic Gesture Recognition Method，2019 IEEE 16th International Conference on Networking, Sensing and Control, ICNSC 2019，20192907183709 , pp. 212-217, 2019.5. **(EI)**

[2] **白云超**, 李东坡, 周献中*. 基于 Kinect 骨骼信息下的手势识别研究[C], 中国系统仿真与虚拟现实会议, 2018.

[3] 周献中, **白云超**, 杨佩, 李东坡, 王砾. 基于目标检测的快速动态手势识别系统及方法[P]. 中国发明专利, 申请号: 201910344106.6. 2019-08.

[4] 徐成成, **白云超**, 周献中*. 基于近似字符串分类的动态手势识别方法研究[C], 中国系统仿真与虚拟现实会议, 2019.

[5] 李东坡, **白云超**, 周献中*.基于眼动的虚拟键盘交互系统的设计与实现[C], 中国指挥与控制学会, 2018.

硕士期间主要参与的科研项目：

1. 国家自然科学基金面上项目（编号 61876079）：面向多任务人机协作的通道匹配机理研究；（2019 年-2022 年）
2. 中央军委装发项目，北方信息控制研究院集团有限公司：作战信息智能协同交互技术。（2018 年-2020 年）

中国知网 https://www.cnki.net