非结构环境下桌面级工件 6D 位姿估计方法研究

摘要

机器视觉在增强机器人的感知和理解能力中扮演着不可或缺的角色，而目标检测则是该领域的一个核心任务，其目的在于识别图像或视频中的物体，并准确确定它们的位置和类别。然而现实生活中，目标检测面临着诸多挑战，例如：大多数物体处于非结构化的环境中，这意味着物体可能受到对象遮挡、光照变化、背景复杂、环境的动态变化等影响。或者现有的方法通常需要某些对象属性，例如有足够纹理的表面或不对称形状，以避免混淆。为了更准确地估计物体的 6D 位姿，解决上述挑战所带来的位姿估计不准确的问题，本文采取了以下两个步骤。首先在公开含桌面级工件的数据集上进行仿真实验并查看效果，其次用迁移学习的方法自制数据集，训练出满足非结构环境下的 RetinaNet 2D 目标检测器和增强自编码器，并得到了如下成果：

（1） 基于仅增强自编码器的模型可以对已训练工件进行 6D 位姿估计，且在无遮挡或遮挡较小的情况下得到较准确的位姿信息。

（2） 基于 keras 的 RetinaNet 2D 目标检测器在经过一定数量的数据集训练后，不仅能检测出无遮挡的物体，而且较大面积遮挡的物体仍能以较高置信度检测出。

（3） 在使用增强自编码器对物体进行 6D 位姿检测前，先将 RGB 图片输入到 RetinaNet 2D 检测器中，将检测出的含目标的边界框裁剪后再投入到增强自编码器中可优化仅使用增强自编码器偶发的因为遮挡而检测失败的问题。

关键词：非结构化环境；桌面级工件；6D 位姿；目标检测

Research on 6D pose estimation method of desktop-level workpieces in unstructured environment

ABSTRACT

Machine vision plays an essential role in enhancing robots' perception and understanding capabilities, and object detection is a core mission in this field, which aims to identify objects in images or videos and accurately determine their location and category. However, in real life, target detection faces many challenges. For example, most objects are in an unstructured environment, which means that objects may be affected by object occlusion, lighting changes, complex backgrounds, dynamic changes in the environment, etc. Existing methods usually require certain object properties, such as sufficiently textured surfaces or asymmetric shapes, to avoid confusion. In order to estimate the 6D pose of the object more accurately and solve the problem of inaccurate pose estimation caused by the above challenges, this thesis takes the following two steps. First, we conduct simulation experiments on a public data set containing desktop-level workpieces and check the results. Secondly, we use the transfer learning method to create a new data set to train the RetinaNet 2D target detector and Augmented Autoencoders that meet the needs of unstructured environments, and obtain the following results:

(1) The model based on only Augmented Autoencoders can perform 6D pose estimation on trained workpieces, and obtain more accurate pose information when there is no occlusion or small occlusion..

(2) After being trained on a certain number of data sets, the RetinaNet 2D object detector based on keras can not only detect unoccluded objects, but also objects with large areas of occlusion can still be detected with a comparatively high degree of confidence..

(3) Before using the Augmented Autoencoders to detect the 6D pose of the object, first input the RGB image into the RetinaNet 2D detector, crop the detected bounding box

with the target, and then put it into the Augmented Autoencoders. The problem of occasional detection failures due to occlusion using only Augmented Autoencoders can be optimized.

Keywords: Unstructured environment; Desktop-level workpieces; 6D pose; Target detection

目录

第 1 章 绪论 6
1.1 研究背景及意义 6
1.2 目标检测算法的研究现状 6
1.2.1 传统目标位姿检测算法 8
1.2.2 基于深度学习的目标位姿检测算法 9
1.3 6D 位姿检测技术概述 10
1.4 存在问题 10
1.5 本文的主要内容及组织框架 11
第 2 章 工件 6D 位姿估计理论基础 12
2.1 RetinaNet 目标检测器算法 12
2.1.1 Focal Loss 12
2.1.2 RetinaNet 算法 13
2.2 自编码器模型 14
2.2.1 自编码器 14
2.2.2 增强自编码器 15
2.3 迁移学习方法 16
2.4 本章小结 17
第 3 章 非结构环境下工件 6D 位姿估计策略研究 18
3.1 基于增强自编码器的工件位姿估计模型 18
3.1.1 距离估计器 19

3.1.2 透视纠正 19
3.2 T-LESS 数据集 20
3.3 仿真结果分析 22
3.3.1 2D 目标检测仿真结果 22
3.3.2 增强自编码器训练结果 26
3.3.3 仅增强自编码器仿真结果 27
3.3.4 RetinaNet 结合增强自编码器检测结果 28
3.4 本章小结 29
第 4 章 基于迁移学习的桌面级工件 6D 位姿估计 30
4.1 实验系统构建 30
4.1.1 相机选型 30
4.1.2 实验方案确定 31
4.2 实验数据集获取 31
4.3 实验结果分析 33
4.3.1 2D 目标检测实验结果 33
4.3.2 AAE 训练自制数据集结果 34
4.3.3 RetinaNet 结合 AAE 检测结果 35
4.4 本章小结 36
总结与展望 37
参考文献 38
致谢 41

第 1 章 绪论

1.1 研究背景及意义

随着机器人技术、人工智能和智能化生产等领域的迅速发展，中国政府提出的旨在推动中国制造业转型升级的战略计划中，机器人视觉技术被认为是关键技术之一，且被列为重点发展方向之一。无论是工业机器人还是自动化系统都需要机器人能够准确地感知并理解环境中物体的位置和姿态，以便进行精确操作和交互，例如智能家居、无人仓库、医疗机器人等领域。在工业生产中，精确的物体定位和姿态估计是智能化生产的基础。通过实现对桌面级工件的准确感知和理解，生产流程可以变得更高效、灵活和智能，从而提高生产效率和产品质量。

然而在现实生活中桌面级工件大多处于非结构化环境中，这导致工件可能存在光照变化、背景复杂等环境问题，同时也可能出现工件之间相互遮挡等实际问题，这些因素给物体识别和姿态估计带来了挑战。因此，研究如何在这样的复杂环境中准确地对物体的 6D 位姿进行估计需要我们不断地实践和创新，努力找寻更好的办法。

当前，随着计算机视觉、深度学习和传感器技术的不断进步，国内已经涌现出了许多用于物体识别和姿态估计的新方法和技术。这些技术的发展为研究非结构环境下桌面级工件的 6D 位姿估计提供了新的机遇和可能性。因此，研究非结构环境下桌面级工件的 6D 位姿估计方法对于推动人工智能、机器人技术和智能制造的发展具有深远的研究意义。

1.2 目标检测算法的研究现状

目标检测(Target Detection)是机器视觉领域的一个重要任务，旨在识别图像或视频中的物体，并确定它们的位置和类别，通常用边界框来框选物体。因为物体的尺

寸变化范围很大而且姿态不定，一张图片上可能有多类物体甚至可以出现在照片的任何位置，所以目标检测要通过特征提取、候选区域生成、目标分类和边界框回归等步骤来识别多个物体。目标检测在不同领域中的主要应用分类有工业自动化领域的物体检测和跟踪以及机器人抓取[1]；增强现实和虚拟现实领域的物体识别和跟踪[2]；自动驾驶和智能交通领域的行人和车辆检测以及障碍物识别[3]；智能监控和安防领域的实时视频监控以及人脸检测和识别[4]；医疗影像分析领域的病灶检测以及器官定位[5]；农业和环境监测领域的农作物检测[6]等（如图 1-1）。

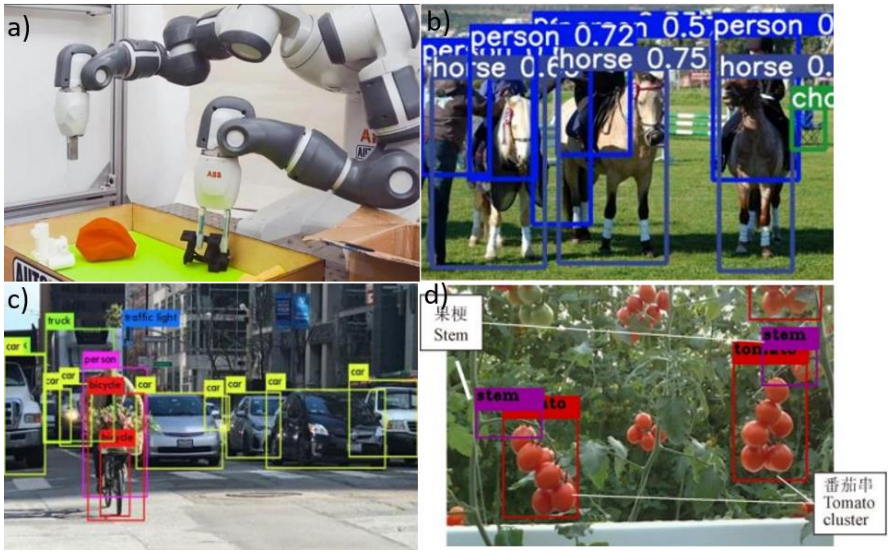

图 1-1 目标检测应用实例

a) 机械臂抓取; b) 物体分类识别; c) 自动驾驶; d) 农作物检测

目标检测主要分为两类：一类是传统的目标检测算法，另一类是基于深度学习的目标检测算法。从 2001 年到 2014 年，主要使用传统的目标检测算法，2014 年随着 RCNN[7]的出现，基于深度学习的目标检测算法发展愈加迅速，图 1-2 概括性描述了目标检测发展史，以下将详细讲述目标检测的两大分类。

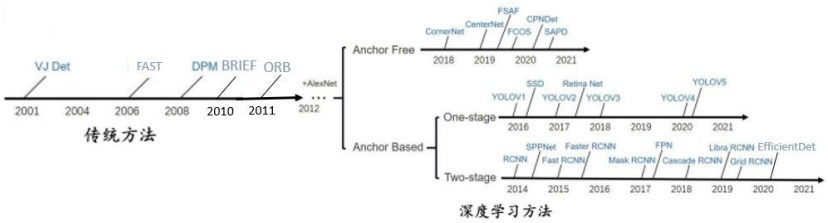

图 1-2 2D 目标检测发展史[8]

1.2.1 传统目标位姿检测算法

传统的目标检测算法流程包括图像预处理、特征提取、目标检测和结果后处理等步骤（如图 1-3）。这些方法通常在简单场景下具有一定的效果。常见的传统目标检测算法有 FAST（Features from Accelerated Segment Test）算法，BRIEF（Binary Robust Independent Elementary Features）算法，ORB（Oriented FAST and Rotated BRIEF）算法。

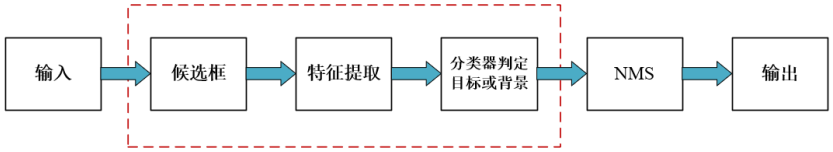

图 1-3 传统目标检测算法原理图[9]

FAST 算法[10]是由 Edward Rosten 和 Tom Drummond 在 2006 年提出的，主要用于在图像中快速检测角点（即关键点）。该算法的设计目的是提高角点检测的速度，使其适用于实时应用，例如实时目标跟踪、三维重建等领域。

BRIEF 算法[11]是由 Michael Calonder 等人在 2010 年提出的，主要用于图像特征描述子的生成，它使用二进制字符串来描述图像的局部特征，并且具有高效性和高鲁棒性。BRIEF 算法的特点使得它在图像匹配、物体识别、图像配准等领域中有着广泛的应用。

ORB 算法[12]是由 Ethan Rublee 等人在 2011 年的论文中提出的，主要用于图像

特征检测和描述子生成，它结合了 FAST 特征检测器和 BRIEF 描述子生成器，同时添加了一些额外的改进，如方向性和旋转不变性，使其在实时应用和计算资源受限的设备上得到广泛应用。ORB 算法常用于图像配准、物体识别、三维重建等计算机视觉任务中。

1.2.2 基于深度学习的目标位姿检测算法

基于深度学习的位姿估计有很大的优势，通过卷积操作提取图像特征，网络能够自主学习物体的语义信息从而估计出物体的 6D 位姿。

深度学习算法主要分为两类：

One-stage 方法：例如 YOLO[13]算法系列、SSD 算法[14]，RetinaNet[15]这类算法是直接通过 CNN 网络一次性进行分类定位（如图 1-4 左图），运算速度非常快，适合做实时监测任务，但是检测精度较低。

Two-stage 方法：例如 Fast-RCNN[16]、 Faster-Rcnn[17]算法、Mask-Rcnn[18]算法，这类算法比 one-stage 方法多了一步预选工作（如图 1-4 右图），效果很好就是速度较慢，检测精度较高。

图 1-4 基于深度学习的目标位姿检测算法的 One-stage 方法原理图（左图）和 Two-stage 方法（右图）

2014 年，Ross Girshick 等人提出了 RCNN[7]，将深度卷积神经网络（CNN）用于目标检测。RCNN 通过使用区域建议方法生成候选区域，并使用 CNN 提取特征进行目标分类和边界框回归。RCNN 的提出标志着深度学习在目标检测领域的崭露头角，为后续的目标检测算法的发展奠定了基础。在 RCNN 的基础上，Girshick 等人于 2015 年提出了 Fast-RCNN[16]，通过将区域提取和特征提取过程合并为单个网络，

从而提高了目标检测的速度和效率。同样在 2015 年，Ren 等人提出了 Faster-RCNN[17]，引入了区域生成网络，实现了端到端的目标检测，进一步提高了速度和准确性。YOLO[13]（You Only Look Once）系列是一种快速的单阶段目标检测算法，通过直接在图像上进行密集预测来实现目标检测。Liu 等人在 2016 年提出了 SSD[14]，也是一种单阶段目标检测算法，通过在图像上应用多尺度的卷积滑动窗口来检测目标，并同时预测目标的类别和边界框。He 等人于 2017 年提出了 Mask R-CNN[18]，通过在 Faster-RCNN[17]基础上添加一个分割头部，实现了目标的精确分割，从而同时完成目标检测和分割任务。Lin 等人在 2017 年提出了 RetinaNet[15]，通过引入 Focal Loss 来解决类别不平衡问题，提高了目标检测算法的性能。EfficientDet[19]是由 Google 在 2020 年提出的一种高效的目标检测算法，通过设计轻量级的模型结构和优化训练策略，实现了高性能和高效率的目标检测。

1.3 6D 位姿检测技术概述

6D 位姿估计是指用于检测物体在三维空间中的位置和姿态的技术。其中的“6D”代表六个自由度，包括三个平移自由度（x、y、z 轴上的位移）和三个旋转自由度（绕 x、y、z 轴的旋转）。

6D 位姿估计通常利用传感器数据（如摄像头、激光雷达等）和算法来确定物体在三维空间中的位置和方向。这些算法可能包括特征提取、目标识别、姿态估计等步骤，最终目标是精确地确定物体的位置和姿态，以便后续的应用，如增强现实技术通过位姿估计来测量真实环境中的物体位姿[20]，自动驾驶通过位姿估计识别道路与交通避障[21]，SLAM 中用位姿估计构建地图及定位[22]。

1.4 存在问题

目前存在的问题：首先，当前的解决方案通常对于诸如对象遮挡、不同种类的背景杂波和环境的动态变化之类的典型挑战的鲁棒性不高。其次，现有的方法通常需要某些对象属性，例如足够的纹理表面结构或不对称形状，以避免混淆。最后，当前的系统在运行时间以及它们所需的注释训练数据的数量和类型方面较为复杂，导致效率不高。

1.5 本文的主要内容及组织框架

本文主要结构如下：

第一章绪论主要介绍了本课题的研究背景以及意义，目标检测算法的研究现状，6D 位姿检测技术概述以及存在的问题，并确定了本文的主要框架结构。

第二章是本课题的理论基础，主要讲述了 RetinaNet 目标检测器的原理，自编码器的原理以及增强自编码器的原理和迁移学习方法。

第三章是仿真部分，主要讲述了降噪自编码器的变体增强自编码器，以及基于增强自编码器的工件位姿估计模型；介绍了本文主要使用的数据集——T-LESS 数据集，以及它的内容和特点；最后进行了对仅增强自编码器的仿真结果分析。

第四章是实验部分，主要讲述了实验使用的硬件以及软件；自制实验数据集的流程；最后是对自制数据集测试出来的实验结果进行分析。

最后是对全文进行总结、分析与展望。

第 2 章 工件 6D 位姿估计理论基础

2.1 RetinaNet 目标检测器算法

2.1.1 Focal Loss

由上面对于基于深度学习的目标位姿检测算法的介绍可知，One-stage 算法的精度相对于 Two-stage 偏低，这是由于正负类别不平衡导致的，因此通过重新设计标准的交叉熵损失来解决这种难易样本不平衡的问题，即 Focal Loss。而结合了 Focal Loss[15]的 One-stage 的目标检测器被称为 RetinaNet。

One-Stage 的模板检测器通常会产生 10k 数量级的框，但只有极少数是正样本，正负样本数量非常不平衡。大家在计算分类的时候常用的损失——交叉熵的公式如下：

$$\mathrm{CE}(p,\mathrm{y})=\begin{cases} -\log(p), & if\ y=1 \\ -\log(1-p), & otherwise \end{cases} \tag{1}$$

为了解决正负样本数量不平衡的问题，大家经常在交叉熵损失前面加一个参数α，即：

$$\mathrm{CE}=\begin{cases} -\alpha\log(p), & if\ y=1 \\ -(1-\alpha)(1-p), & if\ y=0 \end{cases} \tag{2}$$

虽然α平衡了正负样本的数量，但实际上，目标检测中大量的候选目标都是易分样本。这些样本的损失很低，但是由于数量极不平衡，易分样本的数量相对来讲太多，最终主导了总的损失。为了解决难易样本的不平衡的问题，将高置信度(p)样本的损失进行降低， 即下面的公式：

$$\mathrm{FL}=\begin{cases} -(1-p)^{\gamma}\log(p), & if\ y=1 \\ -p^{\gamma}\log(1-p), & if\ y=0 \end{cases} \tag{3}$$

取γ=2，如果p=0.9，那么$(1-0.9)^2=0.001$，损失降低了 1000 倍。公式(3)解决了难易样本的不平衡，公式(2)解决了正负样本的不平衡，将公式（2）与（3）结合使用，同时解决正负难易 2 个问题，所以最终 Focal Loss 的形式如下：

$$\mathrm{FL}=\begin{cases} -\alpha(1-p)^{\gamma}\log(p), & if\ y=1 \\ -(1-\alpha)p^{\gamma}\log(1-p), & if\ y=0 \end{cases} \tag{4}$$

图 2-1 展示了 Focal Loss 取不同的λ时的损失函数下降。

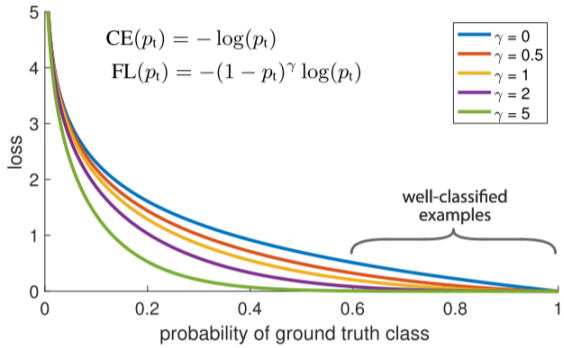

图 2-1 Focal Loss 取不同的 λ 时的损失函数

实验结果展示，当γ=2，α=0.75 时，效果最好。

2.1.2 RetinaNet 算法

2D 检测器是在一定的数据集训练后得到相应的在测试集及验证集上表现较好的训练模型，通过将训练模型转化成推理模型并在目标图片上识别出目标，推理模型会给出目标框需要四个参数：左上角 x 轴、y 轴坐标、右下角 x 轴、y 轴坐标，四个坐标形成的框内便是 2D 检测器检测出来的目标。而 RetinaNet 算法通过将图片调整为正方形，为了防止失真会在图片的边缘加上微调，之后 RetinaNet 算法会将图像分为 5 种不同大小的网格，网格的大小与输入的形状相关，分别是 75×75、38×38、19×19、10×10 和 5×5，其中 75×75、38×38 的网格用来检测小物体，10×10、5×5 的网格用来检测大物体。RetinaNet 的每个网格存在 9 个先验框，当某个物体与某个网格的某个先验框最接近的时候，这个物体就由这个网格的这个先验框来确定。

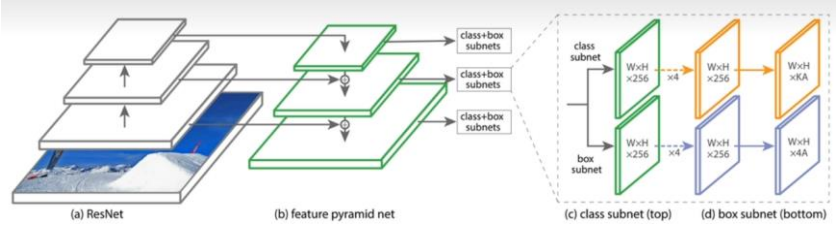

图 2-2 .一级 RetinaNet 网络架构在前馈 ResNet 架构之上使用特征金字塔网络（FPN）骨干

图 2.2 （a）生成丰富的多尺度卷积特征金字塔（b）RetinaNet 在这个主干上连接了两个子网，一个用于分类锚框（c）另一个用于从锚框回归到地面实况对象框（d）网络设计有意简单，这使得这项工作能够专注于一种新的焦点损失函数，该函数消除了一级检测器和最先进的两级检测器之间的准确性差距，如具有 FPN 的 Faster R-CNN，同时以更快的速度运行。[15]

2.2 自编码器模型

2.2.1 自编码器

自编码器（Auto Encoder，简称 AE）[23]是一种无监督的数据维度压缩和数据特征表达方法，通常由两部分组成：编码器（Encoder）和解码器（Decoder）。自编码器的训练过程旨在重新提取特征，降低维度，最小化重构误差，使得解码器能够提取出源数据中具有代表性的信息，缩减输入中的信息量，把提取过后的信息表征放到网络中学习，仍然可以使输出无限接近于原始值。自编码器的主要应用包括特征提取、数据降维、数据去噪等。（如图 2-3）

自编码器的训练目标是最小化输入 x 和解码器重构输出 x’之间的差异，通常使用重构误差作为损失函数，即为重构损失（Reconstruction Loss）。

$$\text{ReconstructionLoss}=l_2=\sum_{i-1}^{n} \| xi - \bar{x}_i \|^2 \qquad (5)$$

自编码器的变体有：堆叠自编码器（SAE）、降噪自编码器（DAE）、稀疏自编码器（SAE）、变分自编码器(VAE)、堆叠稀疏自编码器(SSAE)、堆叠降噪自编码器(SDAE)。

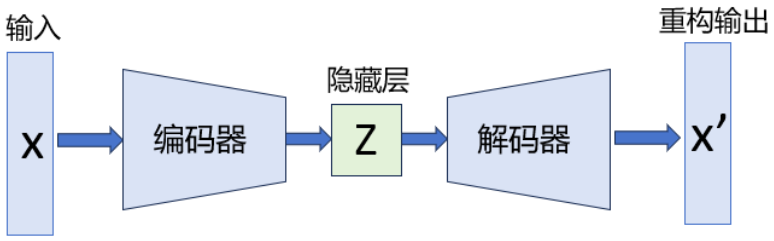

图 2-3 自编码器原理

2.2.2 增强自编码器

本文采用的增强自编码器（AAE）是基于降噪自编码器的一种变体，该变体使用域随机化对 3D 模型的模拟视图进行训练。降噪自编码器 [24]在特征学习和数据去噪领域中得到了广泛应用，与自编码器不同的是：自编码器可能会过度拟合训练数据，只是简单地记住并重现输入，而不会学习到有用的数据表示；降噪自编码器通过训练过程中的噪声注入，迫使模型学习对噪声具有鲁棒性，并集中注意力于学习数据的一般特征，从而产生更加有用和鲁棒性更高的数据表示（如图 2-4）。域随机化建立在一个假设之上，即通过在各种半现实环境，例如随机光照条件、背景、饱和度等中对渲染视图进行训练，将它推广到真实图像。总的概括来说，增强自编码器和降噪自编码器一样，通过引入噪声并在训练过程中最小化噪声污染输入与原始输入之间的重构误差，有助于学习更鲁棒和有意义的数据表示，而不是简单地重现输入。

Commented [h1]: AAE 用图表示

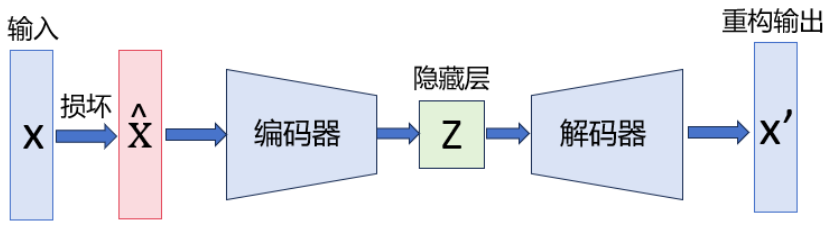

图 2-4 降噪自编码器原理

2.3 迁移学习方法

迁移学习[25]是一种机器学习方法，它利用从一个任务中学到的知识来改善另一个相关任务的学习效果，通俗的来说就是用别人训练好的模型或者权重参数来当自己的权重参数的初始化。通常情况下，迁移学习的目标任务和源任务之间存在某些程度的相关性，即它们共享一些相似的特征空间或任务结构。当手中数据不太多而导致模型容易过拟合或者训练需要调节各种参数、训练模型很大导致花费的时间很多这些情况下迁移学习就起到了很大作用（如图 2-5）。

迁移学习方法通常可以分为以下几种：特征提取器迁移、模型微调和多任务学习。迁移学习方法在各种机器学习任务中都有广泛的应用，特别是在数据稀缺或标记不充分的情况下，可以显著提高模型的性能和泛化能力。通过有效地利用源任务的知识和经验，迁移学习方法可以在各种领域中取得很好的效果，包括图像识别、自然语言处理、语音识别等。

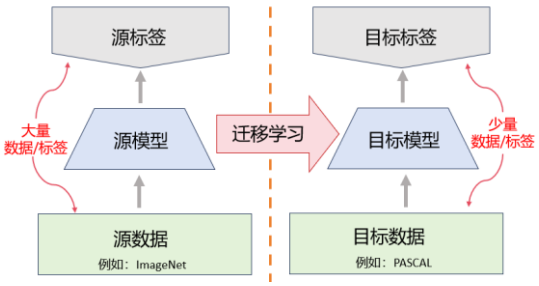

图 2-5 迁移学习原理图

2.4 本章小结

本章主要讲述了三个工件 6D 位姿估计理论基础：RetinaNet 目标检测器算法、自编码器模型、迁移学习方法。首先 RetinaNet 目标检测器算法中主要讲述了它的基础 Focal Loss 的主要公式以及公式的推导，然后讲述了 RetinaNet 算法原理；其次介绍了自编码器模型和增强自编码器的原理和特点；最后介绍了迁移学习的定义、分类、原理以及应用。

第 3 章 非结构环境下工件 6D 位姿估计策略研究

3.1 基于增强自编码器的工件位姿估计模型

首先本文采用的是单个 RGB 图像进行检测。作为第一步，本文建立在 2D 目标检测器提供检测到目标的边界框和类别标签（如图 3-1）。在检测到 2D 目标后，目标所在的边界框被裁剪并输入到增强自编码器中。在生成的场景裁剪上，本文采用了新的 3D 方向估计算法，该方法不同之处在于，本文在训练期间没有使用深度信息，且没有明确地从 3D 姿势注释的标签中学习。相反，本文直接从由域随机化渲染的含 3D 模型的 RGB 图片中学习表征。但是在拍摄时，检测目标向图片边界靠近的情况下，即不位于图像中心位置，图像识别仍然缺乏准确性。因此，本文用了透视纠正模块，通过透视纠正解决了这个问题，并对不位于图像中心的物体进行了更准确的 6D 姿态估计。

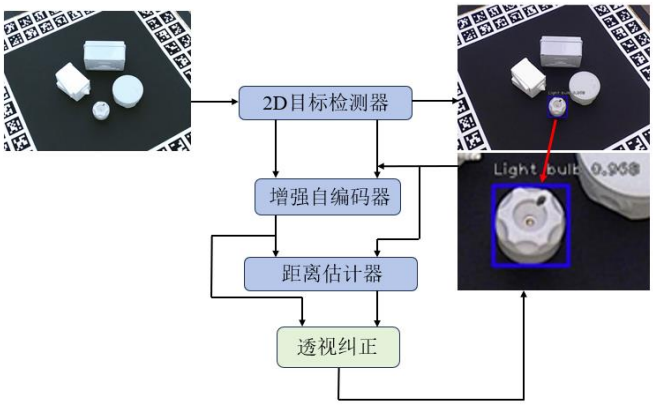

图 3-1 完整的 6D 目标检测流程

本文的方法有几个优点：

(1) 该方法能够独立于具体的方向表示方法，处理由对称视图引起的模糊姿态，并且避免了图像到方向的一对多映射，即能够准确地将图像映射到唯一的物体方向，而不会出现多个可能的方向；

(2) 本文专门针对 3D 方向研究进行了编码，该方法在面对遮挡和杂乱背景时仍能够保持良好的性能，即能够准确地识别物体的方向，不受遮挡和背景干扰的影响，并具有很好的泛化能力，能在不同的环境和测试传感器下有效运行；

(3) 增强自编码器不需要任何真实的姿态标注训练数据。相反，该方法采用了自监督学习的方法来训练增强自编码器，对 3D 模型视图进行编码，从而克服了对大型姿态注释数据集的需求。[27]

3.1.1 距离估计器

本文估计了从相机到物体中心的 3D 距离 t_{real}，类似于 Kehl 等人[26]，将每一个合成对象视图测试出来的 2D 边界框裁剪保存在一个代码本中，并计算边界框对角线长度$\| bb_{syn,i} \|$。在测试时，检测到的边界框对角线的长度$\| bb_{real} \|$和对应代码本的对角线$\| bb_{syn,argmax(cos_i)} \|$的比率，针孔相机模型得到的距离估计值$\hat{t}_{real,z}$

$$\hat{t}_{real,z}=t_{syn,z}\times\frac{\|bb_{syn,argmax(cos_i)}\|}{\|bb_{real}\|}\times\frac{f_{real}}{f_{syn}} \quad (6)$$

与合成渲染距离 $t_{syn,z}$ 和焦距f_{real}、f_{syn}的真实传感器合成试图。如下所示：

$$\Delta\hat{t}=\hat{t}_{real,z}K_{real}^{-1}bb_{real,c}-t_{syn,z}K_{syn}^{-1}bb_{syn,c} \quad (7)$$

$$\hat{t}_{real}=tsyn+\Delta\hat{t} \quad (8)$$

其中$\Delta\hat{t}$是合成物体到真实物体中心的估计向量，K_{real} 和 K_{syn} 是摄像机矩阵$bb_{real,c}$和$bb_{syn,c}$是齐次坐标下的边框中心，$\hat{t}_{real}$和 t_{syn}=（0，0，$t_{syn,z}$）是从相机到物体中心的平移向量。

3.1.2 透视纠正

虽然代码本是通过编码中心对象视图创建的，但测试图像裁剪通常不是来自图

像中心。当以恒定的对象方向平移图像平面中的对象时，对象视图的外观会发生变化。这会导致从代码本到图像边界的旋转估计出现明显的误差。然而，这个错误可以通过确定对象旋转来纠正，该对象旋转在将其转换为本文的估计$\hat{t}_{real}$时大致保留了对象的外观。

$$\begin{pmatrix}\alpha_x\\ \alpha_y\end{pmatrix}=\begin{pmatrix}-\arctan(\hat{t}_{real}/\hat{t}_{real,z})\\ -\arctan(\hat{t}_{real,x}/\sqrt{\hat{t}_{real,z}^2+\hat{t}_{real,y}^2})\end{pmatrix} \tag{9}$$

$$\hat{R}_{\mathrm{obj2cam}}=\mathrm{R_y}(\alpha_y)\mathrm{R_x}(\alpha_x)\,\hat{R}'_{obj2cam} \tag{10}$$

其中α_x、α_y描述相机轴周围的角度，$\mathrm{R_y}(\alpha_y)\mathrm{R_x}(\alpha_x)$对应的旋转矩阵来矫正从物体到相机的初始旋转估计$\hat{R}'_{obj2cam}$。如果在测试时预计会出现强烈的视角失真，那么训练图像x'也可以以随机距离记录，而不是恒定距离。然而，在基准测试中，透视失真是最小的，因此x'的随机在线图像平面缩放就足够了。

3.2 T-LESS 数据集

T-LESS 数据集是一个公开的数据集，主要用于无纹理刚性物体的 6D 姿态估计。该数据集具有 30 个与桌面级工件相关的对象（如图 3-2a），它们没有显著的纹理，也没有任何颜色或反射特性的区别，这意味着对象不能可靠地识别与依赖于光度局部补丁检测器[28]和描述符的传统技术[29]。这些物体在形状和大小上表现出对称性和部分相似性。此外，这些物体的一个独特特征是其中一些是其他物体的一部分，例如：对象 6 构成了对象 7 和 8，对象 10 构成了对象 9，而对象 17 和 18 的中心部分几乎与对象 13 相同。在工业环境中，表现出类似性质的物体是常见的。该数据集使用三个同步传感器捕获训练和测试图像，特别是结构光法和飞行时间法的 RGB-D 传感器以及高分辨率的 RGB 相机。每个传感器大约有 39 K 个训练图像和 10 K 个测试图像。此外，为每个对象提供两种类型的 3D 模型，即手动创建的 CAD 模型和半自动重建的模型。训练图像在黑色背景下描绘单个对象。测试图像来自 20 个具有不同的复杂性的测试场景（如图 3-2b），从简单的场景与几个孤立的对象增加到多个实例

的几个对象将他们大量、混乱且闭塞地摆放。

与其他数据集相比，T-LESS 数据集在以下特征的组合方面是独一无二的。它包含：（1）大量的行业相关对象；（2）在受控条件下捕获的训练图像；（3）具有大的视点变化的测试图像和多个实例中的对象，具有受杂波和遮挡的影响，甚至包括即使对于现有技术的方法也具有挑战性的测试情况；（4）用同步和校准的三个传感器捕获的图像；（5）所有建模对象精确的地面实况 6D 姿态；（6）每个对象的两种类型的 3D 模型。[30]

图 3-2 T-LESS 包括 a) 30 个对象的训练图像和 3D 模型以及 b) 20 个场景的测试图像 [30]

3.3 仿真结果分析

3.3.1 2D 目标检测仿真结果

在 2D 检测器的训练上，本文制作了共计 503 张的含有 Light bulb 的图片，并使用 Make Sense 软件将数据集进行标注，将 503 张的数据集以 8：2 的比例分成相应的训练集和测试集及验证集，并设置训练轮数(epochs)为 11，考虑到具有 RestNet50 主干的 RetinaNet 的 1 个批量(batch size)需要 3400MiB，因此训练指定训练批量为 12，训练步数(steps)为 42，在训练完成时，通过 tensorflow 自带的 tensorboard 对训练的数据记录进行可视化。

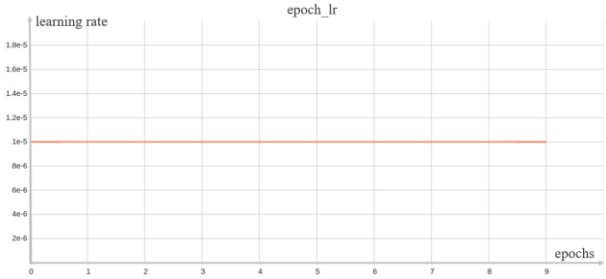

图 3-3 2D 检测学习率图

从图 3-3 可见，11 个训练轮数里采用了固定学习率（learning rate，简称 lr），所以训练时学习率保持保持不变。

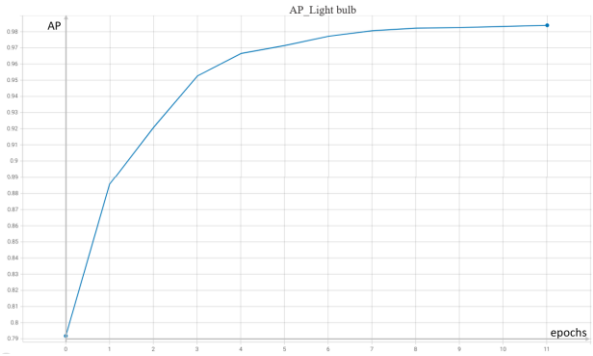

图 3-4 2D 检测 Light bulb 平均精度图

图 3-4 是训练的平均精度图， 它是用于评估目标检测模型在单个类别上的性能的指标，计算方法是根据预测的检测结果按照置信度排序，然后计算精度(Precision)-召回率(Recall)曲线下的面积作为该类别的 AP，一个类别的 AP 范围是 [0, 1]，值越高表示模型在该类别上的性能越好。零件 Light bulb 的平均精确率都随着训练轮数的增加而增加，并在第 7 轮的时候精确率达到 0.98 以上。

以一张图片的物体检测为例，检测算法框出 N 个框，正确检测出物体的框有 k 个，实际上图片中有 M 个物体：

$$\text{Recall} = k / M \tag{11}$$

$$\text{Precision} = k / N \tag{12}$$

Recall 和 Precision 之间是有关系的，如果大幅度增加检测框，此时 k 增加，M 不变，N 增加，那么召回率增加、精度下降。

假设有一组图片，里面有若干待检测的目标，Precision 就代表模型检测出来的目标有多大比例是真正的目标物体，Recall 就代表所有真实的目标有多大比例被模型检测出来了。

表 3-1 目标检测 TP，FP，TN，TP 的值

	相关，正类	无关，负类
被检索到的	TP (true positives)	FP (false positives)
未被检索到的	FN (false negatives)	TN (true negatives)

首先根据上表 3-1 的规则计算出 TP，FP，TN，TP 的值，则 Precision，Recall 可表示为：

$$\text{Precision}=\frac{TP}{TP+FP} \tag{13}$$

$$\text{Recall}=\frac{TP}{TP+FN} \tag{14}$$

对于 PR 曲线来说，使用积分来进行计算:

$$\text{AP}=\int_0^1 p(r)dr \tag{15}$$

在实际应用中，我们并不直接对该 PR 曲线进行计算，而是对 PR 曲线进行平滑处理，即对 PR 曲线上的每个点，Precision 的值取该点右侧最大的 Precision 的值。用公式来描述就是 $P_{smooth}(r)=max_{r'\geq r}P(r')$。用该公式进行平滑后再用上述公式计算 AP 的值。

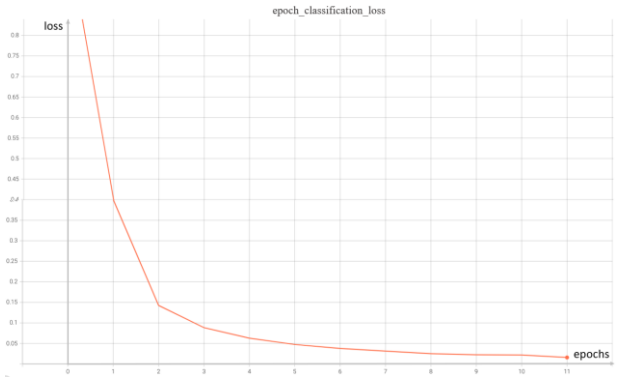

（a）分类损失

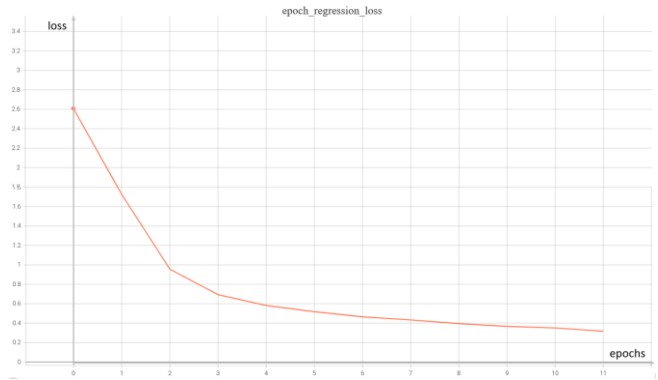

（b）回归损失

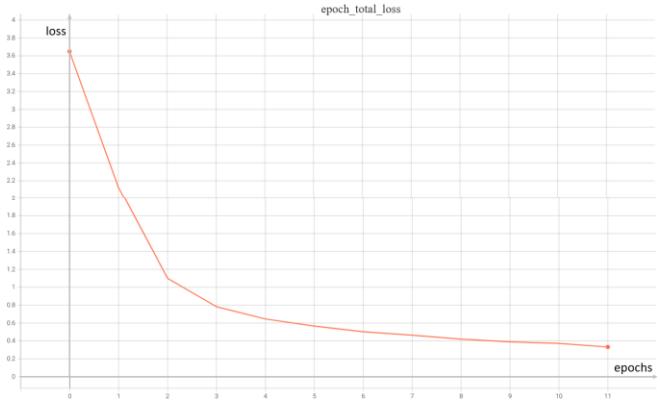

（c）总损失

图 3-5 2D 检测损失图

在机器学习和深度学习中，常见的损失函数有多种，其中包括分类损失（classification loss）、回归损失（regression loss）以及总损失（total loss）。这些损失函数的作用和用途有所不同：

分类损失用于分类任务，它衡量了模型预测结果与实际标签之间的差异，例如 Focal Loss。分类损失关注的是类别之间的区分度，它帮助模型学会将输入数据正确分类到不同的类别中。图 3-5（a）中，分类损失一开始很高，但是随着训练的开始而急速下降，在第 5 轮的时候分类损失已经在 0.05 以下，并且继续向 0 收敛。

回归损失用于回归任务，它衡量了模型预测结果与真实值之间的差异。回归损失关注的是预测值与真实值之间的接近程度，它帮助模型学会预测连续型变量的值。图 3-5（b）反映了训练回归损失的情况，和分类损失一样，刚开始都是从较高的损失快速下降，然后逐渐收敛，趋向于 0。

总损失是指模型训练过程中需要最小化的整体损失，它通常由分类损失和回归损失组成，可以根据任务的需要进行调整和组合。如图 3-5（c），在目标检测任务中，总损失可以由分类损失和回归损失的加权和组成，然后通过优化算法来最小化总损失，以综合考虑分类准确性和目标位置的准确性。由于训练损失都收敛，所以证明训练较为成功，为后续的测试中 2D 检测器能够相应的检测出图片中的预训练零件打下基础。

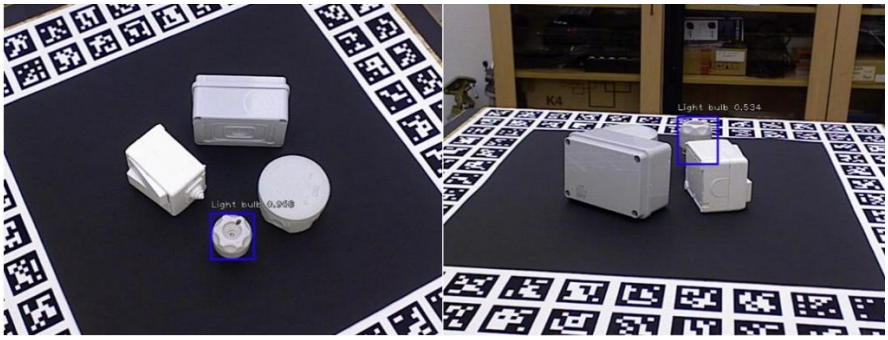

图 3-6 2D 检测仿真结果

RetinaNet 在检测到目标后，通常会在目标周围绘制一个边界框，并输出一些与该框相关的数据。这些数据通常包括：类别标签和置信度分数（如图 3-4）。置信度通常指的是模型对其预测结果的确信程度。通常是一个介于 0 到 1 之间的概率值，

越接近 1 表示模型越确信这个检测结果是正确的。在将训练后得到的训练模型转化成推理模型后，本文使用推理模型进行推理，本文从测试集中挑选了有无遮挡的两张图片，在无遮挡的情况下，如图 3-3(a)所示，其对零件 Light bulb 的置信度能达到 0.968，在遮挡面积较大时，其对零件 Light bulb 的置信度仍能达到 0.534，具有较高的鲁棒性。证明 2D 检测器训练较为成功，将把以上过程进行迁移学习到自制数据集的实验中去。

3.3.2 增强自编码器训练结果

对于增强自编码器的训练，本文输入想要检测的零件模型的 PLY 文件，PLY 文件是一种灵活性高，且易于解析的三维模型的文件格式。对于无纹理的桌面级工件的训练集，首先对训练零件位姿均匀采样，在保持重建目标干净的同时，本文随机地对输入训练视图应用如下几点的额外增强：（1）使用随机光位置和随机漫反射和镜面反射[31]进行渲染，（2）从 Pascal VOC 数据集插入随机背景图像[32]，（3）改变图像对比度、亮度、高斯模糊和颜色失真，（4）使用随机对象遮罩或黑色正方形应用遮挡。然后将上述几何颜色增强输入的图片放入增强自编码器中，反馈出来的重构输出图像基本符合输入图像的 6D 位姿（如图 3-7）。

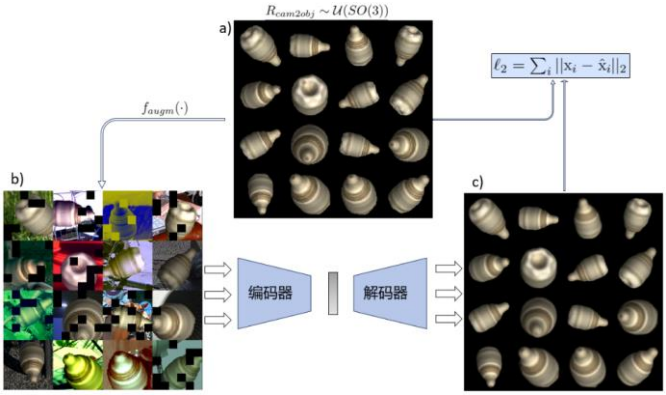

图 3-7 增强自编码器的训练过程; a）均匀采样的 SO（3）对象视图的重建目标批次 x; b）几何和颜色增强输入; c）30000 次迭代后的重建目标批次$\hat{x}$

同时本文也利用 tensorboard 对 30000 次迭代的增强自编码器的重构损失进行了可视化，重构损失在训练轮次 0-5000 时急剧下降，并在 30000 次时最终平稳下降到 0.008，达到了较好的结果（如图 3-8），同时在下面本文对训练完成的模型进行了检测，并将其迁移学习到实验部分的增强自编码器训练中。

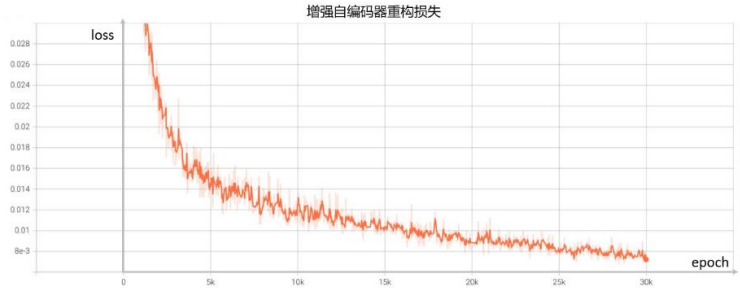

图 3-8 增强自编码器重构损失图

3.3.3 仅增强自编码器仿真结果

在仅使用增强型自动编码器下，在训练好的增强型编码器上，从测试集随意挑选一张图片，将其输入增强自动编码器中，解码器输出的重构物体位姿与实际的工件 6D 位姿基本一致（如图 3-9）。但在后续其他测试中，我们发现，当桌面的工件摆放的更杂乱无章，且工件之间的相互遮挡更为严重时，增强自编码器对图像中的工件的位姿检测准确率有一定的降低。对此推测，当物体变多，存在增强自编码器将其他零件误识别的情况，所以本文将 2D 目标检测和增强自编码器结合起来，通过第一步的 2D 目标检测在图像中找到相应的零件，而后将已检测出的零件送入增强自编码器进一步检测。

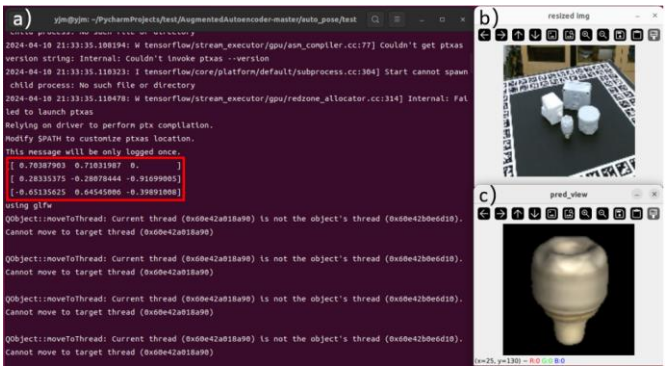

图 3-9 仅增强型自动编码器 a）工件的位姿数据 b）输入的测试集图像从 c）重构的工件 6D 位姿

在上述实验成功后，在基于摄像头的 6D 目标检测中，本文使用单目相机对着桌面上任意摆放的 3D 打印的工件，增强自编码器能实时检测工件的 6D 位姿，并且解码器输出的重构物体位姿与实际的工件 6D 位姿基本一致，如图 3-10 所示。

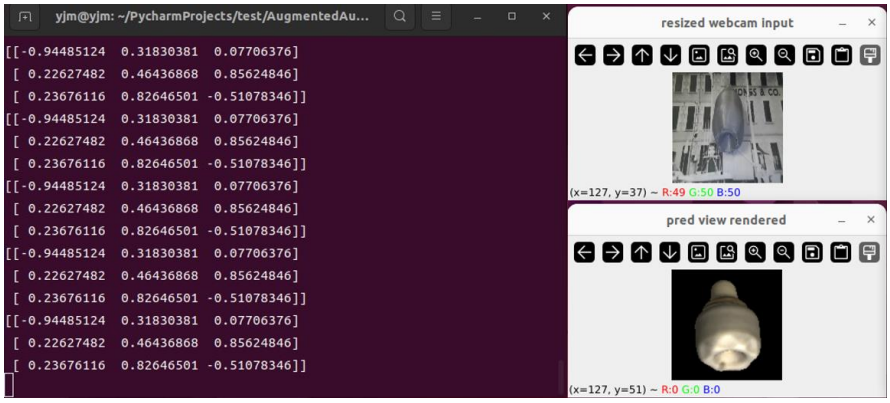

图 3-10 基于摄像头的 6D 目标检测

3.3.4 RetinaNet 结合增强自编码器检测结果

由图 3-11（左图）可以看出，当检测工件遇到物体遮挡并且背景杂乱的现象时训练效果不太理想，所以仅增强自编码器鲁棒性不高，于是本文将 2D 检测器建立

到增强自编码器上，2D 检测首先将检测出来的目标进行框选，然后将框选内容裁剪投入到增强自编码器的 6D 位姿检测过程中去，增强自编码器在通过 2D 检测的框选裁剪之后，处理了背景杂乱等环境问题以及目标由于遮挡定位不准确问题，提升了工件 6D 位姿检测的鲁棒性，如图 3-11（右图）所示，并将其迁移学习到自制数据集的实验中去。

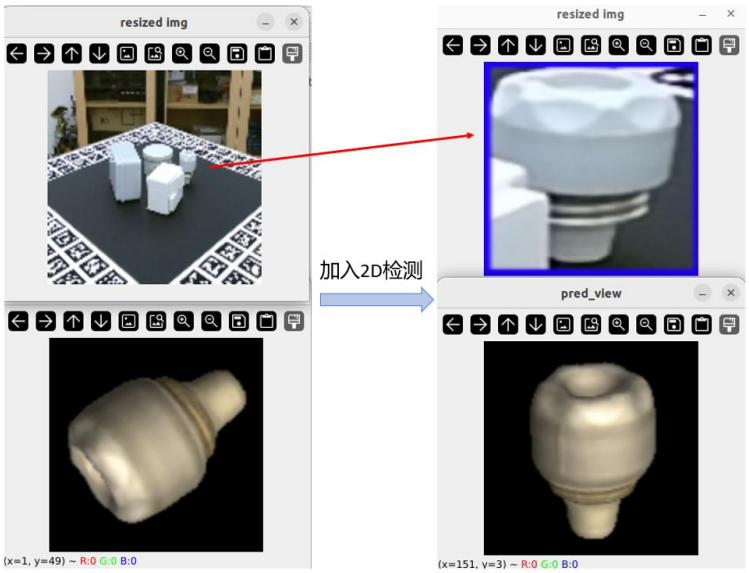

图 3-11 仅增强自编码器测试位姿错误效果（左图）和 2D 检测裁剪检测到的图像再投入增强自编码器训练位姿正确效果（右图）

3.4 本章小结

本章主要是基于增强自编码器，对工件 Light bulb 进行了 6D 位姿检测，在训练好的模型上，发现无遮挡的情况下检测的置信度远远高于有部分遮挡的。为了提高模型的鲁棒性，本文在增强自编码器前加入了基于 Keras 的 RetinaNet 2D 目标检测器。通过将图片在 2D 检测器中检测出目标，并裁剪投入增强自编码器中检测 6D 位姿，大大增强了增强自编码器的鲁棒性。

第 4 章 基于迁移学习的桌面级工件 6D 位姿估计

4.1 实验系统构建

本实验使用工作站、单目相机、桌子以及用于位姿估计的 3D 打印的实验模型，实验中使用的硬件配置参数如表 4-1 所示：

表 4-1：实验硬件配置

工作站配置	
操作系统	Ubuntu 20.04
CPU	Intel i9 14900K
GPU	NVIDIA RTX 4090
内存	32G
显存	24G

其中搭建的 conda 环境中主要使用软件版本如表 4-2：

表 4-2：实验主要使用的软件及版本

软件名称	版本
CUDA	11.1
CUDNN	8.2.1.32
TensorFlow	2.6.0
Python	3.7.12
OpenGL	3.1.1a1
keras	2.6

4.1.1 相机选型

由于不需要采集深度信息，凭单个 RGB 图像就能进行 2D 位姿检测以及 6D 位姿估计，所以本文直接采用单目相机（如图 4-1）来拍摄工件的 RGB 图像。单目相

机操作简单方便且成本低，利用单目相机拍摄的 RGB 图像也是本文研究内容的优点之一。

图 4-1 罗技 C920pro 单目相机

4.1.2 实验方案确定

由于本文主题是非结构环境下桌面级工件 6D 位姿估计，AAE 需要输入三维物体的模型作为训练输入的内容，所以我选取的目标是六角头螺栓，这既符合了桌面级工件的要求，同时也满足了后续研究装配等问题的需求。又由于 2D 检测需要大量数据集来进行标注从而训练 2D 目标检测器，所以训练集的获取本文采用上文提到的单目相机罗技 C920pro 来进行采集。

4.2 实验数据集获取

AAE 需要 ply 格式的的模型文件以及随机背景图片的输入，所以在实验数据集的制作上，随机背景图片本文依然使用 Pascal VOC 的数据集照片，在 ply 的模型文件获取上，本文选取了常见的国标六角螺栓，首先通过使用 Solid Works 三维建模软件建模国标六角螺栓（如图 4-2），而后将模型分别另存为 stl 格式和 obj 格式的三维文件。将 obj 文件进行代码转化，并添加法线和 RGB 等数据使其形成满足要求的 ply 文件用以训练 AAE。而 stl 格式的三维模型文件则输入到 3D 打印机中，将其打印成实体零件，以便后续单目相机拍摄照片形成自制训练集等。

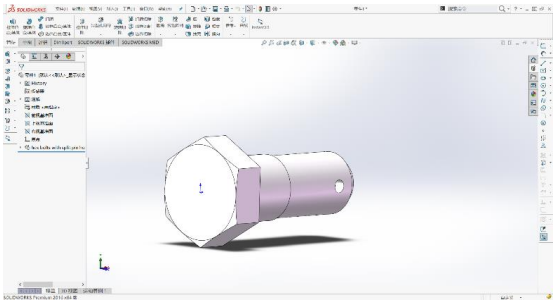

图 4-2 Solid Works 建模国标六角头螺栓

在拍摄 2D 目标检测器的训练图片时，本文共选取了激光笔、剪刀、国标六角螺栓、国标六角螺母以及双面胶这些常见的桌面级工件，其中国标六角螺母与国标六角螺栓都有同一材料打印而成，在颜色及形状上有较高的相似性。在本文采集的图片中，也不乏有部分遮挡和背景稍显杂乱的情况，采集图片示例如图 4-3 所示，随后本文利用 Make Sense 软件对所有的照片进行相同的数据集标定如图 4-4，并按照 8：2 的比例划分训练集和测试集和验证集。

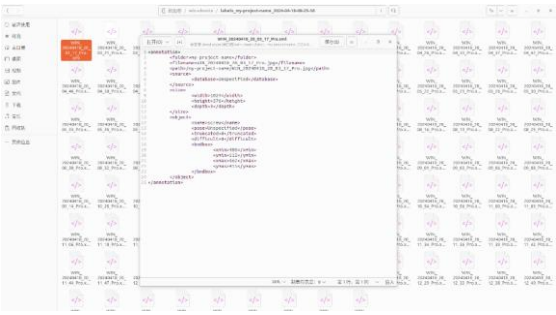

图 4-3 单目相机拍摄的数据集

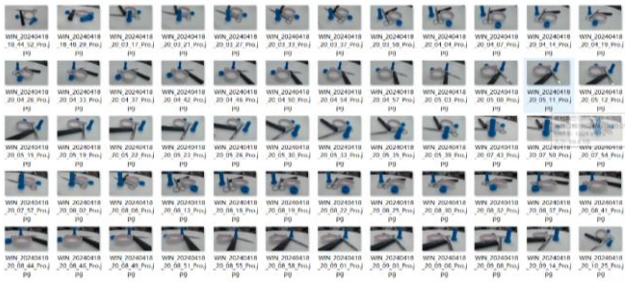

图 4-4 Make Sense 标注数据集

4.3 实验结果分析

4.3.1 2D 目标检测实验结果

本文先用单目相机采集数据集照片，然后通过 Make Sense 标记数据集，并将标记过的数据集投入到 RetinaNet 2D 目标检测器中，并设置训练轮数(epochs)为 20，批次大小(batch size)为 12，训练步数(steps)为 40，得到了训练模型，然后将此训练模型转成推理模型。在训练完成时，通过 tensorflow 自带的 tensorboard 对训练的数据记录进行可视化发现 AP 在第 14 轮训练之后近似于甚至到 1，而且分类损失、回归损失、总损失都向 0 收敛达（如图 4-5），这说明训练效果非常好，RetinaNet 2D 目标检测器能十分精准的检测出工件的位置和类别。

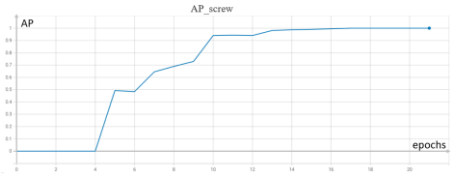

(a) 2D 检测 screw 平均精度图

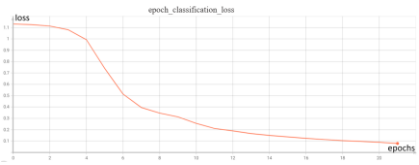

(b)分类损失

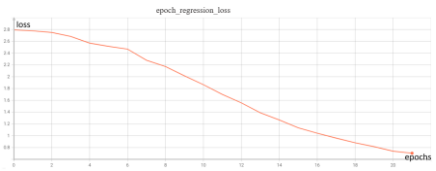

(c)回归损失

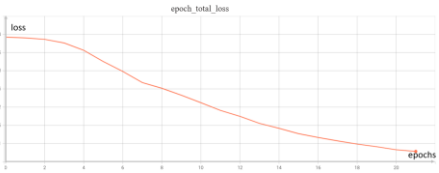

(d)总损失

图 4-5 自制训练集的 2D 检测数据图

RetinaNet 2D 目标检测器训练结束之后，在测试级中挑选任意图片输入，检测器对零件 screw 的检测能以较高的置信度输出，如图 4-6 所示。

图 4-6 自制训练集 2D 检测效果图

4.3.2 AAE 训练自制数据集结果

本文将自制的国标六角螺栓的 PLY 文件投入到 AAE 中，通过迭代 30000 次得到了如图 4-7 所示的检查点结果。该图共分为三个区域，其中左侧为 PLY 零件在相应平移、旋转和缩放后加上 Pascal VOC 的随机背景图像，并通过随机函数，赋予图片随机的亮度、高斯模糊度、对比度和颜色失真度，再加入了随机位置的黑色小方块的遮挡做成的数据集输入，而相应的最右侧区域为对模型进行对应的平移、旋转和缩放操作的应训练得到的标准答案，在最左侧和最右侧训练下，中间区域为 AAE 通过训练后重构的零件位姿。

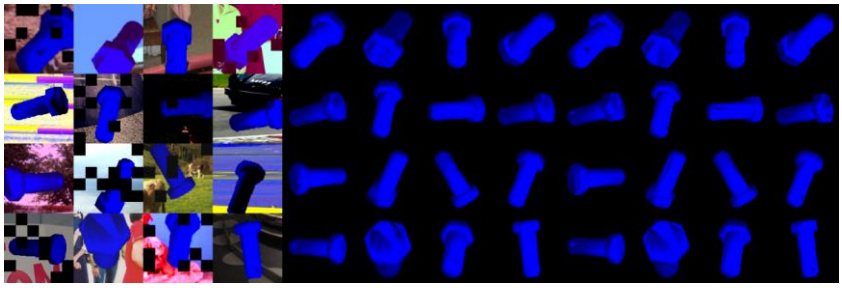

图 4-7 自制训练集训练 AAE 30000 次迭代后的效果

从图中可以看出，30000 次的迭代后，AAE 的重构损失已经非常小，且一直向 0 收敛，这说明 AAE 训练效果较好，已经能够非常好的重构出零件实际的位姿。

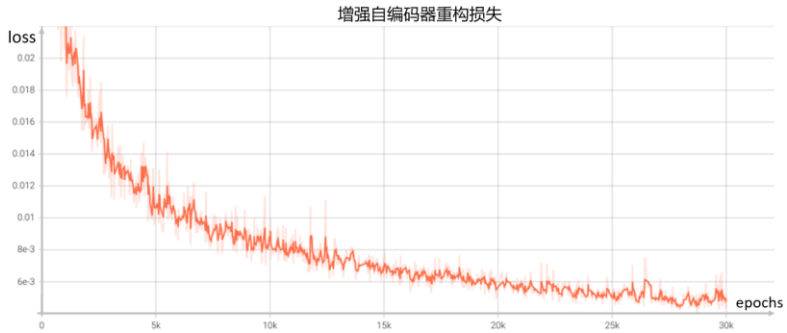

图 4-8 AAE 重构损失图

4.3.3 RetinaNet 结合 AAE 检测结果

在训练好的 AAE 和 RetinaNet 2D 目标检测器的基础上，本文将两者相互结合，输入上述图片，RetinaNet 2D 目标检测器会优先对图像进行检测，对置信区域进行裁剪，而后将裁剪的区域作为输入传输给 AAE，AAE 能够准确的识别出零件 screw 的方向，如图 4-6 所示。

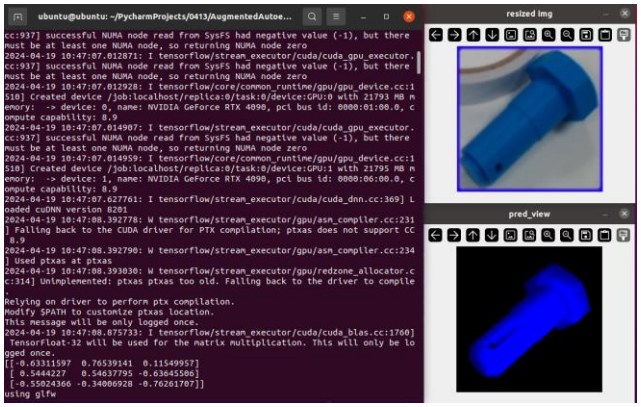

图 4-9 2D 检测裁剪照片投入 AAE 检测

4.4 本章小结

本章主要自制了桌面级工件的本体，以及满足 2D 目标检测器和 AAE 的数据集，并通过迁移学习的方法，在 2D 目标检测器和 AAE 上进行了训练，在训练较好的结果上，本文采用测试集分别对 2D 目标检测器和 AAE 进行了验证，在发现仅 AAE 预测效果不好的基础上，将两者结合并实现对混乱桌面上，目标工件先检测后预测位姿的效果，证明实验的可行性。同时在最后，还尝试对基于视频流对物体进行 6D 位姿检测，为后续的实时目标位姿检测做准备。

总结与展望

本文主要对 RetinaNet 2D 目标检测器和增强自编码器进行研究，首先通过在虚拟数据集上进行训练，查看效果，并通过迁移学习的方法，利用自制数据集训练出满足自身环境下的 RetinaNet 2D 目标检测器和增强自编码器，并得到了如下结论：

（1） 基于仅增强自编码器的模型可以对已训练工件进行 6D 位姿估计，且在无遮挡或遮挡较小的情况下得到较准确的位姿信息。

（2） 基于 keras 的 RetinaNet 2D 目标检测器在经过一定数量的数据集训练后，不仅能检测出无遮挡的物体，而且较大面积遮挡的物体仍能以较高置信度检测出。

（3） 在使用增强自编码器对物体进行 6D 位姿检测前，先将 RGB 图片输入到 RetinaNet 2D 检测器中，将检测出的含目标的边界框裁剪后再投入到增强自编码器中可优化仅使用增强自编码器偶发的因为遮挡而检测失败的问题。

本文对 RetinaNet 2D 目标检测器和增强自编码器的研究，得到一些结果，但是受限于个人能力，导致研究深度不够，仍然存在诸多不足之处，需要进一步研究：

（1） 第四章最后尝试使用的基于摄像头的检测有时不够精准，但是实际场景在机器人抓取中，基于摄像头是非常重要的，应该继续研究。

（2） 在增强自编码器的 6D 位姿检测前，本文加入的 2D 检测是为了更快更精准的找到零件。除了 2D 检测器，融入图片的深度信息，将有利于更精准的位姿检测。

参考文献

[1] 王策.面向机器人抓取的散乱工件识别与三维位姿估计技术研究[D].哈尔滨工业大学,2021.DOI:10.27061/d.cnki.ghgdu.2021.003231.

[2] Jiao C , Chen C , Gou S , et al. L Sparsity-Regularized Attention Multiple-Instance Network for Hyperspectral Target Detection[J]. IEEE Transactions on Cybernetics, 2021, PP(99):1-14.

[3] 王佳荣. 面向自动驾驶的多传感器三维环境感知系统关键技术研究[D].中国科学院大学,2021.DOI:10.27522/d.cnki.gkcgs.2020.000142.

[4] 陈红樑. 基于深度学习的智能视频监控系统构建[D].桂林电子科技大学,2023.DOI:10.27049/d.cnki.ggldc.2023.000854.

[5] 陈俊哲. 基于深度学习的医学影像检测与识别研究[D].中国矿业大学,2023.DOI:10.27623/d.cnki.gzkyu.2023.001282.

[6] 王科宇. 基于深度学习的草莓病虫害检测系统研究[D].浙江科技大学,2024.DOI:10.27840/d.cnki.gzjkj.2024.000132.

[7] Girshick R , Donahue J , Darrell T , et al. Rich Feature Hierarchies for Accurate target detection and Semantic Segmentation[J]. IEEE Computer Society, 2013.

[8] 李富.物体六自由度位姿估计问题中的形状表示方法研究[D].国防科技大学,2022.DOI:10.27052/d.cnki.gzjgu.2022.000086.

[9] 王晨露.基于 YOLOv5 的目标检测与 6D 位姿估计算法研究[D].河南大学,2022.DOI:10.27114/d.cnki.ghnau.2022.001039.

[10] Rosten, E. and Drummond, T., 2006. Machine learning for high-speed corner detection. In Computer Vision–ECCV 2006: 9th European Conference on Computer Vision, Graz, Austria, May 7-13, 2006. Proceedings, Part I 9 (pp. 430-443). Springer Berlin Heidelberg.

[11] Calonder, M., Lepetit, V., Strecha, C. and Fua, P., 2010. Brief: Binary robust independent elementary features. In Computer Vision–ECCV 2010: 11th European Conference on Computer Vision, Heraklion, Crete, Greece, September 5-11, 2010,

Proceedings, Part IV 11 (pp. 778-792). Springer Berlin Heidelberg.

[12] Ethan, R., 2011. ORB: An efficient alternative to SIFT or SURF. ICCV, 2011.

[13] Redmon, J., et al. (2016). "You Only Look Once: Unified, Real-Time Object Detection." IEEE.

[14] Li Z , Zhou F . FSSD: Feature Fusion Single Shot Multibox Detector[J]. 2017.

[15] Lin, T.Y., Goyal, P., Girshick, R., He, K. and Dollár, P., 2017. Focal loss for dense object detection. In Proceedings of the IEEE international conference on computer vision

[16] Girshick R . Fast RCNN[J]. Computer Science, 2015.

[17] Ren S , He K , Girshick R , et al. Faster R-CNN: Towards Real-Time target detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149.

[18] He, Kaiming, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. "Mask r-cnn." In Proceedings of the IEEE international conference on computer vision, 2017.

[19] Tan, Mingxing, Ruoming Pang, and Quoc V. Le. "Efficientdet: Scalable and efficient object detection." In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020.

[20] Lu Y , Kourian S , Salvaggio C , et al. Single Image 3D Vehicle Pose Estimation for Augmented Reality[C]// 2019 IEEE Global Conference on Signal and Information Processing (GlobalSIP). IEEE, 2019.

[21] Yang J , Zeng G , Wang W , et al. Vehicle Pose Estimation Based on Edge Distance Using Lidar Point Clouds (Poster)[C]// 2019 22th International Conference on Information Fusion (FUSION). IEEE, 2020.

[22] Li X , Ling H . Hybrid Camera Pose Estimation With Online Partitioning for SLAM[J]. IEEE Robotics and Automation Letters, 2020, PP(99):1-1.

[23] Rumelhart DE, Hinton GE, Williams RJ (1985) Learning internal representations by error propagation. Tech. rep., California Univ San Diego La Jolla Inst for Cognitive Science

[24] Vincent, P., Larochelle, H., Bengio, Y. and Manzagol, P.A., 2008, July. Extracting and composing robust features with denoising autoencoders. In Proceedings of the 25th international conference on Machine learning (pp. 1096-1103).

[25] Stone, P. and Veloso, M., 2000. Multiagent systems: A survey from a machine learning perspective. Autonomous Robots, 8, pp.345-383.

[26] Kehl W, Manhardt F, Tombari F, Ilic S, Navab N (2017) SSD-6D: Making RGB-Based 3D Detection and 6D Pose Estimation Great Again. In: Proceed-ings of the IEEE Conference on Computer Vision and Pattern Recognition, pp 1521–1529

[27] Sundermeyer, M., Marton, Z.C., Durner, M. and Triebel, R., 2020. Augmented autoencoders: Implicit 3d orientation learning for 6d object detection. International Journal of Computer Vision, 128(3), pp.714-729.

[28] A. Collet, M. Martinez, and S. S. Srinivasa. The MOPED framework: Object recognition and pose estimation for manipulation. IJRR, 2011.

[29] M. Lourakis and X. Zabulis. Model-based pose estimation for rigid objects. In Computer Vision Systems. 2013.

[30] Hodan, T., Haluza, P., Obdržálek, Š., Matas, J., Lourakis, M. and Zabulis, X., 2017, March. T-LESS: An RGB-D dataset for 6D pose estimation of texture-less objects. In 2017 IEEE Winter Conference on Applications of Computer Vision (WACV) (pp. 880-888). IEEE.

[31] Phong BT (1975) Illumination for computer generated pictures. Communications of the ACM 18(6):311–317

[32] Everingham M, Van Gool L, Williams CKI, Winn J, Zisserman A (2012) The PASCAL Visual Object Classes Challenge 2012 (VOC2012) Results

致谢